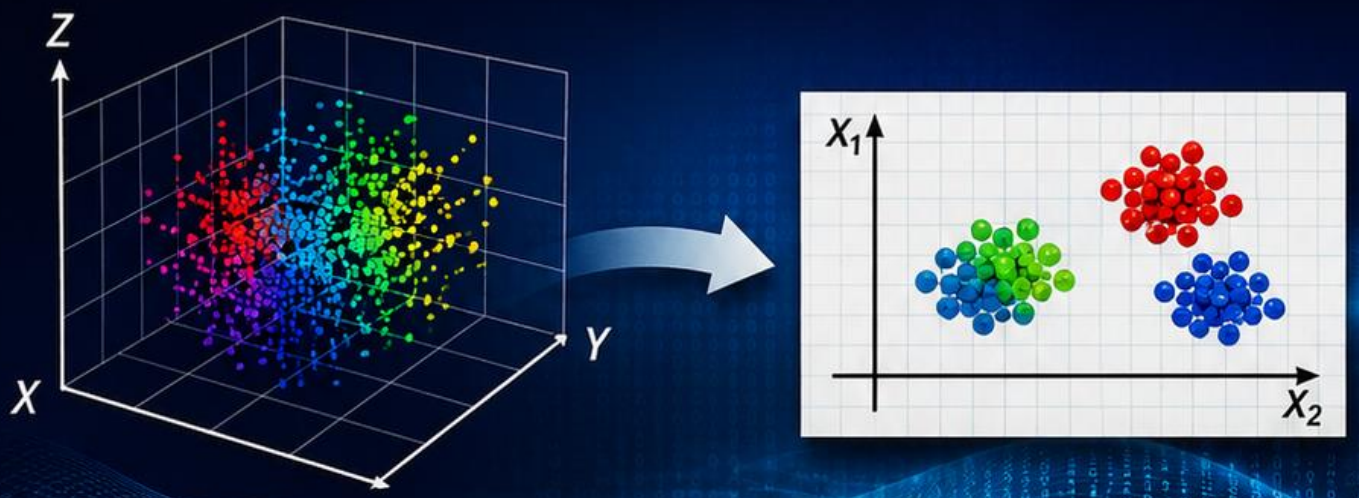


TÉCNICAS DE REDUÇÃO DE DIMENSIONALIDADE

Projeto, Teoria e Aplicações

Uma Abordagem Unificada e Baseada em Cenários

Aderval S. Luna & Nathalia Alvim de Souza

Técnicas de Redução de Dimensionalidade

Projeto, Teoria e Aplicações

Uma Abordagem Unificada e Baseada em Cenários

Aderval S. Luna
Nathalia Alvim de Souza

Técnicas de Redução de Dimensionalidade

Projeto, Teoria e Aplicações

Uma Abordagem Unificada e Baseada em Cenários

Aderval S. Luna

Nathalia Alvim de Souza

Primeira edição

Publicado pelos autores (edição independente)

Local de publicação: Rio de Janeiro, Brasil

Ano de publicação: 2026

ISBN: **978-65-02-42814-6** — esta obra é distribuída gratuitamente em formato digital

DOI: **10.5281/zenodo.23225955**

Técnicas de Redução de Dimensionalidade © 2026 por Aderval S. Luna e Nathalia Alvim de Souza

Esta obra está licenciada sob a licença Creative Commons Atribuição-NãoComercial-CompartilhaIgual 4.0 Internacional (CC BY-NC-SA 4.0). Você tem liberdade para compartilhar e adaptar o material para fins não comerciais, desde que atribua o crédito apropriado e distribua qualquer obra derivada sob a mesma licença. Para ver uma cópia desta licença, visite https://creativecommons.org/licenses/by-nc-sa/4.0/

Esta é uma edição digital não comercial. Um pequeno número de exemplares impressos poderá ser produzido para uso acadêmico, sem fins de venda.

Os conjuntos de dados analisados neste livro são distribuídos pelo UCI Machine Learning Repository e citados individualmente na lista de referências. O código em R e os dados necessários para reproduzir todos os resultados estão disponíveis em https://github.com/Laboratorio-de-Tecnologia-Computacional/Dimensionality-Reduction-Techniques-An-Innovative-Approach

Os nomes dos pacotes de software e suas marcas pertencem aos respectivos proprietários e são aqui utilizados apenas para fins de identificação.

Resumo

Dados de alta dimensionalidade são hoje rotina nas ciências físicas, biológicas e da engenharia, e a redução de dimensionalidade tornou-se uma etapa padrão para deles extrair estrutura interpretável. A dificuldade é que nenhuma técnica é universalmente preferível: cada método otimiza um objetivo diferente, e uma projeção excelente para visualizar agrupamentos pode ser ruim para preservar a geometria global ou para sustentar a reconstrução dos dados.

Este livro trata desse problema com um framework unificado e orientado por cenários para comparar técnicas de redução de dimensionalidade. Quatorze métodos convexos e não convexos — entre eles a Análise de Componentes Principais, a PCA por kernel e a PCA com norma L1, o escalonamento multidimensional clássico e não métrico, o Isomap, os diffusion maps, a análise de componentes independentes, o Hessian locally linear embedding, três algoritmos de leiaute de grafos e o t-SNE — são apresentados com sua formulação matemática, hipóteses, custo computacional e limitações conhecidas.

Seu comportamento é então avaliado com treze medidas de qualidade normalizadas, que abrangem a fidelidade das vizinhanças locais, a geometria global, o erro de reconstrução e a separabilidade entre classes. Essas medidas são combinadas em quatro índices compostos e ponderadas segundo quatro objetivos analíticos — agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina — de modo que a escolha do método decorra do propósito da análise, e não da convenção. Uma análise de robustez baseada na perturbação de ±10% dos pesos quantifica a estabilidade de cada ranqueamento.

O framework é demonstrado em sete conjuntos de dados de referência do UCI Machine Learning Repository, cobrindo tamanhos de amostra de 88 a 13.611 observações. Todos

os resultados são reprodutíveis: o código em R, os conjuntos de dados e as sementes aleatórias estão disponíveis no repositório citado na seção Disponibilidade dos Dados.

Palavras-chave

Redução de dimensionalidade; aprendizado de variedades; avaliação de qualidade; benchmarking multicritério; análise de componentes principais; t-SNE; escalonamento multidimensional; quimiometria; pesquisa reprodutível; R

Autores

Aderval S. Luna é Professor Titular da Universidade do Estado do Rio de Janeiro (UERJ) e docente permanente do Programa de Pós-Graduação em Engenharia Química da instituição. É graduado em Química Industrial pela UERJ, possui MBA em Ciência de Dados pela Universidade de São Paulo (USP – São Carlos) e os títulos de Mestre e Doutor em Química pela Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio). Durante o doutorado, realizou estágio de pesquisa no National Research Council of Canada (NRCC), em Ottawa, no Canadá. Também realizou estágio de pós-doutorado em quimiometria junto ao Grupo de Pesquisa em Qualimetria e Quimiometria da Universitat Rovira i Virgili, em Tarragona, na Catalunha, Espanha.

Nathalia Alvim de Souza é doutoranda do Programa de Pós-Graduação em Engenharia Química da Universidade do Estado do Rio de Janeiro (UERJ). É graduada em Engenharia Química pela Faculdade de Tecnologia da UERJ (Campus Resende) e mestre em Engenharia Química pela UERJ.

Declaração sobre o uso de IA generativa e tecnologias assistidas por IA no processo de elaboração do livro

Este livro foi desenvolvido com o auxílio de IA generativa, como ferramenta de apoio à geração de textos, à organização de ideias e ao desenvolvimento de código. O uso dessa tecnologia visou aumentar a produtividade e facilitar a estruturação de conteúdos técnicos complexos na elaboração do manuscrito. Todo o conteúdo gerado com o auxílio de IA generativa foi cuidadosamente revisado, editado e validado pelos autores, a fim de assegurar sua precisão científica, coerência e alinhamento aos objetivos da obra. Os autores assumem total responsabilidade pelo conteúdo final apresentado neste livro, incluindo eventuais erros, omissões ou imprecisões remanescentes.

Além disso, todos os códigos em R apresentados neste livro foram elaborados com o auxílio de IA generativa e, posteriormente, verificados, testados e, quando necessário, adaptados pelos autores para garantir sua correção, reprodutibilidade e aplicabilidade no contexto metodológico proposto.

Sumário

Prefácio xiii
Agradecimentos xv
1. INTRODUÇÃO 1
2. FUNDAMENTOS TEÓRICOS 4
2.1 Critérios para a Seleção de Algoritmos de Redução de Dimensionalidade 4
2.2 Classificação das Técnicas de Redução de Dimensionalidade 5
2.2.1 Técnicas Convexas de Redução de Dimensionalidade 6
2.2.1.1 Técnicas Baseadas em Matrizes Completas 6
2.2.1.1.1 Análise de Componentes Principais 6
2.2.1.1.2 Análise de Componentes Principais por Kernel 15
2.2.1.1.3 Análise de Componentes Principais com Norma L1 23
2.2.1.1.4 Escalonamento Multidimensional Clássico 30
2.2.1.1.5 Isomap 40
2.2.1.1.6 Diffusion Maps 51
2.2.1.1.7 Redução de Dimensionalidade via Regressão 60
2.2.1.1.8 Análise de Componentes Independentes 71
2.2.1.2 Técnicas Baseadas em Matrizes Esparsas 78
2.2.1.2.1 Hessian Locally Linear Embedding 78
2.2.2 Técnicas Não Convexas de Redução de Dimensionalidade 87
2.2.2.1 Abordagem de Redução de Dimensionalidade Baseada em Paisagens (Landscapes) 87
2.2.2.2 Algoritmo de Kamada–Kawai para Redução de Dimensionalidade e Representação de Grafos 94
2.2.2.3 Algoritmo de Fruchterman–Reingold 103
2.2.2.4 Escalonamento Multidimensional Não Métrico 111
2.2.2.5 Incorporação Estocástica de Vizinhos Distribuída em t (t-SNE) 120
2.3 Resumo dos Métodos de Redução de Dimensionalidade: Uma Visão Geral 128
2.4 Critérios de Qualidade 132
2.4.1 Medidas de Qualidade: Métricas Orientadas à Compacidade 134
2.4.1.1 Qualidade Local (Q_{local}) 134
2.4.1.2 Área Sob a Curva (AUC R(NX)) 135
2.4.1.3 Confiabilidade (Trustworthiness) 136
2.4.1.4 Precisão (Precision) 137
2.4.1.5 Medida C (C-Measure) 138
2.4.2 Medidas de Qualidade: Métricas Orientadas à Conectividade 139
2.4.2.1 Qualidade Global (Q_{global}) 139

2.4.2.2 Continuidade (Continuity) 140
2.4.2.3 Descontinuidade (Discontinuity) 142
2.4.2.4 Sensibilidade (Recall) 143
2.4.2.5 Tau de Kendall (τ) 144
2.4.2.6 Correlação Cofenética 145
2.4.3 Medidas de Qualidade: Não Generalizáveis 146
2.4.3.1 RMSE de Reconstrução 146
2.4.3.2 Exatidão k-NN 147
2.5 Padrões de Desempenho entre Diferentes Classes de Algoritmos 149
2.5.1 Artefatos Comuns e Cuidados Metodológicos 149
2.5.2 Recomendação Prática: Sempre Testar Múltiplos Algoritmos 150
2.5.3 Como Selecionar um Método Candidato de Redução de Dimensionalidade 150
2.5.4 Construção da Classificação Final dos Algoritmos 153
2.5.5 Considerações Finais 153
3. METODOLOGIA 155
3.1 Procedimentos de Redução de Dimensionalidade 155
3.2 Estratégias para Avaliação da Qualidade e Cálculo das Métricas 155
3.3 Esquemas de Ponderação de Acordo com os Objetivos Analíticos 156
3.4 Normalização das Métricas e Construção dos Índices 157
3.5 Classificação dos Métodos de Redução de Dimensionalidade Baseada em Cenários 159
3.6 Visualização dos Métodos Ótimos 160
3.7 Resumo das Saídas Geradas 160
3.8 Estratégia Proposta para Seleção da Melhor Métrica 161
3.9 Aplicação da Metodologia Proposta 162
3.10 Hardware e Software 164
3.11 Pacotes 164
3.12 Ambiente de Software, Controles de Reprodutibilidade e Funções Utilitárias 167
4. ESTUDO DE CASO I 169
4.1 Descrição do Conjunto de Dados 169
4.2 Resultados e Discussão 169
5. ESTUDO DE CASO II 186
5.1 Descrição do Conjunto de Dados 186
5.2 Resultados e Discussão 187
6. ESTUDO DE CASO III 202
6.1 Descrição do Conjunto de Dados 202
6.2 Resultados e Discussão 202
7. ESTUDO DE CASO IV 220

7.1 Descrição do Conjunto de Dados 220
7.2 Resultados e Discussão 220
8. ESTUDO DE CASO V 237
8.1 Descrição do Conjunto de Dados 237
8.2 Resultados e Discussão 237
9. ESTUDO DE CASO VI 256
9.1 Descrição do Conjunto de Dados 256
9.2 Resultados e Discussão 256
10. ESTUDO DE CASO VII 276
10.1 Descrição do Conjunto de Dados 276
10.2 Resultados e Discussão 276
11. CONSIDERAÇÕES FINAIS 295
12. DISPONIBILIDADE DOS DADOS 296
13. REFERÊNCIAS 297
Índice Remissivo 304

Lista de Abreviaturas

AUC	Área sob a Curva
AUC(R_NX)	Área sob a curva de preservação de vizinhança baseada em ordenação
cMDS	Escalonamento Multidimensional Clássico
CRAN	Comprehensive R Archive Network
DR	Redução de Dimensionalidade
DrL	Distributed Recursive (Graph) Layout
DRR	Redução de Dimensionalidade via Regressão
EDXRF	Fluorescência de Raios X por Dispersão de Energia
FastICA	Análise Rápida de Componentes Independentes
FNA	Punção Aspirativa por Agulha Fina
GCE	Gabriel Classification Error
HLLE	Hessian Locally Linear Embedding
ICA	Análise de Componentes Independentes
IR	Infravermelho
JADE	Joint Approximate Diagonalization of Eigenmatrices
kNN, k-NN	k-Vizinhos Mais Próximos
kPCA	Análise de Componentes Principais por Kernel
KK	Kamada–Kawai
KL	Kullback–Leibler
L1-PCA	Análise de Componentes Principais com Norma L1
LLE	Locally Linear Embedding
MDS	Escalonamento Multidimensional
ML	Aprendizado de Máquina
NIR	Infravermelho Próximo
nMDS	Escalonamento Multidimensional Não Métrico
PCA	Análise de Componentes Principais
RBF	Função de Base Radial
RMSE	Raiz do Erro Quadrático Médio
SVD	Decomposição em Valores Singulares
t-SNE	Incorporação Estocástica de Vizinhos Distribuída em t
UCI	University of California, Irvine (Machine Learning Repository)
UMAP	Uniform Manifold Approximation and Projection

Lista de Símbolos

n	número de amostras (observações) no conjunto de dados
p	número de variáveis originais (atributos)
k	tamanho da vizinhança usado pelas medidas de qualidade baseadas em ordenação
X	matriz de dados no espaço original de alta dimensionalidade
Y	representação em baixa dimensionalidade produzida pelo método de redução
d	dimensionalidade da representação (d = 2 em todo este livro)
Q_local	qualidade local: fração de vizinhos mais próximos preservada
Q_global	qualidade global: preservação da disposição em larga escala
R(NX)	preservação de vizinhança corrigida para concordância aleatória
τ	coeficiente de correlação de postos de Kendall
ρ	coeficiente de correlação de postos de Spearman
CCC	coeficiente de correlação cofenética
Índice_Local	índice composto de preservação da estrutura local
Índice_Global	índice composto de preservação da estrutura global
Índice_Geom	índice composto de fidelidade geométrica
Índice_Classe	índice composto de separabilidade entre classes
Pontuação_Final	combinação dos quatro índices compostos ponderada pelo objetivo

Prefácio

A rápida expansão dos dados de alta dimensionalidade nas diversas disciplinas científicas e de engenharia intensificou a necessidade de métodos robustos para extrair estrutura significativa de conjuntos de dados complexos. A redução de dimensionalidade (RD) tornou-se um componente central da análise de dados moderna, fornecendo ferramentas para simplificar a representação dos dados ao mesmo tempo em que preserva as informações relevantes para interpretação, visualização e modelagem.

Este livro apresenta um tratamento sistemático e unificado das técnicas de redução de dimensionalidade, combinando fundamentos teóricos, perspectivas algorítmicas e estratégias práticas de avaliação. Em contraste com abordagens que tratam os métodos isoladamente, o presente trabalho adota um framework comparativo e orientado à aplicação, que permite uma análise consistente de uma ampla gama de técnicas.

Uma premissa fundamental deste trabalho é que o desempenho dos métodos de redução de dimensionalidade depende intrinsecamente do contexto. Nenhuma técnica é universalmente ótima, e a seleção do método deve ser orientada pelos objetivos específicos da análise. Para tratar essa questão, o livro introduz um framework de avaliação orientado por cenários, apoiado por uma estratégia de benchmarking multicritério. Esse framework integra medidas de desempenho complementares que capturam a preservação da estrutura local, da geometria global, da fidelidade de reconstrução e da separabilidade entre classes.

O texto abrange um amplo espectro de métodos, incluindo técnicas lineares clássicas, como a Análise de Componentes Principais e a Análise de Componentes Independentes, bem como abordagens não lineares, entre elas a Kernel PCA, o escalonamento multidimensional, os métodos de aprendizado de variedades (manifold learning) e as técnicas probabilísticas e baseadas em grafos. Cada método é apresentado

com sua formulação matemática, hipóteses subjacentes, aspectos computacionais e limitações conhecidas.

Ênfase particular é dada à avaliação dos resultados da redução de dimensionalidade. O framework de benchmarking proposto incorpora múltiplas métricas quantitativas, possibilitando uma avaliação mais abrangente e reprodutível do que as abordagens baseadas em uma única medida. Adicionalmente, é introduzida uma análise de robustez baseada em perturbações controladas, com o objetivo de avaliar a estabilidade dos ranqueamentos dos métodos sob condições variáveis.

As metodologias discutidas neste livro são aplicáveis a uma ampla gama de domínios, incluindo quimiometria, espectroscopia, aprendizado de máquina e tecnologia analítica de processos. Considerações práticas, incluindo aspectos de implementação e integração em fluxos de trabalho analíticos, são abordadas para apoiar aplicações reais.

Este livro destina-se a pesquisadores, estudantes de pós-graduação e profissionais que buscam uma compreensão rigorosa e estruturada dos métodos de redução de dimensionalidade. Pode também servir como referência para cursos avançados de análise multivariada, aprendizado de máquina e modelagem orientada a dados.

Os autores esperam que este trabalho contribua para um uso mais sistemático e transparente das técnicas de redução de dimensionalidade e apoie escolhas metodológicas fundamentadas na análise de dados de alta dimensionalidade.

Agradecimentos

A. S. Luna agradece ao CNPq (304581/2022-4) e à FAPERJ (E-26/204.174/2024) pela bolsa, e à UERJ pelo Programa PAPD Sênior.

Nathália Alvim de Souza agradece o apoio financeiro do Programa de Formação de Recursos Humanos da Agência Nacional do Petróleo, Gás Natural e Biocombustíveis – PRH-ANP, gerido pela Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP), Brasil. Processo nº 2025/03791-6

1. INTRODUÇÃO

Os dados provenientes de aplicações do mundo real são, frequentemente, de alta dimensionalidade. A redução de dimensionalidade (Dimensionality Reduction – DR) consiste no processo de transformar esses dados em uma representação de menor dimensionalidade, porém mais informativa e significativa. Idealmente, essa representação reduzida deve corresponder à dimensionalidade intrínseca dos dados originais, isto é, ao menor número de parâmetros necessário para explicar adequadamente as propriedades observadas do conjunto de dados [1–2].

A redução de dimensionalidade desempenha um papel fundamental em diversas áreas do conhecimento, pois contribui para mitigar a chamada maldição da dimensionalidade (curse of dimensionality) e outros efeitos indesejáveis associados a espaços de alta dimensionalidade [3]. Como consequência, facilita tarefas como classificação, visualização, compressão de dados, reconhecimento de padrões e modelagem preditiva, tornando mais eficiente a extração de conhecimento a partir de conjuntos de dados complexos.

Entretanto, a principal dificuldade na aplicação de técnicas de redução de dimensionalidade reside no fato de que cada método foi desenvolvido para preservar aspectos específicos da estrutura original dos dados. Assim, uma determinada técnica pode apresentar excelente desempenho em uma aplicação, mas revelar-se inadequada em outra. Além disso, a maioria dos algoritmos possui parâmetros ajustáveis e baseia-se em diferentes hipóteses matemáticas e estatísticas. A qualidade da representação reduzida pode depender fortemente da escolha desses parâmetros, tornando o processo de seleção e otimização significativamente mais complexo [4].

A partir da análise das lacunas existentes na literatura, a principal contribuição desta obra consiste no estabelecimento do primeiro framework abrangente, orientado por

cenários de aplicação e quantitativamente unificado, para a comparação rigorosa de técnicas de redução de dimensionalidade, que abrange tanto métodos convexos quanto não convexos. Enquanto estudos anteriores normalmente avaliam algoritmos de DR utilizando métricas isoladas ou condições experimentais restritas, o framework proposto integra treze medidas de qualidade normalizadas, contemplando perspectivas complementares relacionadas à preservação da estrutura local, da geometria global, das propriedades geométricas e da separabilidade entre classes.

Essas medidas são incorporadas a um modelo sistemático de decisão multicritério que reflete objetivos analíticos fundamentais, como agrupamento (clustering), visualização, reconstrução de dados e desempenho em pipelines de aprendizado de máquina (Machine Learning – ML). Adicionalmente, introduz-se uma análise de robustez baseada em perturbações controladas aplicadas aos pesos atribuídos às métricas de avaliação. Essa estratégia aborda uma limitação histórica dos estudos comparativos em redução de dimensionalidade, ao quantificar a estabilidade do ranqueamento dos algoritmos e revelar sua sensibilidade à variabilidade das métricas utilizadas, um aspecto ainda pouco explorado na literatura especializada.

Essa abordagem integrada transforma o processo de avaliação de métodos de redução de dimensionalidade, antes baseado em práticas pontuais e frequentemente subjetivas, em um paradigma transparente, reprodutível e amplamente generalizável. Dessa forma, estabelece uma base metodológica consistente para orientar a seleção de algoritmos em diferentes áreas do conhecimento que dependem da análise de dados de alta dimensionalidade.

Ao reduzir a distância entre as propriedades teóricas dos métodos de redução de dimensionalidade e sua adequação prática a diferentes aplicações, o framework proposto estabelece um novo referencial para a avaliação de algoritmos de aprendizado de

variedades (manifold learning). Além de fornecer um modelo de referência para futuras pesquisas na área, este estudo apresenta uma metodologia inovadora e abrangente para a seleção sistemática da técnica de redução de dimensionalidade mais adequada, fundamentada na avaliação rigorosa de um amplo conjunto de métricas de desempenho reportadas na literatura científica.

2. FUNDAMENTOS TEÓRICOS

2.1 Critérios para a Seleção de Algoritmos de Redução de Dimensionalidade

A seleção de uma técnica apropriada de redução de dimensionalidade (Dimensionality Reduction – DR) deve ser orientada por quatro aspectos fundamentais:

(i) (i) o objetivo principal da análise;

(ii) (ii) as métricas de avaliação utilizadas para medir o desempenho;

(iii) (iii) a natureza intrínseca do conjunto de dados; e

(iv) (iv) o risco esperado de distorções geométricas ou de artefatos introduzidos pela técnica.

Como etapa inicial, é essencial definir claramente qual estrutura dos dados se deseja preservar, seja a vizinhança local, a geometria global da variedade (manifold), a suavidade e continuidade da representação ou simplesmente uma separação bidimensional visualmente informativa. A Tabela 1 sintetiza esses objetivos, estabelece suas prioridades e identifica as métricas quantitativas mais adequadas para cada categoria de objetivo analítico.

Tabela 1 – Objetivos e métricas de avaliação recomendadas para técnicas de redução de dimensionalidade

Objetivo	Prioridade	Principais métricas
Preservação da vizinhança local (agrupamento, mapas e topologia fina)	Localidade	Qlocal, Trustworthiness, Precision/Recall, Exatidão k-NN
Preservação da estrutura global da variedade (manifold)	Globalidade	Qglobal, AUCR(NX), Coeficiente Cophenético, Tau de Kendall
Representação geométrica estável e contínua	Suavidade e baixa distorção	RMSE, GCE, Medida C, Discontinuity

Visualização bidimensional com boa separação entre grupos	Organização (layout)	t-SNE, Kamada–Kawai, Fruchterman–Reingold

2.2 Classificação das Técnicas de Redução de Dimensionalidade

As técnicas de redução de dimensionalidade podem ser classificadas em dois grandes grupos: convexas e não convexas.

As técnicas convexas baseiam-se na otimização de uma função objetivo que não apresenta ótimos locais, garantindo que a solução encontrada corresponda ao ótimo global. Em contrapartida, as técnicas não convexas otimizam funções objetivo que podem conter múltiplos ótimos locais, o que torna o resultado dependente das condições iniciais e do procedimento de otimização empregado.

As técnicas convexas podem, ainda, ser subdivididas em métodos que realizam decomposição espectral (eigendecomposition) sobre matrizes completas (full matrices) e em métodos que operam sobre matrizes esparsas (sparse matrices). A Tabela 2 apresenta uma taxonomia geral das principais técnicas de redução de dimensionalidade atualmente utilizadas.

Descrições detalhadas de todos os métodos apresentados encontram-se disponíveis na literatura especializada, sendo neste livro fornecido um resumo de seus fundamentos, características e aplicações [5].

Tabela 2 – Taxonomia das técnicas de redução de dimensionalidade

Redução de dimensionalidade	Convexa	Espectral (matriz completa)	Distância Euclidiana	PCA, Escalonamento Clássico (Classical Scaling)

			Distância geodésica	Isomap
			Métodos baseados em kernels	Kernel PCA, MVU
			Distância de difusão	Diffusion Maps
		Espectral (matriz esparsa)	Pesos de reconstrução	LLE
			Laplaciano do grafo de vizinhança	Laplacian Eigenmaps
			Espaço tangente local	Hessian LLE, LTSA
	Não convexa		Distâncias Euclidianas ponderadas	Sammon Mapping
			Alinhamento de modelos lineares locais	LLC, Manifold Charting
			Redes neurais	Autoencoder

Adaptado de van der Maaten et al. [5].

2.2.1 Técnicas Convexas de Redução de Dimensionalidade

2.2.1.1 Técnicas Baseadas em Matrizes Completas

2.2.1.1.1 Análise de Componentes Principais

1. Introdução

A Análise de Componentes Principais (Principal Component Analysis – PCA) é uma técnica linear de redução de dimensionalidade que transforma um conjunto de dados em um novo sistema de coordenadas, no qual as direções, denominadas componentes principais, são definidas de modo a maximizar a variância dos dados.

A Figura 1 apresenta uma representação intuitiva da PCA como uma técnica de redução de dimensionalidade baseada em projeções. O conjunto de dados original, representado por uma nuvem de pontos em um espaço de alta dimensionalidade, é transformado em uma representação de menor dimensionalidade por meio de sua projeção em um novo sistema de coordenadas definido pelos componentes principais. Esses componentes são orientados pelas direções de máxima variância dos dados, assegurando que a estrutura mais informativa seja preservada durante o processo de redução.

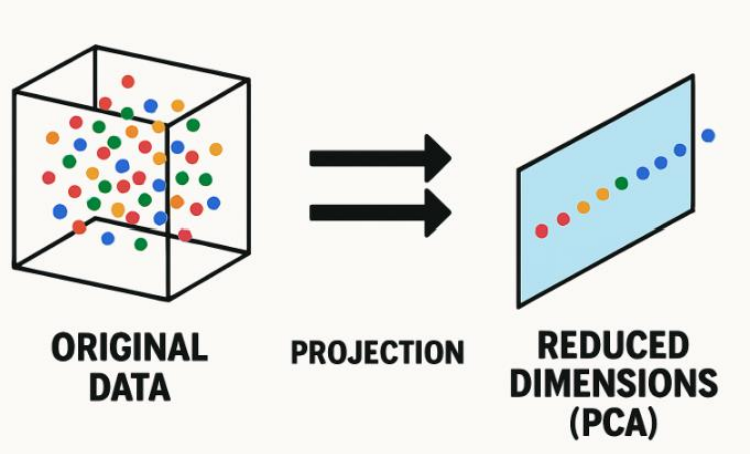


Figura 1 – Ilustração esquemática da Análise de Componentes Principais (Principal Component Analysis – PCA).

Os dados de alta dimensionalidade (à esquerda) são projetados em um subespaço de menor dimensionalidade (à direita), definido pelos componentes principais que maximizam a variância dos dados. Essa projeção transforma as variáveis originais em um novo conjunto de eixos ortogonais, possibilitando a redução da dimensionalidade, preservando ao mesmo tempo as informações mais relevantes do conjunto de dados.

A Tabela 3 resume as propriedades fundamentais que caracterizam a Análise de Componentes Principais (Principal Component Analysis – PCA) como técnica de redução

de dimensionalidade. A PCA é intrinsecamente um método linear, projetando os dados em combinações lineares das variáveis originais e garantindo que os componentes resultantes sejam ortogonais e, consequentemente, não correlacionados entre si. O método baseia-se na maximização da variância, buscando direções que expliquem a maior parcela possível da variabilidade presente no conjunto de dados, o que o torna altamente eficaz na identificação das estruturas dominantes dos dados.

Tabela 3 – Principais propriedades da Análise de Componentes Principais (PCA)

Propriedade	Descrição
Linear	Projeta os dados em combinações lineares das variáveis originais.
Ortogonal	Os componentes principais são ortogonais e, portanto, não correlacionados entre si.
Baseada na variância	Maximiza a variância explicada pelos componentes principais.
Inversível (aproximadamente)	Permite a reconstrução aproximada dos dados originais a partir da representação reduzida.
Global	Considera todo o conjunto de dados para determinar a transformação.

No contexto do aprendizado de máquina, a Análise de Componentes Principais (Principal Component Analysis – PCA) é amplamente utilizada para:

- Extração de variáveis;
- Redução de ruído;
- Compressão de dados;
- Visualização de dados de alta dimensionalidade.

2. Formulação Matemática

1. Centralização dos Dados

Considere um conjunto de dados dado por:

$$\boldsymbol{X} \in \mathbb{R}^{\boldsymbol{nxp}} \tag{1}$$

em que:

n = número de amostras;

p = número de variáveis (atributos ou features).

A matriz de dados centralizada é dada por:

$$\mathbf{X_c} = \mathbf{X} - \mathbf{1}\boldsymbol{\mu}^{\mathbf{T}} \tag{2}$$

em que $\boldsymbol{\mu}$ representa o vetor de médias das variáveis.

3. Matriz de Covariância

$$\boldsymbol{\Sigma} = \frac{\mathbf{1}}{\mathbf{n-1}}\mathbf{X_c^T X_c} \tag{3}$$

4. Decomposição dos autovalores

$$\Sigma = \lambda_i \boldsymbol{\upsilon_i} \tag{4}$$

em que:

λ_i: autovalores (variância explicada)

$\boldsymbol{\upsilon_i}$: autovetores (direções principais)

5. Projeção (Redução de Dimensionalidade)

Selecionam-se os k autovetores correspondentes aos maiores autovalores:

$$\mathbf{W_k} = [\boldsymbol{\upsilon_1}, \boldsymbol{\upsilon_2}, \cdots, \boldsymbol{\upsilon_k}] \tag{5}$$

A projeção dos dados é obtida por:

$$\mathbf{Z} = \mathbf{X_c W_k} \tag{6}$$

6. Reconstrução (Propriedade de Inversibilidade)

A Análise de Componentes Principais (PCA) é aproximadamente inversível, permitindo a reconstrução aproximada dos dados originais a partir da representação reduzida:

$$\widehat{\mathbf{X}} = \mathbf{Z W_k^T} + \boldsymbol{\mu} \tag{7}$$

7. Interpretação da Maximização da Variância

A Análise de Componentes Principais (PCA) resolve o seguinte problema de otimização:

$$\max_{\mathbf{w}} \mathbf{w^T \Sigma w} \quad \text{sujeito à } \|\mathbf{w}\| = 1 \tag{8}$$

Essa formulação garante que cada componente principal capture a variância máxima possível dos dados, respeitando a restrição de ortogonalidade em relação aos componentes previamente determinados.

8. Interpretação no Contexto do Aprendizado de Máquina

A Análise de Componentes Principais (Principal Component Analysis – PCA) identifica um subespaço de baixa dimensionalidade capaz de preservar a maior quantidade possível de informação dos dados, medida pela variância explicada.

A PCA caracteriza-se por ser:

- um método de aprendizado não supervisionado;
- uma transformação ortogonal, na qual os componentes principais permanecem mutuamente ortogonais e não correlacionados;

- um método linear global, pois a transformação é obtida considerando simultaneamente todo o conjunto de dados.

9. Interpretação Geométrica

- os dados são projetados nas direções de máxima variância;
- os componentes principais constituem um novo sistema de eixos ortogonais;
- o primeiro componente principal captura a maior parcela da variância dos dados, o segundo componente captura a maior variância remanescente sob a restrição de ortogonalidade ao primeiro, e assim sucessivamente para os componentes seguintes.

Dessa forma, a PCA fornece um embutimento linear ótimo (optimal linear embedding) em termos da preservação da variância, constituindo uma abordagem matematicamente elegante e computacionalmente eficiente para a redução de dimensionalidade em problemas de aprendizado de máquina [6].

10. Limitações

- captura apenas relações lineares entre as variáveis;
- é sensível à escala dos dados, tornando necessária a padronização ou normalização em muitas aplicações;
- não considera rótulos de classe, por se tratar de um método de aprendizado não supervisionado;
- pode apresentar desempenho insatisfatório quando os dados estão distribuídos sobre variedades não lineares (nonlinear manifolds).

11. Aplicações

A Análise de Componentes Principais (Principal Component Analysis – PCA) tem sido amplamente empregada em diversas áreas da ciência e da engenharia, especialmente na análise de conjuntos de dados de alta dimensionalidade que exigem simplificação, interpretação e redução de ruído. Sua natureza linear, elevada eficiência computacional e facilidade de interpretação fazem da PCA uma das técnicas de redução de dimensionalidade mais utilizadas na literatura científica.

11.1 Quimiometria e Espectroscopia

- Extração dos principais padrões de variabilidade em espectros Raman, NIR, IV (IR) e UV–Vis;
- Detecção da variabilidade química, incluindo efeitos de lote (batch effects) e diferenças de composição;
- Pré-processamento espectral e redução de ruído (por exemplo, como suporte à correção da linha de base);
- Compressão de dados espectrais de alta dimensionalidade, preservando as informações químicas mais relevantes;
- Análise exploratória para detecção de amostras discrepantes (outliers) e classificação de amostras.

11.2 Processamento de Imagens

- Reconhecimento facial por meio da abordagem clássica dos Eigenfaces;
- Compressão de imagens pela redução da redundância no espaço dos pixels;
- Filtragem de ruído utilizando a reconstrução baseada nos componentes principais;
- Extração de características para tarefas posteriores, como classificação e agrupamento (clustering).

11.3 Bioinformática

- Análise de dados de expressão gênica (por exemplo, microarranjos e RNA-seq);
- Identificação dos principais padrões biológicos e agrupamento de amostras;
- Redução da dimensionalidade em conjuntos de dados ômicos de alta escala (high-throughput omics);
- Visualização da estrutura populacional e da variabilidade genética.

11.4 Detecção de Falhas e Monitoramento de Processos

- Controle estatístico multivariado de processos (Multivariate Statistical Process Control – MSPC) na engenharia química;
- Detecção de condições anormais de operação por meio da análise de escores (scores) e resíduos (estatísticas Hotelling T^2 e SPE/Q);
- Monitoramento de processos industriais com variáveis altamente correlacionadas;
- Detecção precoce de falhas em processos contínuos e em batelada.

11.5 Pipelines de Aprendizado de Máquina

- Etapa de pré-processamento para redução da dimensionalidade antes de algoritmos de classificação ou regressão (por exemplo, SVM, k-NN e PLS-DA);
- Redução da multicolinearidade em conjuntos de dados de alta dimensionalidade;
- Aceleração do treinamento de modelos por meio da redução do espaço de características;
- Visualização de conjuntos de dados complexos em espaços latentes bidimensionais ou tridimensionais.

12. Considerações Finais

A Análise de Componentes Principais (Principal Component Analysis – PCA) permanece como uma das técnicas mais fundamentais e consolidadas da análise de dados,

constituindo um dos pilares da redução de dimensionalidade, da análise exploratória e do pré-processamento em pipelines de aprendizado de máquina. Sua principal força reside em seus sólidos fundamentos matemáticos, elevada eficiência computacional e facilidade de interpretação, características que permitem transformar conjuntos de dados complexos e de alta dimensionalidade em um conjunto reduzido de variáveis latentes ortogonais capazes de capturar as principais fontes de variabilidade.

Sob a perspectiva prática, a PCA fornece um poderoso framework para revelar estruturas ocultas nos dados, identificar padrões, detectar observações discrepantes e comprimir informações com perda mínima de conteúdo relevante. Em áreas como quimiometria, espectroscopia, bioinformática e monitoramento de processos, a PCA tornou-se uma ferramenta indispensável para a interpretação de dados multivariados e para o suporte à tomada de decisões. Sua integração ao Controle Estatístico Multivariado de Processos (MSPC), bem como sua utilização na extração de características para modelos de aprendizado de máquina, evidencia sua elevada versatilidade.

Entretanto, apesar de sua ampla aplicabilidade, a PCA apresenta limitações importantes. Por ser um método linear, pode não representar adequadamente relações não lineares frequentemente presentes em dados reais. Além disso, como seu critério de otimização está baseado na maximização da variância, e não na separabilidade entre classes, os componentes principais obtidos nem sempre são os mais adequados para problemas de classificação. O método também é sensível à escala dos dados e à presença de observações discrepantes (outliers), fatores que podem alterar significativamente os componentes principais caso um pré-processamento adequado não seja realizado.

No contexto atual da ciência de dados e do aprendizado de máquina, a PCA deve ser entendida não como uma solução universal, mas como uma metodologia robusta e um componente essencial de um conjunto mais amplo de ferramentas analíticas. Em muitos

estudos, ela representa a primeira etapa da análise dos dados, fornecendo informações que orientam a seleção de técnicas mais sofisticadas, como Kernel PCA, métodos de aprendizado de variedades (manifold learning) e representações baseadas em aprendizado profundo (deep learning), especialmente quando estruturas não lineares estão presentes.

Outro aspecto de grande relevância é sua elevada interpretabilidade. A análise conjunta dos loadings, dos scores e da variância explicada permite compreender a contribuição das variáveis originais para cada componente principal, característica particularmente importante em áreas científicas nas quais compreender os fenômenos físicos, químicos ou biológicos é tão importante quanto obter elevado desempenho preditivo. Nesse sentido, a PCA estabelece uma ponte entre o rigor estatístico e a aplicabilidade prática, tornando-se especialmente valiosa em disciplinas que exigem simultaneamente transparência, interpretabilidade e eficiência computacional.

Em síntese, a PCA continua sendo uma técnica extremamente relevante na era do big data e da inteligência artificial. Seu papel como metodologia fundamental assegura que continuará ocupando posição de destaque tanto na pesquisa quanto na prática profissional, seja empregada de forma independente, seja integrada a frameworks analíticos mais sofisticados.

2.2.1.1.2 Análise de Componentes Principais por Kernel

A Análise de Componentes Principais por Kernel (Kernel Principal Component Analysis – Kernel PCA) é uma extensão não linear da Análise de Componentes Principais (PCA) clássica, desenvolvida para capturar estruturas complexas em dados que não podem ser adequadamente representados em um subespaço linear. Ao mapear implicitamente os dados originais para um espaço de características de alta dimensionalidade por meio de uma função de kernel, o Kernel PCA permite realizar

operações lineares nesse espaço, preservando, ao mesmo tempo, as relações não lineares presentes no domínio de entrada.

A Figura 2 ilustra o princípio fundamental do Kernel PCA: transformar relações não lineares em relações lineares por meio de um mapeamento implícito para um espaço de características de alta dimensionalidade. No espaço original, os dados apresentam uma estrutura que não pode ser adequadamente capturada por projeções lineares, como evidenciado pela disposição circular das amostras. Ao aplicar o truque do kernel (kernel trick), os dados são projetados para um espaço de maior dimensionalidade, no qual sua estrutura torna-se linearmente separável. Em seguida, a PCA é aplicada nesse espaço transformado, permitindo a extração dos componentes principais que refletem a geometria intrínseca dos dados. A projeção final demonstra como o Kernel PCA preserva padrões não lineares em uma representação compacta de baixa dimensionalidade. Essa capacidade torna o Kernel PCA particularmente adequado para conjuntos de dados complexos, nos quais métodos lineares, como a PCA clássica, não conseguem capturar estruturas essenciais.

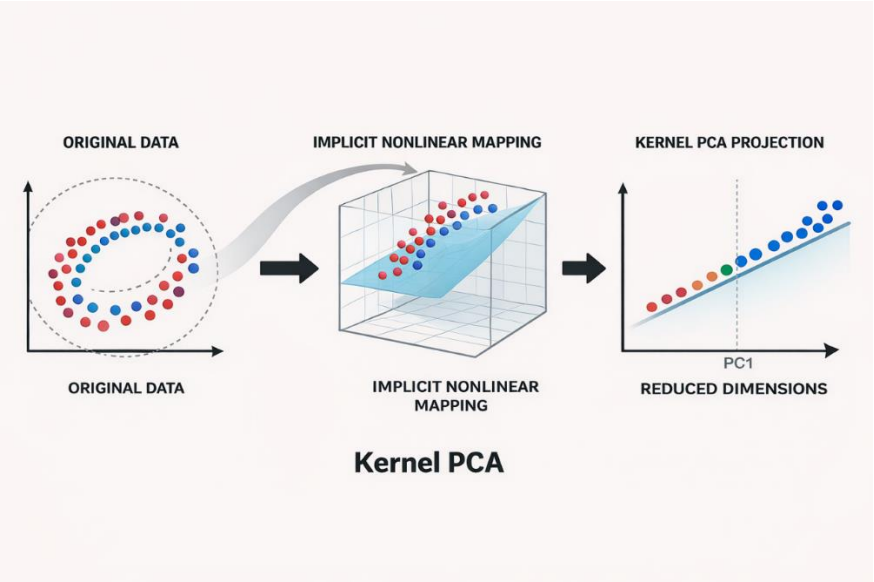


Figura 2 – Ilustração conceitual da Análise de Componentes Principais por Kernel (Kernel PCA).

O conjunto de dados original (à esquerda), caracterizado por uma estrutura não linear no espaço de entrada, é implicitamente mapeado para um espaço de características de maior dimensionalidade por meio de uma função de kernel (ao centro), no qual os dados se tornam aproximadamente linearmente separáveis. Em seguida, a PCA é realizada nesse espaço transformado, e os dados são projetados sobre o(s) componente(s) principal(is) dominante(s), resultando em uma representação de baixa dimensionalidade (à direita) que captura a estrutura não linear subjacente.

A Tabela 4 destaca os compromissos fundamentais entre a Análise de Componentes Principais (PCA) e o Kernel PCA, enfatizando o equilíbrio entre interpretabilidade, eficiência computacional e flexibilidade de modelagem. Por ser um método linear, a PCA oferece elevada interpretabilidade por meio de loadings explícitos e de uma reconstrução direta, o que a torna particularmente atrativa em áreas científicas como a quimiometria, nas quais a compreensão da contribuição das variáveis é essencial. Sua boa escalabilidade também favorece sua aplicação a grandes conjuntos de dados.

Tabela 4 – Comparação das propriedades da PCA e do Kernel PCA.

Característica	PCA	Kernel PCA
Linearidade	Linear	Não linear
Interpretabilidade	Alta	Baixa
Escalabilidade	Boa	Limitada
Espaço de características	Explícito	Implícito
Reconstrução	Direta	Difícil

Em contraste, o Kernel PCA estende a PCA a espaços de características não lineares, possibilitando a captura de estruturas complexas que não podem ser representadas por projeções lineares. Entretanto, essa maior flexibilidade tem como contrapartida uma redução da interpretabilidade, uma vez que a transformação ocorre em um espaço implícito de alta dimensionalidade, definido por uma função de kernel. Além disso, o Kernel PCA é computacionalmente mais exigente e apresenta desafios relacionados à reconstrução dos dados, o que pode limitar sua aplicação prática em problemas de grande escala ou em aplicações em tempo real.

De modo geral, a tabela evidencia que a PCA e o Kernel PCA não devem ser considerados métodos concorrentes, mas sim ferramentas complementares. A escolha entre eles depende da natureza dos dados e do objetivo da análise: a PCA é preferida quando se busca transparência, interpretabilidade e eficiência computacional, enquanto o Kernel PCA é mais adequado quando predominam padrões não lineares e a interpretabilidade é um aspecto menos crítico.

1. Fundamentos Teóricos

Seja $\{x_i\}_{i=1}^{n}$, com $x_i \, \varepsilon \, \mathbb{R}^d$, um conjunto de dados. Na PCA clássica, busca-se determinar as direções que maximizam a variância dos dados projetados. O Kernel PCA estende essa ideia mapeando inicialmente os dados para um espaço de características $\mathcal{F}$, de alta dimensionalidade (possivelmente de dimensão infinita), por meio de um mapeamento não linear:

$$\phi : \mathbb{R}^d \rightarrow \mathcal{F}, \quad \mathbf{x} \mapsto \phi(\mathbf{x})$$

Em vez de calcular explicitamente $\phi(x)$, o Kernel PCA utiliza o truque do kernel (kernel trick), no qual o produto interno no espaço de características $\mathcal{F}$ é calculado por meio de uma função de kernel:

$$k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle \tag{9}$$

As funções de kernel mais comumente utilizadas incluem:

- Kernel linear: $\mathrm{k}(\mathbf{x}, \mathbf{y}) = \mathbf{x}^{\mathbf{T}}\mathbf{y}$
- Kernel polinomial: $\mathrm{k}(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^{\mathbf{T}}\mathbf{y} + \mathbf{c})^{p}$
- Kernel gaussiano (RBF): $\mathrm{k}(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\|\mathbf{x}-\mathbf{y}\|^2}{2\sigma^2}\right)$

2. Matriz de Kernel e Centralização

Define-se a matriz de kernel (ou matriz de Gram) como:

$$\mathbf{K_{ij}} = \mathrm{k}(\mathbf{x_i}, \mathbf{x_j}) \tag{10}$$

Para realizar a PCA no espaço de características, a matriz de kernel deve ser centralizada:

$$\mathbf{K_c} = \mathbf{K} - \mathbf{1_n}\mathbf{K} - \mathbf{K}\mathbf{1_n} + \mathbf{1_n}\mathbf{K}\mathbf{1_n} \tag{11}$$

em que $\mathbf{1_n}$ é uma matriz $n \, x \, n$ cujos elementos são todos iguais a (1/n).

3. Problema de Autovalores

O Kernel PCA resolve o seguinte problema de autovalores:

$$K_c\alpha = \lambda\alpha \tag{12}$$

Os autovetores α correspondem aos componentes principais no espaço de características. A projeção de um novo ponto de dados $\mathbf{x}$, sobre o k-ésimo componente principal é dada por:

$$\mathbf{y_k(x) = \sum_{i=1}^{n} \alpha_i^{(k)} k(x_i, x)} \tag{13}$$

4. Interpretação

Ao contrário da PCA linear, o Kernel PCA não produz direções explícitas no espaço original dos dados de entrada. Em vez disso, fornece projeções em um espaço de características implícito, no qual padrões não lineares — como agrupamentos distribuídos ao longo de variedades (manifolds) curvas — tornam-se linearmente separáveis.

Essa característica torna o Kernel PCA particularmente eficaz para:

- Desdobrar variedades (manifolds) não lineares (por exemplo, o Swiss roll);
- Capturar correlações não lineares;
- Aumentar a separabilidade nas tarefas de classificação.

5. Problema da Pré-imagem

Um dos principais desafios do Kernel PCA é o problema da pré-imagem, isto é, a reconstrução da entrada original $\mathbf{x}$ a partir de sua representação no espaço de características. Como $\phi(\cdot)$ geralmente não é invertível ou não é conhecida explicitamente, torna-se necessário empregar métodos aproximados:

$$\mathbf{x^* \approx \arg\max_x \|\phi(x) - \sum_{k=1}^{m} y_k v_k\|^2} \tag{14}$$

Essa limitação dificulta tanto a interpretabilidade quanto a reconstrução dos dados.

6. Complexidade Computacional

O Kernel PCA apresenta um custo computacional mais elevado do que a PCA linear:

- Cálculo da matriz de kernel: On2
- Decomposição em autovalores e autovetores: On3

Isso torna o Kernel PCA menos adequado para conjuntos de dados muito grandes, embora métodos aproximados, como:

- Método de Nyström;
- Random Fourier Features (Características aleatórias de Fourier);

Possam atenuar essa limitação.

7. Limitações

Apesar de sua flexibilidade, o Kernel PCA apresenta diversos desafios:

1. Escalabilidade: desempenho limitado em grandes conjuntos de dados devido ao custo associado à matriz de kernel.
2. Escolha do kernel: o desempenho depende fortemente da escolha da função de kernel e de seus hiperparâmetros (por exemplo, σ no kernel RBF).
3. Baixa interpretabilidade: os resultados são expressos em um espaço implícito de características.
4. Problema da pré-imagem: a reconstrução dos dados originais é complexa e, em geral, apenas aproximada.

5. Sensibilidade ao ruído: dependendo do kernel utilizado, os métodos baseados em kernel podem amplificar o efeito do ruído.

8. Aplicações

O Kernel PCA tem sido aplicado com sucesso em diversas áreas.

8.1 Quimiometria e Espectroscopia

- Extração de características não lineares de espectros Raman, NIR e IV (IR);
- Detecção de variações químicas sutis;
- Compressão de dados em conjuntos espectrais de alta dimensionalidade.

8.2 Processamento de Imagens

- Reconhecimento facial (Eigenfaces versus Kernel Eigenfaces);
- Remoção de ruído e compressão de imagens;
- Extração de características não lineares.

8.3 Bioinformática

- Análise de expressão gênica;
- Classificação de estruturas de proteínas.

8.4 Detecção de Falhas e Monitoramento de Processos

- Controle de processos não lineares;
- Detecção de anomalias em sistemas de engenharia química.

8.5 Pipelines de Aprendizado de Máquina

- Etapa de pré-processamento para algoritmos de classificação (por exemplo, SVM);
- Visualização de conjuntos de dados complexos.

9. Considerações Finais

O Kernel PCA representa um avanço fundamental nas técnicas de redução de dimensionalidade ao possibilitar a análise de estruturas não lineares por meio de mapeamentos implícitos para espaços de características de alta dimensionalidade. Seu principal diferencial reside na flexibilidade e no elevado poder de representação de padrões complexos. Por outro lado, suas limitações têm motivado pesquisas contínuas voltadas ao desenvolvimento de métodos de kernel mais escaláveis, técnicas de incorporação (embeddings) mais interpretáveis e abordagens híbridas que combinam aprendizado profundo (deep learning) e métodos baseados em kernel.

Em aplicações modernas — particularmente em quimiometria, ciência dos materiais e espectroscopia — o Kernel PCA continua sendo uma ferramenta valiosa sempre que relações não lineares predominam na estrutura dos dados [7].

2.2.1.1.3 Análise de Componentes Principais com Norma L1

A Análise de Componentes Principais baseada na norma L1 (L1-norm Principal Component Analysis, L1-PCA), também conhecida como PCA robusta baseada na norma L1, é uma formulação alternativa da PCA clássica que substitui o critério convencional baseado na norma L2 (mínimos quadrados) por uma função objetivo baseada na norma L1. Essa modificação aumenta significativamente a robustez em relação a valores atípicos (outliers) e a ruídos com caudas pesadas (heavy-tailed noise), tornando a L1-PCA particularmente adequada para conjuntos de dados do mundo real, nos quais desvios em relação à hipótese de normalidade (gaussianidade) são frequentes.

A Figura 3 destaca a principal vantagem da PCA baseada na norma L1 em relação à PCA clássica: sua robustez a valores atípicos. Enquanto a PCA tradicional é baseada na norma L2 e, portanto, é desproporcionalmente influenciada por observações extremas, a

L1-PCA utiliza a norma L1, reduzindo o impacto de grandes desvios. Como consequência, a direção principal obtida pela L1-PCA representa de forma mais fiel a estrutura intrínseca dos dados não contaminados (inliers). Essa característica torna a L1-PCA especialmente indicada para aplicações em quimiometria, espectroscopia e outras áreas em que ruídos e valores atípicos são comuns, proporcionando uma redução de dimensionalidade mais estável, robusta e confiável.

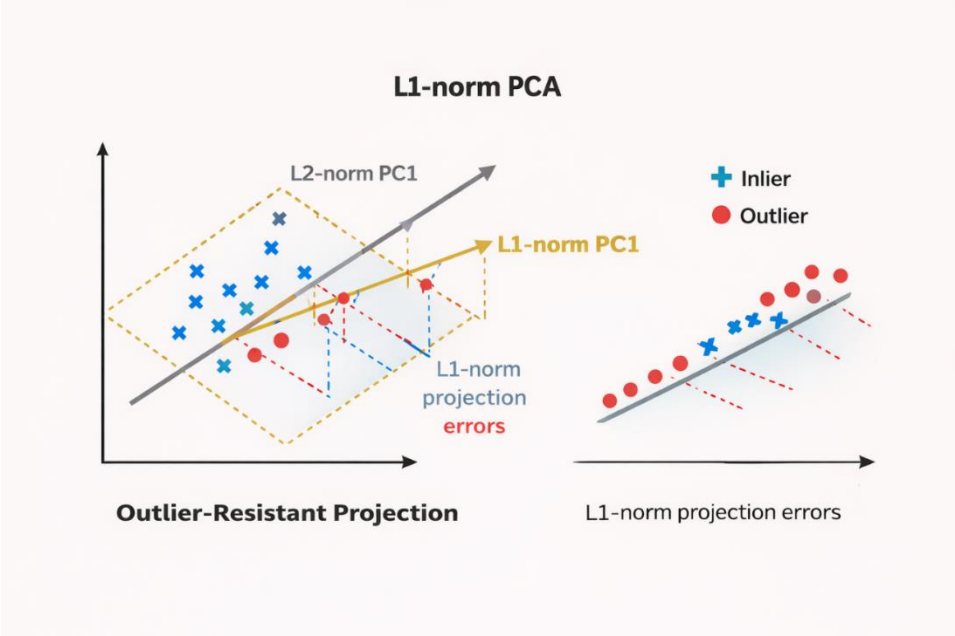


Figura 3 – Ilustração da Análise de Componentes Principais baseada na norma L1 (L1-PCA) em comparação com a PCA clássica baseada na norma L2.

O conjunto de dados contém observações normais (inliers, cruzes azuis) e valores atípicos (outliers, círculos vermelhos). A direção da PCA clássica (PC1 baseada na norma L2, indicada por uma seta cinza) é fortemente influenciada por valores atípicos devido à minimização da soma dos erros quadráticos. Em contraste, a L1-PCA (seta amarela) minimiza a soma dos erros absolutos de projeção, resultando em uma direção principal mais robusta aos valores atípicos e mais alinhada à maioria dos dados. As linhas tracejadas representam os erros de projeção sob a norma L1.

A Tabela 5 resume as principais diferenças entre a PCA clássica e sua variante baseada na norma L1, destacando o impacto do critério de otimização adotado. Enquanto a PCA baseada na norma L2 maximiza a variância e apresenta elevada eficiência computacional, é altamente sensível a valores atípicos devido à sua formulação baseada na soma dos quadrados dos erros. Em contrapartida, a L1-PCA substitui a função objetivo quadrática por um critério baseado na soma dos desvios absolutos, aumentando significativamente a robustez em relação a observações anômalas. Entretanto, essa robustez é obtida à custa de maior complexidade computacional e menor tratabilidade analítica. De modo geral, a tabela reforça que a L1-PCA é particularmente vantajosa para conjuntos de dados ruidosos ou contaminados, enquanto a PCA baseada na norma L2 permanece a escolha mais adequada quando a eficiência computacional e a interpretabilidade são as principais prioridades.

Tabela 5 – Comparação das propriedades fundamentais da PCA baseada na norma L2 (PCA clássica) e da PCA baseada na norma L1 (L1-PCA).

Característica	PCA baseada na norma L2 (PCA clássica)	PCA baseada na norma L1 (L1-PCA)
Objetivo	Maximização da variância	Maximização dos desvios absolutos
Sensibilidade a valores atípicos	Alta	Baixa
Otimização	Solução analítica em forma fechada (SVD)	Algoritmos iterativos/combinatórios
Robustez	Baixa	Alta
Custo computacional	Baixo	Mais elevado

1. Motivação e Contexto

A PCA clássica maximiza a variância dos dados projetados ou, de forma equivalente, minimiza o erro de reconstrução baseado na soma dos erros quadráticos:

$$\min_{\mathbf{w}} \sum_{\mathbf{i=1}}^{\mathbf{n}} \|\mathbf{x_i} - \mathbf{W}\mathbf{W}^{\mathbf{T}}\mathbf{x_i}\|_{\mathbf{2}}^{\mathbf{2}} \quad (15)$$

Essa formulação é ótima sob a hipótese de ruído gaussiano, porém é altamente sensível a valores atípicos (outliers), uma vez que os erros quadráticos amplificam grandes desvios.

Em contraste, a L1-PCA substitui a norma L2 pela norma L1, reduzindo a influência de observações extremas:

$$\min_{\mathbf{w}} \sum_{i=1}^{n} \|\mathbf{x_i} - \mathbf{W}\mathbf{W}^{\mathbf{T}}\mathbf{x_i}\|_1 \quad (16)$$

Ou, na forma de projeção, maximizando a dispersão baseada na norma L1:

$$\max_{\mathbf{x}} \sum_{\mathbf{i=1}}^{\mathbf{n}} |\mathbf{w}^{\mathbf{T}}\mathbf{x_i}| \quad \text{sujeito à} \quad \|\mathbf{w}\|_2 = 1 \quad (17)$$

Essa formulação busca direções que maximizam a soma dos desvios absolutos, em vez de maximizar a soma dos desvios quadráticos.

2. Formulação Matemática

Dado um conjunto de dados centrado $\boldsymbol{X} \in \mathbb{R}^{\boldsymbol{dxn}}$, a primeira componente principal baseada na norma L1 pode ser definida como:

$$\mathbf{w}^* = \arg max_{\|\mathbf{w}\|_2=1} \sum_{i=1}^{n} |\mathbf{w}^{\mathbf{T}}\mathbf{x_i}| \quad (18)$$

Para múltiplas componentes principais, o problema pode ser formulado como:

$$\max_{\mathbf{W}^{\mathbf{T}}\mathbf{W}=\mathbf{I}} \sum_{\mathbf{i=1}}^{\mathbf{n}} \|\mathbf{W}^{\mathbf{T}}\mathbf{x_i}\|_1 \quad (19)$$

Ao contrário da PCA baseada na norma L2 (L2-PCA), esse problema de otimização é não convexo e não suave (não diferenciável), o que torna sua resolução computacionalmente mais desafiadora.

3. Interpretação Geométrica

A L1-PCA busca direções de projeção que maximizam a soma das projeções absolutas, o que corresponde ao alinhamento com a mediana dos dados, em vez da média.

Principais diferenças:

- L2-PCA: sensível à variância → fortemente influenciada por valores atípicos (outliers);
- L1-PCA: sensível à estrutura mediana → robusta a valores atípicos.

Assim, a L1-PCA é mais adequada para conjuntos de dados que apresentam:

- ruído esparso;
- perturbações impulsivas;
- distribuições com caudas pesadas (heavy-tailed distributions).

4. Algoritmos para L1-PCA

Devido à ausência de uma solução analítica em forma fechada, diversos algoritmos foram propostos para resolver o problema de otimização da L1-PCA.

4.1 Métodos Iterativos de Reponderação (Iterative Reweighting Methods)

Aproximar a norma L1 por meio de normas L2 ponderadas: $\sum|\boldsymbol{x}| \approx \sum \mathbf{w_i x_i^2}$

4.2 Algoritmo de Inversão de Sinais (Bit-Flipping Algorithm)

Método eficiente para calcular exatamente as componentes principais baseadas na norma L1 por meio da otimização de vetores de sinais.

4.3 Abordagens de Relaxação Convexa

Transformam o problema original em um problema de otimização convexa tratável computacionalmente.

4.4 Otimização Alternada (Alternating Optimization)

Atualiza iterativamente os vetores de projeção e os pesos até a convergência.

5. Propriedades de Robustez

A principal vantagem da L1-PCA reside em sua elevada robustez:

- Ponto de ruptura (breakdown point): superior ao da L2-PCA;
- Função de influência (influence function): limitada (bounded);
- Resistência a valores atípicos (outliers): elevada.

Como a norma L1 cresce linearmente, em vez de quadraticamente, valores extremos exercem influência limitada sobre a solução obtida.

6. Limitações

Apesar de sua robustez, a L1-PCA apresenta algumas limitações importantes:

1. Maior complexidade computacional
    - Problema de otimização não convexo;
    - Frequentemente requer algoritmos iterativos ou combinatórios.
2. Não unicidade das soluções
    - Podem existir múltiplas direções ótimas.
3. Ausência de garantia de ortogonalidade
    - As componentes principais podem não ser estritamente ortogonais entre si.
4. Problemas de escalabilidade
    - Menor eficiência que a PCA convencional para conjuntos de dados de grande porte.

5. Desafios de interpretabilidade
    - Os resultados podem ser menos intuitivos do que aqueles obtidos pela PCA baseada na maximização da variância.

7. Aplicações

A L1-PCA tem sido aplicada com sucesso em diversas áreas.

7.1 Quimiometria e Espectroscopia

- Extração robusta de características em dados Raman, NIR e IR;
- Tratamento de espectros contendo valores atípicos decorrentes de ruído instrumental.

7.2 Processamento de Imagens

- Reconhecimento facial sob condições de oclusão;
- Subtração de fundo (background subtraction);
- Compressão robusta de imagens.

7.3 Bioinformática

- Análise de expressão gênica na presença de medições ruidosas.

7.4 Processamento de Sinais

- Filtragem de ruído impulsivo;
- Detecção de falhas em sistemas industriais.

7.5 Análise de Dados Financeiros

- Tratamento de eventos extremos, como choques de mercado.

8. Extensões e Variantes

Diversas extensões da L1-PCA foram propostas ao longo dos anos:

- Sparse L1-PCA: incorpora restrições de esparsidade (sparsity constraints);

- Kernel L1-PCA: combina robustez com mapeamentos não lineares por meio de funções kernel;
- Robust PCA (RPCA): decompõe os dados em uma componente de baixa dimensão (low-rank) e uma componente esparsa;
- Online L1-PCA: desenvolvida para processamento de dados em fluxo contínuo (streaming data).

9. Considerações Finais

A Análise de Componentes Principais baseada na norma L1 (L1-PCA) representa uma alternativa poderosa à PCA clássica em cenários nos quais a robustez é um requisito fundamental. Ao basear-se nos desvios absolutos, em vez dos erros quadráticos, a L1-PCA apresenta maior resistência a valores atípicos e a ruídos não gaussianos. Entretanto, essa robustez é obtida à custa de maior complexidade computacional e de um problema de otimização significativamente mais desafiador.

Na ciência de dados moderna e, particularmente, na quimiometria, a L1-PCA é especialmente relevante para conjuntos de dados de alta dimensionalidade e contaminados por ruído — como medições espectroscópicas — nos quais a PCA tradicional pode não conseguir capturar adequadamente a verdadeira estrutura subjacente dos dados [8–10].

2.2.1.1.4 Escalonamento Multidimensional Clássico

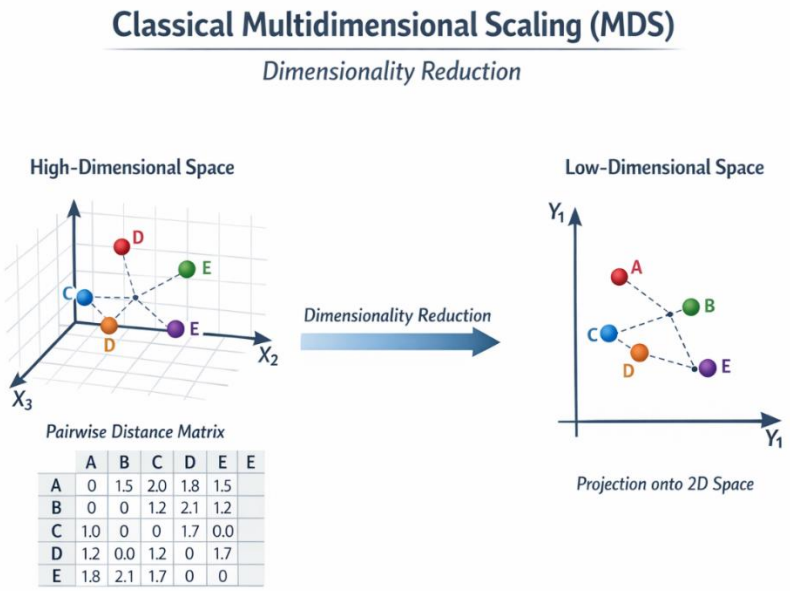
1. Introdução

O Escalonamento Multidimensional Clássico (Classical Multidimensional Scaling – cMDS) é um método geométrico que tem como objetivo representar objetos como pontos em um espaço euclidiano de baixa dimensionalidade, de modo que as distâncias entre pares de pontos aproximem, o melhor possível, as dissimilaridades

originais. Essa abordagem é particularmente útil quando os dados originais não estão explicitamente disponíveis e apenas uma matriz de distâncias ou de dissimilaridades é conhecida [11–12].

O cMDS apresenta fortes conexões teóricas com a álgebra linear e a decomposição espectral e, sob condições euclidianas, é matematicamente equivalente à Análise de Componentes Principais (PCA).

A Figura 4 ilustra o princípio fundamental do Escalonamento Multidimensional Clássico: a transformação das distâncias entre pares de objetos em uma representação geométrica em um espaço de dimensionalidade reduzida. Ao preservar as distâncias entre os pontos, o MDS fornece uma visualização fiel da estrutura global dos dados, tornando-se particularmente adequado para análises exploratórias e para modelagem baseada em similaridade.



	A	B	C	D	E	E
A	0	1.5	2.0	1.8	1.5	
B	0	0	1.2	2.1	1.2	
C	1.0	0	0	1.7	0.0	
D	1.2	0.0	1.2	0	1.7	
E	1.8	2.1	1.7	0	0	

Figura 4 – Representação esquemática do Escalonamento Multidimensional Clássico (Classical Multidimensional Scaling – cMDS) aplicado à redução de dimensionalidade.

À esquerda, um conjunto de pontos é representado em um espaço de alta dimensionalidade, cujas relações entre pares são codificadas em uma matriz de distâncias. Essas distâncias sintetizam as diferenças entre as observações. O cMDS opera transformando essa matriz de distâncias em uma matriz de produtos internos (matriz de Gram) por meio da dupla centralização (double centering), seguida da decomposição em autovalores e autovetores. À direita, os dados são projetados em um espaço de baixa dimensionalidade (tipicamente bidimensional), de modo que as distâncias euclidianas entre os pontos sejam preservadas o mais fielmente possível. A configuração resultante mantém a estrutura geométrica global do conjunto de dados original.

A Tabela 6 resume as principais características teóricas e práticas do Escalonamento Multidimensional Clássico (cMDS). O método é fundamentalmente baseado em distâncias, operando sobre uma matriz de dissimilaridades entre pares e buscando preservar as distâncias euclidianas em uma representação de dimensionalidade reduzida. Sua formulação matemática baseia-se na dupla centralização da matriz de distâncias quadráticas, seguida pela decomposição espectral (decomposição em autovalores e autovetores), tornando-o intimamente relacionado à Análise de Componentes Principais (PCA) quando são utilizadas distâncias euclidianas. O cMDS é eficiente na preservação da estrutura global dos dados, porém apresenta menor capacidade para representar relações locais ou altamente não lineares. Embora produza uma incorporação (embedding) geométrica significativa, sua interpretabilidade e invertibilidade são limitadas, pois as coordenadas obtidas não estão diretamente associadas às variáveis originais. Além disso, o método pode ser sensível ao ruído e computacionalmente oneroso para grandes conjuntos de dados devido à sua complexidade cúbica. De modo geral, o Escalonamento Multidimensional Clássico

constitui uma ferramenta poderosa para análise exploratória e visualização quando a preservação da estrutura global dos dados é o principal objetivo.

Tabela 6 – Principais propriedades do Escalonamento Multidimensional Clássico (Classical Multidimensional Scaling – cMDS)

Propriedade	Descrição
Tipo de método	Técnica de redução de dimensionalidade baseada em distâncias
Dados de entrada	Matriz de distâncias (ou dissimilaridades) entre pares de observações
Objetivo	Preservar as distâncias euclidianas entre pares de pontos em um espaço de menor dimensionalidade
Fundamentação matemática	Dupla centralização da matriz de distâncias quadráticas, seguida da decomposição em autovalores e autovetores
Linearidade	Linear (equivalente à PCA quando as distâncias são euclidianas)
Saída	Coordenadas em um espaço de baixa dimensionalidade (embedding dos dados)
Hipótese métrica	Assume distâncias euclidianas (MDS métrico)
Preservação da estrutura global	Elevada (prioriza a preservação da geometria global dos dados)
Preservação da estrutura local	Limitada em comparação com métodos não lineares
Interpretabilidade	Moderada (as coordenadas obtidas não estão diretamente associadas às variáveis originais)
Invertibilidade	Limitada (as variáveis originais não podem ser totalmente recuperadas)
Sensibilidade ao ruído	Moderada a elevada (dependente da qualidade da matriz de distâncias)
Complexidade computacional	(O(n^3)), devido à decomposição em autovalores

Propriedade	Descrição
Escalabilidade	Limitada para conjuntos de dados de grande porte
Relação com a PCA	Equivalente à PCA quando aplicada a uma matriz de distâncias euclidianas
Tratamento da não linearidade	Limitado (não captura variedades (manifolds) não lineares)
Interpretação dos autovalores	Autovalores positivos correspondem a dimensões significativas; autovalores negativos indicam que a estrutura de distâncias não é estritamente euclidiana

2. Formulação Matemática

Seja $\mathbf{D} = [d_{ij}]$ uma matriz de distâncias entre pares de n objetos. O objetivo do Escalonamento Multidimensional Clássico (cMDS) é encontrar uma configuração de pontos $\mathbf{X}\ \varepsilon\ \mathbb{R}^{nx\ p}$ tal que:

$$d_{ij}^2 \approx \left\|\mathbf{x_i} - \mathbf{x_j}\right\|^2 \tag{20}$$

2.1 Dupla Centralização (Double Centering)

O método inicia-se pela transformação da matriz de distâncias em uma matriz de Gram (matriz de produtos internos). Para isso, define-se a seguinte matriz:

$$\mathbf{B} = -\frac{1}{2}\mathbf{J}\mathbf{D}^{(2)}\mathbf{J} \tag{21}$$

em que:

- $\mathbf{D}^{(2)}$ é a matriz das distâncias ao quadrado;
- $\mathbf{J} = \mathbf{I} - \frac{1}{n}\mathbf{1}\mathbf{1}^{\mathbf{T}}$ é a matriz de centralização.

Essa operação, conhecida como dupla centralização (double centering), transforma a matriz de distâncias em uma matriz de produtos internos (produtos escalares).

2.2 Decomposição em Autovalores e Autovetores

A matriz é simétrica e pode ser decomposta da seguinte forma:

$$\mathbf{B} = \mathbf{V}\boldsymbol{\Lambda}\mathbf{V}^{\mathbf{T}} \tag{22}$$

em que:

- contém os autovetores;
- $\boldsymbol{\Lambda}$ é uma matriz diagonal contendo os autovalores.

A representação dos dados em um espaço de baixa dimensionalidade (embedding) é obtida por:

$$\mathbf{X_p} = \mathbf{V_p}\boldsymbol{\Lambda}_\mathbf{p}^{\mathbf{1/2}} \tag{23}$$

em que apenas os p maiores autovalores positivos são mantidos.

3. Interpretação Geométrica

O cMDS reconstrói uma configuração de pontos cujos produtos internos correspondem aos obtidos a partir da matriz de distâncias original. Dessa forma, o método encontra uma incorporação euclidiana (embedding) que preserva, da melhor maneira possível, as distâncias entre pares de objetos no sentido dos mínimos quadrados.

É importante destacar que:

- Se as distâncias forem euclidianas, é possível uma reconstrução exata da configuração.
- Caso contrário, surgirão autovalores negativos, indicando que a estrutura subjacente não é estritamente euclidiana.

4. Relação com a Análise de Componentes Principais (PCA)

Quando a matriz de distâncias é calculada a partir de um conjunto de dados previamente centrado,

$$d_{ij}^2 \approx \left\|\mathbf{x_i} - \mathbf{x_j}\right\|^2 \quad (24)$$

Então o Escalonamento Multidimensional Clássico (cMDS) torna-se equivalente à Análise de Componentes Principais (PCA):

$$\mathbf{B} = \mathbf{X}\mathbf{X}^{\mathbf{T}} \quad (25)$$

Assim:

- A PCA opera sobre a estrutura de covariância dos dados;
- O cMDS opera sobre a estrutura de distâncias.

5. Vantagens

5.1 Trabalha diretamente com matrizes de distâncias

- Não requer os dados originais (raw data);
- Pode ser aplicado a matrizes de dissimilaridade arbitrárias.

5.2 Sólida fundamentação matemática

- Baseia-se na decomposição espectral em autovalores e autovetores;
- É um método determinístico e não iterativo.

5.3 Preservação da estrutura global

- Preserva a geometria em larga escala dos dados;
- É eficaz para visualizar a estrutura global do conjunto de dados.

5.4 Interpretabilidade

- Os autovalores indicam a proporção da variância explicada, de forma análoga ao que ocorre na PCA.

6. Estresse (Stress) e Erro de Reconstrução

Embora o Escalonamento Multidimensional Clássico (cMDS) não minimize explicitamente uma função de estresse (stress), a qualidade da representação em baixa dimensionalidade (embedding) pode ser avaliada por:

$$Stress = \sqrt{\frac{\sum_{i<j}(d_{ij} - \|y_i - y_j\|)^2}{\sum_{i<j} d_{ij}^2}} \tag{26}$$

- Baixos valores de estresse indicam uma boa preservação das distâncias entre os objetos.

7. Desvantagens e Limitações

7.1 Sensibilidade a distâncias não euclidianas

- Podem surgir autovalores negativos;
- A representação obtida (embedding) pode não possuir uma interpretação física adequada.

7.2 Baixa preservação da estrutura local

- O método não preserva explicitamente as vizinhanças entre os pontos;
- Apresenta desempenho inferior ao de métodos como t-SNE e UMAP para tarefas de agrupamento (clustering).

7.3 Complexidade computacional

- Requer a decomposição em autovalores de uma matriz (n \times n);
- Complexidade computacional: (O(n^3)).

7.4 Sensibilidade ao ruído

- O ruído presente na matriz de distâncias propaga-se globalmente ao longo da representação obtida.

7.5 Não é intrinsecamente não linear

- Não é capaz de capturar variedades (manifolds) complexas.

8. Aplicações

8.1 Quimiometria

- Análise de similaridade entre espectros (Raman, NIR e IR);
- Agrupamento e visualização de amostras.

8.2 Bioinformática

- Análise de distâncias genéticas;
- Visualização de relações filogenéticas.

8.3 Ecologia

- Mapeamento de dissimilaridades entre espécies;
- Análise da estrutura de comunidades.

8.4 Ciências sociais

- Mapeamento perceptual;
- Psicometria.

8.5 Ciência dos materiais

- Avaliação da similaridade entre materiais com base em descritores.

9. Considerações Práticas

- Sempre inspecione os autovalores:
    - Autovalores negativos indicam que as distâncias não são estritamente euclidianas.
- Escolha a dimensionalidade da representação considerando a variância acumulada explicada.

- Realize o pré-processamento da matriz de distâncias (por exemplo, normalização), quando apropriado.
- Utilize medidas de estresse ou erro de reconstrução para avaliar a qualidade da representação em baixa dimensionalidade.

10. Considerações Finais

O Escalonamento Multidimensional Clássico (Classical Multidimensional Scaling – cMDS) permanece como um dos métodos de redução de dimensionalidade mais elegantes e teoricamente bem fundamentados. Sua formulação, baseada na reconstrução da matriz de produtos internos a partir das distâncias entre pares de objetos, seguida de uma decomposição espectral em autovalores e autovetores, fornece uma interpretação geométrica clara do processo de incorporação (embedding). Essa sólida base matemática garante determinismo, reprodutibilidade e interpretabilidade da estrutura global dos dados, tornando o cMDS um método de referência tanto em estudos teóricos quanto em aplicações práticas.

Uma das principais vantagens do cMDS é sua capacidade de operar diretamente sobre matrizes de dissimilaridade, característica particularmente valiosa em áreas como quimiometria, espectroscopia e bioinformática, nas quais medidas de distância frequentemente carregam informações mais relevantes do que as variáveis originais. Além disso, sua equivalência à Análise de Componentes Principais (PCA) quando as distâncias são euclidianas reforça sua importância conceitual dentro da família dos métodos espectrais, estabelecendo uma ponte entre abordagens baseadas na variância e abordagens fundamentadas em distâncias.

Entretanto, o cMDS apresenta limitações importantes. Sua dependência da hipótese de distâncias euclidianas restringe sua aplicação a conjuntos de dados com

estruturas não euclidianas ou altamente não lineares, situação frequentemente evidenciada pelo aparecimento de autovalores negativos e por representações distorcidas. Além disso, a prioridade dada à preservação da estrutura global ocorre em detrimento da preservação das vizinhanças locais, tornando o método menos adequado para tarefas como agrupamento (clustering) e aprendizado de variedades (manifold learning) em conjuntos de dados complexos. Outro fator limitante é sua escalabilidade computacional, uma vez que o método exige a decomposição completa de uma matriz de dimensão (n \times n).

No contexto dos fluxos modernos de análise de dados, o cMDS deve ser encarado não como uma solução universal, mas como uma ferramenta de referência e interpretação. O método fornece informações valiosas sobre a geometria intrínseca dos dados e constitui um importante parâmetro de comparação para técnicas não lineares mais avançadas, como Isomap, t-SNE e UMAP. Quando empregado de forma criteriosa, especialmente em combinação com métodos complementares, o cMDS continua oferecendo elevado valor analítico, reunindo simplicidade, rigor matemático e interpretabilidade em uma estrutura conceitual consistente [11–12].

2.2.1.1.5 Isomap

O Isomap (Isometric Mapping) é uma técnica não linear de redução de dimensionalidade que estende o Escalonamento Multidimensional Clássico (Classical Multidimensional Scaling – cMDS) ao preservar distâncias geodésicas, em vez de distâncias euclidianas. Introduzido em 2000, o Isomap é um dos primeiros e mais influentes métodos de aprendizado de variedades (manifold learning), desenvolvido para recuperar a geometria intrínseca de dados que se encontram sobre uma variedade não linear de baixa dimensionalidade imersa em um espaço de alta dimensionalidade [13–14].

A Figura 5 ilustra como o Isomap estende o Escalonamento Multidimensional Clássico para cenários não lineares, substituindo as distâncias euclidianas por distâncias geodésicas calculadas a partir de um grafo de vizinhança. Ao aproximar a verdadeira estrutura da variedade, o Isomap é capaz de desdobrar (unfold) dados não lineares em um espaço de menor dimensionalidade, preservando as relações globais entre as observações. Essa característica torna o método particularmente adequado para conjuntos de dados distribuídos sobre variedades curvas, nos quais técnicas lineares, como a Análise de Componentes Principais (PCA) ou o Escalonamento Multidimensional Clássico (cMDS), podem não representar adequadamente a geometria subjacente.

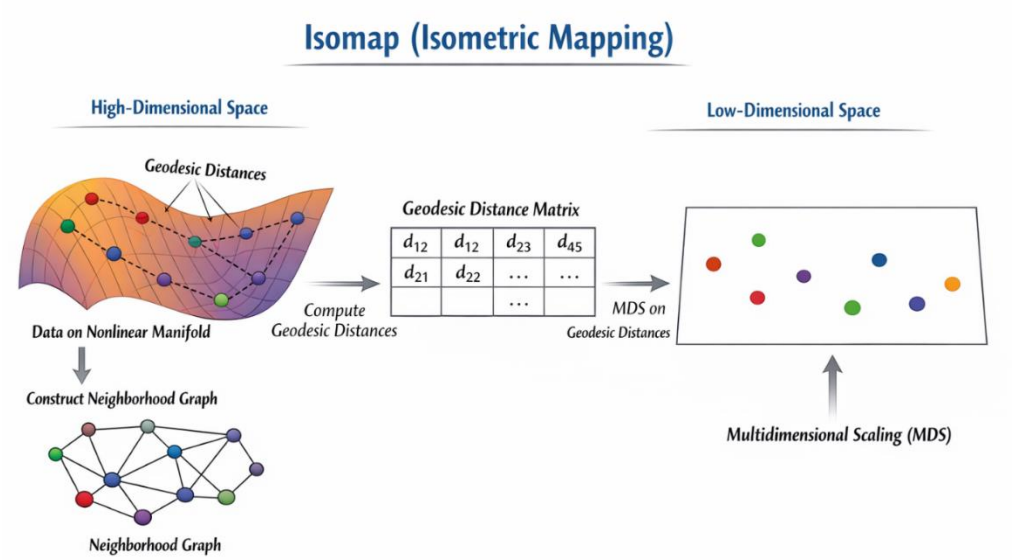


Figura 5 – Ilustração esquemática do algoritmo Isomap para redução não linear de dimensionalidade.

À esquerda, os pontos de dados encontram-se distribuídos sobre uma variedade curva em um espaço de alta dimensionalidade, na qual as distâncias euclidianas não representam adequadamente as relações reais entre as observações. Inicialmente, constrói-se um grafo de vizinhança, conectando pontos próximos (por exemplo, pelos (k)

vizinhos mais próximos) para capturar a estrutura local da variedade. Em seguida, as distâncias geodésicas entre todos os pares de pontos são aproximadas por meio do cálculo de caminhos mínimos no grafo. Essas distâncias são organizadas em uma matriz de distâncias geodésicas, que posteriormente é utilizada como entrada no Escalonamento Multidimensional Clássico (Classical Multidimensional Scaling – cMDS). À direita, a representação de baixa dimensionalidade (embedding) resultante preserva a geometria intrínseca da variedade ao manter as distâncias geodésicas, em vez das distâncias euclidianas retilíneas.

A Tabela 7 resume as principais características do Isomap, uma técnica de redução não linear de dimensionalidade baseada no aprendizado de variedades (manifold learning). Diferentemente dos métodos lineares, o Isomap preserva as distâncias geodésicas calculadas sobre um grafo de vizinhança, permitindo capturar a geometria intrínseca de estruturas de dados curvas. Ao combinar a estimativa de distâncias baseada em grafos com o Escalonamento Multidimensional Clássico (cMDS), o método alcança elevada preservação da estrutura global, ao mesmo tempo em que mantém as relações locais entre as observações. Entretanto, seu desempenho depende criticamente da escolha dos parâmetros de vizinhança e da qualidade do grafo construído, tornando-o sensível ao ruído, a valores atípicos e à presença de componentes desconectados. Além disso, a ausência de um mapeamento inverso explícito e o elevado custo computacional limitam a escalabilidade. De modo geral, o Isomap constitui uma abordagem poderosa para o desdobramento (unfolding) de variedades não lineares, especialmente quando a preservação das relações geométricas globais é um requisito fundamental.

Tabela 7 – Principais propriedades do Isomap

Propriedade	Descrição
Tipo de método	Técnica de redução não linear de dimensionalidade baseada em aprendizado de variedades (manifold learning)
Dados de entrada	Dados de alta dimensionalidade ou matriz de distâncias entre pares de observações
Objetivo	Preservar as distâncias geodésicas (ao longo da variedade) em uma representação de baixa dimensionalidade
Fundamentação matemática	Construção de um grafo de vizinhança + cálculo dos caminhos mínimos (distâncias geodésicas) + Escalonamento Multidimensional Clássico (cMDS)
Linearidade	Não linear
Saída	Coordenadas em baixa dimensionalidade que preservam a geometria intrínseca da variedade
Hipótese métrica	Assume que os dados estão distribuídos sobre uma variedade suave e utiliza distâncias geodésicas
Preservação da estrutura global	Elevada (superior à de muitos métodos não lineares)
Preservação da estrutura local	Boa (por meio da construção do grafo de vizinhança)
Interpretabilidade	Moderada (a representação não está diretamente relacionada às variáveis originais)
Invertibilidade	Limitada (não possui um mapeamento inverso explícito)
Sensibilidade ao ruído	Elevada (sensível ao ruído e a valores atípicos que afetam a construção do grafo)
Complexidade computacional	Elevada (construção do grafo + cálculo dos caminhos mínimos + decomposição em autovalores; tipicamente (O(n^3)))$O(n^3)$

Propriedade	Descrição
Escalabilidade	Limitada para conjuntos de dados de grande porte
Relação com o cMDS	Extensão do Escalonamento Multidimensional Clássico (cMDS), substituindo as distâncias euclidianas por distâncias geodésicas
Tratamento da não linearidade	Elevado (captura a estrutura de variedades não lineares)
Parâmetro principal	Número de vizinhos ((k)) ou raio de vizinhança ((\varepsilon))
Modos de falha	Erros de atalho (short-circuit) no grafo, componentes desconectados e seleção inadequada da vizinhança
Interpretação dos autovalores	Os maiores autovalores definem a dimensionalidade intrínseca da variedade; autovalores negativos podem indicar distorções na representação

1. Motivação Conceitual

Muitos conjuntos de dados do mundo real — como sinais espectroscópicos, imagens e descritores moleculares — encontram-se distribuídos sobre variedades curvas (manifolds), em vez de subespaços lineares. Técnicas lineares, como a Análise de Componentes Principais (PCA), não são capazes de representar adequadamente essas estruturas não lineares.

O Isomap supera essa limitação ao:

1. Aproximar as distâncias geodésicas (ao longo da variedade) entre os pontos de dados;
2. Representar os dados em um espaço de baixa dimensionalidade que preserva essas distâncias.

Dessa forma, o Isomap pode ser interpretado como uma generalização não linear do Escalonamento Multidimensional Clássico (cMDS).

2. Etapas do Algoritmo

Dado um conjunto de dados $\{x_i\}_{i=1}^{n}$, o algoritmo Isomap é composto por três etapas principais.

2.1 Construção do Grafo de Vizinhança

Inicialmente, constrói-se um grafo G = (V, E), em que cada nó representa um ponto de dados. As arestas do grafo são definidas utilizando um dos seguintes critérios:

- K-vizinhos mais próximos (k-nearest neighbors – k-NN); ou
- ε-Vizinhança.

As arestas são ponderadas pelas distâncias euclidianas entre os pontos:

$$\mathbf{w_{ij}} = \left\|\mathbf{x_i} - \mathbf{x_j}\right\| \tag{27}$$

2.2 Estimativa das Distâncias Geodésicas

Calculam-se as distâncias correspondentes aos caminhos mínimos entre todos os pares de nós do grafo:

$$d_{ij}^{(G)} = \text{shortest path distance between i and j} \tag{28}$$

Esse cálculo é normalmente realizado por meio dos seguintes algoritmos:

- Algoritmo de Dijkstra;
- Algoritmo de Floyd–Warshall.

As distâncias obtidas constituem uma aproximação das distâncias geodésicas ao longo da variedade (manifold).

2.3 Representação em Baixa Dimensionalidade (Etapa de cMDS)

Aplica-se o Escalonamento Multidimensional Clássico (Classical Multidimensional Scaling – cMDS) à matriz de distâncias geodésicas D(G):

$$\mathbf{B} = -\frac{\mathbf{1}}{\mathbf{2}}\mathbf{J}\left(\mathbf{D}^{(\mathbf{G})}\right)^{\mathbf{2}}\mathbf{J} \tag{29}$$

Em seguida, obtém-se a representação em baixa dimensionalidade (embedding) por meio da decomposição em autovalores e autovetores:

$$\mathbf{Y_p} = \mathbf{V_p}\boldsymbol{\Lambda}_\mathbf{p}^{\mathbf{1/2}} \tag{30}$$

3. Interpretação Teórica

O Isomap pode ser interpretado como:

- Um método de aprendizado global de variedades (global manifold learning);
- Uma técnica espectral que combina conceitos da teoria dos grafos e da álgebra linear;
- Uma extensão não linear do Escalonamento Multidimensional Clássico (cMDS), destinada à preservação da geometria intrínseca dos dados.

Quando a variedade é suficientemente amostrada e o grafo de vizinhança é construído corretamente, o Isomap é capaz de recuperar a verdadeira estrutura de baixa dimensionalidade dos dados.

4. Vantagens

- Captura estruturas globais não lineares;
- Preserva distâncias geodésicas, em vez de distâncias euclidianas;
- Produz representações (embeddings) de fácil interpretação;
- Apresenta excelente desempenho para variedades suaves, como o clássico exemplo do Swiss Roll.

5. Limitações e Desvantagens

Apesar de suas vantagens, o Isomap apresenta diversas limitações importantes.

5.1 Sensibilidade ao Tamanho da Vizinhança

- Valores muito pequenos de (k) podem tornar o grafo desconectado;

- Valores muito grandes de (k) fazem com que as distâncias geodésicas se aproximem das distâncias euclidianas;
- A escolha do parâmetro de vizinhança requer ajuste cuidadoso.

5.2 Sensibilidade ao Ruído e a Valores Atípicos

- O ruído pode distorcer a construção do grafo de vizinhança;
- Valores atípicos (outliers) podem criar atalhos artificiais (shortcuts), comprometendo a estimativa das distâncias geodésicas.

5.3 Complexidade Computacional

- Construção do grafo: O(n2);
- Cálculo dos caminhos mínimos: O(n2 log n) ou O(n3);
- Etapa de cMDS: O(n3).

Consequentemente, o Isomap não é adequado para conjuntos de dados muito grandes sem o emprego de aproximações.

5.4 Hipótese de uma Única Variedade Conectada

- O método falha quando os dados estão distribuídos sobre múltiplas variedades desconectadas;
- Não lida adequadamente com topologias complexas.

5.5 Ausência de um Mapeamento Explícito

- Não há função direta $f: \mathbb{R}^d \rightarrow \mathbb{R}^p$
- Torna difícil projetar novas observações, caracterizando o chamado problema de amostras fora da amostra (out-of-sample problem).

5.6 Erros de Atalho (Short-Circuit Errors)

- Podem surgir atalhos no grafo quando pontos distantes são conectados incorretamente;

- Esses atalhos podem provocar distorções severas na representação em baixa dimensionalidade.

6. Extensões e Melhorias

Diversas variantes foram propostas para superar as limitações do Isomap, entre elas:

- Landmark Isomap: reduz significativamente o custo computacional;
- C-Isomap: aumenta a robustez ao ruído;
- Extensões para projeção de novas amostras, baseadas na aproximação de Nyström;
- Hessian LLE e Diffusion Maps, que constituem abordagens alternativas de aprendizado de variedades.

7. Aplicações

7.1 Quimiometria e Espectroscopia

- Análise não linear de dados Raman, NIR e IR;
- Descoberta de estruturas químicas ocultas.

7.2 Processamento de Imagens

- Reconhecimento facial e estimação de pose;
- Extração não linear de características.

7.3 Bioinformática

- Análise de expressão gênica;
- Estudo de vias de dobramento (folding) de proteínas.

7.4 Ciência dos Materiais

- Exploração de relações entre estrutura e propriedades;
- Visualização de descritores de alta dimensionalidade.

7.5 Fluxos de Trabalho em Aprendizado de Máquina

- Pré-processamento para modelos de classificação e regressão;
- Visualização de conjuntos de dados complexos.

8. Comparação com Outros Métodos

A Tabela 8 apresenta uma visão comparativa de quatro técnicas amplamente utilizadas para redução de dimensionalidade, destacando suas diferenças fundamentais quanto ao tipo de método, à estrutura preservada e às características do mapeamento. Métodos lineares, como a Análise de Componentes Principais (PCA), concentram-se na preservação da variância global por meio de um mapeamento explícito, proporcionando elevada interpretabilidade e possibilidade de reconstrução dos dados. Em contraste, abordagens não lineares, como Kernel PCA e Isomap, operam em espaços de características implícitos, sendo capazes de capturar estruturas de dados mais complexas — o Kernel PCA por meio de transformações induzidas por funções kernel e o Isomap pela preservação das distâncias geodésicas ao longo de uma variedade. O Escalonamento Multidimensional Clássico (cMDS) ocupa uma posição intermediária entre os métodos baseados em distâncias, preservando as distâncias euclidianas, mas utilizando um mapeamento implícito. De modo geral, a tabela evidencia o compromisso (trade-off) entre interpretabilidade e capacidade de modelar estruturas não lineares, fornecendo subsídios para a escolha do método mais adequado em função da natureza dos dados e do objetivo da análise.

Tabela 8 – Comparação das características das técnicas de redução de dimensionalidade (DRs).

Método	Tipo	Estrutura preservada	Mapeamento
PCA	Linear	Variância global	Explícito
Kernel PCA	Não linear	Espaço de características implícito	Implícito
Escalonamento Multidimensional Clássico (cMDS)	Baseado em distâncias	Distâncias euclidianas	Implícito
Isomap	Não linear	Distâncias geodésicas	Implícito

9. Considerações Finais

O Isomap representa um marco na evolução das técnicas de redução não linear de dimensionalidade, ao introduzir o conceito de preservação das distâncias geodésicas. O método fornece uma estrutura poderosa para revelar a geometria intrínseca dos dados, superando as limitações impostas pelas abordagens lineares. Ao considerar a conectividade local entre as observações e aproximar as distâncias ao longo da variedade (manifold), o Isomap é capaz de recuperar estruturas complexas que não podem ser adequadamente representadas por métodos como a Análise de Componentes Principais (PCA) ou o Escalonamento Multidimensional Clássico (cMDS).

2.2.1.1.6 Diffusion Maps

Diffusion Maps é uma técnica de redução não linear de dimensionalidade fundamentada na teoria espectral dos grafos e em processos estocásticos. O método fornece uma estrutura poderosa para revelar a geometria intrínseca dos dados ao modelar a conectividade entre os pontos como um processo de difusão (random walk). Diferentemente de métodos como a Análise de Componentes Principais (PCA) ou o Escalonamento Multidimensional Clássico (cMDS), que se baseiam na estrutura euclidiana global dos dados, o Diffusion Maps captura a conectividade e a estrutura em múltiplas escalas da variedade (manifold), tornando-se particularmente eficaz para conjuntos de dados complexos, ruidosos e não lineares [15].

A Figura 6 ilustra como o Diffusion Maps utiliza um processo estocástico de difusão para revelar a geometria intrínseca de dados de alta dimensionalidade. Inicialmente, é construído um grafo de similaridade, sobre o qual são analisados passeios aleatórios (random walks), permitindo definir distâncias de difusão, que apresentam elevada robustez ao ruído e são sensíveis à conectividade global dos dados. A representação em baixa dimensionalidade (embedding), obtida a partir dos principais autovetores do operador de difusão, fornece uma descrição significativa de estruturas não lineares, tornando o Diffusion Maps particularmente adequado para conjuntos de dados complexos organizados em variedades (manifolds).

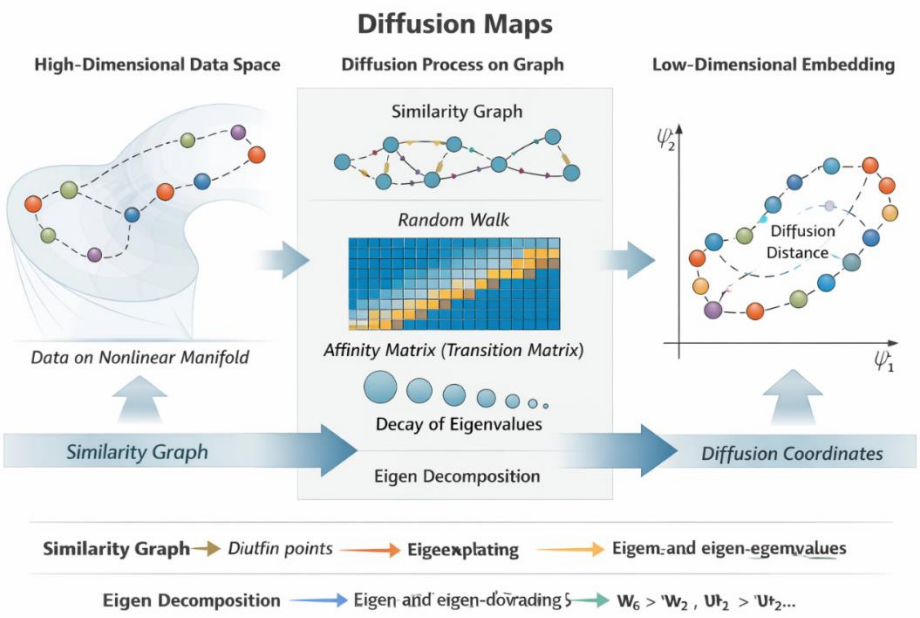


Figura 6 – Representação esquemática do algoritmo Diffusion Maps para redução não linear de dimensionalidade.

À esquerda, os pontos de dados encontram-se distribuídos sobre uma variedade não linear (manifold) em um espaço de alta dimensionalidade. Um grafo de similaridade é construído por meio de uma função kernel (tipicamente uma função gaussiana), que codifica as afinidades locais entre pontos vizinhos. No painel central, a matriz de similaridade é normalizada para formar uma matriz de transição de Markov (matriz de difusão), que modela um passeio aleatório (random walk) sobre os dados. O processo de difusão captura padrões de conectividade ao longo de múltiplas etapas, definindo distâncias de difusão que refletem simultaneamente as estruturas: local e global dos dados. A decomposição em autovalores e autovetores da matriz de transição fornece os autovalores e autovetores dominantes, cujos principais componentes definem as coordenadas de difusão. À direita, os dados são projetados em um espaço de baixa dimensionalidade, no qual as distâncias correspondem às distâncias de difusão, preservando a geometria intrínseca da variedade.

A Tabela 9 resume as principais características do Diffusion Maps, um método de redução não linear de dimensionalidade, fundamentado no aprendizado de variedades (manifold learning) e na análise espectral. Ao construir uma matriz de similaridade baseada em kernel e modelar um processo de difusão de Markov, o método define distâncias de difusão capazes de capturar de forma eficiente tanto as estruturas locais quanto as globais dos dados. Essa preservação simultânea torna o Diffusion Maps particularmente eficiente para representar variedades complexas, mantendo elevada robustez ao ruído. A representação em baixa dimensionalidade (embedding) é obtida a partir dos principais autovetores do operador de difusão, que codificam os modos dominantes de conectividade dos dados. Entretanto, o método apresenta interpretabilidade limitada, não dispõe de um mapeamento inverso explícito e pode ter um custo computacional elevado quando aplicado a grandes conjuntos de dados. De modo geral, o Diffusion Maps constitui uma abordagem flexível e teoricamente bem fundamentada para revelar a geometria intrínseca de dados de alta dimensionalidade.

Tabela 9 – Principais propriedades do Diffusion Maps

Propriedade	Descrição
Tipo de método	Técnica de redução não linear de dimensionalidade baseada em aprendizado de variedades (manifold learning)
Dados de entrada	Dados de alta dimensionalidade ou matriz de similaridades entre pares de amostras
Objetivo	Preservar as distâncias de difusão que representam a geometria intrínseca dos dados
Fundamentação matemática	Matriz de similaridade baseada em kernel + matriz de transição de Markov + decomposição em autovalores e autovetores
Linearidade	Não linear

Propriedade	Descrição
Saída	Coordenadas de difusão em baixa dimensionalidade (embedding)
Hipótese de métrica	Baseada em distâncias de difusão (conectividade), e não em distâncias euclidianas
Preservação da estrutura global	Elevada (captura conectividade de longo alcance por meio do processo de difusão)
Preservação da estrutura local	Elevada (por meio de similaridades locais baseadas em kernel)
Interpretabilidade	Moderada (os autovetores representam modos de difusão dos dados)
Invertibilidade	Limitada (não possui mapeamento inverso explícito)
Sensibilidade ao ruído	Baixa a moderada (robusto devido ao processo de difusão)
Complexidade computacional	Elevada (construção da matriz e decomposição em autovalores; tipicamente (O(n^3)))
Escalabilidade	Limitada para grandes conjuntos de dados (pode ser aprimorada por meio de aproximações)
Relação com métodos espectrais	Fortemente relacionado ao agrupamento espectral (Spectral Clustering) e aos Mapas de Autovetores do Laplaciano (Laplacian Eigenmaps)
Tratamento da não linearidade	Elevado (captura estruturas complexas de variedades)
Principais parâmetros	Largura de banda do kernel ((\varepsilon)) e número de etapas de difusão ((t))
Interpretação dos autovalores	O decaimento dos autovalores reflete a dimensionalidade intrínseca e a conectividade dos dados

1. Motivação Conceitual

Em muitos problemas do mundo real — como espectroscopia, dinâmica molecular e sistemas biológicos — os dados encontram-se distribuídos sobre uma variedade não

linear (manifold) imersa em um espaço de alta dimensionalidade. Em vez de se basear exclusivamente nas distâncias entre pares de pontos, o Diffusion Maps analisa como a informação se propaga ao longo do conjunto de dados por meio de similaridades locais. A ideia central do método é a seguinte:

Essa concepção conduz ao conceito de distância de difusão (diffusion distance), que representa de forma mais robusta a geometria intrínseca dos dados do que as distâncias euclidianas ou geodésicas.

2. Construção do Operador de Difusão

Dado um conjunto de dados $\{x_i\}_{i=1}^{n}$, o método inicia-se com a construção de uma matriz de similaridade (matriz kernel):

$$k(x_i, x_j) = exp\left(-\frac{\|x_i - x_j\|^2}{\varepsilon}\right) \quad (31)$$

Em que ε é um parâmetro de escala que controla o tamanho da vizinhança.

2.1 Normalização

Define-se a função grau (degree function):

$$\mathbf{d(x_i) = \sum_{j=1}^{n} k(x_i, x_j)} \quad (32)$$

A matriz kernel é então normalizada para construir uma matriz de transição de Markov:

$$\mathbf{p_{ij} = \frac{k(x_i, x_j)}{d(x_i)}} \quad (33)$$

Isso define um passeio aleatório (random walk) sobre o grafo dos dados.

3. Processo de Difusão

A matriz de transição P descreve um processo de Markov. Após t etapas, as probabilidades de difusão são dadas por:

$$\mathbf{P^t} \quad (34)$$

A distância de difusão entre os pontos x_i e x_j é definida como:

$$D_t^2(i,j) = \sum_{k=1}^{n} \frac{\left(p_{ik}^{(t)} - p_{jk}^{(t)}\right)^2}{\phi_0(k)} \quad (35)$$

em que ϕ_0 representa a distribuição estacionária do processo de Markov.

4. Decomposição Espectral e Representação em Baixa Dimensionalidade (Embedding)

A etapa fundamental do método consiste na decomposição em autovalores e autovetores da matriz de transição P:

$$\mathbf{P}\psi_l = \lambda_l \psi_l \quad (36)$$

A representação em baixa dimensionalidade (embedding) é definida por:

$$\psi_t(x_i) = \left(\lambda_1^t \psi_1(i), \lambda_2^t \psi_2(i), \cdots, \lambda_m^t \psi_m(i)\right) \quad (37)$$

Essa representação preserva as distâncias de difusão.

$$D_t(i,j)^2 \approx \sum_{l=1}^{m} \lambda_l^{2t} \left(\psi_l(i) - \psi_l(j)\right)^2 \quad (38)$$

5. Interpretação

O método Diffusion Maps pode ser interpretado como:

- Um método de representação espectral (spectral embedding);
- Uma ferramenta de análise em múltiplas escalas, controlada pelo parâmetro (t);
- Um método que captura a conectividade entre os dados, em vez de apenas as distâncias diretas.

Principais propriedades:

- Robusto ao ruído;
- Captura simultaneamente a estrutura local e global dos dados;
- Revela as coordenadas intrínsecas da variedade (manifold).

6. Vantagens

- Robustez ao ruído: a média sobre múltiplos caminhos reduz os efeitos do ruído;
- Representação em múltiplas escalas: o parâmetro (t) controla a resolução da análise;
- Capacidade para modelar relações não lineares: captura variedades complexas;
- Fundamentação teórica sólida: baseada nos operadores de Laplace–Beltrami.

7. Limitações e Desvantagens

Apesar de suas vantagens, o método Diffusion Maps apresenta diversas limitações.

7.1 Sensibilidade aos Parâmetros

- A escolha da largura de banda do kernel ε é crítica;
- Uma escolha inadequada pode produzir grafos desconectados ou excessivamente densos.

7.2 Custo Computacional

- Construção da matriz kernel: O(n2);
- Decomposição em autovalores e autovetores: O(n3).

7.3 Escalabilidade

- Não é adequado para conjuntos de dados muito grandes sem o emprego de aproximações;
- Requer técnicas como a aproximação de Nyström ou kernels esparsos.

7.4 Ausência de um Mapeamento Explícito

- Não fornece uma função de mapeamento direta para novos pontos de dados;
- Requer métodos de extensão para amostras fora da amostra (out-of-sample extensions).

7.5 Complexidade de Interpretação

- Os autovetores podem não ser facilmente interpretáveis;
- A representação em baixa dimensionalidade é menos intuitiva do que a obtida pelo PCA.

8. Comparação com Outros Métodos

A Tabela 10 destaca as características distintivas do método Diffusion Maps em comparação com outras técnicas de redução de dimensionalidade. Enquanto métodos clássicos, como PCA e Kernel PCA, concentram-se na preservação da variância (linear e não linear, respectivamente), e métodos como MDS e Isomap enfatizam a preservação das distâncias (euclidianas e geodésicas), o Diffusion Maps distingue-se por capturar a conectividade intrínseca dos dados por meio das distâncias de difusão. Ao modelar o conjunto de dados como um passeio aleatório de Markov, essa abordagem revela de forma eficaz a estrutura subjacente da variedade (manifold), tornando-se particularmente robusta ao ruído e especialmente adequada para conjuntos de dados complexos e não lineares, nos quais a conectividade fornece informações mais relevantes do que as distâncias diretas.

Tabela 10 – Comparação do método Diffusion Maps com métodos relacionados

Método	Estrutura preservada	Ideia principal
PCA	Variância global	Projeção linear
Kernel PCA	Variância não linear	Truque do kernel
MDS	Distâncias entre pares de pontos	Preservação das distâncias

Método	Estrutura preservada	Ideia principal
Isomap	Distâncias geodésicas	Desdobramento da variedade (manifold)
Diffusion Maps	Conectividade (distância de difusão)	Passeios aleatórios (random walks)

O método Diffusion Maps difere do Isomap por evitar a instabilidade associada aos caminhos mínimos (shortest paths), baseando-se, em vez disso, na conectividade probabilística entre os dados.

9. Aplicações

9.1 Quimiometria e Espectroscopia

- Análise de dados Raman, NIR e IR;
- Extração de características químicas não lineares;
- Redução de dimensionalidade robusta ao ruído.

9.2 Dinâmica Molecular

- Identificação de variáveis coletivas lentas;
- Análise de paisagens conformacionais.

9.3 Bioinformática

- Análise de expressão gênica;
- Estudo de trajetórias de diferenciação celular.

9.4 Processamento de Imagens

- Análise de formas;
- Extração de características não lineares.

9.5 Ciência dos Materiais

- Exploração das relações entre estrutura e propriedades;
- Redução de dimensionalidade de descritores.

10. Considerações Finais

O método Diffusion Maps representa um avanço significativo na redução não linear de dimensionalidade ao introduzir uma perspectiva probabilística para a geometria dos dados. Ao explorar processos de difusão, o método fornece uma estrutura robusta e flexível para revelar as estruturas intrínsecas presentes em conjuntos de dados complexos. No contexto moderno do aprendizado de máquina e da quimiometria, o Diffusion Maps mostra-se particularmente valioso para dados ruidosos, não lineares e de alta dimensionalidade, complementando métodos como Isomap e Kernel PCA. Sua natureza multiescala e sua sólida fundamentação teórica fazem dele uma técnica de referência no campo do aprendizado de variedades (manifold learning) [15].

2.2.1.1.7 Redução de Dimensionalidade via Regressão

A Redução de Dimensionalidade via Regressão (Dimensionality Reduction via Regression – DRR) é uma abordagem de redução não linear de dimensionalidade que estende a Análise de Componentes Principais (PCA) por meio da modelagem e da remoção de dependências não lineares entre os componentes principais, utilizando técnicas de regressão. Diferentemente de métodos de aprendizado de variedades (manifold learning), como Isomap e Diffusion Maps, que se baseiam em representações construídas a partir de grafos, o DRR permanece fundamentado em uma transformação coordenada, preservando a interpretabilidade enquanto captura a estrutura não linear dos dados.

O DRR é particularmente relevante em quimiometria, espectroscopia e na análise de dados de alta dimensionalidade, nas quais as variáveis frequentemente apresentam dependências não lineares estruturadas que métodos lineares podem não capturar adequadamente [16–17].

A Figura 7 ilustra o princípio fundamental da Redução de Dimensionalidade via Regressão, na qual dados de alta dimensionalidade são modelados progressivamente por uma sequência de funções de regressão para extrair variáveis latentes. Diferentemente de métodos puramente geométricos, o DRR explora relações preditivas entre variáveis para construir uma representação de baixa dimensionalidade (embedding). Ao combinar modelagem por regressão com interpolação no espaço dos dados, o método é capaz de capturar dependências não lineares, preservando informações estruturais relevantes. Essas características tornam o DRR uma abordagem flexível e poderosa para a redução de dimensionalidade, especialmente em cenários em que as relações funcionais entre as variáveis desempenham um papel central.

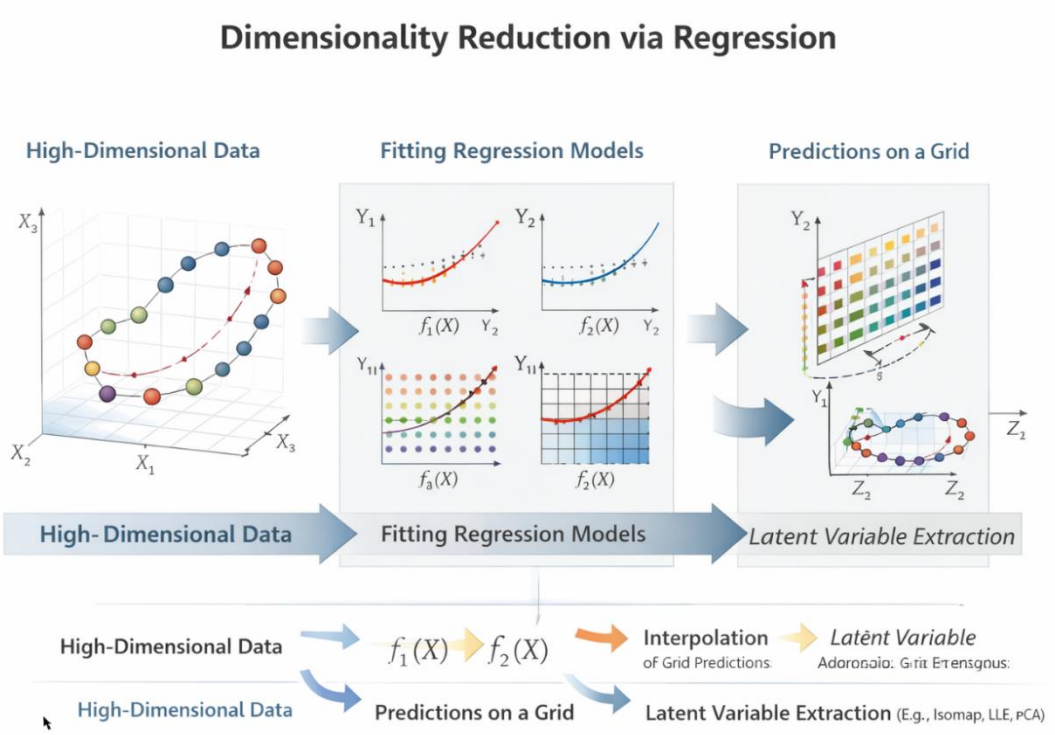


Figura 7 – Ilustração esquemática da Redução de Dimensionalidade via Regressão (Dimensionality Reduction via Regression – DRR).

À esquerda, os dados de alta dimensionalidade são representados no espaço original de atributos, no qual podem existir relações não lineares entre as variáveis. No painel central, uma sequência de modelos de regressão f(X1), f(X2), ... é ajustada para capturar as dependências entre variáveis ou componentes, geralmente de forma sequencial ou hierárquica. Esses modelos aproximam a estrutura dos dados ao aprender relações funcionais que descrevem a variância não explicada pelos componentes anteriores. Em seguida, as predições são avaliadas sobre uma malha no espaço de atributos, permitindo a interpolação da estrutura aprendida. À direita, as variáveis latentes Z1, Z2 são extraídas a partir das saídas dos modelos de regressão, formando uma representação de baixa dimensionalidade que preserva a estrutura intrínseca dos dados. Essa abordagem combina modelagem por regressão e por projeção, possibilitando o tratamento flexível de relações não lineares.

A Tabela 11 resume as principais características da Redução de Dimensionalidade via Regressão (DRR), uma abordagem flexível, orientada por modelos, de redução de dimensionalidade. Diferentemente dos métodos tradicionais baseados em distâncias ou variância, o DRR captura a estrutura intrínseca dos dados ao modelar as dependências funcionais entre as variáveis por meio de regressões sequenciais. Isso permite que o método trate de forma eficaz relações não lineares, ao mesmo tempo em que oferece um arcabouço potencialmente interpretável, dependendo do modelo de regressão escolhido. A abordagem pode ser vista como uma generalização da PCA, substituindo projeções lineares por funções de regressão e extraindo, iterativamente, componentes a partir da informação residual. Entretanto, seu desempenho depende fortemente da seleção do modelo, do ajuste de hiperparâmetros e da qualidade dos dados, fatores que podem influenciar tanto a robustez quanto o custo computacional. De modo geral, o DRR constitui uma alternativa poderosa para aplicações em que a modelagem de relações complexas entre variáveis é mais importante do que a preservação das distâncias geométricas.

Tabela 11 – Principais Propriedades da Redução de Dimensionalidade via Regressão (Dimensionality Reduction via Regression – DRR)

Propriedades	Descrição
Tipo de método	Técnica não linear de redução de dimensionalidade baseada em regressão
Dados de entrada	Matriz de dados de alta dimensionalidade
Objetivo	Capturar a estrutura intrínseca dos dados por meio da modelagem das dependências entre as variáveis via regressão

Propriedades	Descrição
Fundamentação matemática	Modelagem sequencial por regressão (por exemplo, (f_1(X), f_2(X), \ldots)) combinada com a extração de variáveis latentes
Linearidade	Não linear (dependendo do modelo de regressão utilizado)
Saída	Variáveis latentes de baixa dimensionalidade (embedding)
Hipótese métrica	Não pressupõe preservação explícita de distâncias; baseia-se em relações funcionais
Preservação da estrutura global	Moderada (depende da qualidade do modelo de regressão)
Preservação da estrutura local	Moderada a forte (captura dependências locais por meio da regressão)
Interpretabilidade	Moderada a alta (as funções de regressão podem ser interpretadas)
Invertibilidade	Possível (inversa aproximada por meio dos modelos de regressão)
Sensibilidade ao ruído	Moderada (depende da robustez dos modelos de regressão)
Complexidade computacional	Moderada a alta (depende do método de regressão e do número de componentes)
Escalabilidade	Moderada (pode ser escalável com algoritmos de regressão eficientes)
Relação com a PCA	Generaliza a PCA ao substituir projeções lineares por funções de regressão
Tratamento da não linearidade	Forte (flexibilidade proporcionada por modelos de regressão não lineares)
Parâmetro principal	Escolha do modelo de regressão (linear, kernel, redes neurais, etc.)
Dependência do modelo	Forte (o desempenho depende da seleção e do ajuste do modelo de regressão)

Propriedades	Descrição
Natureza sequencial	Os componentes são extraídos iterativamente, modelando a variância residual

1. Motivação Conceitual

A PCA clássica transforma os dados em componentes ortogonais:

$$\mathbf{z} = \mathbf{W}^{\mathbf{T}}\mathbf{x} \tag{39}$$

em que $\mathbf{z} = (z_1, z_2, \cdots, z_d)$ são os componentes principais não correlacionados. Entretanto, não correlacionados não implica independentes. Em muitos conjuntos de dados reais, os componentes de ordem superior exibem dependências não lineares em relação aos de ordem inferior.

O DRR aborda essa limitação ao:

- modelar, de forma sequencial, cada componente principal como uma função não linear dos componentes anteriores e remover essa dependência.

Como resultado, obtém-se uma representação em que tanto as redundâncias lineares quanto as não lineares são reduzidas.

2. Formulação Matemática

Seja $\mathbf{z} = (z_1, z_2, \cdots, z_d)$ o conjunto de dados transformado pela PCA. O DRR modela cada componente zk da seguinte forma:

$$z_k = f_k(z_1, z_2, \cdots, z_{k-1}) + \varepsilon \tag{40}$$

em que:

- $f_k(\cdot)$ é uma função de regressão não linear;
- ε é o resíduo (termo de inovação).

A representação transformada pelo DRR é:

$$\tilde{z}_k = z_k - \hat{f}_k(z_1, \cdots, z_{k-1}) \tag{41}$$

Para k = 2, ..., d, com $\tilde{z}_1 = z_1$.

Assim, o DRR produz uma nova representação:

$$\tilde{\mathbf{z}} = (\tilde{z}_1, \tilde{z}_2, \cdots, \tilde{z}_d) \quad (42)$$

Em que os componentes não são apenas descorrelacionados, mas também aproximadamente independentes.

3. Modelos de Regressão

As funções fk podem ser modeladas por diferentes técnicas de regressão, tais como:

- Regressão por kernel;
- Regressão por Processos Gaussianos (Gaussian Process Regression);
- Redes neurais;
- Regressão polinomial;
- Regressão por Vetores de Suporte (Support Vector Regression – SVR).

A escolha do modelo de regressão determina o grau de flexibilidade e a complexidade da transformação realizada pelo DRR.

4. Invertibilidade e Reconstrução

Uma das principais vantagens do DRR é fornecer uma transformação invertível (sob condições relativamente gerais), diferentemente de muitos métodos de aprendizado de variedades (manifold learning).

A reconstrução é realizada de forma sequencial:

$$z_k = \tilde{z}_k + \hat{f}_k(z_1, \cdots, z_{k-1}) \quad (43)$$

Em seguida, os dados originais podem ser reconstruídos utilizando a transformação inversa da PCA:

$$\mathbf{x} \approx \mathbf{W}\mathbf{z} \quad (44)$$

Essa propriedade torna o DRR particularmente útil em aplicações que exigem:

- Compressão de dados;
- Reconstrução de sinais;
- Modelagem generativa.

5. Interpretação

O DRR pode ser interpretado como:

- Uma extensão não linear da PCA;
- Um modelo hierárquico de regressão no espaço latente;
- Um método para remover redundâncias não lineares.

Diferentemente da Kernel PCA, que projeta os dados em um espaço implícito de características, o DRR opera em um sistema explícito de coordenadas, proporcionando maior interpretabilidade.

6. Vantagens

- Captura dependências não lineares entre os componentes;
- Possui transformação invertível, permitindo a reconstrução dos dados;
- Apresenta maior eficiência de compressão em comparação com a PCA;
- Mantém uma representação explícita, favorecendo a interpretabilidade;
- Oferece elevada flexibilidade por meio da escolha do modelo de regressão.

7. Limitações e Desvantagens

Apesar de suas vantagens, o DRR apresenta algumas limitações importantes.

7.1 Dependência do Modelo

- O desempenho depende fortemente do modelo de regressão utilizado;

- Existe risco de subajuste (underfitting) ou sobreajuste (overfitting).

7.2 Custo Computacional

- Requer o ajuste de múltiplos modelos de regressão;
- A complexidade computacional aumenta com a dimensionalidade dos dados.

7.3 Propagação de Erros

- Erros nos componentes iniciais afetam as regressões subsequentes;
- A natureza sequencial do método pode amplificar imprecisões.

7.4 Ausência de Garantias sobre a Estrutura Global da Variedade

- Não preserva explicitamente distâncias ou relações topológicas;
- Diferentemente do Isomap e dos Diffusion Maps, não modela diretamente a geometria dos dados.

7.5 Sensibilidade aos Hiperparâmetros

- Requer o ajuste cuidadoso dos hiperparâmetros do modelo de regressão;
- A seleção do modelo mais adequado pode ser desafiadora.

8. Comparação com Outros Métodos

A Tabela 12 apresenta uma visão comparativa das principais técnicas de redução de dimensionalidade (DR), destacando as diferenças fundamentais quanto ao tipo de método, à capacidade de modelar não linearidades, às características do mapeamento e à possibilidade de reconstrução dos dados. A PCA destaca-se como um método linear com mapeamento explícito e reconstrução direta, o que a torna altamente interpretável e computacionalmente eficiente. Em contraste, métodos não lineares, como Kernel PCA, Isomap e Diffusion Maps, oferecem maior capacidade de capturar estruturas complexas dos dados, porém dependem de mapeamentos implícitos e, em geral, não permitem reconstrução direta. A Redução de Dimensionalidade via Regressão (DRR) combina as

vantagens da modelagem não linear com um mapeamento explícito, proporcionando flexibilidade para representar relações não lineares e, ao mesmo tempo, possibilitando a reconstrução dos dados. De modo geral, a tabela evidencia os compromissos (trade-offs) entre interpretabilidade, flexibilidade e capacidade de reconstrução, auxiliando na seleção da técnica mais adequada conforme o objetivo analítico.

Tabela 12 – Comparação das Técnicas de Redução de Dimensionalidade (DR)

Método	Tipo	Não linearidade	Mapeamento	Reconstrução
PCA	Linear	Não	Explícito	Sim
Kernel PCA	Não linear	Sim	Implícito	Difícil
Isomap	Não linear	Sim	Implícito	Não
Diffusion Maps	Não linear	Sim	Implícito	Não
DRR	Não linear	Sim	Explícito	Sim

Portanto, o DRR combina de forma única:

- Modelagem não linear;
- Mapeamento explícito;
- Capacidade de reconstrução.

9. Aplicações

9.1 Quimiometria e Espectroscopia

- Compressão de dados espectrais (Raman, NIR e IR);
- Remoção de redundâncias não lineares;
- Pré-processamento para modelos de classificação.

9.2 Processamento de Imagens

- Extração não linear de características;
- Compressão e reconstrução de imagens.

9.3 Processamento de Sinais

- Redução de ruído;
- Representação eficiente de sinais.

9.4 Pipelines de Aprendizado de Máquina

- Engenharia de atributos (feature engineering);
- Pré-processamento para modelos de regressão e classificação.

9.5 Ciência dos Materiais

- Redução de dimensionalidade de espaços de descritores;
- Modelagem da relação estrutura–propriedade.

10. Considerações Finais

A Redução de Dimensionalidade via Regressão (Dimensionality Reduction via Regression – DRR) representa uma extensão poderosa e conceitualmente elegante da Análise de Componentes Principais (PCA), estabelecendo uma ponte entre os métodos lineares e as técnicas totalmente não lineares de aprendizado de variedades (manifold learning). Ao modelar explicitamente as dependências não lineares entre os componentes principais, o DRR melhora a compressão e a representação dos dados, preservando simultaneamente a interpretabilidade e a invertibilidade da transformação.

Em aplicações modernas — particularmente em quimiometria e espectroscopia — o DRR constitui uma alternativa valiosa aos métodos baseados em kernels e em grafos, especialmente quando a reconstrução dos dados e a transparência do modelo são requisitos essenciais.

2.2.1.1.8 Análise de Componentes Independentes

A Análise de Componentes Independentes (Independent Component Analysis – ICA) é uma técnica estatística e computacional de redução de dimensionalidade e separação cega de fontes (blind source separation) que tem como objetivo representar dados multivariados como uma combinação linear de componentes estatisticamente independentes. Diferentemente da Análise de Componentes Principais (PCA), que busca direções não correlacionadas que maximizam a variância, a ICA vai além ao identificar componentes maximamente independentes, explorando, em geral, estruturas estatísticas de ordem superior.

A ICA tornou-se uma ferramenta fundamental em aprendizado de máquina, processamento de sinais e quimiometria, sendo particularmente útil em aplicações em que os dados observados resultam da mistura de fontes latentes [18–20].

A Figura 8 ilustra o princípio fundamental da Análise de Componentes Independentes (Independent Component Analysis – ICA), na qual os dados observados são modelados como misturas lineares de fontes estatisticamente independentes. Por meio da estimação de uma transformação de separação (unmixing transformation), a ICA decompõe os sinais misturados em componentes independentes, revelando estruturas latentes que não podem ser identificadas por métodos baseados apenas na variância, como a PCA. Essa característica torna a ICA particularmente eficaz em aplicações que envolvem separação de sinais, extração de características e análise de conjuntos de dados complexos, nas quais a independência estatística, e não a variância, constitui o principal critério de análise.

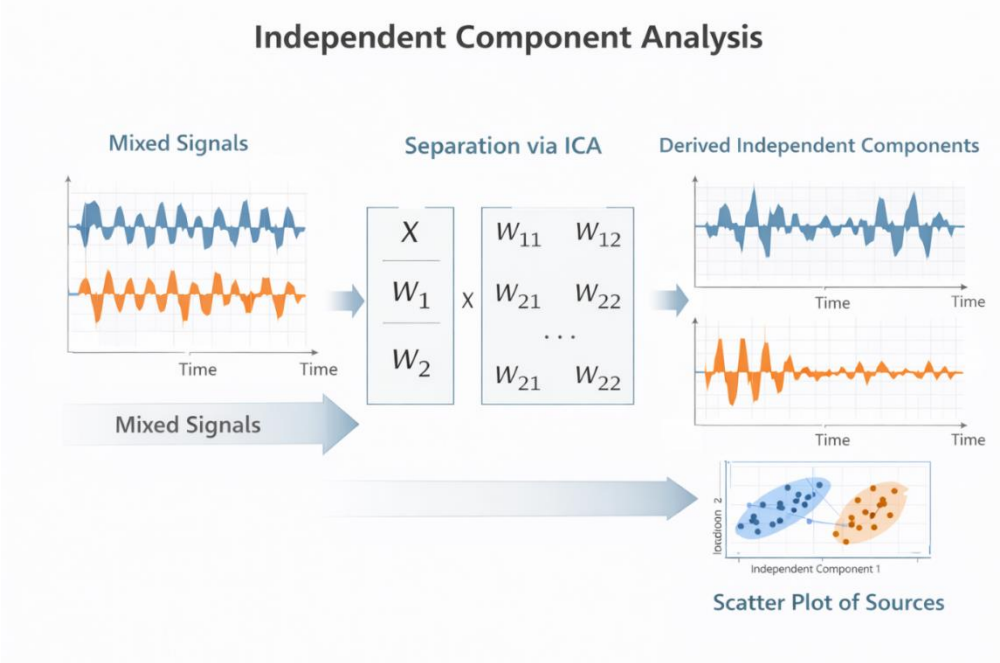


Figura 8 – Representação esquemática da Análise de Componentes Independentes (Independent Component Analysis – ICA) para separação cega de fontes (blind source separation) e redução de dimensionalidade.

À esquerda, os sinais observados (sinais misturados) são apresentados como combinações de fontes subjacentes independentes, normalmente representadas por séries temporais. No painel central, a ICA estima uma matriz de separação W, que transforma a matriz de dados observados X em componentes estatisticamente independentes, de modo que S = WX. Essa transformação é obtida pela maximização da independência estatística, geralmente por meio de medidas de não gaussianidade. À direita, os componentes independentes recuperados são apresentados como sinais separados, acompanhados de um gráfico de dispersão que ilustra sua independência estatística. Os componentes resultantes representam fontes latentes assumidas como não gaussianas e mutuamente independentes.

1. Motivação Conceitual

Em muitos cenários do mundo real, os sinais observados são misturas de fontes subjacentes independentes. Um exemplo clássico é o problema da festa do coquetel (cocktail party problem), no qual múltiplos sinais de áudio são gravados simultaneamente e precisam ser separados.

Seja $\mathbf{x}$ ε $\mathbb{R}^{\mathrm{d}}$ o vetor de dados observados. A ICA assume que:

$$\mathbf{x} = \mathbf{As} \tag{45}$$

em que:

- $s = (s_1, s_2, \cdots, s_d)$ representa os componentes independentes latentes;
- A é uma matriz de mistura desconhecida.

O objetivo da ICA é estimar tanto a matriz A quanto os componentes s a partir apenas das observações x.

2. Formulação Matemática

A ICA busca determinar uma matriz de separação (unmixing matrix) W tal que:

$$\mathbf{s} = \mathbf{Wx} \tag{46}$$

Em que os componentes si sejam o mais estatisticamente independentes possível.

3. Independência e Não-Gaussianidade

Um dos princípios fundamentais da ICA é que a independência estatística pode ser alcançada por meio da maximização da não-gaussianidade, com base no Teorema Central do Limite: a soma de variáveis independentes tende a apresentar uma distribuição mais próxima da Gaussiana do que as variáveis originais. Assim, a ICA identifica direções nas quais os dados projetados são maximamente não gaussianos.

4. Medidas de Não-Gaussianidade

Diversos critérios podem ser utilizados para quantificar a não gaussianidade.

4.1 Curtose (Kurtosis)

$$\mathrm{kurt}(y) = \mathbb{E}[y^4] - 3(\mathbb{E}[y^2])^2 \tag{47}$$

- Igual a zero para distribuições gaussianas;
- Positiva ou negativa para sinais não gaussianos.

4.2 Negentropia

$$J(y) = H(y_{gauss}) - H(y) \tag{48}$$

em que $H(\cdot)$ representa a entropia. A negentropia é sempre não negativa e assume o valor zero apenas para variáveis gaussianas.

4.3 Funções de Contraste

Na prática, aproximações da negentropia são frequentemente utilizadas:

$$J(y) \approx (\mathbb{E}[G(y)] - \mathbb{E}[G(v)])^2 \tag{49}$$

Em que v é uma variável gaussiana e $G(G(\cdot))$ é uma função não linear.

5. Etapas de Pré-processamento

Antes da aplicação da ICA, os dados são normalmente submetidos às seguintes etapas de pré-processamento:

5.1 Centralização (Centering)

$$\mathbf{x} \leftarrow \mathbf{x} - \mathbb{E}[\mathbf{x}] \tag{50}$$

5.2 Branqueamento (Whitening)

$$\mathbf{x_{white}} = \mathbf{D^{-1/2}E^{T}x} \tag{51}$$

onde E e D são obtidas a partir da decomposição em autovalores da matriz de covariância.

O branqueamento garante: $\mathbb{E}[\mathbf{x_{white}x_{white}}] = \mathbf{I}$

6. Algoritmos para ICA

Diversos algoritmos foram desenvolvidos para resolver o problema da ICA:

6.1 FastICA

- Iteração por ponto fixo;
- Maximiza eficientemente a não-gaussianidade.

6.2 Infomax ICA

- Maximiza a informação mútua;
- Baseia-se no aprendizado por meio de redes neurais.

6.3 JADE (Diagonalização Aproximada Conjunta)

- Utiliza cumulantes de ordem superior.

7. Interpretação

A ICA fornece:

- Componentes estatisticamente independentes, e não apenas descorrelacionadas;
- Uma representação alinhada às fontes latentes;
- Uma decomposição baseada em estatísticas de ordem superior.

Em comparação com a PCA:

- A PCA captura a variância;
- A ICA captura a independência estatística.

8. Vantagens

- Eficaz para separação cega de fontes (Blind Source Separation);
- Captura estruturas não gaussianas;
- Fornece variáveis latentes interpretáveis;
- Útil para decomposição de sinais.

9. Limitações e Desvantagens

9.1 Hipótese de Independência

- Assume que as fontes reais são independentes;
- Violações dessa hipótese reduzem o desempenho.

9.2 Requisito de Não-Gaussianidade

- No máximo um componente pode apresentar distribuição gaussiana;
- Caso contrário, a separação torna-se indetectável.

9.3 Sensibilidade ao Ruído

- O desempenho diminui na presença de ruído intenso;
- O ruído pode violar as hipóteses de independência.

9.4 Ambiguidade de Escala e Permutação

- A ordem e a escala dos componentes não podem ser identificadas unicamente.

9.5 Complexidade Computacional

- Algoritmos iterativos podem apresentar elevado custo computacional.

9.6 Hipótese de Mistura Linear

- Assume que as misturas são lineares;
- Não é capaz de tratar diretamente misturas não lineares.

10. Comparação com Outros Métodos

A

Tabela 13 compara os principais métodos de redução de dimensionalidade com base em seus objetivos, propriedades fundamentais e características de mapeamento. A PCA e a L1-PCA concentram-se em representações baseadas na variância, sendo que a L1-PCA oferece maior robustez à presença de valores discrepantes (outliers). A Kernel

PCA amplia esse conceito para estruturas não lineares por meio de mapeamentos implícitos em espaços de características de alta dimensionalidade.

Tabela 13 – Comparação dos Métodos de Redução de Dimensionalidade

Método	Objetivo	Propriedade Principal	Mapeamento
PCA	Maximização da variância	Componentes descorrelacionadas	Linear
L1-PCA	Maximização robusta da variância	Resistência a valores discrepantes (outliers)	Linear
Kernel PCA	Maximização da variância não linear	Mapeamento implícito	Não linear
ICA	Independência estatística	Estatísticas de ordem superior	Linear
DRR	Descorrelação não linear	Baseado em regressão	Não linear

Portanto, a ICA é única por se concentrar na independência estatística, em vez de geometria ou de variância.

11. Aplicações

11.1 Processamento de Sinais

- Separação de fontes de áudio;
- Análise de sinais de EEG/MEG;
- Remoção de ruído.

11.2 Quimiometria

- Decomposição de misturas espectrais;
- Resolução de sinais sobrepostos;

- Extração de características em espectroscopia.

11.3 Processamento de Imagens

- Extração de características;
- Separação cega de imagens.

11.4 Finanças

- Identificação de fatores latentes em séries temporais.

11.5 Aprendizado de Máquina

- Etapa de pré-processamento para classificação;
- Engenharia de atributos (feature engineering).

12. Considerações Finais

A Análise de Componentes Independentes (ICA) constitui um paradigma fundamental de redução de dimensionalidade que enfatiza a independência estatística, em vez da preservação da variância ou das distâncias entre as observações. Sua capacidade de separar fontes latentes torna essa técnica particularmente valiosa em aplicações de processamento de sinais e quimiometria [18–20].

2.2.1.2 Técnicas Baseadas em Matrizes Esparsas

2.2.1.2.1 Hessian Locally Linear Embedding

O Hessian Locally Linear Embedding (Hessian LLE, ou HLLE) é uma técnica não linear de redução de dimensionalidade (RD) proposta por Donoho e Grimes (2003) como extensão do método clássico Locally Linear Embedding (LLE). O método foi desenvolvido para recuperar a estrutura de variedades (manifolds) de baixa dimensionalidade por meio da incorporação explícita da geometria local de segunda

ordem, por meio da estimação do operador hessiano. Diferentemente do LLE convencional, que preserva relações locais de primeira ordem entre vizinhos, o HLLE busca capturar com maior precisão a curvatura intrínseca da variedade [21–23].

A Figura 9 ilustra o fluxo de trabalho do HLLE, destacando sua principal diferença em relação aos métodos de primeira ordem: a incorporação da curvatura por meio da estimativa local da matriz Hessiana. Ao modelar cada vizinhança por uma aproximação quadrática, o HLLE captura a estrutura geométrica de segunda ordem, permitindo uma representação mais fiel de variedades suavemente curvas do que a obtida por técnicas lineares ou por métodos não lineares de primeira ordem.

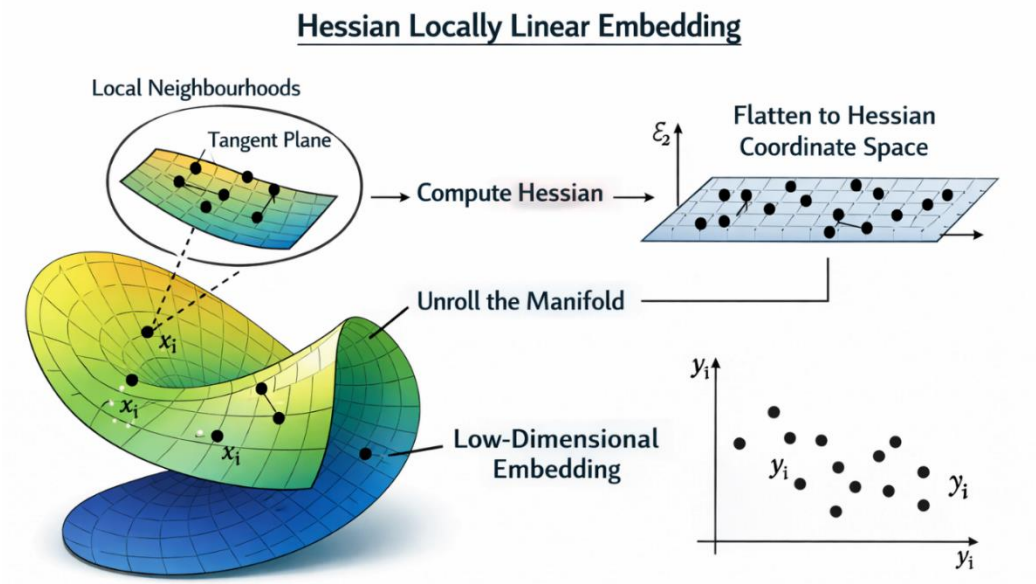


Figura 9 – Representação esquemática do algoritmo Hessian Locally Linear Embedding (HLLE).

Partindo de uma variedade não linear de alta dimensionalidade (na parte inferior esquerda), identificam-se as vizinhanças locais em torno de cada ponto de dados xi. Em cada vizinhança, estima-se um espaço tangente local para aproximar a geometria da

variedade. Em seguida, calcula-se o operador hessiano para captar informações de segunda ordem (curvatura) da variedade. Essas estimativas locais são reunidas em um problema global de otimização, cuja solução produz um embedding de baixa dimensionalidade, yi, que preserva a curvatura intrínseca dos dados. A representação final (na parte inferior direita) corresponde a uma versão "desenrolada" da variedade original, preservando sua estrutura não linear em um espaço de menor dimensionalidade.

A Tabela 14 resume as principais características do Hessian Locally Linear Embedding (HLLE), um método não linear de aprendizado de variedades que estende abordagens lineares locais ao incorporar informações geométricas de segunda ordem. O método baseia-se na análise de vizinhanças locais para estimar espaços tangentes e utiliza o operador hessiano para capturar a curvatura, proporcionando uma representação mais fiel da estrutura intrínseca da variedade. Embora o HLLE ofereça um melhor desenrolamento de dados não lineares quando comparado a métodos de primeira ordem, como o LLE, ele exige a resolução de um problema de autovalores e a escolha criteriosa do tamanho da vizinhança. Além disso, apresenta elevado custo computacional, sensibilidade ao ruído e não possui capacidade de reconstrução direta, o que pode limitar sua escalabilidade para grandes conjuntos de dados.

Tabela 14 – Principais Propriedades do Hessian Locally Linear Embedding (HLLE)

Propriedade	Descrição
Tipo de método	Redução de dimensionalidade não linear
Base teórica	Aprendizado de variedades utilizando geometria de segunda ordem (Hessiana)
Aproximação local	Estimativa do espaço tangente local por meio da análise da vizinhança

Propriedade	Descrição
Ordem da aproximação	Segunda ordem (captura a curvatura da variedade)
Geometria preservada	Curvatura local e estrutura intrínseca da variedade
Requisito de vizinhança	k-vizinhos mais próximos (k-Nearest Neighbors, k-NN)
Tipo de mapeamento	Implícito (não possui função de transformação explícita)
Capacidade de reconstrução	Não realiza reconstrução direta dos dados
Problema de otimização	Problema de autovalores baseado na minimização do funcional Hessiano
Sensibilidade ao ruído	Alta (devido à estimação de derivadas de segunda ordem)
Custo computacional	Moderado a elevado (dependente do tamanho da vizinhança e da dimensionalidade dos dados)
Escalabilidade	Limitada para conjuntos de dados muito grandes
Restrição de dimensionalidade	Requer número suficiente de vizinhos (k maior que a dimensionalidade intrínseca)
Vantagens	Captura a curvatura não linear da variedade; proporciona um desdobramento (unfolding) da variedade mais exato do que o LLE.

1. Fundamentos Teóricos

Considere um conjunto de dados $\{x_i \, \varepsilon \, \mathbb{R}^d\}_{i=1}^n$ assumido como pertencente ou próximo de uma variedade suave de dimensionalidade intrínseca d, com $d \ll D$. O objetivo é encontrar representações de baixa dimensionalidade $\{y_i \, \varepsilon \, \mathbb{R}^d\}$ que preservem a geometria local da variedade.

O HLLE baseia-se na hipótese de que, localmente, a variedade pode ser aproximada por uma função quadrática. Assim, em vez de preservar os pesos de reconstrução linear (como no LLE), o HLLE estima o funcional hessiano das coordenadas do espaço de representação (embedding).

2. Estimativa do Espaço Tangente Local

Para cada ponto x_i, define-se uma vizinhança N(i) contendo k vizinhos. Em seguida, o espaço tangente local é estimado por meio da Análise de Componentes Principais (PCA):

$$\mathbf{X_i} = \left[\mathbf{x_{i_1}} - \mathbf{x_i}, \cdots, \mathbf{x_{i_k}} - \mathbf{x_i}\right] \tag{52}$$

Realize a decomposição em valores singulares (SVD):

$$\mathbf{X_i} = \mathbf{U_i \Sigma_i V_i^T} \tag{53}$$

As primeiras d colunas de $\mathbf{U_i}$ definem as coordenadas do espaço tangente local:

$$\mathbf{Z_i} = \mathbf{U_i^{(d)} \Sigma_i^{(d)}} \tag{54}$$

3. Estimação da Hessiana

A principal inovação do HLLE consiste em estimar o operador Hessiano $\mathcal{H}$ da variedade. Localmente, assume-se que as coordenadas do espaço de representação (embedding) (y) satisfazem:

$$\mathcal{H}(f) = \sum_{p,q} \frac{\delta^2 f}{\delta z_p \delta z_q} \tag{55}$$

O HLLE constrói um conjunto de funções de base sobre as coordenadas locais Zi, incluindo, tipicamente, termos quadráticos:

$$\phi(z) = [z_1, \cdots, z_d, z_1^2, z_1 z_2, \cdots, z_d^2] \tag{56}$$

A estimativa da Hessiana é obtida ao ajustar essas funções quadráticas locais e ao extrair os coeficientes de segunda ordem. Esse procedimento conduz à construção de uma

matriz Hessiana local Hi, cujo espaço nulo (null space) codifica as direções de curvatura mínima.

4. Representação Global (Global Embedding)

A representação global (embedding) é obtida reunindo todas as estimativas hessianas locais em uma matriz esparsa (H) e resolvendo:

$$min_Y \sum_i \|\mathbf{H_i Y}\|^2 \quad (57)$$

Isso se reduz à resolução de um problema de autovalores:

$$\mathbf{H^T H Y = \lambda Y} \quad (58)$$

A representação (embedding) é dada pelos autovetores associados aos menores autovalores não nulos, excluindo-se as soluções triviais.

5. Resumo do Algoritmo

1. Identificar os k-vizinhos mais próximos de cada ponto.
2. Estimar as coordenadas do espaço tangente local por meio da PCA.
3. Construir os estimadores Hessianos locais.
4. Montar uma matriz global esparsa.
5. Resolver o problema de autovalores para obter a representação (embedding).

6. Principais Propriedades

- Método não linear: captura variedades curvas.
- Precisão de segunda ordem: incorpora a curvatura por meio da Hessiana.
- Mapeamento implícito: não possui função explícita de transformação.
- Consistência global: derivada de restrições Hessianas locais.

7. Vantagens

- Melhor representação de variedades curvas em comparação com o LLE.
- Maior fidelidade na preservação da estrutura geométrica, especialmente para variedades com variação suave.
- Fundamentação teórica sólida baseada na geometria diferencial.
- Melhor capacidade de lidar com não linearidades do que métodos baseados em aproximações de primeira ordem.

8. Desvantagens e Limitações

Apesar de sua elegância teórica, o HLLE apresenta diversos desafios práticos.

8.1 Sensibilidade ao Ruído

A estimação de derivadas de segunda ordem torna o HLLE altamente sensível ao ruído. Pequenas perturbações nos dados podem distorcer significativamente a estimativa da Hessiana.

8.2 Dependência do Tamanho da Vizinhança

A escolha de k é crítica:

- k pequeno: estimação hessiana instável.
- k grande: violação da hipótese de linearidade local.

8.3 Complexidade Computacional

O HLLE requer:

- execução da PCA para cada vizinhança;
- construção de grandes matrizes esparsas;
- decomposição em autovalores de matrizes n x n.

Essas etapas resultam em problemas de escalabilidade em conjuntos de dados de grande porte.

8.4 Baixo Desempenho em Variedades Não Suaves

O HLLE pressupõe que a variedade seja suave. Seu desempenho é reduzido quando:

- a variedade apresenta descontinuidades;
- os dados pertencem a variedades que se intersectam;
- Existem arestas ou cantos acentuados.

8.5 Ausência de Mapeamento Explícito (Problema Out-of-Sample)

Assim como o LLE, o HLLE não possui um mapeamento paramétrico:

- não permite projetar facilmente novos pontos de dados;
- requer extensões, como a aproximação de Nyström, para tratar novos exemplos.

9. Aplicações

O HLLE tem sido aplicado em diversas áreas nas quais a estrutura da variedade é suave e não linear, incluindo:

- Processamento de imagens: reconhecimento facial e estimativa de pose.
- Visão computacional: rastreamento de objetos e análise de movimento.
- Bioinformática: visualização de dados de expressão gênica.
- Espectroscopia e quimiometria: modelagem de estruturas não lineares em conjuntos de dados espectrais.
- Processamento de sinais: extração de características de sinais não lineares.

No contexto da quimiometria, especialmente em aplicações envolvendo espectroscopia vibracional, o HLLE pode ser particularmente útil para capturar relações não lineares em conjuntos de dados Raman ou NIR, sobretudo quando os efeitos de curvatura desempenham um papel relevante.

10. Comparação com Métodos Relacionados

A Tabela 15 resume as principais diferenças entre o HLLE e outros métodos de redução de dimensionalidade quanto à representação geométrica e às propriedades de mapeamento. Enquanto o LLE captura apenas relações lineares locais de primeira ordem, o HLLE estende essa abordagem ao incorporar informações de segunda ordem, preservando, assim, a curvatura local da variedade. Em contraste, o Isomap enfatiza a geometria global por meio de distâncias geodésicas, enquanto a PCA representa a variância global utilizando um mapeamento linear explícito com capacidade de reconstrução dos dados. É importante destacar que tanto o LLE quanto o HLLE utilizam mapeamentos implícitos e não permitem reconstrução direta, evidenciando o compromisso (trade-off) entre fidelidade geométrica e interpretabilidade existente entre esses métodos.

Tabela 15 – Comparação do HLLE com Métodos Relacionados

Método	Ordem	Geometria Capturada	Mapeamento	Reconstrução
LLE	Primeira ordem	Estrutura linear local	Implícito	Não
HLLE	Segunda ordem	Curvatura local	Implícito	Não
Isomap	Global	Distâncias geodésicas	Implícito	Não
PCA	Linear	Variância global	Explícito	Sim

O HLLE pode ser interpretado como uma extensão de segunda ordem do LLE, estabelecendo uma ponte entre os métodos lineares locais e as abordagens de aprendizado de variedades que preservam a curvatura.

11. Considerações Finais

O Hessian Locally Linear Embedding (HLLE) representa um importante avanço teórico no aprendizado de variedades ao incorporar a estrutura diferencial de segunda ordem. Entretanto, sua aplicação prática é frequentemente limitada pela elevada sensibilidade ao ruído e pelo alto custo computacional. Em aplicações modernas, seu desempenho costuma ser superado por métodos mais robustos, como t-SNE e UMAP. Ainda assim, o HLLE permanece uma ferramenta valiosa para compreender representações (embeddings) que preservam a curvatura em cenários controlados e para o estudo dos fundamentos geométricos da redução de dimensionalidade não linear [21–23].

2.2.2 Técnicas Não Convexas de Redução de Dimensionalidade

2.2.2.1 Abordagem de Redução de Dimensionalidade Baseada em Paisagens (Landscapes)

1. Introdução

A Redução de Dimensionalidade por Aprendizado de uma Paisagem (Dimensionality Reduction by Learning a Landscape – DrL) é uma técnica de redução de dimensionalidade não linear que preserva simultaneamente as vizinhanças locais e a estrutura global dos dados ao modelá-los como um sistema físico que evolui sobre uma paisagem de energia. Originalmente inspirada em algoritmos de desenho de grafos baseados em forças (force-directed graph drawing) e na física estatística, a DrL trata os pontos de dados como partículas interagentes, cujas posições são otimizadas iterativamente para minimizar uma função de energia [24–25].

A Figura 10 ilustra como a DrL transforma dados de alta dimensionalidade em uma representação de baixa dimensionalidade por meio da modelagem do sistema como uma paisagem de energia. Por meio de um processo iterativo de otimização, conduzido por forças atrativas e repulsivas, o método produz uma representação (embedding) que preserva tanto as vizinhanças locais quanto a estrutura global dos dados.

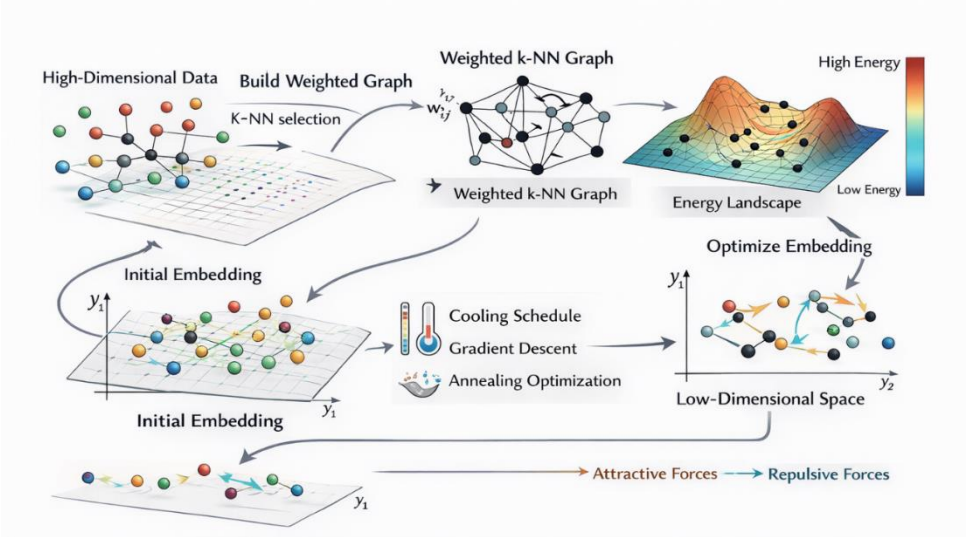


Figura 10 – Representação esquemática do método de Redução de Dimensionalidade por Aprendizado de uma Paisagem (Dimensionality Reduction by Learning a Landscape – DrL).

O processo inicia-se com dados de alta dimensionalidade, a partir dos quais é construído um grafo ponderado de k-vizinhos mais próximos (k-Nearest Neighbors, k-NN) para representar as similaridades entre pares de amostras. Esse grafo define uma paisagem de energia, na qual forças atrativas preservam as relações locais e forças repulsivas evitam o colapso dos pontos. Uma representação inicial de baixa dimensionalidade é então otimizada iterativamente por meio do método do gradiente descendente (gradient descent), combinado com um esquema de resfriamento (annealing), o que permite que o sistema convirja para uma configuração estável. A representação final em baixa dimensionalidade reflete um equilíbrio entre a coesão local e a separação global, preservando a estrutura intrínseca dos dados originais.

Diferentemente de métodos clássicos, como a PCA, ou de abordagens baseadas em variedades, como Isomap e LLE, a DrL oferece uma estrutura flexível que equilibra forças de atração e repulsão, possibilitando a visualização robusta de conjuntos de dados complexos e de alta dimensionalidade.

2. Fundamentação Conceitual

A ideia central da DrL é construir uma representação dos dados em forma de grafo e, em seguida, incorporá-lo a um espaço de baixa dimensionalidade por meio da minimização de uma função de energia.

Considere um conjunto de dados:

$$\mathbf{X} = \{x_1, x_2, \cdots, x_n\}, \;\; x_i \; \varepsilon \;\; \mathbb{R}^D \tag{59}$$

A DrL define inicialmente um grafo ponderado:

- Os nós representam os pontos de dados.
- As arestas representam as relações de similaridade, determinadas, por exemplo, pelo método dos k-vizinhos mais próximos (k-NN).

O objetivo é encontrar representações de baixa dimensionalidade:

$$\mathbf{Y} = \{y_1, y_2, \cdots, y_n\}, \;\; y_i \; \varepsilon \;\; \mathbb{R}^d, \;\; d \ll D \tag{60}$$

de modo que a energia do sistema seja minimizada.

3. Formulação Matemática

3.1 Função de Energia

A DrL baseia-se em uma função de energia que combina forças atrativas e repulsivas:

$$E(Y) = \sum_{(i,j)\varepsilon\, \epsilon} w_{ij} \left\| y_i - y_j \right\|^2 + \lambda \sum_{i \neq j} \frac{1}{\left\| y_i - y_j \right\|^{\alpha}} \tag{61}$$

Onde:

- w_{ij} = peso de similaridade entre os pontos i e j

- ϵ = conjunto de arestas, geralmente definido por um grafo de k-vizinhos mais próximos (k-NN)
- primeiro termo = força atrativa (preserva a estrutura local)
- segundo termo = força repulsiva (previne o colapso)
- λ = parâmetro de regularização
- α = controla o decaimento da repulsão

3.2 Otimização

A representação (embedding) é obtida por meio da minimização de:

$$\mathbf{Y}^* = \arg\min_{\mathbf{Y}} \mathrm{E}(\mathrm{Y}) \tag{62}$$

Esse problema é normalmente resolvido por meio de métodos iterativos de otimização, tais como:

- gradiente descendente (gradient descent);
- simulação baseada em forças (force-directed simulation);
- estratégias de recozimento (annealing) em múltiplas escalas (multi-scale annealing strategies).

A regra de atualização pode ser expressa como:

$$y_i^{(t+1)} = y_i^t - \eta \frac{\delta E}{\delta y_i} \tag{63}$$

em que η representa a taxa de aprendizado.

3.3 Interpretação das Forças

O gradiente da função de energia define as forças:

- Força atrativa:

$$F_{ij}^{(att)} = -w_{ij}\left(y_i - y_j\right) \tag{64}$$

- Força repulsiva:

$$F_{ij}^{(rep)} = \lambda \frac{y_i - y_j}{\|y_i - y_j\|^{\alpha+2}} \tag{65}$$

Assim, a DrL pode ser interpretada como um sistema dinâmico de partículas interagentes, semelhante a:

- algoritmos de desenho de grafos baseados em forças (force-directed graph drawing);
- métodos de minimização de energia.

4. Etapas do Algoritmo

1. Construir um grafo de k-vizinhos mais próximos (k-NN) a partir dos dados.
2. Atribuir pesos às arestas w_{ij}
3. Inicializar as coordenadas de baixa dimensionalidade, aleatoriamente ou por meio de PCA.
4. Atualizar iterativamente as posições com base no equilíbrio entre as forças.
5. Aplicar um esquema de resfriamento (cooling/annealing) para estabilizar a solução.
6. Obter a representação final de baixa dimensionalidade.

5. Vantagens

- Preserva tanto a estrutura local quanto a global dos dados.
- Apresenta uma formulação de energia flexível.
- É adequada para variedades não lineares complexas.
- Possui uma interpretação física intuitiva.
- Produz representações visualmente significativas.

6. Desvantagens e Limitações

Apesar de sua flexibilidade, a DrL apresenta diversos desafios.

6.1 Complexidade Computacional

- O termo repulsivo apresenta complexidade da ordem de: O(n2).

- Requer o uso de aproximações, como os métodos de Barnes–Hut.

6.2 Sensibilidade aos Parâmetros

- O método é sensível aos seguintes parâmetros:
  - número de vizinhos k
  - λ (66)
  - α (67)
- Uma escolha inadequada desses parâmetros pode distorcer a estrutura dos dados.

6.3 Ausência de Mapeamento Explícito

- O método não fornece uma função explícita da forma:

  $f: \mathbb{R}^D \rightarrow \mathbb{R}^d$ (68)

- Consequentemente, novos pontos não podem ser incorporados diretamente à representação, o que caracteriza o denominado problema out-of-sample.

6.4 Problemas de Convergência

- O processo de otimização não é convexo.
- Há risco de convergência para mínimos locais.

6.5 Sensibilidade ao Ruído

- A construção do grafo pode ser instável na presença de ruído.
- Comparação com Métodos Relacionados

7. Comparação com Métodos Relacionados

A Tabela 16 compara a Redução de Dimensionalidade por Aprendizado de uma Paisagem (Dimensionality Reduction by Learning a Landscape – DrL) com métodos clássicos de redução de dimensionalidade, destacando seus princípios fundamentais e sua capacidade de preservação estrutural. Enquanto a PCA se concentra na variância global e a LLE enfatiza a reconstrução local, o Isomap procura equilibrar ambas por meio de

distâncias geodésicas. Em contraste, a DrL destaca-se por construir uma representação em forma de paisagem, orientada por uma função de energia, que privilegia a estrutura de vizinhança e a conectividade do grafo.

Tabela 16 – Comparação da DrL com métodos relacionados.

Método	Ideia principal	Estrutura global	Estrutura local	Mapeamento
PCA	Maximização da variância	Sim	Não	Explícito
LLE	Reconstrução linear	Não	Sim	Implícito
Isomap	Distâncias geodésicas	Sim	Moderada	Implícito
DrL	Otimização da paisagem de energia	Sim	Sim	Implícito

8. Aplicações

A DrL tem sido amplamente utilizada em diversas áreas.

8.1 Visualização de Dados

- Visualização de conjuntos de dados de alta dimensionalidade (ômicas, espectroscopia);
- Descoberta de agrupamentos (clusters).

8.2 Análise de Redes

- Representação de grafos (graph embedding);
- Redes sociais.

8.3 Bioinformática

- Análise de expressão gênica;
- Redes de interação entre proteínas.

8.4 Quimiometria

No contexto da quimiometria, a DrL é particularmente útil para:

- dados espectroscópicos (Raman, NIR e IR);
- análise exploratória de sistemas químicos complexos;
- descoberta de padrões não lineares.

8.5 Fluxos de Trabalho em Aprendizado de Máquina

- Pré-processamento para classificação e regressão;
- Extração de características.

9. Considerações Finais

A Redução de Dimensionalidade por Aprendizado de uma Paisagem (Dimensionality Reduction by Learning a Landscape – DrL) representa uma estrutura poderosa e flexível para a obtenção de representações não lineares, integrando conceitos da teoria dos grafos, da física e da otimização. Ao modelar explicitamente a dinâmica entre forças de atração e repulsão, a DrL alcança um equilíbrio entre a preservação das estruturas local e global dos dados. Entretanto, seu elevado custo computacional, a sensibilidade à escolha dos parâmetros e a ausência de um mapeamento explícito limitam sua escalabilidade e sua aplicação prática em problemas de grande porte ou em aplicações que exigem processamento em tempo real [24–25].

2.2.2.2 Algoritmo de Kamada–Kawai para Redução de Dimensionalidade e Representação de Grafos

1. Introdução

O algoritmo de Kamada–Kawai (KK) é um método clássico de desenho de grafos baseado em forças (force-directed graph layout), que também pode ser interpretado como

uma técnica de redução de dimensionalidade não linear. Originalmente proposto para a visualização de grafos, o método busca posicionar os nós em um espaço de baixa dimensionalidade de modo que as distâncias geométricas entre eles reflitam, com a maior fidelidade possível, as distâncias definidas pela estrutura do grafo.

Diferentemente de abordagens puramente estatísticas, como a PCA, ou de técnicas de aprendizado de variedades, como o Isomap, o algoritmo KK baseia-se em um modelo de incorporação por molas (spring-embedding model), no qual os nós são conectados por molas virtuais cujos comprimentos naturais correspondem às distâncias dos caminhos mínimos no grafo. Essa formulação permite ao método preservar a estrutura global dos dados, mantendo simultaneamente uma representação espacial coerente [26].

A Figura 11 ilustra como o algoritmo de Kamada–Kawai transforma um grafo em uma representação de baixa dimensionalidade por meio da modelagem do sistema como um conjunto de molas interconectadas. Ao minimizar uma função de energia derivada das distâncias definidas pela teoria dos grafos, o método produz uma representação (embedding) que preserva as relações globais, mantendo uma disposição espacial coerente e de fácil interpretação.

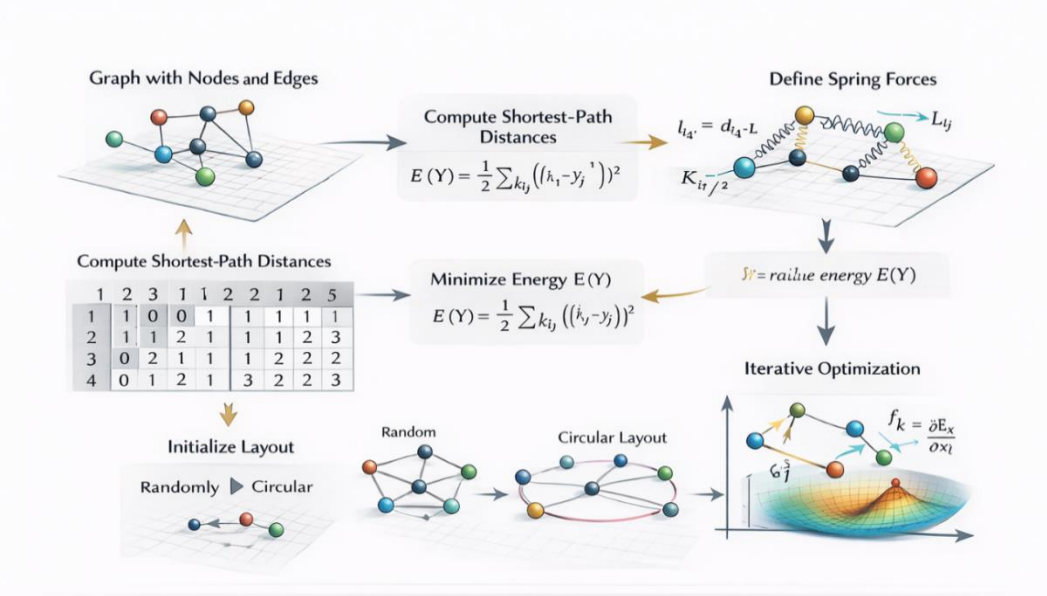


Figura 11 – Representação esquemática do algoritmo de Kamada–Kawai (KK) para representação de grafos e redução de dimensionalidade.

O processo inicia-se com um grafo composto por nós e arestas, a partir do qual são calculadas as distâncias dos caminhos mínimos entre todos os pares de nós. Essas distâncias definem os comprimentos ideais das molas lij, enquanto as constantes elásticas kij são atribuídas para controlar a intensidade das interações. Em seguida, é gerada uma configuração inicial (aleatória ou circular), e o sistema minimiza iterativamente uma função de energia que mede a discrepância entre as distâncias na representação (embedding) e as distâncias ideais definidas pelo grafo. Por meio de sucessivas atualizações baseadas no gradiente ou no método de Newton–Raphson, os nós convergem para uma configuração em que a estrutura global do grafo é preservada em um espaço de baixa dimensionalidade.

A Tabela 17 resume as principais propriedades do algoritmo de Kamada–Kawai, destacando sua fundamentação como um método de redução de dimensionalidade baseado em grafos e orientado por forças (force-directed). Ao modelar os nós como um sistema de molas e ao minimizar uma função de energia baseada nas distâncias ao longo

dos caminhos mínimos, o algoritmo preserva eficazmente a estrutura global dos dados. A tabela apresenta seus fundamentos teóricos, características computacionais e aspectos práticos de utilização, ressaltando tanto suas vantagens na geração de representações facilmente interpretáveis quanto suas limitações relacionadas ao custo computacional, à escalabilidade e à sensibilidade à inicialização.

Tabela 17 – Principais propriedades do algoritmo de Kamada–Kawai.

Propriedade	Descrição
Tipo de método	Redução de dimensionalidade não linear baseada em grafos / representação baseada em forças (force-directed layout)
Fundamentação teórica	Modelo de incorporação por molas (spring-embedding model) com minimização de energia
Princípio fundamental	Preservação das distâncias definidas pela teoria dos grafos (caminhos mínimos)
Geometria preservada	Estrutura global do grafo
Métrica de distância	Distâncias dos caminhos mínimos (distâncias geodésicas no grafo)
Função de energia	Soma dos quadrados das diferenças entre as distâncias na representação (embedding) e as distâncias ideais
Método de otimização	Minimização iterativa baseada no método de Newton–Raphson ou em gradiente
Tipo de mapeamento	Implícito (sem função explícita de transformação)
Capacidade de reconstrução	Não reconstrutivo
Complexidade computacional	Elevada: (O(n^3)) para o cálculo dos caminhos mínimos + (O(n^2)) para a otimização
Escalabilidade	Limitada a conjuntos de dados de pequeno e médio porte

Propriedade	Descrição
Sensibilidade à inicialização	Moderada a elevada (pode convergir para mínimos locais)
Sensibilidade ao ruído	Moderada (dependente da construção do grafo)
Dimensionalidade	Representação tipicamente em 2D ou 3D
Vantagens	Boa preservação da estrutura global; interpretação física intuitiva
Limitações	Alto custo computacional; baixa escalabilidade; preservação limitada da estrutura local

2. Fundamentação Conceitual

Considere um grafo definido como:

$$G = (V.E) \tag{69}$$

em que:

- $V = \{1,2,\cdots,n\}$ é o conjunto de nós;
- E é o conjunto de arestas.

O objetivo é encontrar uma representação (embedding):

$$\mathbf{Y} = \{y_1, y_2, \cdots, y_n\},\ y_i\ \varepsilon\ \mathbb{R}^d \tag{70}$$

De modo que as distâncias no espaço de representação (embedding) aproximem as definidas pela teoria dos grafos.

3. Formulação Matemática

3.1 Distâncias Definidas pela Teoria dos Grafos

Inicialmente, calculam-se as distâncias dos caminhos mínimos:

$$d_{ij} = shortest\ path\ between\ nodes\ i\ and\ j \tag{71}$$

utilizando algoritmos como Dijkstra ou Floyd–Warshall.

3.2 Modelo de Molas

Cada par de nós i,j é conectado por uma mola virtual com:

- Comprimento ideal:

$$l_{ij} = L \cdot d_{ij} \tag{72}$$

- Constante da mola:

$$k_{ij} = \frac{K}{d_{ij}^2} \tag{73}$$

em que:

- L é um fator de escala;
- K é um parâmetro global de rigidez.

3.3 Função de Energia

O algoritmo Kamada–Kawai minimiza a energia total do sistema:

$$E(Y) = \frac{1}{2}\sum_{i \neq j} k_{ij}\left(\left\|y_i - y_j\right\| - l_{ij}\right)^2 \tag{74}$$

Essa função de energia penaliza as discrepâncias entre as distâncias na representação (embedding) e as distâncias ideais definidas pelo grafo.

3.4 Otimização

A representação ótima é obtida por meio de:

$$\mathbf{Y}^* = \arg\min_{\mathbf{Y}} \mathrm{E}(\mathbf{Y}) \tag{75}$$

A otimização é normalmente realizada utilizando:

- método de Newton–Raphson;
- atualizações iterativas baseadas no gradiente.

Para cada nó i, as derivadas parciais são:

$$\frac{\delta E}{\delta x_i}, \frac{\delta E}{\delta y_i} \tag{76}$$

e o nó que apresenta o maior gradiente é ajustado iterativamente.

4. Interpretação

O algoritmo Kamada–Kawai pode ser interpretado como:

- um método semelhante ao Escalonamento Multidimensional (MDS), uma vez que preserva as distâncias entre pares de pontos;
- um sistema baseado em forças (force-directed), no qual:
    - as molas impõem a preservação da estrutura global;
    - a minimização da energia conduz ao estado de equilíbrio.

O método está intimamente relacionado à minimização do estresse (stress minimization):

$$Stress = \sum_{i<j} w_{ij}\left(\|y_i - y_j\| - d_{ij}\right)^2 \quad (77)$$

5. Etapas do Algoritmo

1. Calcular as distâncias dos caminhos mínimos dij;
2. Definir lij e kij;
3. Inicializar as posições dos nós (aleatórias ou em uma disposição circular);
4. Calcular os gradientes da função de energia;
5. Selecionar o nó com a maior contribuição para a energia;
6. Atualizar sua posição utilizando o método de Newton–Raphson;
7. Repetir o processo até a convergência.

6. Vantagens

- Preserva a estrutura global do grafo;
- Produz representações visualmente intuitivas e de fácil interpretação;
- Fundamenta-se teoricamente na minimização de energia;
- Adequado para grafos de pequeno e médio porte.

7. Desvantagens e Limitações

7.1 Complexidade Computacional

- Requer os caminhos mínimos entre todos os pares: $\mathcal{O}(n^3)$
- Minimização de energia: $\mathcal{O}(n^2)$

7.2 Problemas de Escalabilidade

- Não é adequado para grafos de grande porte;
- Torna-se lento para (n > 103).

7.3 Sensibilidade à Inicialização

- Diferentes configurações iniciais podem conduzir a mínimos locais distintos.

7.4 Mínimos Locais

- Problema de otimização não convexo;
- Não há garantia de obter o ótimo global.

7.5 Ênfase Excessiva na Estrutura Global

- Pode distorcer as vizinhanças locais;
- Menos eficaz do que LLE ou t-SNE na preservação da estrutura local.

8. Comparação com Métodos Relacionados

A Tabela 18 compara o algoritmo de Kamada–Kawai com métodos clássicos de redução de dimensionalidade em termos de seus princípios fundamentais e da preservação da estrutura dos dados. Enquanto a PCA e o MDS enfatizam a estrutura global por meio da preservação da variância e das distâncias, e o LLE concentra-se nas relações locais, o Isomap oferece um equilíbrio ao preservar as distâncias geodésicas. Em contraste, o Kamada–Kawai emprega uma estrutura baseada na minimização da energia de um sistema de molas, preservando eficazmente a estrutura global, porém com fidelidade

limitada às relações locais. Isso o caracteriza como um método visualmente intuitivo, mas computacionalmente exigente e baseado em um mapeamento implícito.

Tabela 18 – Comparação do algoritmo de Kamada–Kawai com métodos relacionados.

Método	Princípio	Estrutura global	Estrutura local	Mapeamento
PCA	Maximização da variância	Sim	Não	Explícito
MDS	Preservação das distâncias	Sim	Moderada	Explícito
Isomap	Distâncias geodésicas	Sim	Moderada	Implícito
LLE	Reconstrução local	Não	Sim	Implícito
Kamada–Kawai	Minimização da energia de um sistema de molas	Sim	Limitada	Implícito

9. Aplicações

9.1 Visualização de Grafos

- Redes sociais;
- Redes biológicas;
- Sistemas de comunicação.

9.2 Quimiometria e Espectroscopia

- Visualização de grafos de similaridade;
- Exploração de agrupamentos em conjuntos de dados espectrais.

9.3 Bioinformática

- Redes de interação entre proteínas;
- Redes regulatórias de genes.

9.4 Aprendizado de Máquina

- Visualização de grafos de similaridade em dados de alta dimensionalidade;

- Pré-processamento para agrupamento (clustering).

9.5 Ciência de Redes

- Análise estrutural de sistemas complexos.

10. Considerações Finais

O algoritmo Kamada–Kawai é uma abordagem fundamental de redução de dimensionalidade baseada em grafos, que oferece uma estrutura fisicamente interpretável para a obtenção de representações (embeddings) dos dados. Embora seja altamente eficaz na preservação das relações globais, seu elevado custo computacional e sua sensibilidade à convergência para mínimos locais restringem sua aplicação a conjuntos de dados de pequeno porte. Ainda assim, permanece um importante método de referência e uma ponte conceitual entre a teoria dos grafos, a otimização e as modernas técnicas de representação (embedding) [26].

2.2.2.3 Algoritmo de Fruchterman–Reingold

1. Introdução e Visão Conceitual

O algoritmo de Fruchterman–Reingold (FR) é um método de representação de grafos baseado em forças (force-directed graph layout) e em redução de dimensionalidade não linear, originalmente proposto por Thomas M. J. Fruchterman e Edward M. Reingold em 1991. Ele pertence à classe de técnicas de representação (embedding) baseadas em energia, nas quais os nós de um grafo são posicionados em um espaço de baixa dimensionalidade (tipicamente bidimensional ou tridimensional) para refletir a estrutura subjacente do grafo.

O método modela o grafo como um sistema físico em que os nós se repelem mutuamente, de maneira análoga a partículas eletricamente carregadas, enquanto as

arestas atuam como molas que atraem os nós conectados. A configuração de equilíbrio resultante da competição entre essas forças produz uma representação (embedding) capaz de revelar agrupamentos, padrões de conectividade e a organização global da rede [27–29].

A Figura 12 demonstra como o algoritmo de Fruchterman–Reingold transforma uma configuração inicial aleatória do grafo em uma representação estruturada por meio do balanceamento iterativo entre forças atrativas e repulsivas. A representação (embedding) resultante evidencia padrões relacionais e a topologia da rede, tornando o método particularmente eficaz para a visualização de estruturas complexas de grafos.

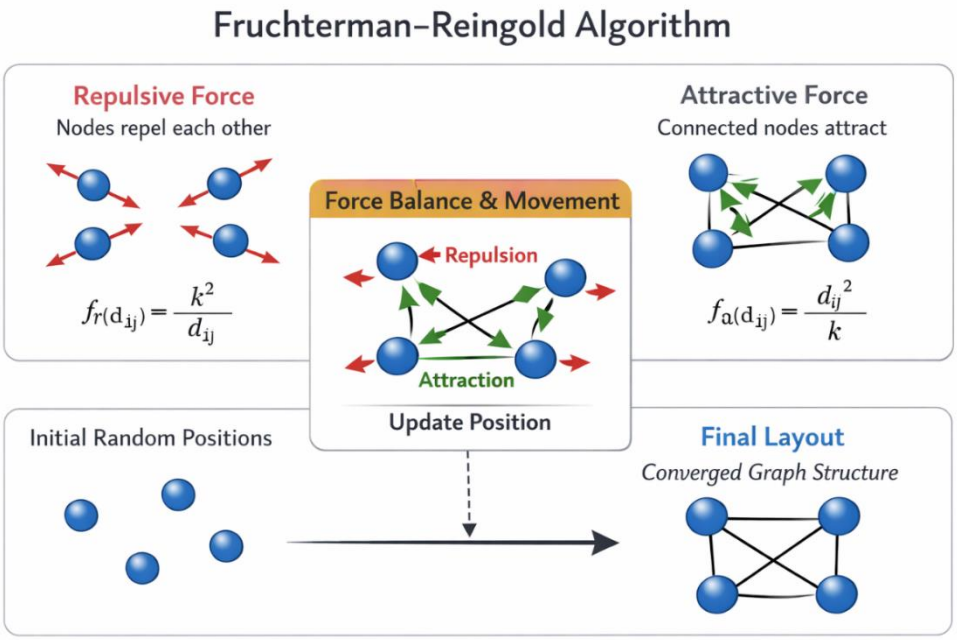


Figura 12 – Ilustração esquemática do algoritmo de leiaute dirigido por forças de Fruchterman–Reingold.

A partir de uma disposição inicial aleatória dos nós (à esquerda), as forças atrativas ao longo das arestas e as forças repulsivas entre todos os pares de nós são equilibradas

iterativamente, até que o sistema atinja uma configuração de energia mínima (à direita), na qual os agrupamentos e os padrões de conectividade tornam-se visualmente aparentes.

Em seguida, dois tipos de forças são aplicados iterativamente:

(i) forças repulsivas entre todos os pares de nós, proporcionais a $\frac{k^2}{d_{ij}}$, que afastam os nós para evitar sobreposição; e

(ii) forças atrativas ao longo das arestas do grafo, proporcionais a $\frac{d_{ij}^2}{k}$, que aproximam os nós conectados.

O painel central (Equilíbrio das Forças e Movimento) mostra como essas forças concorrentes são combinadas para atualizar as posições dos nós a cada iteração. Por meio de um processo de resfriamento (annealing), que limita progressivamente o deslocamento dos nós ao longo das iterações, o sistema converge para uma configuração estável. O resultado final (Representação Final) evidencia a estrutura intrínseca do grafo, na qual agrupamentos e padrões de conectividade são visualmente destacados.

A Tabela 19 resume as principais características do algoritmo de Fruchterman–Reingold, destacando sua formulação baseada em forças físicas, seu mapeamento implícito e sua adequação à visualização de estruturas de grafos, em vez da preservação rigorosa das relações métricas.

Tabela 19 – Principais propriedades do algoritmo de Fruchterman–Reingold.

Propriedade	Descrição
Tipo de método	Redução de dimensionalidade não linear baseada em grafos / representação baseada em forças (force-directed layout)
Fundamentação teórica	Analogia física baseada em forças atrativas (molas) e repulsivas (eletrostáticas)

Propriedade	Descrição
Princípio fundamental	Equilíbrio entre a repulsão dos nós e a atração ao longo das arestas
Geometria preservada	Estrutura global do grafo e padrões de conectividade
Conceito de distância	Implícito; baseado na topologia do grafo, e não em distâncias métricas explícitas
Forças modeladas	Força atrativa ; força repulsiva$f_a(d_{ij}) = \frac{d_{ij}^2}{k} f_r(d_{ij}) = \frac{k^2}{d_{ij}}$
Interpretação energética	Minimização de uma função global de energia que combina forças atrativas e repulsivas
Método de otimização	Atualizações iterativas das forças com um esquema de resfriamento (simulated annealing-like)
Tipo de mapeamento	Implícito (sem função explícita de transformação)
Capacidade de reconstrução	Não reconstrutivo (não inversível)
Escalabilidade	Limitada; O(n2) por iteração (podendo ser aprimorada por aproximações)
Sensibilidade à inicialização	Elevada; diferentes configurações iniciais podem conduzir a soluções distintas
Dependência de parâmetros	Requer ajuste da distância ótima k, da temperatura e do número de iterações
Robustez ao ruído	Moderada; preserva a conectividade, mas pode distorcer relações métricas
Dimensionalidade típica da saída	Espaço de visualização em 2D ou 3D
Principais aplicações	Visualização de redes, detecção de agrupamentos e análise de grafos sociais e biológicos
Interpretabilidade	Elevada (interpretação visual de agrupamentos, nós centrais (hubs) e da estrutura do grafo)

2. Formulação Matemática

Seja G = (V, E) um grafo com n = |V| vértices. A cada nó $i \, \varepsilon \, \boldsymbol{V}$ é atribuído um vetor de posição $x_i \, \varepsilon \, \mathbb{R}^d$, sendo tipicamente $d = 2$.

Um parâmetro fundamental do modelo é a distância ótima entre pares de nós:$k = C\sqrt{\frac{A}{n}}$

em que:

- A é a área do espaço de disposição (layout);
- C é uma constante, com $\mathcal{C} \approx 1$.

2.1 Força Atrativa (Arestas)

Para dois nós i e j conectados por uma aresta:$f_a(d_{ij}) = \frac{d_{ij}^2}{k}$

2.2 Força Repulsiva (Todos os Pares de Nós)

Para todos os pares de nós:$f_r(d_{ij}) = \frac{k^2}{d_{ij}}$

Onde:

$d_{ij} = \|\boldsymbol{x_i} - \boldsymbol{x_j}\|$

2.3 Atualização das Forças

O deslocamento do nó i é calculado como:$\Delta x_i = \sum_{j \neq i} \frac{x_i - x_j}{d_{ij}} f_r(d_{ij}) +$

$\sum_{j \, \varepsilon \, \mathcal{N}(i)} \frac{x_j - x_i}{d_{ij}} f_a(d_{ij})$

Um parâmetro de temperatura T é utilizado para limitar o movimento e garantir a convergência:$\boldsymbol{x}_i^{(t+1)} = \boldsymbol{x}_i^{(t)} + min(\|\Delta \boldsymbol{x}_i\|, T) \cdot \frac{\Delta x_i}{\|\Delta \boldsymbol{x_i}\|}$

A temperatura é gradualmente reduzida (esquema de resfriamento), de forma análoga ao recozimento simulado.

3. Interpretação Energética

O algoritmo pode ser interpretado como a minimização de uma função de energia da forma:$E = \sum_{(i,j)\ \varepsilon\ \boldsymbol{E}} \frac{d_{ij}^2}{k} - \sum_{i \neq j} k^2\ ln(d_{ij})$

Essa formulação reflete um equilíbrio entre:

- Energia atrativa: aproxima os nós conectados;
- Energia repulsiva: afasta globalmente os nós.

4. Procedimento Algorítmico

1. Inicializar aleatoriamente as posições dos nós;
2. Calcular as forças repulsivas entre todos os pares de nós;
3. Calcular as forças atrativas ao longo das arestas;
4. Atualizar as posições dos nós considerando a restrição de temperatura;
5. Reduzir a temperatura (resfriamento);
6. Repetir o procedimento até a convergência ou até que o número máximo de iterações seja atingido.

5. Propriedades

- Tipo de método: Representação não linear baseada em grafos;
- Mapeamento: Implícito, sem função explícita de transformação;
- Geometria preservada: Estrutura global e conectividade do grafo;
- Conceito de distância: Topologia do grafo, em vez de distâncias euclidianas ou geodésicas;
- Reconstrução: Não invertível;
- Interpretabilidade: Visual e estrutural, incluindo separação de agrupamentos, nós centrais e comunidades.

6. Fragilidades e Limitações

Apesar de sua formulação intuitiva, o algoritmo de Fruchterman–Reingold apresenta várias limitações.

6.1 Complexidade Computacional

- A implementação ingênua requer O(n2) cálculos por iteração devido à repulsão entre todos os pares de nós;
- Isso torna o algoritmo inadequado para conjuntos de dados de grande escala sem o uso de aproximações, como o método de Barnes–Hut.

6.2 Mínimos Locais

- A superfície de energia é altamente não convexa;
- O layout final depende da inicialização e pode convergir para configurações subótimas.

6.3 Ausência de Preservação Métrica

- Diferentemente do MDS ou do Isomap, o algoritmo não preserva explicitamente distâncias euclidianas ou geodésicas;
- A representação obtida é qualitativa, em vez de quantitativamente fiel.

6.4 Sensibilidade aos Parâmetros

- A escolha de k, do esquema de temperatura e do número de iterações afeta o resultado final;
- Não existe uma configuração universal de parâmetros.

6.5 Problemas de Escalabilidade

- O desempenho se deteriora em grafos densos ou em conjuntos com um número muito grande de nós;
- São necessárias estratégias de otimização, como layouts multiníveis e aceleração por GPU.

7. Aplicações

O algoritmo de Fruchterman–Reingold é amplamente utilizado em situações nas quais a estrutura relacional é mais importante do que a métrica de exatidão.

7.1 Visualização de Redes

- Redes sociais;
- Redes biológicas, como redes de interação proteína–proteína e redes gênicas;
- Redes de comunicação e transporte.

7.2 Exploração de Dados

- Visualização de grafos de similaridade, como grafos de k-vizinhos mais próximos;
- Detecção de agrupamentos e análise da estrutura de comunidades.

7.3 Quimiometria e Dados Científicos

- Visualização das relações de similaridade entre espectros;
- Representação baseada em grafos de conjuntos de dados químicos de alta dimensionalidade.

7.4 Pipelines de Aprendizado de Máquina

- Pré-processamento para métodos de aprendizado baseados em grafos;
- Visualização de representações obtidas por métodos de aprendizado de variedades.

8. Extensões e Variantes

Várias melhorias foram propostas:

- Aproximação de Barnes–Hut: reduz o cálculo das forças repulsivas para O(n log n);

- Métodos multiníveis: utilizam o agrupamento hierárquico do grafo para melhorar a escalabilidade;
- ForceAtlas (Gephi): layout dirigido por forças contínuo e adaptativo;
- Algoritmo de Kamada–Kawai: utiliza uma função de energia baseada nas distâncias dos caminhos mínimos.

9. Considerações Finais

O algoritmo de Fruchterman–Reingold permanece como um dos métodos dirigidos por forças mais influentes devido à sua simplicidade e à sua analogia física intuitiva. Embora não forneça uma representação geométrica rigorosa no sentido clássico, destaca-se por revelar padrões estruturais, constituindo uma ferramenta poderosa para a análise exploratória de dados e a visualização de redes [27–29].

2.2.2.4 Escalonamento Multidimensional Não Métrico

1. Introdução e Estrutura Conceitual

O Escalonamento Multidimensional Não Métrico (Nonmetric Multidimensional Scaling – nMDS) é uma técnica de redução não linear de dimensionalidade que representa dados de alta dimensionalidade em um espaço de baixa dimensionalidade, preservando a ordem das dissimilaridades em vez de suas magnitudes absolutas. Diferentemente do MDS clássico ou métrico, que busca preservar as distâncias reais, o nMDS concentra-se em manter a relação monotônica entre as dissimilaridades e as distâncias no espaço de representação.

Essa característica torna o nMDS particularmente adequado para conjuntos de dados nos quais apenas informações ordinais são confiáveis ou nos quais a escala das dissimilaridades é desconhecida ou não euclidiana [30–31].

A Figura 13 ilustra o princípio fundamental do Escalonamento Multidimensional Não Métrico (nMDS): transformar dados de dissimilaridade de alta dimensionalidade em uma representação de baixa dimensionalidade, preservando a ordem relativa das relações entre pares de objetos. Diferentemente das abordagens métricas, o nMDS não procura reproduzir distâncias exatas; em vez disso, garante que objetos com menores dissimilaridades permaneçam mais próximos no espaço de representação do que aqueles com maiores dissimilaridades. Essa preservação baseada na ordenação permite uma visualização significativa de estruturas complexas e não lineares, mesmo quando a escala original das distâncias é desconhecida ou não euclidiana.

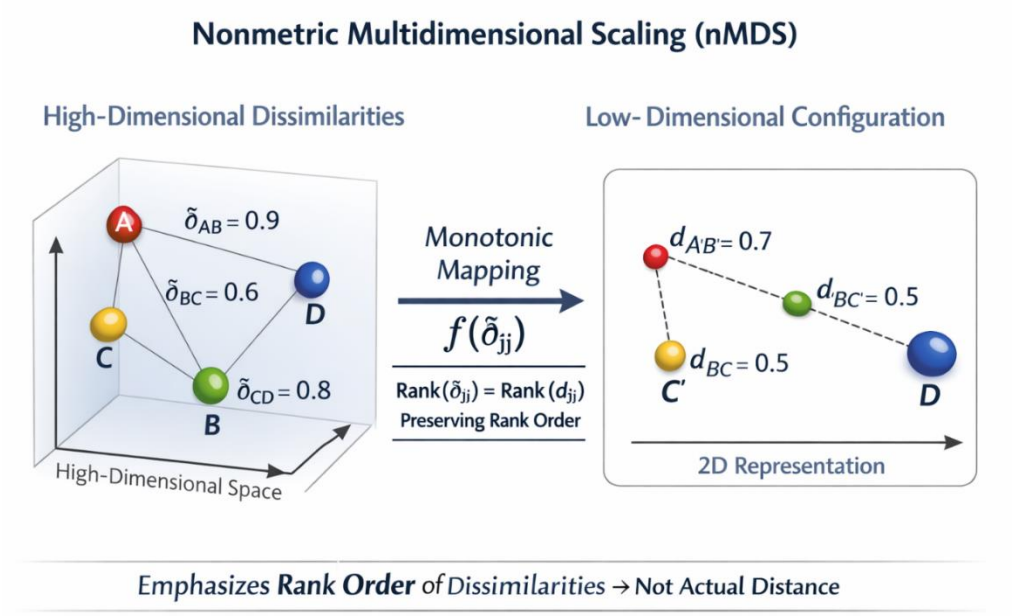


Figura 13 – Ilustração esquemática do Escalonamento Multidimensional Não Métrico (nMDS)

O painel esquerdo representa objetos (A–D) em um espaço de alta dimensionalidade, no qual as dissimilaridades entre pares de objetos (δ_{ij}) são definidas e quantificadas. Essas dissimilaridades não correspondem necessariamente a distâncias euclidianas, mas codificam as relações relativas entre os objetos. A etapa central ilustra a aplicação de uma transformação monotônica $f(\delta_{ij})$, que preserva a ordem das

dissimilaridades em vez de seus valores absolutos. O painel direito mostra a configuração resultante em um espaço bidimensional (2D), no qual as distâncias (d_{ij}) aproximam as dissimilaridades transformadas de modo que:

$$\text{Rank}(\delta_{ij}) = \text{Rank}(d_{ij})$$

As linhas tracejadas representam as distâncias no espaço de representação, enfatizando que o nMDS prioriza a consistência ordinal em detrimento da fidelidade métrica. As principais propriedades do Escalonamento Multidimensional Não Métrico (nMDS) são resumidas na Tabela 20, destacando seus fundamentos conceituais, características computacionais e implicações práticas. O método baseia-se fundamentalmente na preservação das relações de ordem entre as dissimilaridades por meio de uma transformação monotônica, distinguindo-se das abordagens métricas, que buscam reproduzir os valores absolutos das distâncias.

Tabela 20 – Principais Propriedades do Escalonamento Multidimensional Não Métrico (nMDS)

Propriedade	Descrição
Tipo de método	Técnica não linear de redução de dimensionalidade/ordenação
Base teórica	Preservação da ordem das dissimilaridades por meio de uma transformação monotônica
Princípio fundamental	Preservar a ordenação das dissimilaridades entre pares de objetos, em vez de seus valores exatos
Dados de entrada	Matriz de dissimilaridade (ou de distâncias), métrica ou não métrica
Representação das distâncias	Distâncias euclidianas no espaço de baixa dimensionalidade
Tipo de mapeamento	Implícito (sem função explícita de transformação)
Função de transformação	Função monotônica (f(\delta_{ij})), estimada por regressão isotônica$f(\delta_{ij})$

Propriedade	Descrição
Função objetivo	Minimização do stress (por exemplo, Stress-1 de Kruskal)
Método de otimização	Iterativo (por exemplo, SMACOF e métodos baseados em gradiente)
Geometria preservada	Estrutura ordinal (baseada na ordenação) das dissimilaridades
Preservação da estrutura local	Moderada a alta (dependendo dos dados e da configuração)
Preservação da estrutura global	Moderada (com menor ênfase do que no MDS métrico ou no Isomap)
Capacidade de reconstrução	Não reconstrutivo (não possui mapeamento inverso)
Escalabilidade	Limitada (o custo computacional cresce aproximadamente com (O(n^2)))
Sensibilidade à inicialização	Alta (pode convergir para mínimos locais)
Robustez a dados não métricos	Alta (desenvolvido para dados ordinais)
Interpretabilidade dos eixos	Baixa (os eixos não possuem significado físico direto)
Saída típica	Configuração em baixa dimensionalidade (geralmente 2D ou 3D)
Principal vantagem	Flexibilidade para lidar com dissimilaridades arbitrárias e robustez a distorções de escala
Principal limitação	Ausência de um mapeamento explícito para novos dados (problema out-of-sample)

2. Formulação Matemática

Seja δ_{ij} a dissimilaridade entre os objetos i e j, e seja d_{ij} a distância euclidiana entre seus pontos correspondentes no espaço de representação de baixa dimensionalidade.

O objetivo do nMDS é encontrar uma configuração de pontos tal que:

$$d_{ij} \approx f(\delta_{ij}) \tag{78}$$

em que $f(\cdot)$ é uma função monotônica (não decrescente), normalmente estimada por meio de regressão isotônica.

3. Função de Stress

A qualidade da representação é quantificada por uma função de stress, que mede a discrepância entre as distâncias d_{ij} e as dissimilaridades transformadas $f(\delta_{ij})$.

Uma das formulações mais amplamente utilizadas é o Stress-1 de Kruskal:

$$Stress = \sqrt{\frac{\sum_{i<j}\left(d_{ij} - f(\delta_{ij})\right)^2}{\sum_{i<j} d_{ij}^2}}$$

Alternativamente, uma forma mais simples (não normalizada) da função de stress pode ser definida como:

$$Stress = \sum_{i<j}\left(d_{ij} - f(\delta_{ij})\right)^2 \tag{79}$$

O problema de otimização consiste em minimizar a função de stress em função da configuração dos pontos no espaço de baixa dimensionalidade.

4. Procedimento de Otimização

A solução é normalmente obtida por meio de um algoritmo iterativo:

1. Inicialização: iniciar com uma configuração aleatória ou previamente definida.
2. Cálculo das Distâncias: calcular as distâncias d_{ij}.
3. Regressão Monotônica: ajustar $f(\delta_{ij})$ a d_{ij}, preservando a ordem das dissimilaridades.

4. Atualização da Configuração: ajustar as posições dos pontos para reduzir o stress (por exemplo, por meio da descida do gradiente ou da majorização).
5. Iteração: repetir o procedimento até que seja atingida a convergência.

Um dos algoritmos mais utilizados é o SMACOF (Scaling by Majorizing a Complicated Function), que garante a convergência monotônica da função de stress.

5. Interpretação dos Valores de Stress

As diretrizes típicas para a interpretação dos valores de stress (Kruskal) são apresentadas na .

Tabela 21.

Tabela 21 – Associação entre o valor de stress e sua interpretação

Valor de Stress	Interpretação
< 0,05	Representação excelente
0,05–0,10	Boa
0,10–0,20	Razoável
> 0,20	Fraca

6. Principais Características

- Método não linear;
- Baseado na ordenação (preservação ordinal);
- Mapeamento implícito (sem função explícita de transformação);
- Aplicável a medidas arbitrárias de dissimilaridade;
- Não reconstrutivo.

7. Vantagens

- Flexibilidade: funciona com dissimilaridades não euclidianas e não métricas.
- Robustez a distorções de escala: apenas a ordem das dissimilaridades é relevante.
- Ferramenta eficaz para visualização de conjuntos de dados complexos.
- Ampla aplicabilidade em diferentes áreas do conhecimento.

8. Fragilidades e Limitações

Apesar de sua flexibilidade, o nMDS apresenta diversas limitações:

- Complexidade computacional: tipicamente O(n2) ou superior, devido ao cálculo das distâncias entre todos os pares de objetos.
- Mínimos locais: o problema de otimização é não convexo e sensível à configuração inicial.
- Ausência de mapeamento explícito: não permite projetar diretamente novos dados (problema out-of-sample).
- Baixa interpretabilidade: os eixos não possuem significado físico direto.
- Limitações de escalabilidade: não é adequado para conjuntos de dados muito grandes sem o uso de técnicas de aproximação.
- Dependência da qualidade das dissimilaridades: medidas de dissimilaridade inadequadas podem produzir representações enganosas.

9. Aplicações

O Escalonamento Multidimensional Não Métrico (nMDS) tem sido amplamente aplicado em diversas áreas:

- Quimiometria: visualização de similaridades espectrais (por exemplo, dados de NIR, Raman e UV–Vis).
- Ecologia: análise da composição de espécies e de padrões de biodiversidade.
- Bioinformática: exploração de dados de expressão gênica e de estudos ômicos.
- Ciências sociais: mapeamento perceptual e análise de preferências.
- Mineração de texto e Processamento de Linguagem Natural (PLN): visualização de similaridades entre documentos.
- Ciência dos materiais: investigação das relações entre a estrutura e as propriedades em sistemas complexos.

Na quimiometria, o nMDS é particularmente útil quando as medidas de distância (por exemplo, medidas baseadas em correlação) não satisfazem as propriedades de uma métrica.

10. Comparação com Métodos Relacionados

A Tabela 22 compara o Escalonamento Multidimensional Não Métrico (nMDS) com outras técnicas amplamente utilizadas de redução de dimensionalidade, destacando seus princípios fundamentais, o tipo de estrutura preservada e a natureza dos mapeamentos. Essa comparação evidencia a principal característica distintiva do nMDS — seu foco na preservação da ordem das dissimilaridades — em contraste com métodos como PCA e MDS métrico, que se baseiam em propriedades métricas, e com o Isomap, que busca preservar a geometria global da variedade (manifold). A tabela fornece uma visão sintética das diferenças conceituais entre esses métodos, auxiliando na seleção da abordagem mais adequada ao objetivo da análise.

Tabela 22 – Comparação entre o nMDS e métodos relacionados

Método	Princípio	Estrutura preservada	Mapeamento
PCA	Maximização da variância	Estrutura global	Explícito
MDS Métrico	Preservação das distâncias	Distâncias métricas	Explícito
Isomap	Distâncias geodésicas	Geometria global da variedade (manifold)	Implícito
nMDS	Ordem das dissimilaridades	Relações ordinais	Implícito

11. Considerações Finais

O Escalonamento Multidimensional Não Métrico (nMDS) ocupa uma posição singular entre as técnicas de redução de dimensionalidade por enfatizar a fidelidade ordinal em vez da precisão métrica. Essa característica o torna particularmente eficaz para a análise exploratória de dados, especialmente quando as relações exatas de distância são desconhecidas ou pouco confiáveis. Entretanto, sua limitada escalabilidade e a ausência de uma função explícita de mapeamento restringem sua aplicação em pipelines preditivos, tornando-o mais adequado para tarefas de visualização e análise exploratória de dados [30–31].

2.2.2.5 Incorporação Estocástica de Vizinhos Distribuída em t (t-SNE)

1. Introdução e Estrutura Conceitual

A Incorporação Estocástica de Vizinhos Distribuída em t (t-Distributed Stochastic Neighbor Embedding – t-SNE) é uma técnica não linear de redução de dimensionalidade desenvolvida especificamente para a visualização de dados de alta dimensionalidade em espaços de baixa dimensionalidade (geralmente 2D ou 3D). Proposto originalmente por Laurens van der Maaten e Geoffrey Hinton, o t-SNE estende a estrutura do Stochastic Neighbor Embedding (SNE) ao resolver o problema do adensamento (crowding problem) e ao melhorar a representação das estruturas locais.

A ideia central do t-SNE consiste em converter as distâncias entre pares de pontos de dados em distribuições de probabilidade que representam suas similaridades e, em seguida, minimizar a divergência entre essas distribuições nos espaços de alta e de baixa dimensionalidade [32–33].

A Figura 14 apresenta uma representação esquemática do algoritmo t-SNE, destacando sua estrutura probabilística de redução de dimensionalidade. Ao transformar as distâncias entre pares de pontos em distribuições de probabilidade e ao minimizar a divergência entre elas, o t-SNE captura de forma eficaz as relações locais presentes em dados de alta dimensionalidade. O uso de uma distribuição de cauda pesada no espaço de representação reduz os efeitos do problema do adensamento (crowding problem) e melhora a separação entre agrupamentos, tornando o método particularmente adequado para a visualização de estruturas de dados complexas e não lineares.

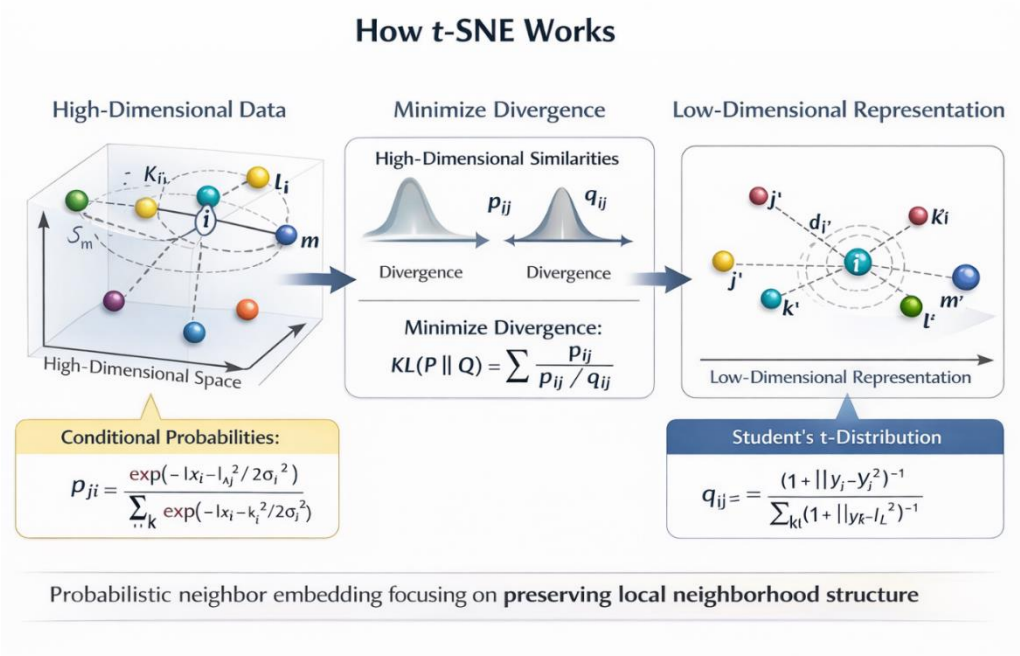


Figura 14 – Ilustração do algoritmo t-Distributed Stochastic Neighbor Embedding (t-SNE). A figura apresenta o fluxo de trabalho do t-SNE em três etapas.

O painel esquerdo mostra os dados em um espaço de alta dimensionalidade, no qual as relações entre pares de pontos são modeladas como probabilidades condicionais utilizando distribuições gaussianas. O painel central ilustra o objetivo do método: minimizar a divergência de Kullback–Leibler (KL) entre a distribuição de similaridades no espaço de alta dimensionalidade P e a correspondente no espaço de baixa dimensionalidade Q. O painel direito apresenta a representação resultante em baixa dimensionalidade, na qual as similaridades são modeladas por uma distribuição t de Student, permitindo uma melhor separação entre os agrupamentos. Todo o processo enfatiza a preservação da estrutura de vizinhança local, garantindo que pontos próximos no espaço original permaneçam próximos no espaço de representação.

A Tabela 23 resume as principais propriedades do t-Distributed Stochastic Neighbor Embedding (t-SNE), fornecendo uma visão geral de seus fundamentos teóricos, características computacionais e comportamento prático. A tabela destaca a natureza

probabilística do método, sua ênfase na preservação das estruturas de vizinhança locais e o papel da divergência de Kullback–Leibler (KL) na condução do processo de otimização. Além disso, apresenta aspectos importantes, como a escalabilidade, a sensibilidade aos hiperparâmetros e a ausência de uma função explícita de mapeamento, oferecendo uma referência concisa para compreender as principais vantagens e limitações do t-SNE em tarefas de análise exploratória de dados e visualização.

Tabela 23 – Principais Propriedades do t-Distributed Stochastic Neighbor Embedding (t-SNE)

Propriedade	Descrição
Tipo de método	Redução de dimensionalidade não linear / representação probabilística
Base teórica	Correspondência entre distribuições de probabilidade por meio da divergência de Kullback–Leibler
Princípio fundamental	Preservar as relações de vizinhança local por meio de probabilidades de similaridade
Dados de entrada	Matriz de atributos de alta dimensionalidade ou matriz de distâncias entre pares
Similaridade no espaço de alta dimensionalidade	Probabilidades condicionais (p_{ij}) baseadas em distribuições Gaussianas
Similaridade no espaço de baixa dimensionalidade	Probabilidades (q_{ij}) modeladas por uma distribuição t de Student (cauda pesada)
Função objetivo	Minimização da divergência de Kullback–Leibler (KL(P||Q))
Método de otimização	Descida do gradiente com momento (momentum) e exagero inicial (early exaggeration)
Tipo de mapeamento	Implícito (não paramétrico, sem função explícita de transformação)
Geometria preservada	Estrutura local (relações de vizinhança)

Propriedade	Descrição
Preservação da estrutura global	Limitada (as distâncias entre agrupamentos podem ser distorcidas)
Capacidade de reconstrução	Não reconstrutivo (não possui mapeamento inverso)
Escalabilidade	Moderada a baixa (tipicamente (O(n^2)), podendo ser melhorada por técnicas de aproximação)
Sensibilidade aos hiperparâmetros	Alta (perplexidade, taxa de aprendizado e inicialização)
Determinismo	Não determinístico (os resultados podem variar entre diferentes execuções)
Robustez ao ruído	Moderada a alta para estruturas locais
Interpretabilidade dos eixos	Baixa (os eixos não possuem significado físico direto)
Saída típica	Representação bidimensional (2D) ou tridimensional (3D) para visualização
Principal vantagem	Excelente visualização de agrupamentos e preservação da estrutura local
Principal limitação	Representação limitada da estrutura global e ausência de um mapeamento para novos dados (out-of-sample)

2. Formulação Matemática

2.1 Similaridades no Espaço de Alta Dimensionalidade

Dado um conjunto de dados $\{x_1, x_2, \cdots, x_n\}$, a similaridade entre dois pontos xi e xj no espaço de alta dimensionalidade é definida como uma probabilidade condicional:

$$p_{j|i} = \frac{exp\left(-\|x_i - x_j\|^2\right)}{\sum_{k \neq i}(-\|x_i - x_k\|^2 / 2\sigma_i^2)} \tag{80}$$

em que σ_i é um parâmetro de largura de banda (bandwidth) determinado pela perplexidade, a qual controla o número efetivo de vizinhos.

A probabilidade conjunta é então simetrizada:

$$\boldsymbol{p_{ij}} = \frac{\boldsymbol{p_{j|i}+p_{i|j}}}{\boldsymbol{2n}} \tag{81}$$

2.2 Similaridades no Espaço de Baixa Dimensionalidade

No espaço de baixa dimensionalidade, os pontos yi e yj são modelados por uma distribuição t de Student com um grau de liberdade (equivalente à distribuição de Cauchy):

$$q_{ij} = \frac{\left(1+\|y_i-y_j\|^2\right)^{-1}}{\sum_{k\neq l}(1+\|y_k-y_l\|^2)^{-1}} \tag{82}$$

O uso dessa distribuição de cauda pesada reduz o problema do adensamento (crowding problem), ao permitir que distâncias moderadas no espaço de alta dimensionalidade sejam representadas por distâncias maiores no espaço de representação.

2.3 Função Objetivo

A representação ótima é obtida por meio da minimização da divergência de Kullback–Leibler (KL) entre as duas distribuições:

$$KL(P||Q) = \sum_{i\neq j} p_{ij}\ log\frac{p_{ij}}{q_{ij}} \tag{83}$$

Essa função objetivo enfatiza a preservação da estrutura de vizinhança local, uma vez que erros na representação de pontos próximos são fortemente penalizados.

3. Procedimento de Otimização

A minimização da divergência de Kullback–Leibler (KL) é realizada por meio do método de descida do gradiente, com atualizações da forma:

$$\frac{\delta KL}{\delta y_i} = 4\sum_j(p_{ij}-q_{ij})(y_i-y_j)\left(1+\|y_i-y_j\|^2\right)^{-1} \tag{84}$$

Diversos aprimoramentos práticos são comumente empregados:

- Exagero inicial (early exaggeration): amplifica p_{ij} para melhorar a separação entre agrupamentos nas primeiras iterações.

- Momento (momentum): acelera a convergência do algoritmo.
- Taxas de aprendizado adaptativas.

4. Principais Características

- Método não linear e probabilístico;
- Ênfase na preservação da estrutura local;
- Mapeamento implícito (não paramétrico);
- Utilização de uma distribuição de cauda pesada no espaço de representação;
- Desenvolvido principalmente para fins de visualização.

5. Vantagens

- Excelente visualização de agrupamentos em conjuntos de dados complexos;
- Captura de forma eficaz relações não lineares;
- Robusto ao ruído em dados de alta dimensionalidade;
- Amplamente aplicável em diversas áreas do conhecimento.

O t-SNE é particularmente eficaz para revelar padrões ocultos, agrupamentos e estruturas de manifold que métodos lineares, como a PCA, não conseguem identificar.

6. Fragilidades e Limitações

Apesar de sua popularidade, o t-SNE apresenta diversas limitações importantes:

- Preservação limitada da estrutura global: as distâncias entre agrupamentos podem não possuir significado interpretável.
- Resultados não determinísticos: diferentes execuções podem produzir representações distintas.

- Custo computacional elevado: tipicamente (O(n^2)), embora aproximações, como o Barnes–Hut t-SNE, reduzam essa complexidade.
- Sensibilidade aos hiperparâmetros: a perplexidade, a taxa de aprendizado e a inicialização influenciam fortemente os resultados.
- Ausência de um mapeamento explícito: não permite incorporar diretamente novos pontos de dados (problema out-of-sample).
- Distorção do tamanho dos agrupamentos: as áreas ocupadas pelos agrupamentos não refletem necessariamente a densidade real dos dados.
- Possibilidade de interpretações equivocadas: artefatos visuais podem sugerir estruturas inexistentes nos dados.

7. Aplicações

O t-SNE tornou-se uma ferramenta padrão para análise exploratória de dados em diversas áreas:

- Quimiometria: visualização de conjuntos de dados espectrais (por exemplo, NIR, Raman e espectrometria de massas).
- Bioinformática: análise de expressão gênica e de dados de RNA-seq de célula única (single-cell RNA-seq).
- Visão computacional: visualização de espaços de atributos em modelos de aprendizado profundo.
- Processamento de Linguagem Natural (PLN): visualização de representações vetoriais de palavras (word embeddings) e similaridade entre documentos.
- Ciência dos materiais: agrupamento de compostos e análise das relações entre estrutura e propriedades.

- Ciências sociais: visualização de dados comportamentais e de pesquisas de opinião.

Em aplicações de quimiometria, o t-SNE é particularmente útil para identificar estruturas de classes ocultas em dados espectrais de alta dimensionalidade.

8. Comparação com Métodos Relacionados

A Tabela 24 apresenta uma visão comparativa do t-Distributed Stochastic Neighbor Embedding (t-SNE) em relação a outras técnicas amplamente utilizadas de redução de dimensionalidade, destacando seus princípios fundamentais, o tipo de estrutura preservada e a natureza de seus mapeamentos. Essa comparação evidencia a principal característica distintiva do t-SNE — sua formulação probabilística voltada para a preservação das relações de vizinhança local — em contraste com métodos como PCA e MDS, que enfatizam a preservação da estrutura global, e com Isomap e nMDS, que buscam preservar, respectivamente, a geometria da manifold e as relações ordinais. A tabela fornece uma estrutura concisa para a seleção do método mais adequado em função do objetivo da análise e do tipo de estrutura presente nos dados.

Tabela 24 – Comparação entre o t-SNE e métodos relacionados

Método	Princípio	Estrutura preservada	Mapeamento
PCA	Maximização da variância	Estrutura global	Explícito
MDS	Preservação das distâncias	Estrutura global	Explícito
Isomap	Distâncias geodésicas	Geometria global da variedade (manifold)	Implícito

Método	Princípio	Estrutura preservada	Mapeamento
nMDS	Preservação da ordem das dissimilaridades	Estrutura ordinal	Implícito
t-SNE	Correspondência entre distribuições de probabilidade	Estrutura local	Implícito

9. Considerações Finais

O t-SNE é uma abordagem poderosa e amplamente utilizada para a visualização de dados complexos de alta dimensionalidade, especialmente quando as relações locais são o principal foco. Sua formulação probabilística e o uso de distribuições de cauda pesada permitem uma separação eficaz entre agrupamentos e a revelação de estruturas complexas nos dados. Entretanto, suas limitações — especialmente a distorção da estrutura global e a falta de reprodutibilidade dos resultados — exigem uma interpretação cuidadosa. Consequentemente, o t-SNE é mais adequado como uma ferramenta de visualização exploratória do que como um método de análise quantitativa [32–33].

2.3 Resumo dos Métodos de Redução de Dimensionalidade: Uma Visão Geral

A Tabela 25 resume as principais características de um amplo conjunto de técnicas de redução de dimensionalidade (RD), abrangendo abordagens lineares, não lineares, baseadas em manifolds, espectrais, probabilísticas e baseadas em grafos. A comparação destaca aspectos fundamentais, incluindo a categoria metodológica, o tipo de estrutura preservada (por exemplo, variância, distâncias, topologia ou similaridades locais) e a capacidade de inversão de cada técnica. Essa visão geral fornece uma estrutura unificada para compreender as diferenças fundamentais entre os métodos de redução de

dimensionalidade e auxilia na seleção da técnica mais apropriada de acordo com objetivos analíticos específicos, como visualização, reconstrução ou integração com modelos de aprendizado de máquina.

Tabela 25 – Características das Técnicas de Redução de Dimensionalidade (RD)

Técnica	Categoria	Estrutura preservada	Invertível*
PCA	Linear (Global)	Variância/Covariância	Sim
PCA L1	Linear (Global)	Variância (robusta à norma L1)	Aproximadamente
Fast ICA	Linear (Global)	Independência estatística	Aproximadamente
MDS	Linear (Global)	Distâncias euclidianas	Sim
KPCA	Não linear (Kernel)	Variância no espaço de kernel	Não
nMDS	Não linear (Global)	Ordem das distâncias	Não
Isomap	Não linear (Manifold)	Distâncias geodésicas	Não
HLLE	Não linear (Manifold)	Curvatura local	Não
Diffusion Maps	Não linear (Espectral)	Geometria de difusão	Não
DrL	Não linear (Baseado em grafos/Probabilístico)	Probabilidades de vizinhança	Não
t-SNE	Não linear (Probabilístico)	Similaridades locais	Não
DRR	Não linear (Invertível)	Redução de redundâncias não lineares	Sim
Fruchterman–Reingold	Baseado em grafos (Dirigido por forças)	Topologia do grafo	Não
Kamada–Kawai	Baseado em grafos (Dirigido por forças)	Distâncias baseadas na teoria dos grafos	Não

*Nota: Um método de redução de dimensionalidade é considerado invertível quando existe um mapeamento inverso bem definido, f^{-1}, que permite reconstruir de forma exata

ou aproximada os dados originais de alta dimensionalidade $\mathbf{x} \in \mathbb{R}^D$ a partir de sua representação em baixa dimensionalidade $\mathbf{z} \in \mathbb{R}^d$, em que $d < D$:

$$\mathbf{z} = f(\mathbf{x}),\ \mathbf{x} \approx f^{-1}(\mathbf{z}) \tag{85}$$

Os métodos invertíveis de redução de dimensionalidade preservam informações suficientes para permitir a reconstrução dos dados originais, normalmente por meio da minimização de um erro de reconstrução (por exemplo, a RMSE). Em contraste, os métodos não invertíveis realizam um mapeamento de muitos para um, comprimindo os dados de forma irreversível e priorizando a preservação da estrutura ou da topologia em detrimento da capacidade de reconstrução.

A Figura 15 ilustra a distinção conceitual entre métodos de redução de dimensionalidade invertíveis e não invertíveis. Os métodos invertíveis preservam informações suficientes para reconstruir os dados originais, tornando-os adequados para tarefas como compressão de dados e engenharia de atributos (feature engineering). Em contrapartida, os métodos não invertíveis priorizam a preservação de relações estruturais ou de vizinhança, frequentemente à custa da perda de informação, o que limita sua aplicação principalmente à análise exploratória de dados e à visualização. Essa distinção é fundamental para a seleção da técnica de redução de dimensionalidade mais apropriada, dependendo do objetivo principal ser a reconstrução dos dados ou a representação de sua estrutura.

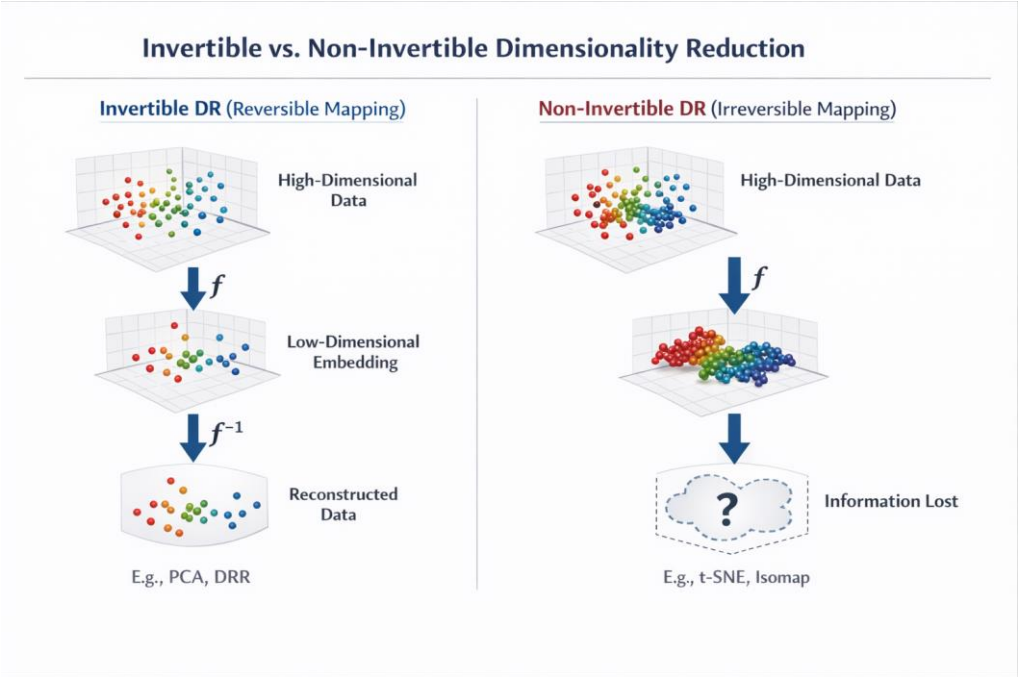


Figura 15 – Redução de Dimensionalidade Invertível versus Não Invertível

A Figura 15 compara duas classes fundamentais de métodos de redução de dimensionalidade (RD) com base na capacidade de reconstrução dos dados originais. O painel à esquerda ilustra um método de RD invertível, no qual um mapeamento f projeta os dados de alta dimensionalidade em um espaço de menor dimensionalidade, enquanto um mapeamento inverso f^{-1} permite reconstruir os dados originais com perda mínima de informação. Exemplos típicos incluem a PCA e a DRR. O painel à direita representa uma RD não invertível, na qual o mapeamento direto produz uma representação de baixa dimensionalidade, mas não há transformação inversa capaz de recuperar os dados originais, o que resulta em perda irreversível de informação. Métodos representativos dessa categoria incluem o t-SNE e o Isomap. O diagrama destaca o compromisso fundamental (trade-off) entre a capacidade de reconstrução e a flexibilidade para capturar estruturas complexas nos dados.

2.4 Critérios de Qualidade

O aprendizado não supervisionado não requer a especificação prévia de classes ou de uma variável-alvo. Nesse contexto, o algoritmo escolhido organiza os dados de entrada, por exemplo, agrupando-os em clusters ou projetando-os em uma representação de menor dimensionalidade. Diferentemente do aprendizado supervisionado, não existe uma forma natural de medir diretamente a qualidade do resultado obtido ou de comparar duas técnicas por meio de medidas objetivas, como eficiência de modelagem ou erro de classificação. Isso ocorre porque cada técnica otimiza uma função de erro distinta, tornando inadequado, por exemplo, comparar o MDS não linear e a Kernel PCA com base na variância recuperada ou na divergência de Kullback–Leibler (KL) [34–36].

De modo geral, as métricas de qualidade da redução de dimensionalidade (RD) podem ser agrupadas em três categorias principais, além de um pequeno número de casos especiais. A primeira categoria compreende as métricas orientadas à compacidade (compactness-oriented), que avaliam o quão bem a disposição relativa dos pontos no espaço métrico é preservada após a projeção. Essas métricas quantificam a preservação da densidade local e da estrutura dos agrupamentos por meio da comparação das distâncias entre amostras vizinhas nos espaços original e reduzido. Exemplos representativos incluem Q_{local}, AUC R(NX), Trustworthiness, Precision e C-Measure, que avaliam principalmente a consistência das relações intra e intergrupos.

A segunda categoria compreende as métricas orientadas à conectividade (connectivity-oriented), que se concentram na preservação das relações de vizinhança e da organização global da variedade (manifold) dos dados. Essas métricas avaliam se a topologia geral do conjunto de dados e a ordenação das distâncias permanecem consistentes após a redução de dimensionalidade. Exemplos típicos incluem Q_{global}, Continuity, Discontinuity, Recall, τ de Kendall, Gabriel Classification Error (GCE) e a

correlação cofenética. Diferentemente das métricas de compacidade, esses indicadores enfatizam a coerência estrutural da representação reduzida em vez da densidade dos agrupamentos locais.

A terceira categoria compreende as métricas não generalizáveis, que dependem de pressupostos específicos do algoritmo, de modelos de reconstrução ou de rótulos de classe e, portanto, não avaliam exclusivamente as propriedades geométricas da representação reduzida. Entre elas destacam-se a RMSE de reconstrução e a exatidão do classificador k-vizinhos mais próximos (k-NN), que medem, respectivamente, a fidelidade da reconstrução ou o desempenho de classificação, em vez da estrutura intrínseca da variedade.

Essa classificação ajuda a explicar por que diferentes famílias de algoritmos de redução de dimensionalidade tendem a apresentar melhor desempenho segundo diferentes critérios de avaliação. Algoritmos voltados para a preservação da estrutura local, como *t-SNE*, *HLLE* e *diffusion maps*, normalmente alcançam valores elevados em métricas relacionadas à compacidade, como Q_{local}, Trustworthiness e exatidão do k-NN, refletindo sua elevada capacidade de preservar relações de vizinhança e a estrutura dos agrupamentos. Entretanto, esses métodos podem comprometer a consistência da geometria global.

Em contrapartida, algoritmos voltados para a preservação da estrutura global, como *Isomap*, *MDS clássico* e *Kernel PCA*, tendem a apresentar melhor desempenho em métricas orientadas à conectividade, como Q_{global}, AUC R(NX) e correlação cofenética, indicando maior capacidade de preservar a estrutura global da variedade.

Um terceiro grupo é composto por algoritmos lineares e estruturalmente estáveis, como *PCA*, *PCA-L1*, *FastICA* e *DRR*, que frequentemente apresentam baixos erros de reconstrução, elevados valores de Continuity e representações de baixa dimensionalidade

facilmente interpretáveis. Em particular, *PCA* e *DRR* preservam integralmente a invertibilidade do mapeamento.

Por fim, os algoritmos baseados em grafos, como *Fruchterman–Reingold*, *Kamada–Kawai* e *DrL*, foram desenvolvidos principalmente para tarefas de visualização. Embora esses métodos produzam representações visualmente bem separadas, sua capacidade de preservar a geometria global e a fidelidade estrutural quantitativa pode variar substancialmente.

Em conjunto, essa estrutura conceitual esclarece que o comportamento dos algoritmos de redução de dimensionalidade está intimamente relacionado às propriedades estruturais enfatizadas por diferentes métricas de qualidade, ressaltando a importância de uma avaliação orientada pelo objetivo da análise na seleção da técnica de RD mais apropriada [38]. Assim, existe uma série de estimadores independentes que podem ser utilizados para avaliar a qualidade de uma representação em baixa dimensionalidade, conforme descrito a seguir.

2.4.1 Medidas de Qualidade: Métricas Orientadas à Compacidade

2.4.1.1 Qualidade Local (Q_{local})

A qualidade local (Q_{local}) mede o grau em que os vizinhos mais próximos de cada ponto no espaço original de alta dimensionalidade permanecem vizinhos após a redução de dimensionalidade. Formalmente, essa métrica avalia a preservação da estrutura local: se duas amostras são próximas no espaço original, espera-se que permaneçam próximas na representação de baixa dimensionalidade. A qualidade local pode ser expressa como a fração de vizinhos preservados:

$$Q_{local} = \frac{1}{nk}\sum_{i=1}^{n}|N_k(i) \cap N_k'(i)| \quad (86)$$

em que:

$\mathrm{N_k(i)} =$ set of k nearest neighbors of point i in the original space (87)

$\mathrm{N'_k(i)} =$ set of k nearest neighbors of point i in the embedded space (88)

n = número de amostras;

k = tamanho da vizinhança.

Os valores de Q_{local} variam, em geral, entre 0, indicando ausência de preservação da estrutura local, e 1, indicando preservação perfeita dos vizinhos mais próximos [34].

2.4.1.2 Área Sob a Curva (AUC R(NX))

A métrica AUC R_{NX} corresponde à Área Sob a Curva da função $R_{NX}(k)$, em que $R_{NX}(k)$ quantifica a concordância entre os k vizinhos mais próximos no espaço original e os no espaço reduzido, corrigida pelo acordo esperado ao acaso.

O índice corrigido de preservação da vizinhança é dado por:

$$R_{NX}(k) = \frac{(N-1)Q_{NX}(k)-(k)}{N-1-k} \quad (89)$$

em que:

$Q_{NX}(k)$ representa a sobreposição entre os conjuntos dos k vizinhos mais próximos nos espaços original e reduzido. A correção elimina o efeito da concordância por acaso.

A AUC R_{NX} é calculada como:

$$AUC_{R_{NX}} = \frac{1}{K}\sum_{k=1}^{K} R_{NX}(k) \quad (90)$$

em que K é normalmente escolhido como $N-2$ ou como um subconjunto representativo de tamanhos de vizinhança.

A métrica AUC R(NX) fornece uma medida quantitativa de quão bem um método de redução de dimensionalidade preserva as relações de vizinhança do espaço original de alta dimensionalidade na representação de baixa dimensionalidade. Quando o AUC R(NX) é aproximadamente 0, a representação reduzida se comporta de forma semelhante

à de um mapeamento aleatório, indicando que a estrutura de vizinhança dos dados não foi preservada. Valores entre 0,1 e 0,3 sugerem fraca preservação da vizinhança, indicando que apenas uma parcela limitada das relações locais entre as amostras é mantida. Quando a métrica assume valores entre 0,3 e 0,6, a representação apresenta preservação moderada da estrutura dos dados, indicando que uma fração significativa das informações de vizinhança originais foi preservada. Valores superiores a 0,6 indicam forte preservação da vizinhança, o que reflete que o método de redução de dimensionalidade mantém de forma eficaz a estrutura local dos dados na representação de baixa dimensionalidade [34].

2.4.1.3 Confiabilidade (Trustworthiness)

A Confiabilidade (Trustworthiness) mede o grau em que os vizinhos presentes na representação de baixa dimensionalidade também são vizinhos no espaço original. Se dois pontos aparecem próximos na representação reduzida, embora distantes nos dados originais, considera-se que a representação reduzida apresenta baixa confiabilidade. Assim, a métrica Trustworthiness penaliza as chamadas intrusões (intrusions), isto é, pontos que passam a ser vizinhos no espaço reduzido, embora originalmente não fossem.

A Confiabilidade (Trustworthiness) é definida por:

$$T(k) = 1 - \frac{2}{Nk(2N-3k-1)} \sum_{i=1}^{N} \sum_{j\ \varepsilon\ U_k(i)} (r(i,j) - k) \tag{91}$$

em que:

N = número de amostras;

k = tamanho da vizinhança;

$U_k(i)$ = conjunto de pontos que pertencem aos k vizinhos mais próximos de i na representação em baixa dimensionalidade, mas não pertencem aos k vizinhos mais próximos no espaço original;

$r(i,j)$ = posição (posto) do ponto j na lista ordenada de vizinhos do ponto i no espaço original.

A métrica Confiabilidade (Trustworthiness) avalia o quão bem um método de redução de dimensionalidade preserva as relações de vizinhança local ao projetar dados de alta dimensionalidade em um espaço de menor dimensionalidade. Valores de Trustworthiness próximos de 1,0 indicam que a representação reduzida preserva com elevada fidelidade a estrutura de vizinhança local, ou seja, pontos que são vizinhos no espaço original permanecem vizinhos na representação de baixa dimensionalidade. Valores entre 0,80 e 0,95 sugerem preservação moderada das relações de vizinhança, indicando que a maior parte da estrutura local é mantida, embora algumas distorções possam ocorrer. Quando os valores de Trustworthiness são inferiores a 0,80, a representação apresenta distorções significativas na vizinhança, indicando que muitos pontos que aparecem próximos na representação de baixa dimensionalidade não eram vizinhos no espaço original de alta dimensionalidade [34, 39].

2.4.1.4 Precisão (Precision)

A Precisão (Precision) é uma métrica de classificação que mede a fração das instâncias preditas como positivas que são efetivamente positivas, refletindo a confiabilidade das predições positivas de um modelo de aprendizado de máquina.

A Precisão é definida por:

$$\text{Precision} = \frac{TP}{TP+FP} \tag{92}$$

em que:

TP (True Positives): instâncias positivas corretamente classificadas como positivas;

FP (False Positives): instâncias negativas incorretamente classificadas como positivas.

A métrica Precisão mede a proporção de instâncias positivas corretamente preditas entre todas as instâncias classificadas como positivas por um modelo de classificação. Um valor de Precisão igual a 1,0 indica que todos os casos preditos como positivos estão corretos, ou seja, o modelo não produz falsos positivos. Valores entre 0,8 e 0,9 indicam elevada confiabilidade das predições positivas, sugerindo que a maioria das instâncias classificadas como positivas pertence de fato à classe positiva. Quando a precisão é inferior a 0,5, o modelo gera um grande número de falsos positivos, indicando que uma parcela substancial dos casos preditos como positivos é incorreta [34, 40–41].

2.4.1.5 Medida C (C-Measure)

A Medida C (C-Measure) quantifica a consistência entre as ordenações das distâncias par a par no espaço original e no espaço reduzido por meio da matriz de co-ranking. Essa métrica avalia o grau em que as relações de vizinhança locais e globais são preservadas simultaneamente após a redução de dimensionalidade. A medida é derivada da estrutura de co-ranking, que analisa como a ordenação dos pares de pontos se altera após a projeção.

Uma matriz de co-ranking, Q , é construída de modo que:

Cada elemento da matriz contabiliza o número de vezes em que um par de pontos possui posto k no espaço original e posto l na representação de baixa dimensionalidade. A Medida C (C-Measure) avalia quanto da massa dessa matriz está concentrada próxima à diagonal principal, indicando que a ordenação dos pares de pontos foi preservada.

A Medida C (C-Measure) avalia o quão bem um método de redução de dimensionalidade preserva a estrutura de vizinhança dos dados ao projetá-los de um espaço de alta dimensionalidade para uma representação de baixa dimensionalidade. Valores da Medida C próximos de 1,0 indicam forte preservação da estrutura de

vizinhança, o que significa que as relações entre pontos próximos no espaço original são amplamente preservadas na representação reduzida. Valores entre 0,5 e 0,8 sugerem preservação moderada, indicando que uma parcela significativa das relações de vizinhança é preservada, embora algumas distorções possam ocorrer. Quando a Medida C é inferior a 0,5, a representação apresenta distorções substanciais, indicando que muitas das relações de vizinhança existentes no espaço original não são preservadas na representação de baixa dimensionalidade [34].

2.4.2 Medidas de Qualidade: Métricas Orientadas à Conectividade

2.4.2.1 Qualidade Global (Q_{global})

A Qualidade Global (Q_{global}) é uma métrica de avaliação da redução de dimensionalidade que quantifica o quão bem as relações em larga escala e a geometria global do conjunto de dados original são preservadas na representação de baixa dimensionalidade. Em contraste com a Qualidade Local (Q_{local}), que se concentra na preservação dos vizinhos mais próximos, a Q_{global} avalia se pontos que estão distantes no espaço original permanecem distantes na representação reduzida. Dessa forma, a Q_{global} reflete a capacidade de um método de redução de dimensionalidade em preservar a organização global dos agrupamentos, das variedades (manifolds) e das tendências presentes nos dados.

A Q_{global} é normalmente calculada por meio da comparação entre os conjuntos dos k vizinhos mais próximos no espaço original e no espaço reduzido. Para cada ponto i, procede-se da seguinte forma:

- Determinam-se os k vizinhos mais próximos no espaço de alta dimensionalidade;

- Determinam-se os k vizinhos mais próximos na representação em baixa dimensionalidade;
- Calcula-se a sobreposição entre esses conjuntos de vizinhos.

Uma forma geral dessa métrica pode ser escrita como:

em que:

N = número de pontos de dados;

$N_k^{high}(i)$= conjunto dos k vizinhos mais próximos do ponto i no espaço original;

$N_k^{low}(i)$= conjunto dos k vizinhos mais próximos na representação em baixa dimensionalidade.

A métrica Qualidade Global (Q_{global}) avalia o quão bem um método de redução de dimensionalidade preserva a estrutura global dos dados ao projetá-los de um espaço de alta dimensionalidade para uma representação de baixa dimensionalidade. Valores de Q_{global} próximos de 1,0 indicam excelente preservação das relações globais, o que significa que a organização geral e as distâncias relativas entre os pontos no espaço original são amplamente mantidas na representação reduzida. Valores entre 0,6 e 0,8 sugerem preservação moderada da estrutura global, indicando que a organização geral dos dados é razoavelmente preservada, embora algumas distorções possam ocorrer. Quando os valores de Q_{global} são inferiores a 0,5, a representação apresenta forte distorção das relações globais, o que implica que a estrutura em grande escala do conjunto de dados é pouco preservada no espaço de dimensionalidade reduzida [34].

2.4.2.2 Continuidade (Continuity)

A Continuidade (Continuity) quantifica o grau em que um método de redução de dimensionalidade deixa de preservar os vizinhos originais, penalizando situações em que vizinhos reais no espaço de alta dimensionalidade são projetados para posições distantes

na representação em baixa dimensionalidade. Em outras palavras, essa métrica avalia os vizinhos perdidos, isto é, pontos que eram próximos nos dados originais, mas deixaram de ser vizinhos após a projeção.

A Continuidade é, portanto, complementar à métrica Confiabilidade (Trustworthiness). Enquanto a Continuidade penaliza os vizinhos verdadeiros que deixam de ser preservados após a projeção, a Confiabilidade penaliza os falsos vizinhos introduzidos pela representação em baixa dimensionalidade.

A Continuidade (Continuity) é definida por:

$$C(k) = 1 - \frac{2}{Nk(2N-3k-1)} \sum_{i=1}^{N} \sum_{j\ \varepsilon\ V_k(i)} (r'(i,j) - k) \quad (93)$$

em que:

N = número de amostras;

k = tamanho da vizinhança;

$V_k(i)$= conjunto de pontos que pertencem aos k-vizinhos mais próximos do ponto i no espaço original, mas não pertencem aos k-vizinhos mais próximos na representação em baixa dimensionalidade;

$r'(i,j)$= posto do ponto j em relação ao ponto i na representação em baixa dimensionalidade.

A métrica Continuidade (Continuity) avalia o grau em que os vizinhos no espaço original de alta dimensionalidade permanecem vizinhos após a redução de dimensionalidade. Valores de Continuidade próximos de 1,0 indicam que as relações de vizinhança originais são preservadas com elevada fidelidade na representação reduzida, ou seja, pontos próximos no espaço de alta dimensionalidade tendem a permanecer próximos na representação em baixa dimensionalidade. Valores entre 0,80 e 0,95 sugerem preservação moderada das relações de vizinhança, indicando que a maior parte da estrutura local original é mantida, embora alguns vizinhos possam ser deslocados durante

a projeção. Quando os valores de Continuidade são inferiores a 0,80, a representação apresenta perda significativa das relações de vizinhança, indicando que muitos pontos que originalmente eram vizinhos deixam de permanecer próximos no espaço de dimensionalidade reduzida [34].

2.4.2.3 Descontinuidade (Discontinuity)

A Descontinuidade (Discontinuity) é o complemento da Continuidade: quantifica com que frequência pontos que eram vizinhos no espaço original de alta dimensionalidade deixam de ser vizinhos após a projeção. Em outras palavras, a representação torna-se descontínua em relação à topologia original, porque pontos que estavam próximos entre si acabam separados. Ela é obtida diretamente como Descontinuidade = 1 − Continuidade e, portanto, penaliza os vizinhos perdidos, enquanto a Confiabilidade (Trustworthiness) penaliza os falsos vizinhos introduzidos pela representação em baixa dimensionalidade.

A métrica Descontinuidade (Discontinuity) avalia o grau em que as relações de vizinhança são perturbadas quando os dados são projetados de um espaço de alta dimensionalidade para uma representação em baixa dimensionalidade. Valores de Descontinuidade próximos de 0 indicam que a representação preserva adequadamente a estrutura de vizinhança, ou seja, pontos próximos no espaço original permanecem próximos na representação reduzida. Valores entre 0,1 e 0,3 indicam distorções moderadas, sugerindo que algumas relações de vizinhança são alteradas durante o processo de redução de dimensionalidade. Quando os valores de Descontinuidade são superiores a 0,3, a representação apresenta fortes distorções da vizinhança, indicando que muitos pontos que eram vizinhos no espaço original de alta dimensionalidade deixam de estar próximos na representação em baixa dimensionalidade [34].

2.4.2.4 Sensibilidade (Recall)

A Sensibilidade (Recall) quantifica a eficácia com que um classificador identifica as instâncias positivas. Assim, essa métrica avalia a capacidade do modelo de evitar falsos negativos, isto é, casos positivos incorretamente classificados como negativos.

A Sensibilidade (Recall) é definida por:

$$\text{Recall} = \frac{TP}{TP+FN} \tag{94}$$

em que:

TP (True Positives): instâncias positivas corretamente classificadas como positivas;

FN (False Negatives): instâncias positivas incorretamente classificadas como negativas.

A Sensibilidade (Recall) é uma métrica de desempenho de classificação que mede a proporção de instâncias realmente positivas corretamente identificadas por um modelo de aprendizado de máquina, refletindo sua capacidade de detectar casos positivos. Em outras palavras, a sensibilidade quantifica a fração das instâncias positivas reais que o modelo reconhece corretamente.

Um valor de sensibilidade igual a 1,0 indica que todas as instâncias positivas foram detectadas, ou seja, o modelo identifica corretamente todos os casos da classe positiva. Valores entre 0,80 e 0,90 indicam uma elevada taxa de detecção, sugerindo que a maior parte das instâncias positivas é corretamente reconhecida pelo modelo. Quando a Sensibilidade assume valores inferiores a 0,50, o modelo deixa de detectar muitas instâncias positivas, indicando que uma parcela substancial dos verdadeiros positivos não é identificada [34, 40–41].

2.4.2.5 Tau de Kendall (τ)

O Tau de Kendall (τ) é uma métrica de correlação por postos que mede o grau de concordância entre duas ordenações por meio da comparação entre o número de pares concordantes e discordantes. Essa métrica é amplamente utilizada no aprendizado de máquina para avaliar a consistência das ordenações e a preservação da estrutura dos dados. Assim, o Tau de Kendall quantifica a associação entre duas variáveis ordenadas comparando o número de pares de observações concordantes e discordantes.

Considere duas ordenações, *X* e *Y*, de *n* observações.

Para cada par de observações (*i*,*j*):

Um par concordante (C) ocorre quando a ordem relativa do par é a mesma em ambas as ordenações.

Um par discordante (D) ocorre quando a ordem relativa do par é invertida entre as duas ordenações.

O Tau de Kendall (τ) é definido por:

$$\tau = \frac{C-D}{\frac{1}{2}n(n-1)} \tag{95}$$

em que:

C = número de pares concordantes;

D = número de pares discordantes;

n = número de observações.

O denominador corresponde ao número total de pares possíveis.

O coeficiente Tau de Kendall (τ) mede o grau de concordância entre duas ordenações, avaliando a correspondência entre os pares ordenados de observações. Um valor de τ igual a +1 indica concordância perfeita entre as ordenações, significando que todos os pares de observações apresentam a mesma ordem relativa em ambas as classificações. Um valor igual a 0 indica ausência de correlação, sugerindo que as duas

ordenações são independentes e não compartilham um padrão consistente de ordenação. Um valor igual a −1 representa ordenação inversa perfeita, o que significa que a ordem relativa de todos os pares de observações é completamente invertida entre as duas ordenações [42].

2.4.2.6 Correlação Cofenética

O coeficiente de correlação cofenética mede a correlação entre as distâncias originais entre pares de observações e as distâncias cofenéticas obtidas a partir de um dendrograma de agrupamento hierárquico. A distância cofenética entre duas observações é definida como a altura do dendrograma em que são reunidas pela primeira vez em um único grupo. Assim, a correlação cofenética quantifica o quão bem a estrutura do agrupamento hierárquico representa as dissimilaridades presentes no conjunto de dados original.

O coeficiente de correlação cofenética (CCC, Cophenetic Correlation Coefficient) é calculado como o coeficiente de correlação de Pearson entre essas duas matrizes de distâncias:

$$CCC = \frac{\sum_{i<j}(d(i,j)-\bar{d})(d_c(i,j)-\overline{d_c})}{\sqrt{\sum_{i<j}(d(i,j)-\bar{d})^2}\sqrt{\sum_{i<j}(d_c(i,j)-\overline{d_c}d(i,j)-\bar{d})^2}} \quad (96)$$

em que:

$d(i,j)$= distância original entre as observações i e j;

$d_c(i,j)$= distância cofenética entre as observações i e j no dendrograma;

$\bar{d}$ = média das distâncias originais;

$\bar{d}_c$= média das distâncias cofenéticas.

O coeficiente de correlação cofenética (CCC) avalia o quão bem um dendrograma de agrupamento hierárquico preserva as distâncias aos pares do conjunto de dados

original. Valores do CCC superiores a 0,90 indicam uma excelente representação da estrutura dos dados, o que significa que o dendrograma reflete com elevada fidelidade as relações reais entre as observações. Valores entre 0,75 e 0,90 indicam uma boa representação do agrupamento, sugerindo que o dendrograma captura a maior parte das relações estruturais presentes no conjunto de dados. Quando o coeficiente se encontra entre 0,50 e 0,75, o agrupamento fornece apenas uma representação moderada da estrutura dos dados, indicando a presença de algumas distorções. Valores inferiores a 0,50 caracterizam uma representação insatisfatória, indicando que o dendrograma não representa adequadamente as relações originais entre os pares de observações [34, 37, 43–44].

2.4.3 Medidas de Qualidade: Não Generalizáveis

2.4.3.1 RMSE de Reconstrução

O RMSE de Reconstrução (Reconstruction RMSE) mede a magnitude média da diferença entre os dados originais e os reconstruídos por um modelo. Essa métrica avalia a quantidade de informação perdida durante processos de redução de dimensionalidade ou de codificação–decodificação.

O RMSE de reconstrução é uma métrica que quantifica a raiz do erro quadrático médio entre os dados originais e os dados reconstruídos por um modelo de aprendizado de máquina, fornecendo uma medida da perda de informação decorrente da redução de dimensionalidade ou do aprendizado de representações (representation learning).

O RMSE de reconstrução é definido por:

$$RMSE = \sqrt{\frac{1}{np}\sum_{i=1}^{n}\sum_{j=1}^{p}(x_{ij} - \hat{x}_{ij})^2} \tag{97}$$

em que:

x_i = ponto de dados original;

$\hat{x}_i$ = ponto de dados reconstruído;

n = número de amostras;

p = número de variáveis (atributos);

x_{ij} = valor original;

$\hat{x}_{ij}$ = valor reconstruído.

A métrica RMSE de reconstrução (Reconstruction RMSE) mede a diferença entre os dados originais e os dados reconstruídos após a redução de dimensionalidade ou o aprendizado de representações (representation learning). Valores de RMSE de reconstrução próximos de 0 indicam uma reconstrução praticamente perfeita, ou seja, os dados reconstruídos reproduzem o conjunto de dados original com erro mínimo. Pequenos valores de RMSE indicam baixa perda de informação, sugerindo que a maior parte da estrutura e da variabilidade relevantes dos dados originais é preservada durante o processo de reconstrução. Em contraste, valores elevados de RMSE indicam uma reconstrução insatisfatória dos dados originais, refletindo perda significativa de informação e diferenças substanciais entre os conjuntos de dados reconstruído e original [34, 45–46].

2.4.3.2 Exatidão k-NN

A exatidão *k*-NN (*k*-NN Accuracy) corresponde à acurácia de classificação obtida quando um classificador dos k-Vizinhos Mais Próximos (k-Nearest Neighbors, k-NN) é aplicado ao conjunto de dados original ou à representação em baixa dimensionalidade produzida por um método de redução de dimensionalidade. Essa métrica avalia o quão

bem as amostras de uma mesma classe permanecem próximas entre si no espaço de atributos ou na representação reduzida.

Considere:

y_i = rótulo verdadeiro da classe da amostra i;

$\hat{y}_i$ = classe prevista pelo classificador k-NN;

N = número total de amostras.

A exatidão k-NN é definida por:

$$\text{Accuracy}_{kNN} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}(y_i = \hat{y}_i) \tag{98}$$

em que:

$\mathbf{1}(\cdot)$é a função indicadora, assumindo valor 1 quando a condição é verdadeira e 0 caso contrário.

A exatidão k-NN (k-NN Accuracy) avalia o quão bem uma representação em baixa dimensionalidade preserva a estrutura de classes dos dados originais, medindo a acurácia de classificação obtida por um classificador dos k-Vizinhos Mais Próximos (k-NN) aplicado à representação reduzida. Valores de exatidão k-NN próximos de 1,0 indicam elevada preservação das vizinhanças entre classes, o que significa que amostras pertencentes à mesma classe permanecem próximas entre si na representação de baixa dimensionalidade. Valores entre 0,70 e 0,90 indicam boa preservação da estrutura de classes, sugerindo que a representação reduzida mantém a maior parte das relações de vizinhança associadas às classes. Quando a exatidão k-NN é aproximadamente igual ao desempenho esperado ao acaso (random baseline), a representação em baixa dimensionalidade não preserva a separabilidade entre as classes, indicando que ela não consegue manter a organização das classes presente nos dados originais [34, 47–48].

2.5 Padrões de Desempenho entre Diferentes Classes de Algoritmos

Diferentes famílias de algoritmos de redução de dimensionalidade (RD) tendem a apresentar melhor desempenho em critérios distintos. Uma interpretação estruturada pode ser feita da seguinte forma:

- Algoritmos que preservam a estrutura local: t-SNE, HLLE e Diffusion Maps. Esses métodos geralmente apresentam elevados valores de Q_{local}, confiabilidade (Trustworthiness) e exatidão *k*-NN, embora possam apresentar desempenho inferior na preservação da estrutura global dos dados.
- Algoritmos que preservam a estrutura global: Isomap, MDS, Escalonamento Clássico (Classical Scaling) e Kernel PCA. Esses métodos, em geral, apresentam elevados valores de Q_{global}, AUC R(NX) e Correlação Cofenética.
- Algoritmos lineares e estáveis: PCA, PCA-L1, FastICA e DRR. Esses métodos tendem a produzir baixos valores de RMSE de Reconstrução, altos níveis de continuidade (Continuity) e representações de fácil interpretação. Além disso, DRR e PCA são métodos totalmente invertíveis.
- Algoritmos baseados em grafos: Fruchterman–Reingold, Kamada–Kawai e DrL. Esses métodos proporcionam representações visuais de alta qualidade, com boa separação entre grupos; entretanto, as distorções geométricas e a preservação da estrutura global podem variar significativamente entre si.

2.5.1 Artefatos Comuns e Cuidados Metodológicos

Os usuários devem estar atentos aos artefatos característicos associados às técnicas de redução de dimensionalidade, resumidos na Tabela 26.

Tabela 26. Artefatos Típicos Observados em Algoritmos Comuns de Redução de Dimensionalidade

Algoritmo	Problemas típicos
t-SNE	Superestima a separação entre grupos (clusters); a geometria global é parcialmente relaxada.
Isomap	Sensível ao ruído e a descontinuidades na variedade (manifold), como a presença de "lacunas" (holes).
HLLE	Instável para conjuntos de dados com pequeno número de amostras.
MDS	Forte dependência da métrica de distância utilizada.
PCA	Incapacidade de reconstruir variedades (manifolds) não lineares ou curvas.

2.5.2 Recomendação Prática: Sempre Testar Múltiplos Algoritmos

Uma prática robusta consiste em avaliar pelo menos dois ou três métodos candidatos, por exemplo:

- Preservação da estrutura global: PCA versus Isomap versus Diffusion Maps.
- Preservação da estrutura local: t-SNE versus HLLE.
- Interpretabilidade e invertibilidade: DRR versus PCA versus Kernel PCA.
- Visualização: t-SNE versus DrL.

Cada método candidato deve ser avaliado utilizando o conjunto completo de métricas normalizadas de qualidade.

2.5.3 Como Selecionar um Método Candidato de Redução de Dimensionalidade

A seleção de uma técnica apropriada de redução de dimensionalidade (RD) é, por natureza, um processo orientado pelo objetivo da análise, uma vez que diferentes métodos priorizam distintos aspectos da estrutura dos dados, como variância, distâncias, topologia ou separabilidade entre classes. Na prática, não existe um método universalmente ótimo;

em vez disso, a escolha depende do objetivo da aplicação, seja visualização, agrupamento, reconstrução ou tarefas subsequentes de aprendizado de máquina.

Para auxiliar esse processo de decisão, a Figura 16 apresenta um framework prático que organiza os métodos de redução de dimensionalidade de acordo com seus princípios fundamentais e com o tipo de estrutura que procuram preservar. Ao relacionar os objetivos analíticos às características metodológicas de cada abordagem, esse framework facilita uma seleção mais sistemática e fundamentada das técnicas de redução de dimensionalidade, tanto em análises exploratórias quanto em aplicações preditivas.

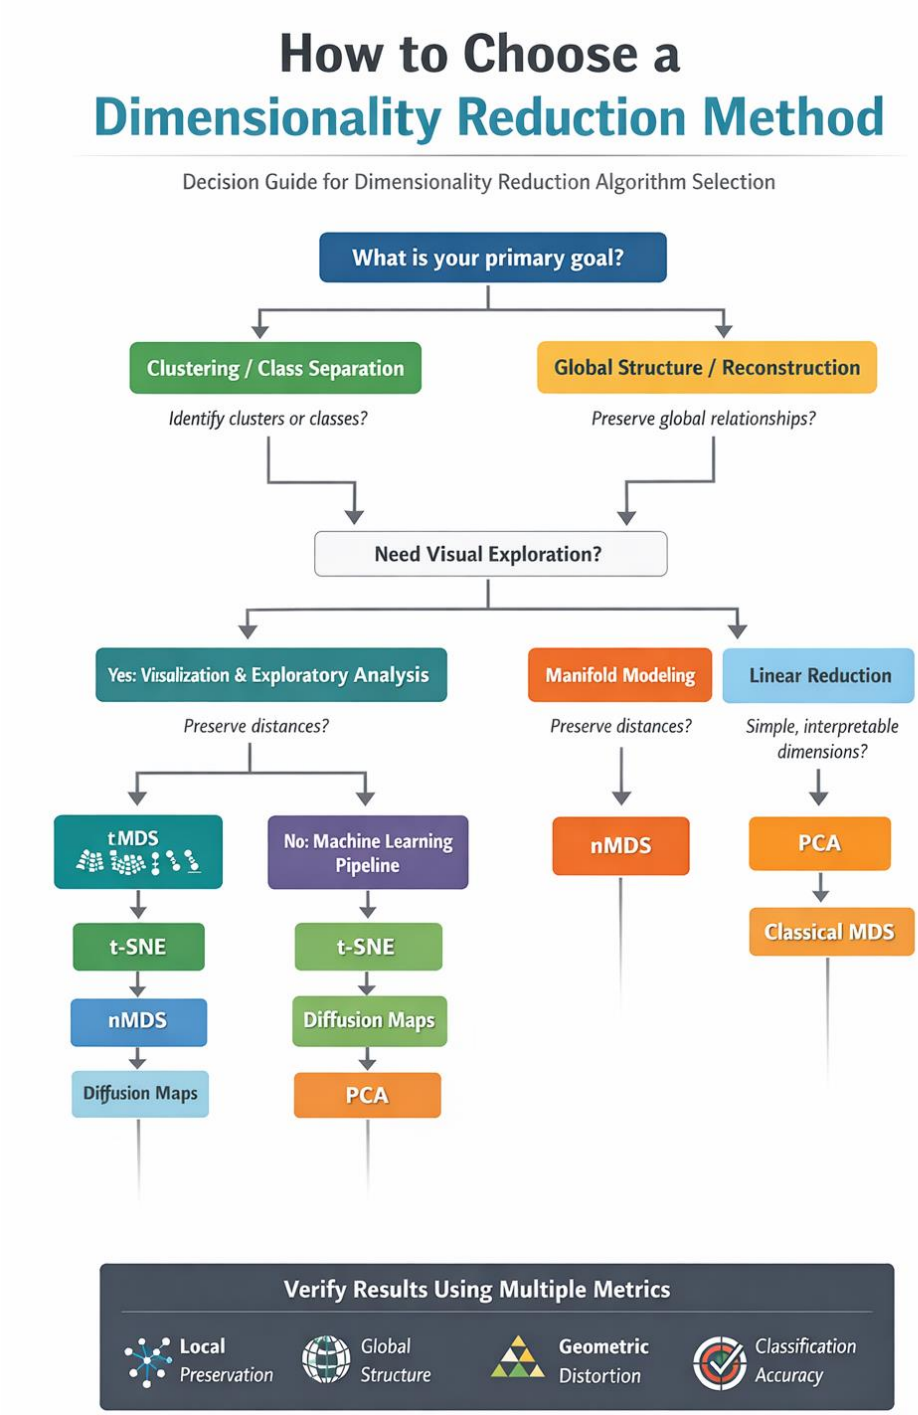


Figura 16 – Framework para seleção de métodos de redução de dimensionalidade.

A Figura 16 apresenta uma árvore de decisão estruturada para orientar a seleção de técnicas de redução de dimensionalidade (RD) com base no principal objetivo da análise. O processo inicia-se pela identificação de se o objetivo é agrupamento/separação entre classes ou preservação da estrutura global/reconstrução. Para tarefas voltadas ao

agrupamento, são recomendados métodos que enfatizam a preservação das vizinhanças locais (por exemplo, t-SNE e Diffusion Maps), enquanto técnicas que preservam distâncias, como t-MDS e nMDS, são preferíveis quando as relações geométricas são mais importantes. Para objetivos relacionados à preservação da estrutura global e à reconstrução, o framework distingue entre métodos de redução linear (por exemplo, PCA e MDS Clássico), que fornecem componentes facilmente interpretáveis, e abordagens de aprendizado de variedades (manifold learning) (por exemplo, nMDS), capazes de capturar relações não lineares. O diagrama também destaca o papel da exploração visual e da integração em pipelines de aprendizado de máquina na escolha do método. Por fim, enfatiza que a qualidade de qualquer representação em baixa dimensionalidade deve ser validada por meio de múltiplos critérios, incluindo preservação da estrutura local, preservação da estrutura global, distorção geométrica e desempenho de classificação.

2.5.4 Construção da Classificação Final dos Algoritmos

O procedimento para estabelecer a classificação final dos algoritmos deve seguir as etapas abaixo:

Normalizar todas as métricas;

- Aplicar pesos de acordo com o objetivo da análise;
- Calcular a soma ponderada das métricas para cada algoritmo;
- Ordenar os algoritmos com base em suas pontuações finais;
- Avaliar a robustez da classificação variando os pesos em ±10%.

2.5.5 Considerações Finais

A estratégia ótima de redução de dimensionalidade resulta da combinação dos seguintes aspectos:

i) definição precisa dos objetivos analíticos (preservação da estrutura local, preservação da geometria global, qualidade da visualização e interpretabilidade);

ii) comparação normalizada baseada em múltiplas métricas, utilizando pesos definidos em função do objetivo da análise;

iii) aplicação de um protocolo sistemático de classificação dos algoritmos;

iv) avaliação empírica dos métodos mais bem classificados; e

v) consideração crítica dos artefatos conhecidos associados a cada método.

Essa abordagem integrada fornece um framework transparente, reprodutível e tecnicamente fundamentado para a seleção de algoritmos de redução de dimensionalidade em uma ampla variedade de aplicações científicas.

3. METODOLOGIA

3.1 Procedimentos de Redução de Dimensionalidade

Foi avaliado um conjunto abrangente de técnicas de redução de dimensionalidade (RD), incluindo métodos de preservação da estrutura global e local. Os métodos voltados à preservação da estrutura global incluíram DRR, Isomap, PCA, PCA-L1, Kernel PCA, FastICA, MDS clássico, MDS não métrico (nMDS), NNMF, DrL, Fruchterman–Reingold e Kamada–Kawai. Os métodos voltados à preservação da estrutura local e ao aprendizado de variedades (manifold learning) incluíram HLLE, Diffusion Maps e t-SNE.

Antes da execução dos algoritmos, a disponibilidade dos pacotes necessários foi verificada automaticamente. Os métodos de RD foram executados por meio de uma função unificada (wrapper), denominada run_dimred(), responsável por padronizar a parametrização dos algoritmos e o tratamento de erros. Em particular, o t-SNE foi implementado utilizando o pacote Rtsne, sendo o valor da perplexidade determinado automaticamente em função do número de amostras. Todos os demais métodos foram implementados por meio da função dimRed::embed(), o que garante uma interface padronizada. Apenas as representações de baixa dimensionalidade geradas com sucesso foram consideradas nas etapas subsequentes de avaliação.

3.2 Estratégias para Avaliação da Qualidade e Cálculo das Métricas

Para cada método de RD foi calculado um conjunto de mais de 13 métricas de avaliação, destinadas a quantificar a preservação da estrutura local, a preservação da estrutura global, a distorção geométrica, a consistência da classificação e o erro de reconstrução (quando aplicável). Essas métricas foram organizadas em quatro grupos conceituais:

i. Preservação da Vizinhança Local: Qlocal, Confiabilidade (Trustworthiness), Precisão (Precision) e Sensibilidade (Recall).

ii. Preservação da Estrutura Global: Qglobal, AUC R(NX), Correlação Cofenética e Tau de Kendall (τ).

iii. Suavidade Geométrica e Distorção: RMSE de Reconstrução (para métodos invertíveis: PCA, Kernel PCA, FastICA e DRR), Descontinuidade (1 − Continuidade), Erro de Classificação de Gabriel (GCE) e Medida C (C-Measure).

iv. Consistência e Separabilidade entre Classes: Exatidão k-NN, Precisão (Precision) e Sensibilidade (Recall).

As métricas de preservação da estrutura local e global (métricas Q) foram calculadas utilizando a função dimRed::quality(), enquanto Continuidade, Confiabilidade (Trustworthiness), Precisão, Sensibilidade, Erro de Classificação de Gabriel (GCE), Medida C (C-Measure) e Tau de Kendall foram obtidos por meio do pacote DRquality. Sempre que uma determinada métrica não pudesse ser calculada devido a restrições específicas de um algoritmo, utilizava-se uma implementação alternativa (fallback). A preservação da estrutura global também foi quantificada por meio do cálculo da curva R(NX), considerando até 30 vizinhos, e a respectiva área sob a curva (AUC R(NX)) foi obtida por integração numérica, pela regra dos trapézios. Todas as métricas foram reunidas em uma única tabela mestre, utilizada para a classificação e comparação dos algoritmos.

3.3 Esquemas de Ponderação de Acordo com os Objetivos Analíticos

Após a normalização, as métricas devem ser agregadas com pesos que reflitam o objetivo da análise. Os esquemas de ponderação recomendados são os seguintes:

a) Agrupamento e análise da estrutura local

- Estrutura local: 0,50
- Estrutura global: 0,20
- Suavidade geométrica: 0,15
- Classificação k-NN: 0,15

b) Reconstrução física e modelagem de variedades (manifolds)

- Estrutura local: 0,30
- Estrutura global: 0,30
- Geometria/suavidade: 0,40

c) Visualização exploratória

- Estrutura local: 0,40
- Estrutura global: 0,20
- Qualidade do layout/estabilidade: 0,40

d) Pipelines de aprendizado de máquina

- Estrutura local: 0,40
- Estabilidade da classificação: 0,40
- Estrutura global: 0,20

A pontuação final de cada algoritmo é, portanto, dada por:

$$\text{Final score} = \sum_i(\text{weight}_i \times \text{normalized metric}) \quad (99)$$

3.4 Normalização das Métricas e Construção dos Índices

Para possibilitar comparações justas entre métricas com escalas heterogêneas, todas foram normalizadas para o intervalo [0,1], ajustando-se suas escalas para que fosse possível identificar se valores maiores ou menores indicam melhor desempenho. As métricas foram classificadas da seguinte forma:

- Quanto maior, melhor:

  - Qlocal;
  - Qglobal;
  - AUC R(NX);
  - Correlação Cofenética;
  - Confiabilidade (Trustworthiness);
  - Precisão (Precision);
  - Sensibilidade (Recall);
  - Tau de Kendall (τ);
  - Exatidão k-NN.

- Quanto menor, melhor:

  - RMSE de Reconstrução;
  - Descontinuidade;
  - Erro de Classificação de Gabriel (GCE);
  - Medida C (C-Measure).

A partir das métricas normalizadas, foram calculados índices compostos representando o desempenho em cada família de métricas:

- Índice Local (IndexLocal): média das métricas locais;
- Índice Global (IndexGlobal): média das métricas globais;
- Índice Geométrico (IndexGeom): média das métricas de distorção geométrica;
- Índice de Classificação (IndexClass): média das métricas de classificação.

3.5 Classificação dos Métodos de Redução de Dimensionalidade Baseada em Cenários

Para representar a diversidade de aplicações práticas da redução de dimensionalidade, foram definidos quatro cenários de utilização:

- Agrupamento e preservação da topologia;
- Reconstrução e mapeamento invertível;
- Visualização e separação entre classes;
- Representação para pipelines de aprendizado de máquina.

Cada cenário foi associado a um conjunto de pesos que atribuiu diferentes importâncias relativas aos índices Local, Global, Geométrico e de Classificação. Para cada método de RD e para cada cenário foi calculada uma pontuação global (Score Final), a partir da qual foi estabelecida a classificação dos algoritmos.

Para avaliar a robustez da metodologia proposta, os pesos foram perturbados em ±10%, gerando diferentes combinações de pontuações. A média dessas pontuações foi utilizada como valor final de cada algoritmo.

Adicionalmente, foi realizada uma meta-análise para identificar, em cada cenário, a métrica mais consistente, definida como a que apresentou a maior correlação absoluta de Spearman entre as classificações induzidas pelas diferentes métricas. Em seguida, foi identificado o algoritmo com melhor desempenho nessa métrica. Essa abordagem dupla permitiu identificar simultaneamente:

- o método de redução de dimensionalidade mais adequado para cada cenário;
- o algoritmo campeão para a métrica considerada mais representativa.

3.6 Visualização dos Métodos Ótimos

Para cada cenário foram produzidas duas representações gráficas:

- um gráfico de dispersão da representação em baixa dimensionalidade produzida pelo método que maximizou a métrica mais representativa daquele cenário;
- um gráfico de barras que apresenta a classificação dos métodos de RD, ordenados por suas pontuações compostas finais.

Essas visualizações possibilitaram avaliações tanto qualitativas quanto quantitativas da qualidade da representação de baixa dimensionalidade, da separabilidade entre as classes e da preservação global da estrutura dos dados.

3.7 Resumo das Saídas Geradas

O fluxo computacional produziu:

- uma tabela abrangente contendo todas as métricas calculadas para todos os métodos de redução de dimensionalidade executados com sucesso;
- uma lista de resultados para cada cenário (results_obj), contendo:
- a classificação completa dos métodos de RD;
- a métrica mais consistente para o cenário;
- o algoritmo campeão dessa métrica;
- os respectivos gráficos de visualização das representações em baixa dimensionalidade e da classificação dos algoritmos.

Esses componentes possibilitaram uma avaliação rigorosa, multicritério e orientada ao objetivo analítico das técnicas de redução de dimensionalidade.

3.8 Estratégia Proposta para Seleção da Melhor Métrica

A função best_metric_and_champion implementa uma estratégia orientada por dados para identificar a métrica que melhor representa o consenso global entre diversos critérios concorrentes de qualidade e, a partir dela, selecionar o melhor método de redução de dimensionalidade.

Inicialmente, a análise é restrita ao subconjunto de métricas previamente classificadas como "quanto maior, melhor" ou "quanto menor, melhor". Esses conjuntos, definidos externamente (larger_better e smaller_better), são intersectados com os nomes das colunas do objeto all_metrics, produzindo uma matriz (mat) cujas linhas representam os algoritmos avaliados e cujas colunas correspondem às métricas de desempenho. Esse procedimento garante que apenas índices interpretáveis, com direção de otimização claramente definida, sejam utilizados no processo de classificação.

Na etapa seguinte, essa matriz é convertida para o formato longo (long format), em que cada linha contém um algoritmo, uma métrica e seu respectivo valor. Para cada métrica, o algoritmo identifica automaticamente a direção de otimização (maximização ou minimização) e converte seus valores em posições de classificação (ranks) utilizando a função auxiliar rank_dir. Nesse esquema, posto igual a 1 corresponde sempre ao melhor algoritmo para aquela métrica, independentemente de ela exigir maximização ou minimização. O resultado é uma matriz de classificações em que cada coluna representa a ordenação dos algoritmos segundo uma métrica específica.

A ideia central do procedimento baseia-se na concordância entre as métricas. Para isso, calcula-se a matriz de correlação de Spearman entre todas as colunas da matriz de classificações, o que quantifica o grau de similaridade entre as ordenações produzidas pelas diferentes métricas. Em seguida, considera-se o valor absoluto dessas correlações,

uma vez que interessa apenas a intensidade da concordância, independentemente de sua direção.

Para cada métrica, calcula-se a média das correlações absolutas com as demais métricas, interpretada como um índice de consistência. Valores elevados desse índice indicam que a ordenação produzida por determinada métrica apresenta, em média, elevada concordância com as classificações obtidas pelas demais métricas.

A melhor métrica é definida como aquela que apresenta a maior média das correlações absolutas de Spearman, isto é, a métrica cuja classificação é mais consistente com o padrão multivariado global. Esse critério privilegia métricas que atuam como indicadores robustos de consenso, em vez de métricas cujas classificações divergem substancialmente das demais.

Uma vez identificada a melhor métrica, o algoritmo campeão é determinado de maneira direta: caso a métrica pertença ao grupo "quanto maior, melhor", seleciona-se o algoritmo que apresenta o maior valor; caso pertença ao grupo "quanto menor, melhor", seleciona-se o algoritmo que apresenta o menor valor.

Em síntese, o procedimento não privilegia arbitrariamente um único índice de qualidade. Em vez disso, constrói um consenso interno entre todas as métricas disponíveis no espaço de classificação (rank space) e seleciona a que melhor o representa. O algoritmo correspondente torna-se, então, o método campeão, proporcionando um procedimento transparente, fundamentado e reproduzível para selecionar simultaneamente o critério de avaliação mais representativo e a técnica de redução de dimensionalidade mais adequada.

3.9 Aplicação da Metodologia Proposta

A validação do framework metodológico proposto requer o uso de conjuntos de dados de referência (benchmark datasets) que sejam simultaneamente diversificados e

bem caracterizados, permitindo uma avaliação sistemática e reprodutível do desempenho das técnicas de redução de dimensionalidade. Nesse contexto, foram utilizados conjuntos de dados públicos do UCI Machine Learning Repository. Esse repositório é amplamente reconhecido pela comunidade de aprendizado de máquina como uma fonte confiável de bases de dados cuidadosamente organizadas, abrangendo uma ampla variedade de domínios, estruturas de dados e níveis de complexidade. Seu uso extensivo na literatura científica favorece a comparabilidade dos resultados e fortalece a validade externa.

Os conjuntos de dados selecionados possuem duas ou mais classes previamente definidas e estão predominantemente associados a problemas de classificação supervisionada. Essa característica é fundamental para o presente estudo, pois permite incorporar ao framework de avaliação métricas dependentes das classes, como exatidão, precisão, sensibilidade e preservação das vizinhanças. Como a estrutura verdadeira das classes é conhecida a priori, é possível avaliar rigorosamente não apenas a preservação geométrica e topológica dos dados, mas também o grau de separabilidade entre as classes mantida após a redução de dimensionalidade.

Além disso, a diversidade dos conjuntos de dados selecionados — que variam em dimensionalidade, número de amostras e estrutura intrínseca — fornece um ambiente abrangente para avaliar a robustez e a capacidade de generalização da estratégia proposta. A escolha deliberada de bases voltadas à classificação permite investigar simultaneamente métricas de qualidade relacionadas à compacidade, à conectividade e à não generalização dentro de um único framework de avaliação.

Esses conjuntos de dados são empregados como estudos de caso ilustrativos, destinados a demonstrar a aplicabilidade prática da metodologia proposta. Os resultados são apresentados e discutidos sistematicamente nas seções subsequentes, organizadas como Estudos de Caso I a VII, nas quais cada caso enfatiza diferentes aspectos do

processo de avaliação e o comportamento das técnicas de redução de dimensionalidade sob distintas características dos dados.

3.10 Hardware e Software

As análises estatísticas foram realizadas em um computador pessoal equipado com processador AMD Ryzen 9 7900X, unidade de armazenamento SSD M.2 NVMe Western Digital de 1 TB, 128 GB de memória RAM Kingston Fury Beast DDR5 6000, placa-mãe ASUS Prime X670E-PRO WIFI e placa de vídeo MSI GeForce RTX 5090 VENTUS OC 3X com 32 GB de memória.

Neste trabalho, foram utilizados o R, versão 4.5.1 (2025-06-13) [49], e o RStudio, versão 2025.09.1 [50], ambos executados no sistema operacional Windows de 64 bits.

3.11 Pacotes

A Tabela 27 apresenta uma visão abrangente dos pacotes da linguagem R utilizados ao longo deste trabalho, destacando suas principais funcionalidades e as respectivas referências bibliográficas. A seleção desses pacotes reflete a natureza multidisciplinar da metodologia proposta, que integra pré-processamento de dados, visualização, redução de dimensionalidade, agrupamento e avaliação quantitativa em um único framework analítico.

O ecossistema do R fornece uma plataforma robusta e flexível para a implementação de fluxos de trabalho avançados de aprendizado de máquina e quimiometria. Nesse contexto, pacotes como ggplot2 e dplyr oferecem suporte à visualização e manipulação de dados, fundamentados, respectivamente, na Gramática dos Gráficos (Grammar of Graphics) e nos princípios de dados organizados (tidy data).

Ferramentas complementares, como tidyr, readr e stringr, facilitam o tratamento, a organização e a transformação eficiente dos dados.

Pacotes especializados desempenham um papel central na implementação e na avaliação de técnicas de redução de dimensionalidade. Por exemplo, Rtsne, kernlab, diffusionMap e fastICA disponibilizam implementações de importantes métodos de projeção linear e não linear. Além disso, DRquality e coRanking são essenciais para o cálculo de métricas de qualidade, como Confiabilidade (Trustworthiness) e Continuidade (Continuity), bem como de índices baseados em co-ranking, que constituem elementos centrais da estratégia de avaliação proposta neste livro.

Adicionalmente, pacotes como igraph e RANN possibilitam modelagem eficiente baseada em grafos e cálculos rápidos de vizinhança, enquanto RSpectra e Matrix oferecem suporte a operações escaláveis de álgebra linear numérica necessárias para a análise de conjuntos de dados de alta dimensionalidade.

Em conjunto, os pacotes apresentados na Tabela 27 constituem uma infraestrutura computacional coesa que assegura reprodutibilidade, escalabilidade e rigor metodológico na aplicação das técnicas de redução de dimensionalidade e de suas respectivas métricas de avaliação.

Tabela 27 – Pacotes da linguagem R: funcionalidades e referências

Pacote	Principais funcionalidades	Referência
ggplot2	Gramática dos gráficos para visualização de dados	[51]
readr	Importação rápida de dados	[52]
dplyr	Gramática para manipulação de dados	[53]
Corrplot	Visualização de matrizes de correlação	[54]

Pacote	Principais funcionalidades	Referência
coRanking	Métricas de qualidade para redução de dimensionalidade	[4]
psych	Métodos psicométricos e análise fatorial	[55]
GGally	Extensões do ggplot2, incluindo gráficos de relações pareadas	[56]
purrr	Ferramentas para programação funcional	[57]
tidyr	Organização e estruturação de dados (data tidying)	[58]
writexl	Escrita de arquivos Excel	[59]
stringr	Manipulação de cadeias de caracteres	[60]
rlang	Infraestrutura para avaliação tidy	[61]
farff	Leitura de arquivos ARFF	[62]
readxl	Leitura de arquivos Excel	[63]
magrittr	Operadores pipe para composição de fluxos funcionais	[64]
DRquality	Métricas de qualidade para redução de dimensionalidade	[65]
ProjectionBasedClustering	Ferramentas para agrupamento baseado em projeções	[66]
FastKNN	Busca eficiente dos k-vizinhos mais próximos (k-NN)	[67]
FCPS	Conjuntos de dados de referência para agrupamento	[68]

Pacote	Principais funcionalidades	Referência
pcaPP	Análise de Componentes Principais robusta	[69]
cccd	Construção de grafos de proximidade	[70]
spdep	Análise de dependência espacial	[71]
fastICA	Análise de Componentes Independentes (ICA)	[72]
Rtsne	Implementação do algoritmo t-SNE	[73]
vegan	Métodos de ordenação ecológica, incluindo nMDS	[74]
diffusionMap	Implementação de Diffusion Maps	[75]
pcaL1	PCA baseada na norma L1	[76]
DRR	Redução de Dimensionalidade via Regressão	[77]
igraph	Análise de redes e algoritmos de layout	[78–80]
kernlab	Métodos de kernel, incluindo Kernel PCA	[81–82]
RANN	Busca aproximada dos vizinhos mais próximos	[83]
Matrix	Manipulação de matrizes esparsas	[84]
RSpectra	Decomposição espectral em larga escala	[85]
MASS	Métodos estatísticos e MDS clássico	[86]

3.12 Ambiente de Software, Controles de Reprodutibilidade e Funções Utilitárias

Todas as análises foram realizadas na linguagem R, utilizando um framework integrado para redução de dimensionalidade (RD), avaliação da qualidade e comparação

de algoritmos baseada em métricas. Para assegurar a reprodutibilidade completa dos resultados, foi estabelecida uma semente pseudoaleatória fixa por meio do gerador Mersenne–Twister, utilizando o comando set.seed(123).

Todos os pacotes necessários foram carregados com as mensagens de inicialização suprimidas, garantindo um ambiente de execução controlado. O fluxo de trabalho baseia-se principalmente nos pacotes dimRed, DRquality, RANN, ggplot2, purrr, dplyr, tidyr e em bibliotecas adicionais específicas para redução de dimensionalidade, como Rtsne, vegan, igraph, kernlab, pcaL1, fastICA e MASS.

Foi desenvolvido um conjunto de funções utilitárias personalizadas para padronizar a extração de dados e o cálculo das métricas de qualidade entre as diferentes técnicas de redução de dimensionalidade, incluindo:

- get_coords2d() — extrai a representação bidimensional dos objetos produzidos pelas diferentes rotinas de redução de dimensionalidade;
- get_label_vec() — recupera automaticamente os rótulos de classes ou grupos, quando disponíveis no conjunto de dados;
- get_knn_idx() — calcula os (k)-vizinhos mais próximos no espaço original utilizando a biblioteca RANN;

rn_curve() e auc_trapz_norm() — calculam, respectivamente, a curva R(NX) e sua correspondente área normalizada sob a curva (AUC), utilizada como métrica de preservação da estrutura global;

trust_continuity() — implementação alternativa (fallback) para o cálculo das métricas Confiabilidade (Trustworthiness) e Continuidade (Continuity) nos casos em que essas métricas não podem ser obtidas por meio do pacote DRquality.

4. ESTUDO DE CASO I

4.1 Descrição do Conjunto de Dados

O banco de dados Diagnostic Wisconsin Breast Cancer Database foi denominado df1. Ele contém 569 instâncias, 30 variáveis (atributos) e duas classes. As variáveis foram obtidas a partir de uma imagem digitalizada de uma punção aspirativa por agulha fina (Fine Needle Aspirate – FNA) de uma massa mamária e descrevem as características dos núcleos celulares presentes na imagem [87].

4.2 Resultados e Discussão

O mapa de calor de correlação, apresentado na Figura 17, resume as relações entre as principais métricas de avaliação empregadas para medir o desempenho das técnicas de redução de dimensionalidade (RD).

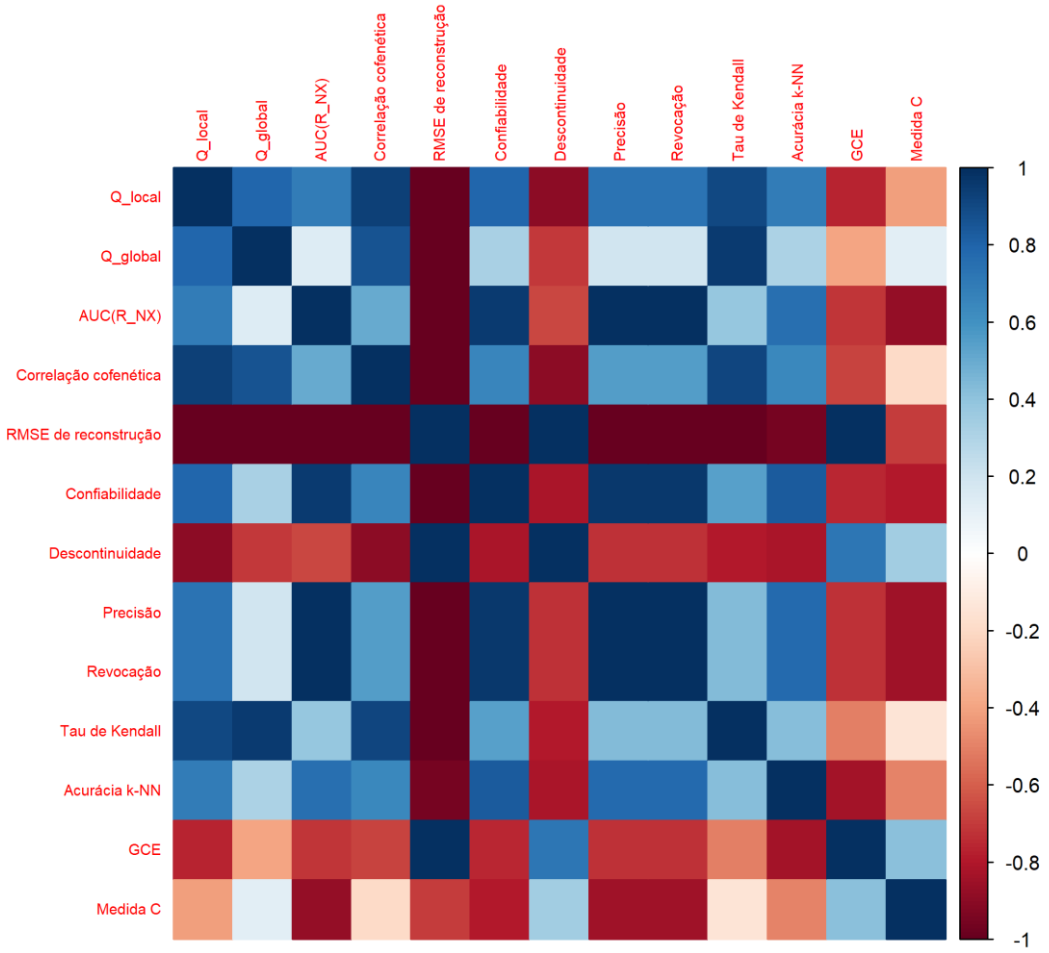


Figura 17 – Estrutura da matriz de correlação entre as métricas de avaliação utilizadas no framework de benchmarking.

Dois agrupamentos coerentes emergem: um composto pelas métricas orientadas à preservação da vizinhança local (Qlocal, Trustworthiness, Precision, Recall e Accuracy_kNN) e outro pelas métricas voltadas à preservação da estrutura global (Qglobal, AUC_R(NX), Cophenetic e Kendall Tau), ambos com fortes correlações positivas entre si. Esse padrão indica que as métricas de cada grupo capturam aspectos complementares, porém internamente consistentes, da preservação da estrutura da variedade (manifold). Em contraste, os critérios baseados em reconstrução e distorção (RMSE_Reconstruction, Discontinuity, GCE e C_measure) exibem correlações negativas

acentuadas com os grupos de preservação local e global, revelando um compromisso (trade-off) inerente ao desempenho das técnicas de redução de dimensionalidade: métodos que enfatizam a fidelidade topológica ou a preservação das vizinhanças tendem a apresentar maior erro de reconstrução, enquanto algoritmos otimizados para reconstrução tendem a distorcer a geometria da variedade. De modo geral, a figura reforça a natureza multidimensional da avaliação de técnicas de redução de dimensionalidade e destaca a importância de selecionar métricas compatíveis com o objetivo analítico pretendido.

Os resultados resumidos na Tabela 28A e na Tabela 28B apresentam uma comparação abrangente dos algoritmos de redução de dimensionalidade, com base em métricas de avaliação complementares. Métodos convexos e baseados em grafos, como DRR, PCA/MDS, Isomap e nMDS, demonstram desempenho consistentemente elevado tanto nas métricas de preservação local (Qlocal e Trustworthiness) quanto nas de preservação da estrutura global (Qglobal, AUC_R(NX), Cophenetic e Kendall Tau). Esses métodos também alcançam elevada acurácia do classificador k-NN e valores equilibrados de Precisão e Revocação (Recall), indicando uma preservação estável da topologia das vizinhanças em todo o espaço de projeção.

Métodos não lineares, como o t-SNE, destacam-se especificamente nas métricas relacionadas à preservação da vizinhança local e nos índices de precisão e revocação, porém apresentam desempenho inferior na preservação da estrutura global, em concordância com sua concepção voltada principalmente para a separabilidade visual dos dados, em vez da preservação da variedade. Em contrapartida, abordagens orientadas à reconstrução (por exemplo, Kernel PCA) apresentam valores mais elevados de RMSE e das métricas de distorção (GCE e C_Measure), confirmando o compromisso entre fidelidade geométrica e precisão de reconstrução. De modo geral, as tabelas evidenciam

que nenhum algoritmo domina simultaneamente todos os critérios de avaliação. Em vez disso, cada método apresenta um perfil de desempenho compatível com seus fundamentos teóricos, o que ressalta a necessidade de uma seleção orientada pelo objetivo da análise nos fluxos de trabalho de redução de dimensionalidade.

Tabela 28A – Figuras de mérito obtidas do conjunto de dados df1.

Algoritmo	Q_local	Q_global	AUC(R_NX)	Correlação cofenética	RMSE de reconstrução	Confiabilidade	Continuidade
DRR	0.506	0.888	0.283	0.931	**0.606**	0.875	0.949
Isomap	0.503	0.886	0.296	0.927		0.885	**0.951**
PCA	0.502	0.887	0.285	0.931	**0.606**	0.876	0.950
PCA L1	0.487	0.878	0.260	0.877		0.866	0.938
kPCA	0.282	0.672	0.185	0.055	50.037	0.801	0.839
FastICA	0.486	0.870	0.281	0.915	**0.606**	0.874	0.944
MDS	0.502	0.887	0.285	0.931		0.876	0.950
nMDS	**0.525**	**0.904**	0.301	**0.966**		0.892	0.938
DrL	0.349	0.763	0.110	0.331		0.768	0.822
Fruchterman-Reingold	0.456	0.828	0.256	0.600		0.848	0.939
Kamada-Kawai	0.513	0.892	0.301	0.935		0.891	0.949
HLLE	0.406	0.862	0.107	0.486		0.743	0.840
Diffusion Maps	0.432	0.837	0.238	0.405		0.855	0.892
t-SNE	0.509	0.755	**0.492**	0.642		**0.944**	0.915

Tabela 28B – Figuras de mérito obtidas do conjunto de dados df1.

Algoritmo	Descontinuidade	Precisão	Revocação	Tau de Kendall	Acurácia k-NN	GCE	Medida C
DRR	0.051	0.297	0.297	0.750	0.940	0.833	1457.6
Isomap	**0.049**	0.310	0.310	0.749	0.940	0.859	1317.5
PCA	0.050	0.304	0.304	0.751	0.940	0.871	1518.4
PCA L1	0.062	0.272	0.272	0.704	**0.947**	1.029	1448.2
kPCA	0.161	0.192	0.192	0.075	0.910	1.631	1443.6
FastICA	0.056	0.295	0.295	0.721	0.931	0.787	1508.0
MDS	0.050	0.304	0.304	0.751	0.940	0.871	1518.4
nMDS	0.062	0.317	0.317	**0.827**	0.926	1.028	1317.4
DrL	0.178	0.107	0.107	0.259	0.917	1.031	1656.6
Fruchterman-Reingold	0.061	0.268	0.268	0.481	0.942	0.834	1571.5
Kamada-Kawai	0.051	0.319	0.319	0.772	0.937	0.983	1350.3
HLLE	0.160	0.108	0.108	0.592	0.889	1.505	1707.3
Diffusion Maps	0.108	0.246	0.246	0.623	0.919	1.134	1370.8
t-SNE	0.085	**0.488**	**0.488**	0.493	**0.947**	**0.630**	**972.2**

A Tabela 29 resume o desempenho multiobjetivo dos algoritmos de redução de dimensionalidade utilizando quatro índices compostos — Local, Global, Geométrico e Classe — além de uma Pontuação Final (Final Score) agregada. Os resultados indicam claramente que o t-SNE apresenta o melhor desempenho em todos os cenários avaliados, alcançando os maiores valores dos índices de preservação local e dos relacionados à classificação, além de obter, de forma consistente, a maior Pontuação Final para objetivos de agrupamento, visualização e pipelines de aprendizado de máquina.

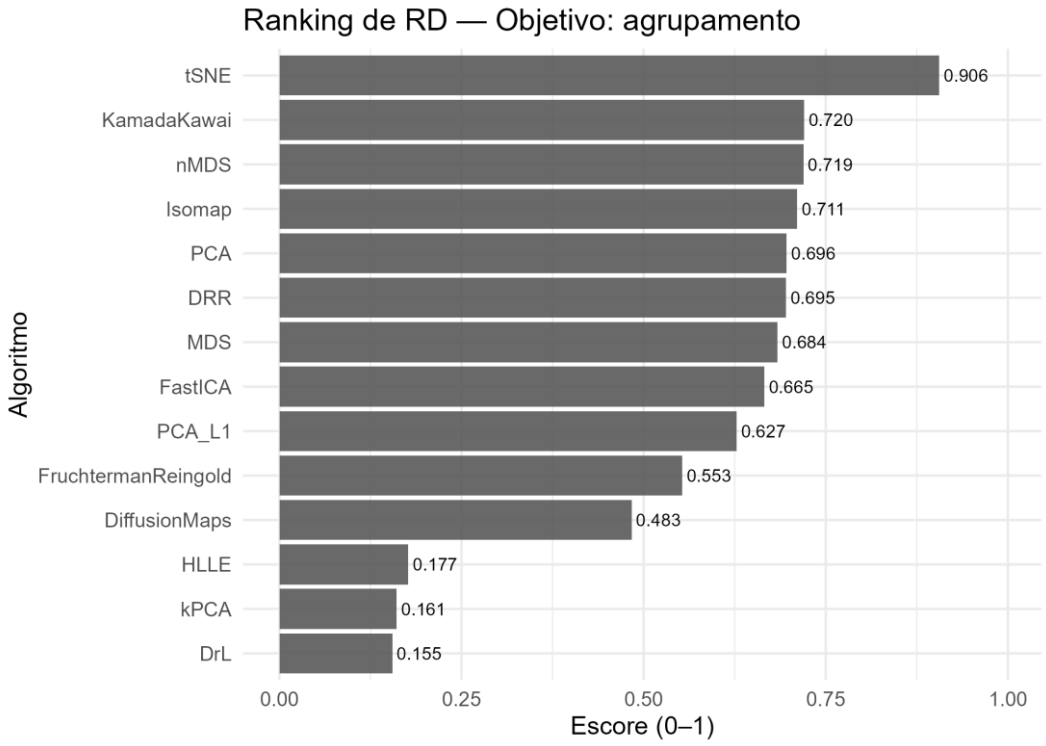
Métodos clássicos de aprendizado de variedades (manifold learning), como nMDS, Kamada–Kawai, Isomap e PCA, constituem um segundo nível de desempenho, apresentando um comportamento equilibrado, com fidelidade global e geométrica de moderada a elevada, porém com índices de classificação inferiores aos do t-SNE. Em tarefas de reconstrução, métodos como DRR e PCA mantêm uma preservação geométrica competitiva, embora ainda permaneçam atrás do t-SNE no ranqueamento geral ponderado pelos objetivos.

De modo geral, a tabela reforça que a adequação de um algoritmo depende do cenário de aplicação. Enquanto o t-SNE se destaca em tarefas que priorizam a preservação das vizinhanças locais e a separabilidade entre grupos, métodos com melhor preservação da estrutura global, como nMDS, Isomap e PCA, continuam sendo mais vantajosos em aplicações que exigem continuidade da variedade (manifold) ou maior interpretabilidade.

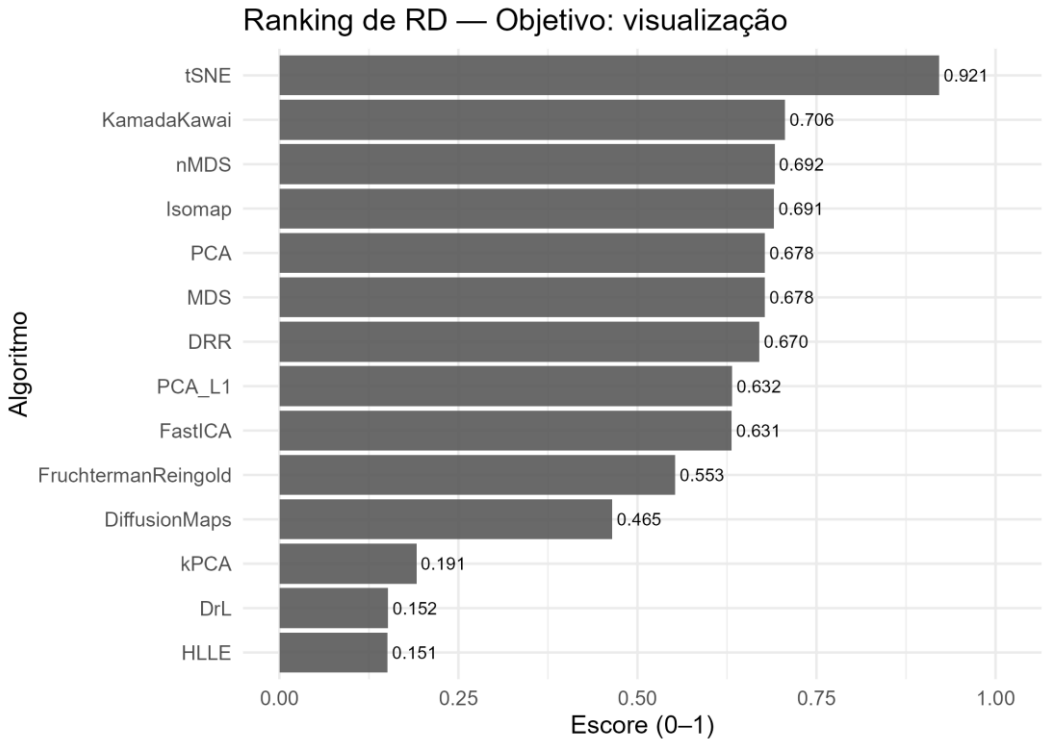
Tabela 29 – Figuras de mérito obtidas do conjunto de dados df1.

Algoritmo	Índice_Local	Índice_Global	Índice_Geom	Índice_Classe	Pontuação_Final	Objetivo
tSNE	0.984	0.639	0.907	1.000	**0.906**	**agrupamento**
KamadaKawai	0.700	0.836	0.706	0.647	0.720	agrupamento
nMDS	0.711	0.876	0.677	0.580	0.719	agrupamento
Isomap	0.670	0.817	0.767	0.648	0.711	agrupamento
PCA	0.650	0.812	0.752	0.638	0.696	agrupamento
tSNE	0.984	0.639	0.907	1.000	**0.921**	**visualização**
KamadaKawai	0.700	0.836	0.706	0.647	0.706	visualização
nMDS	0.711	0.876	0.677	0.580	0.692	visualização
Isomap	0.670	0.817	0.767	0.648	0.691	visualização
PCA	0.650	0.812	0.752	0.638	0.678	visualização
tSNE	0.984	0.639	0.907	1.000	**0.850**	**reconstrução**
Isomap	0.670	0.817	0.767	0.648	0.753	reconstrução
DRR	0.644	0.812	0.780	0.626	0.749	reconstrução
nMDS	0.711	0.876	0.677	0.580	0.747	reconstrução
KamadaKawai	0.700	0.836	0.706	0.647	0.743	reconstrução
tSNE	0.984	0.639	0.907	1.000	**0.921**	**pipeline de ML**
KamadaKawai	0.700	0.836	0.706	0.647	0.706	pipeline de ML
nMDS	0.711	0.876	0.677	0.580	0.692	pipeline de ML
Isomap	0.670	0.817	0.767	0.648	0.691	pipeline de ML
PCA	0.650	0.812	0.752	0.638	0.678	pipeline de ML

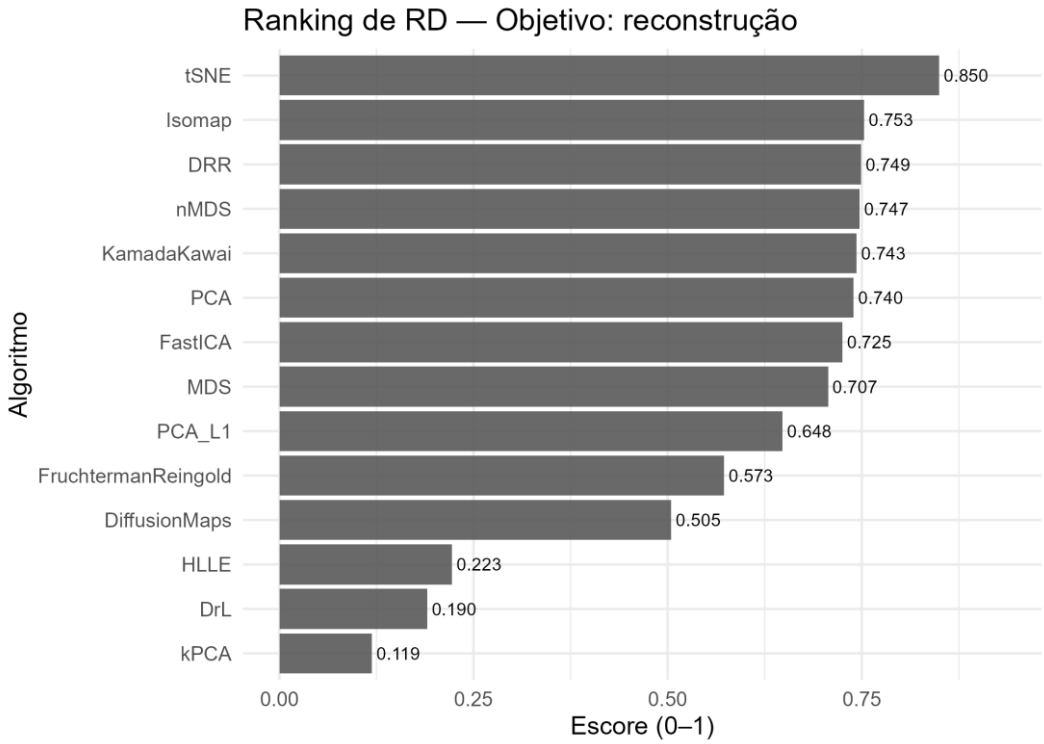
A Figura 18 resume o ranqueamento dos algoritmos de redução de dimensionalidade com base em objetivos específicos em quatro cenários analíticos: agrupamento (clustering), visualização, reconstrução e integração em pipelines de aprendizado de máquina. Em todos os casos, o t-SNE alcança consistentemente as maiores pontuações, refletindo sua elevada capacidade de preservar a estrutura local dos dados e aumentar a separabilidade entre as classes. Métodos clássicos de aprendizado de variedades (manifold learning), como nMDS, Kamada–Kawai, Isomap, PCA e MDS, constituem um segundo nível de desempenho, apresentando resultados equilibrados, com pontuações de moderadas a elevadas em diferentes objetivos analíticos.



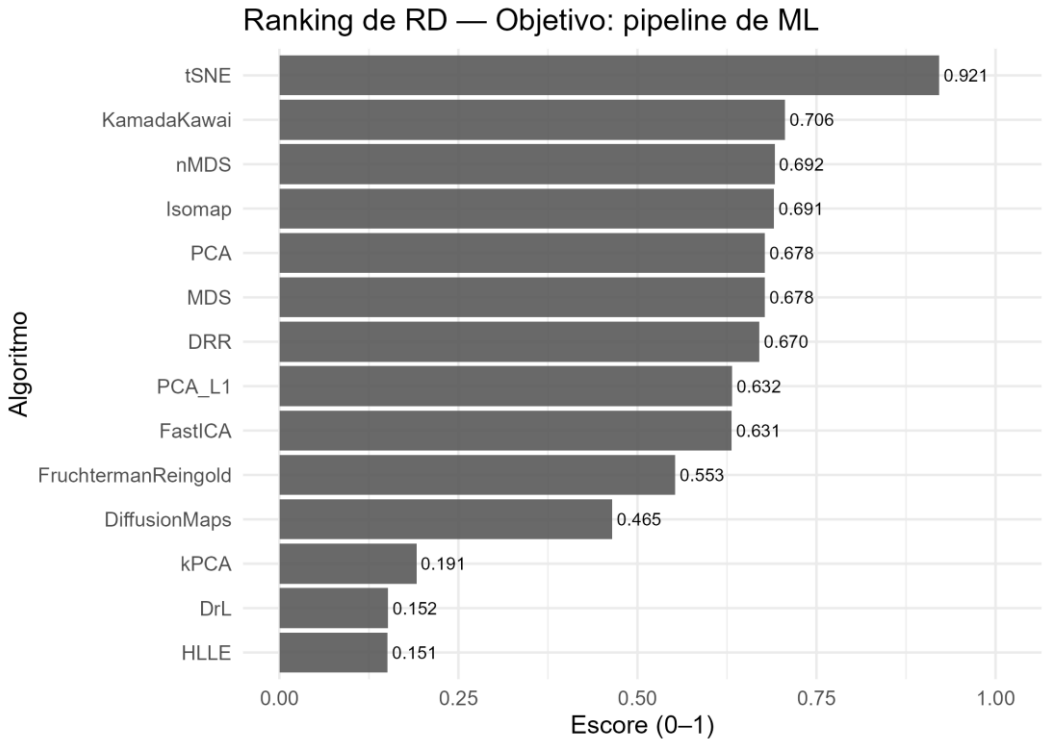
(a)


Ranking de RD — Objetivo: visualização
tSNE
KamadaKawai
nMDS
Isomap
PCA
MDS
DRR
PCA_L1
FastICA
FruchtermanReingold
DiffusionMaps
kPCA
DrL
HLLE
0.921
0.706
0.692
0.691
0.678
0.678
0.670
0.632
0.631
0.553
0.465
0.191
0.152
0.151
Algoritmo
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

(b)


Ranking de RD — Objetivo: reconstrução
tSNE
Isomap
DRR
nMDS
KamadaKawai
PCA
FastICA
MDS
PCA_L1
FruchtermanReingold
DiffusionMaps
HLLE
DrL
kPCA
0.850
0.753
0.749
0.747
0.743
0.740
0.725
0.707
0.648
0.573
0.505
0.223
0.190
0.119
Algoritmo
0.00
0.25
0.50
0.75
Escore (0–1)

(c)



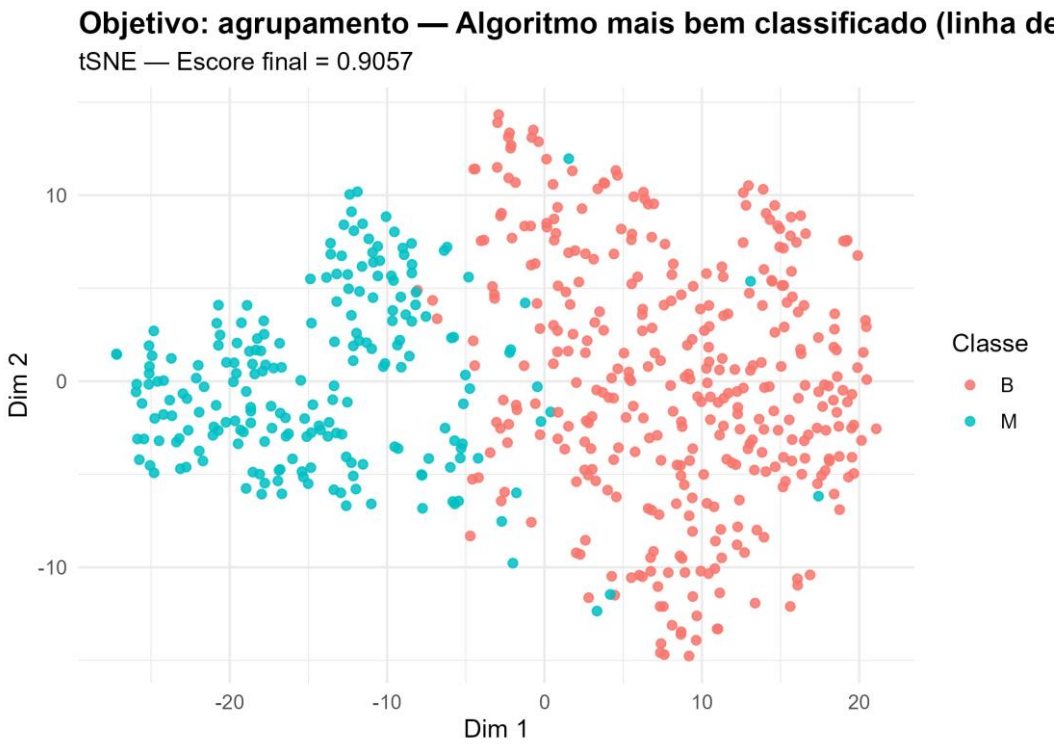
(d)

Figura 18 – Gráficos de barras horizontais mostrando as pontuações de desempenho normalizadas (0–1) para cada algoritmo de redução de dimensionalidade nos quatro objetivos analíticos: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

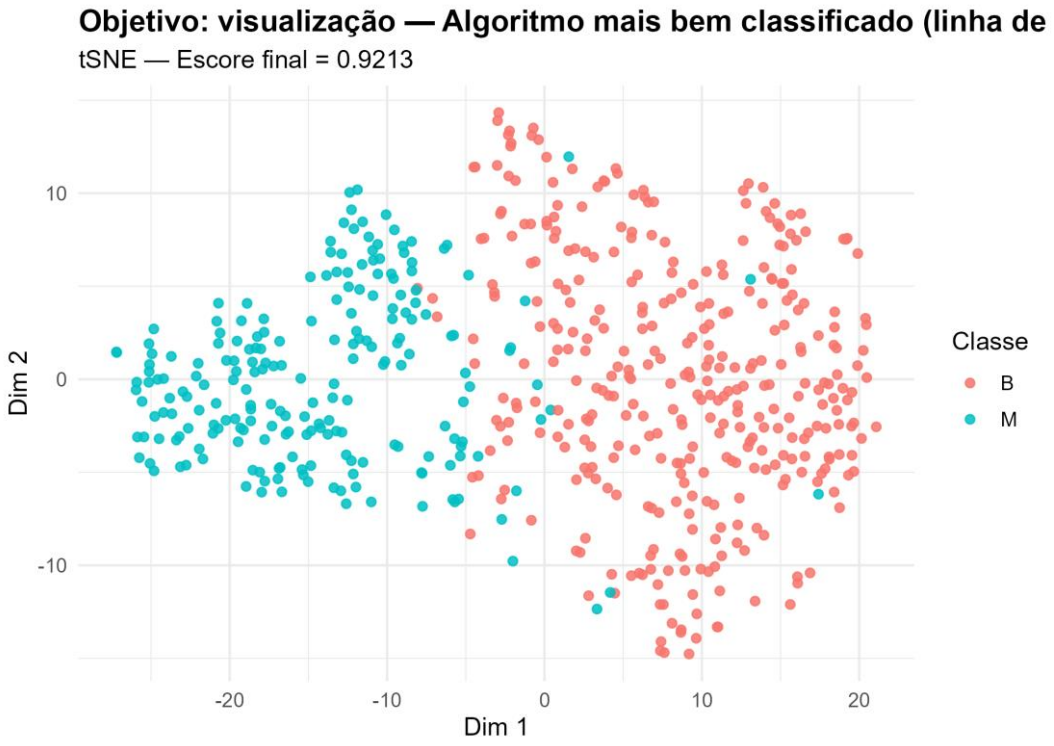
As tarefas centradas na reconstrução revelam uma hierarquia ligeiramente diferente, com DRR, PCA e FastICA apresentando desempenho competitivo e reduzindo a diferença em relação ao t-SNE, que permanece como o algoritmo de melhor desempenho geral. Métodos de desenho de grafos, como Fruchterman–Reingold, e abordagens espectrais não lineares, como Diffusion Maps, HLLE, DrL e Kernel PCA (kPCA), apresentam desempenho inferior nos diferentes objetivos analíticos, refletindo limitações relacionadas à preservação da continuidade global ou da estrutura de vizinhança, dependendo do método. De modo geral, os resultados comparativos indicam que não existe um algoritmo universalmente ótimo. Entretanto, o t-SNE oferece o desempenho mais robusto em uma ampla variedade de necessidades analíticas, enquanto

métodos clássicos de aprendizado de variedades (manifold learning) permanecem como alternativas sólidas quando a interpretabilidade ou a estabilidade geométrica constituem prioridades.

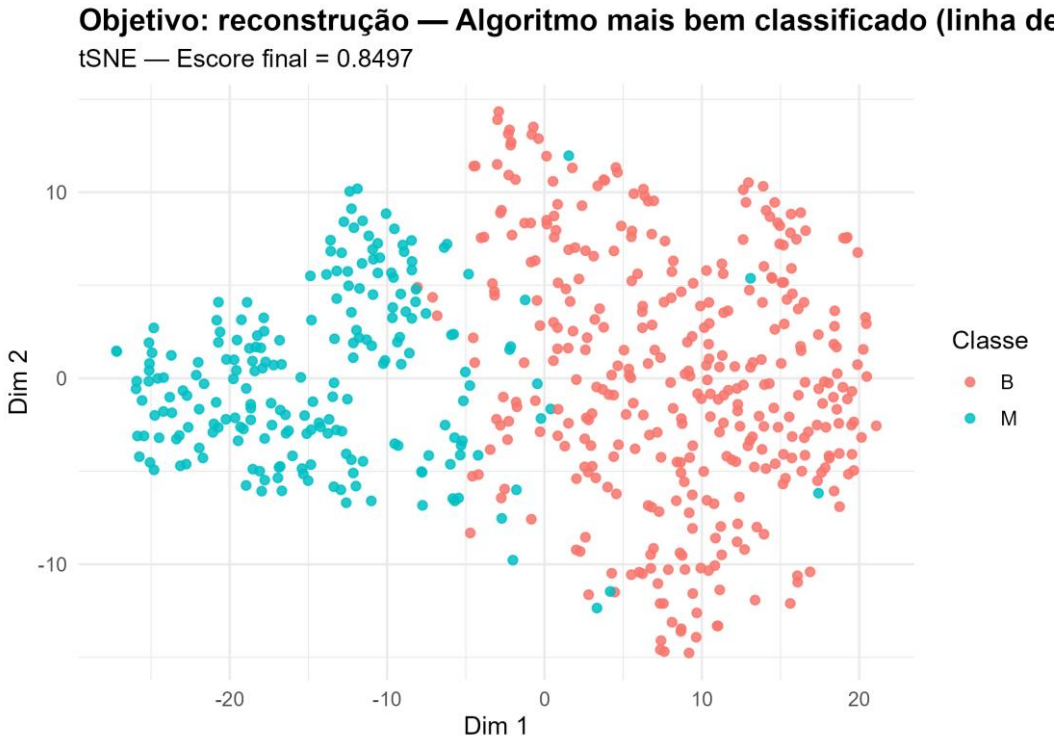
A Figura 19 apresenta as projeções bidimensionais produzidas pelo algoritmo de redução de dimensionalidade mais bem classificado — t-SNE — para quatro objetivos analíticos: agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina. Em todos os cenários, o t-SNE produz uma separação bem definida entre as duas classes, com agrupamentos intraclasse compactos e fronteiras interclasse claramente delimitadas. Essa estrutura consistente demonstra a elevada capacidade do método de preservar as relações locais de vizinhança, aumentar a separabilidade entre as classes e gerar projeções visualmente interpretáveis. A disposição praticamente idêntica das projeções nos diferentes objetivos evidencia a robustez da representação obtida e reforça a superioridade do t-SNE em cenários em que a estrutura discriminante e a clareza visual constituem prioridades analíticas centrais.



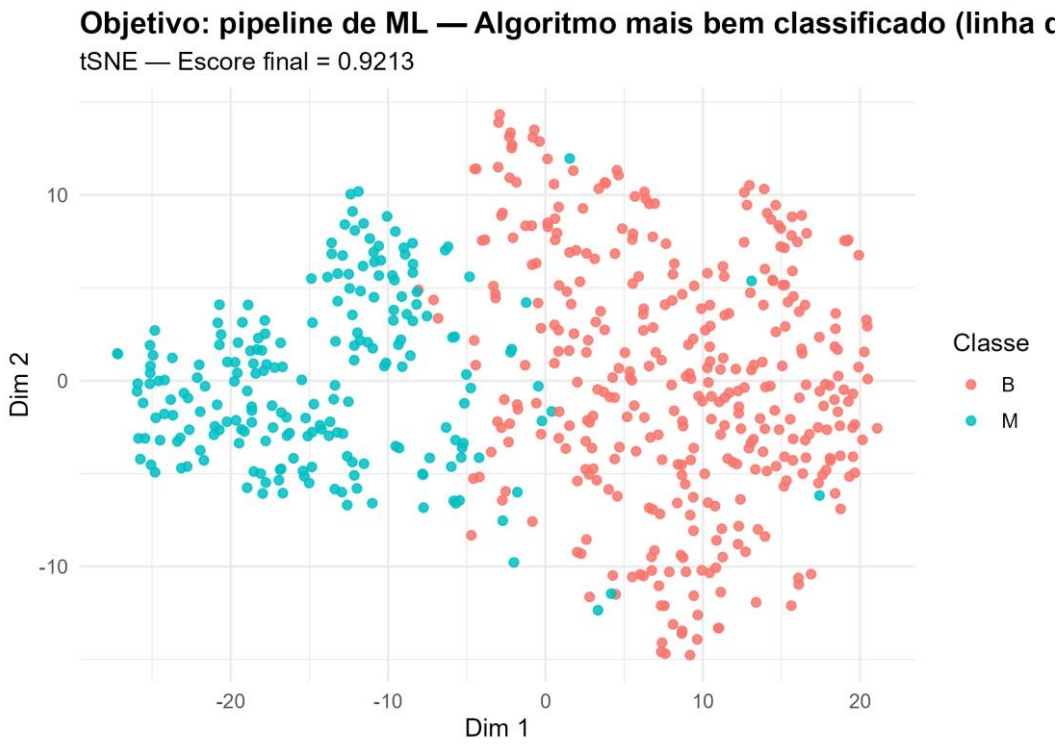
(a)


Objetivo: visualização — Algoritmo mais bem classificado (linha de
tSNE — Escore final = 0.9213
Dim 2
Dim 1
10
0
-10
-20
-10
0
10
20
Classe
B
M

(b)


Objetivo: reconstrução — Algoritmo mais bem classificado (linha de
tSNE — Escore final = 0.8497
Dim 2
Dim 1
10
0
-10
-20
-10
0
10
20
Classe
B
M

(c)



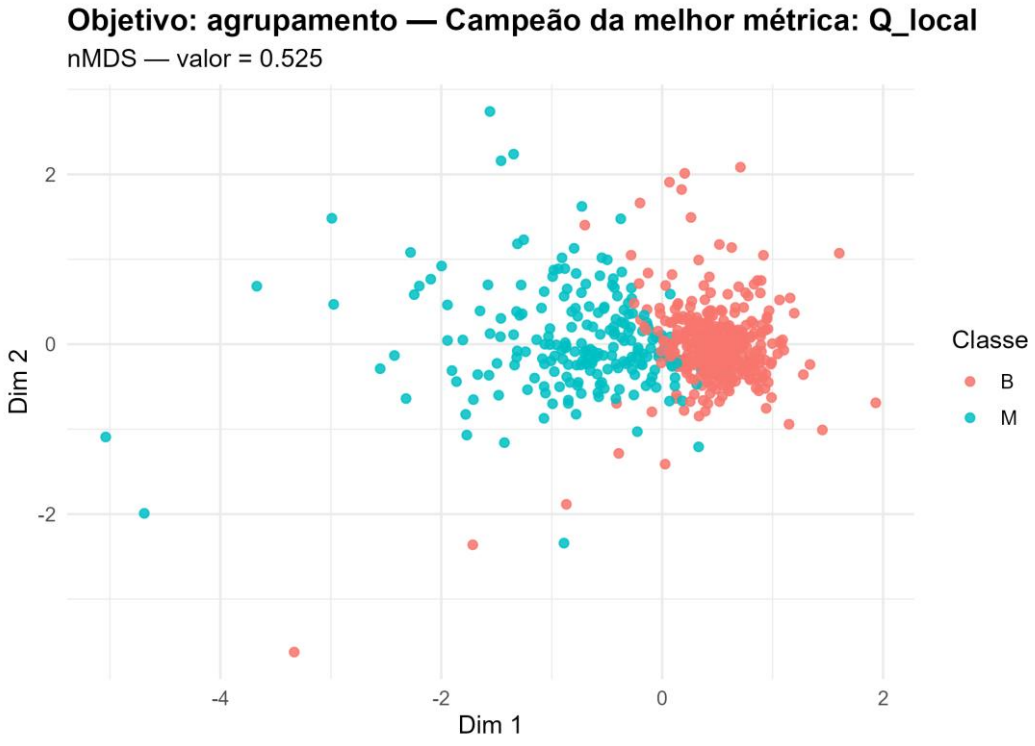
(d)

Figura 19 – Projeções bidimensionais produzidas pelo algoritmo melhor classificado para cada objetivo, com base na Pontuação Final (Final Score) do ranqueamento de referência (Baseline Ranking): (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

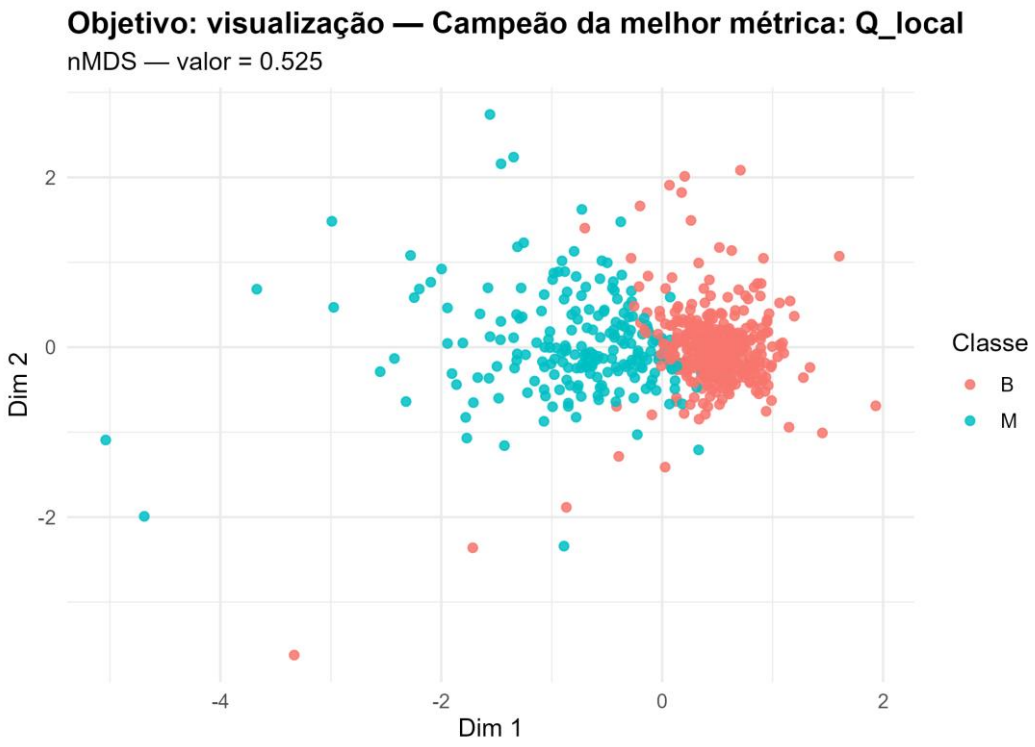
A Figura 20 apresenta as projeções bidimensionais geradas pelo algoritmo que alcançou o melhor desempenho na métrica Qlocal em todos os objetivos analíticos — nMDS. Em cada cenário (agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina), o nMDS produz projeções com coesão intraclasse moderada e fronteiras entre classes parcialmente sobrepostas. As representações preservam de forma consistente a estrutura das vizinhanças locais, conforme evidenciado pelo valor estável de Qlocal (0,5253), porém apresentam separação global mais limitada quando comparadas a métodos otimizados para visualização discriminante.

De modo geral, os resultados demonstram que o nMDS é eficaz na preservação da topologia em pequena escala, produzindo projeções semelhantes entre os diferentes objetivos analíticos. Entretanto, essas representações também evidenciam o compromisso (trade-off) inerente à priorização da fidelidade local. Embora as relações de vizinhança sejam preservadas, a separabilidade entre classes e a preservação da estrutura global da variedade (manifold) tornam-se menos pronunciadas do que em algoritmos especificamente desenvolvidos para visualização ou agrupamento.

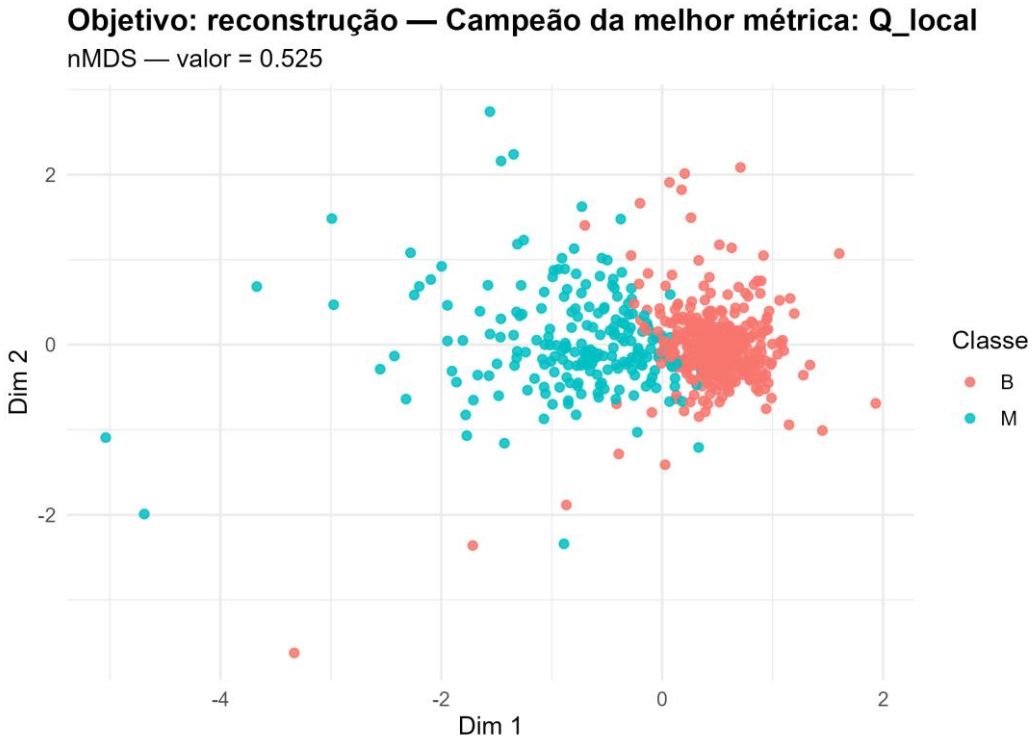
Nesse contexto, recomenda-se que o leitor compare o desempenho das técnicas de redução de dimensionalidade t-SNE e nMDS e selecione a que melhor atenda ao objetivo específico de sua aplicação.



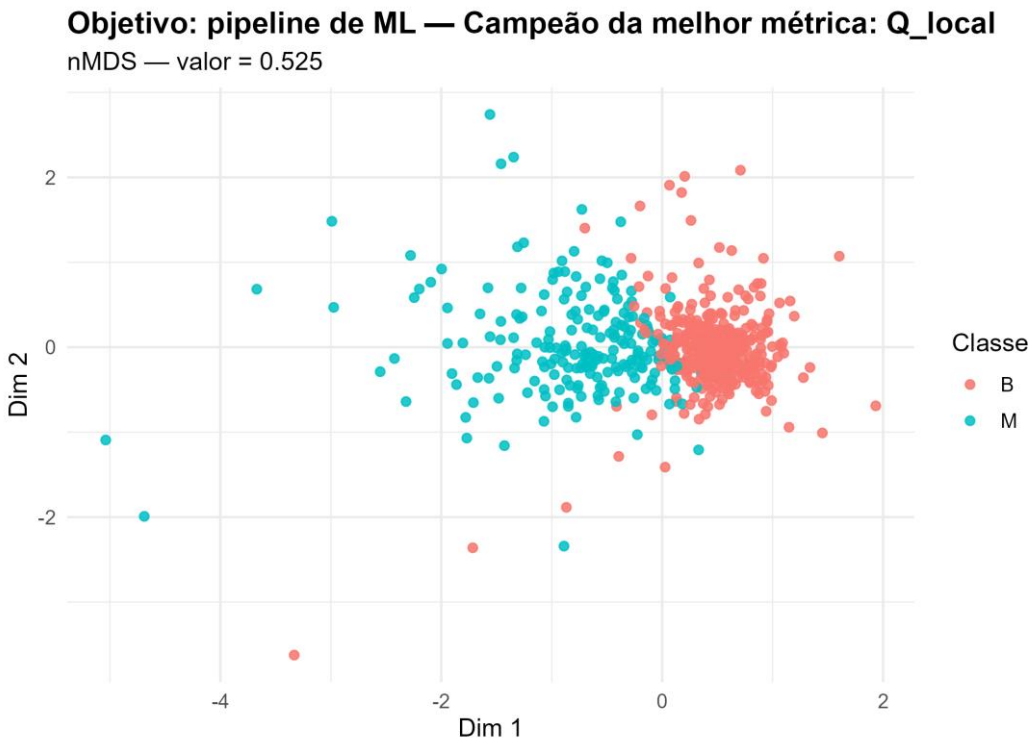
(a)


Objetivo: visualização — Campeão da melhor métrica: Q_local
nMDS — valor = 0.525
Dim 2
Dim 1
2
0
-2
-4
-2
0
2
Classe
B
M

(b)


Objetivo: reconstrução — Campeão da melhor métrica: Q_local
nMDS — valor = 0.525
Dim 2
Dim 1
2
0
-2
-4
-2
0
2
Classe
B
M

(c)



(d)

Figura 20 – Projeções bidimensionais geradas pelo algoritmo campeão, selecionado com base na métrica de melhor desempenho para cada objetivo analítico: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

5. ESTUDO DE CASO II

5.1 Descrição do Conjunto de Dados

O conjunto de dados "Chemical Composition of Ceramic Samples" foi denominado df2. Ele contém 88 instâncias, 19 variáveis (atributos) e duas classes. A técnica de fluorescência de raios X por dispersão de energia (Energy-Dispersive X-ray Fluorescence – EDXRF) foi empregada para determinar a composição química dos corpos cerâmicos e dos esmaltes (glazes) provenientes dos fornos de Longquan (Condado de Dayao) e de Jingdezhen. Foram selecionados 40 fragmentos cerâmicos representativos, pertencentes a quatro períodos culturais, com o objetivo de investigar as matérias-primas utilizadas e as tecnologias de queima empregadas. O propósito do estudo foi identificar os elementos químicos que atuam como variáveis explicativas mais importantes para classificar as amostras em diferentes períodos culturais e centros produtores (fornos) [88].

O conjunto de dados df2, que representa as composições químicas dos materiais cerâmicos, foi importado diretamente a partir de um arquivo no formato CSV. Quando presentes, colunas de identificação sem conteúdo informativo (por exemplo, "ID", "id" e "index") foram removidas da análise. As concentrações dos óxidos metálicos, originalmente expressas em porcentagem em massa (% m/m), foram sistematicamente convertidas para unidades de $mg.kg^{-1}$, multiplicando-se por 10.000 as variáveis correspondentes a Na_2O, MgO, Al_2O_3, SiO_2, K_2O, CaO, TiO_2 e Fe_2O_3. Para evitar inconsistências numéricas, todos os valores negativos — normalmente decorrentes do ruído instrumental — foram substituídos pelos respectivos valores absolutos.

Na etapa de redução de dimensionalidade, apenas as variáveis numéricas foram mantidas. Essas variáveis foram submetidas à centralização em torno da média e ao escalonamento para variância unitária por meio da padronização z-score, eliminando os efeitos de escala e assegurando que todas as técnicas de redução de dimensionalidade

fossem avaliadas sob condições comparáveis. A matriz padronizada resultante constituiu o espaço de dados de alta dimensionalidade (**X**high), utilizado em todos os procedimentos computacionais. Adicionalmente, mapas de correlação opcionais foram gerados utilizando o pacote corrplot para visualizar as interdependências entre as variáveis.

5.2 Resultados e Discussão

A estrutura de correlação entre as métricas de avaliação empregadas no framework de benchmarking é apresentada na Figura 21.

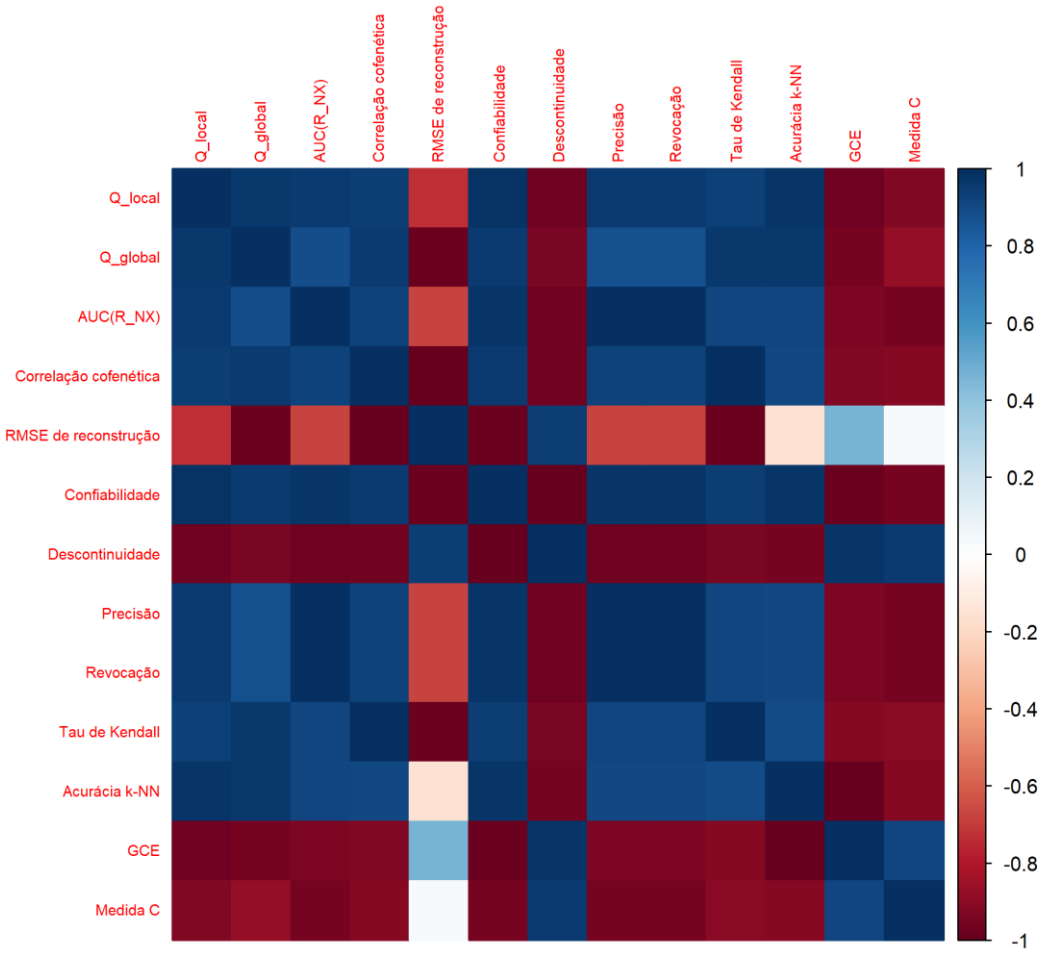


Figura 21 – Estrutura da matriz de correlação entre as métricas de avaliação utilizadas no framework de benchmarking.

Dois agrupamentos (clusters) predominantes são claramente observados. As métricas relacionadas à preservação das estruturas locais e globais (por exemplo, Q_{local}, Q_{global}, AUC_R(NX), correlação cofenética, trustworthiness, precision, recall, Kendall Tau e acurácia do kNN) formam um bloco com forte correlação positiva, indicando que capturam aspectos semelhantes da fidelidade das relações de vizinhança e da geometria relevante para a separação entre classes. Em contraste, as métricas baseadas em erro e distorção (RMSE_Reconstruction, GCE e C_measure) apresentam fortes correlações negativas com esse grupo, refletindo o compromisso (trade-off) inerente entre a preservação das relações de vizinhança e a precisão da reconstrução. A métrica RMSE_Reconstruction exibiu um perfil de correlação distinto, mostrando maior afinidade com as métricas orientadas à distorção e correlação inversa com as voltadas à preservação da topologia. Essa separação confirma que métodos focados na reconstrução otimizam critérios fundamentalmente diferentes daqueles que priorizam a continuidade local ou a separação entre classes. De modo geral, o mapa de calor evidencia que as métricas de redução de dimensionalidade se organizam naturalmente em famílias coerentes, cada uma associada a um objetivo analítico específico. Esse resultado reforça a necessidade de uma abordagem multimétrica e dependente do cenário de aplicação na seleção de algoritmos de redução de dimensionalidade.

A Tabela 30A e a Tabela 30B apresentam as diferenças de desempenho observadas entre as técnicas de redução de dimensionalidade avaliadas. t-SNE e nMDS alcançaram, de forma consistente, os melhores resultados nas métricas de preservação da estrutura local — trustworthiness, continuity, Q_{local} e AUC_R(NX) — indicando elevada fidelidade das relações de vizinhança e excelente capacidade de separação entre classes. O MDS destacou-se na preservação da estrutura global, como evidenciado por sua maior correlação cofenética. O método Diffusion Maps apresentou desempenho robusto tanto

nas métricas locais quanto nas globais, além de exibir a menor distorção geométrica (GCE). Os métodos convexos clássicos, como PCA, MDS e FastICA, apresentaram desempenho intermediário e estável, enquanto Kernel PCA (kPCA), HLLE, DrL e Fruchterman–Reingold exibiram redução substancial no desempenho nas métricas estruturais, de reconstrução e de classificação. Em conjunto, os resultados confirmam que não existe um único método universalmente superior para redução de dimensionalidade. Em vez disso, os padrões de desempenho específicos para cada objetivo evidenciam a necessidade de um processo de seleção de algoritmos baseado em múltiplas métricas e dependente do cenário de aplicação, de modo a obter representações de baixa dimensionalidade confiáveis.

Tabela 30A – Figuras de mérito obtidas do conjunto de dados df2.

Algoritmo	Q_local	Q_global	AUC(R_NX)	Correlação cofenética	RMSE de reconstrução	Confiabilidade	Continuidade
DRR	0.568	0.878	0.563	0.783	**0.684**	0.904	0.928
Isomap	0.555	**0.896**	0.576	0.855		0.910	0.940
PCA	0.497	0.871	0.600	0.847	**0.684**	0.911	0.949
PCA L1	0.481	0.859	0.569	0.808		0.907	0.936
kPCA	0.454	0.740	0.555	0.400	11.11	0.870	0.890
FastICA	0.504	0.852	0.587	0.812	**0.684**	0.908	0.942
MDS	0.497	0.871	0.600	0.847		0.911	0.949
nMDS	0.565	**0.896**	0.645	**0.919**		0.939	0.946
DrL	0.023	0.495	0.166	-0.085		0.505	0.496
Fruchterman-Reingold	0.057	0.497	0.177	-0.206		0.501	0.457
Kamada-Kawai	0.507	0.861	0.571	0.839		0.901	0.927
HLLE	0.317	0.779	0.286	0.226		0.715	0.660
Diffusion Maps	0.544	0.872	0.613	0.683		0.925	0.947
t-SNE	**0.595**	0.851	**0.740**	0.768		**0.960**	**0.964**

* Os valores em negrito representam os melhores resultados.

Tabela 30B – Figuras de mérito obtidas do conjunto de dados df2.

Algoritmo	Descontinuidade	Precisão	Revocação	Tau de Kendall	Acurácia k-NN	GCE	Medida C
DRR	0.072	0.608	0.608	0.603	**1.000**	0.241	187.6
Isomap	0.060	0.600	0.600	0.682	0.989	0.238	181.2
PCA	0.051	0.639	0.639	0.676	**1.000**	0.240	153.6
PCA L1	0.064	0.610	0.610	0.629	**1.000**	0.199	195.7
kPCA	0.110	0.598	0.598	0.273	0.989	0.320	168.6
Fast ICA	0.058	0.618	0.618	0.622	0.977	0.337	161.6
MDS	0.051	0.639	0.639	0.676	**1.000**	0.240	153.6
nMDS	0.054	0.681	0.681	**0.776**	**1.000**	0.272	**148.6**
DrL	0.504	0.164	0.164	-0.047	0.511	3.886	293.5
Fruchterman-Reingold	0.543	0.156	0.156	-0.129	0.557	4.225	274.9
Kamada-Kawai	0.073	0.605	0.605	0.665	0.989	0.556	156.4
HLLE	0.340	0.264	0.264	0.220	0.886	1.475	245.3
Diffusion Maps	0.053	0.651	0.651	0.647	**1.000**	**0.058**	167.7
t-SNE	**0.036**	**0.769**	**0.769**	0.619	**1.000**	0.097	160.3

* Os valores em negrito representam os melhores resultados.

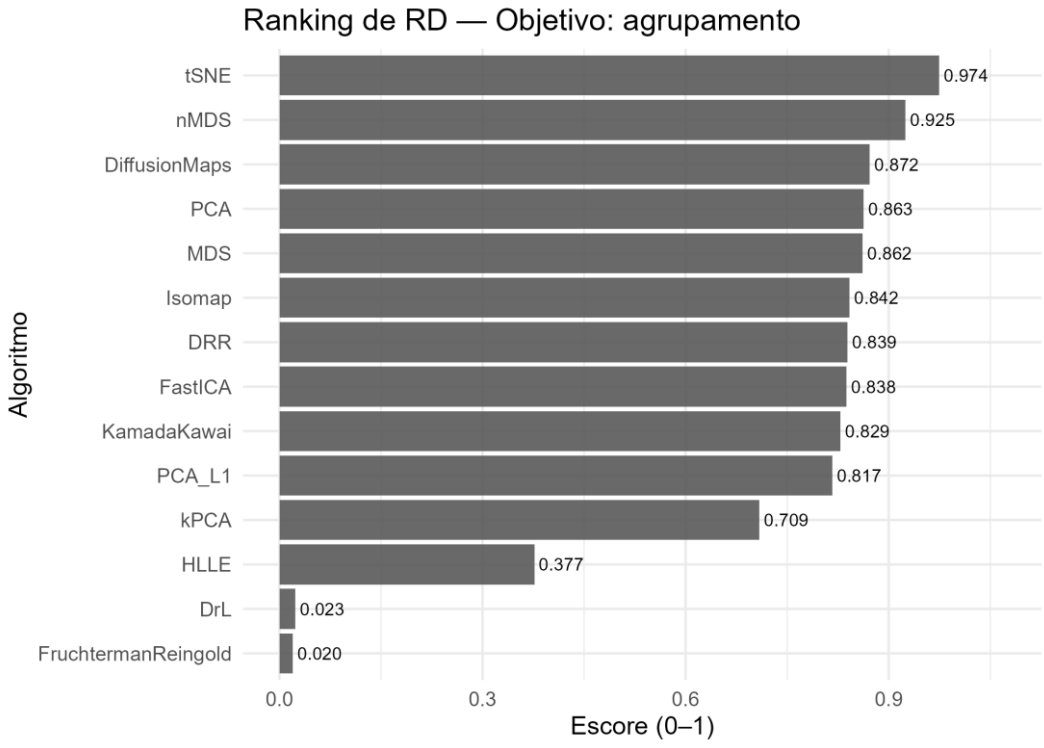
Os ranqueamentos baseados em cenários, apresentados na Tabela 31, mostram que t-SNE e nMDS alcançaram, de forma consistente, o melhor desempenho global em todos os objetivos analíticos avaliados. Nas tarefas de agrupamento (clustering), visualização e integração em pipelines de aprendizado de máquina, o t-SNE obteve as maiores pontuações finais devido aos seus índices máximos de preservação da estrutura local e de separação entre classes, confirmando sua elevada capacidade de manter as relações de vizinhança e maximizar a discriminabilidade entre as classes. O t-SNE também ficou em primeiro lugar na reconstrução, porém apenas marginalmente: o nMDS vem menos de 0,01 atrás, impulsionado por seu índice global superior e por um comportamento geométrico equilibrado, o que o mantém como a escolha mais natural para tarefas que priorizam a preservação das distâncias. Os métodos Diffusion Maps, PCA e MDS constituíram um segundo grupo de desempenho, apresentando resultados competitivos e consistentes em diferentes cenários analíticos. Esses resultados evidenciam que a seleção do método de redução de dimensionalidade ideal depende intrinsecamente do objetivo da análise e que o framework proposto, baseado em índices de desempenho, fornece uma base confiável para identificar a técnica mais apropriada para cada contexto analítico. Nesta tabela, foram apresentados apenas os cinco principais métodos de redução de dimensionalidade que obtiveram os melhores resultados.

Tabela 31 – Figuras de mérito obtidas do conjunto de dados df2.

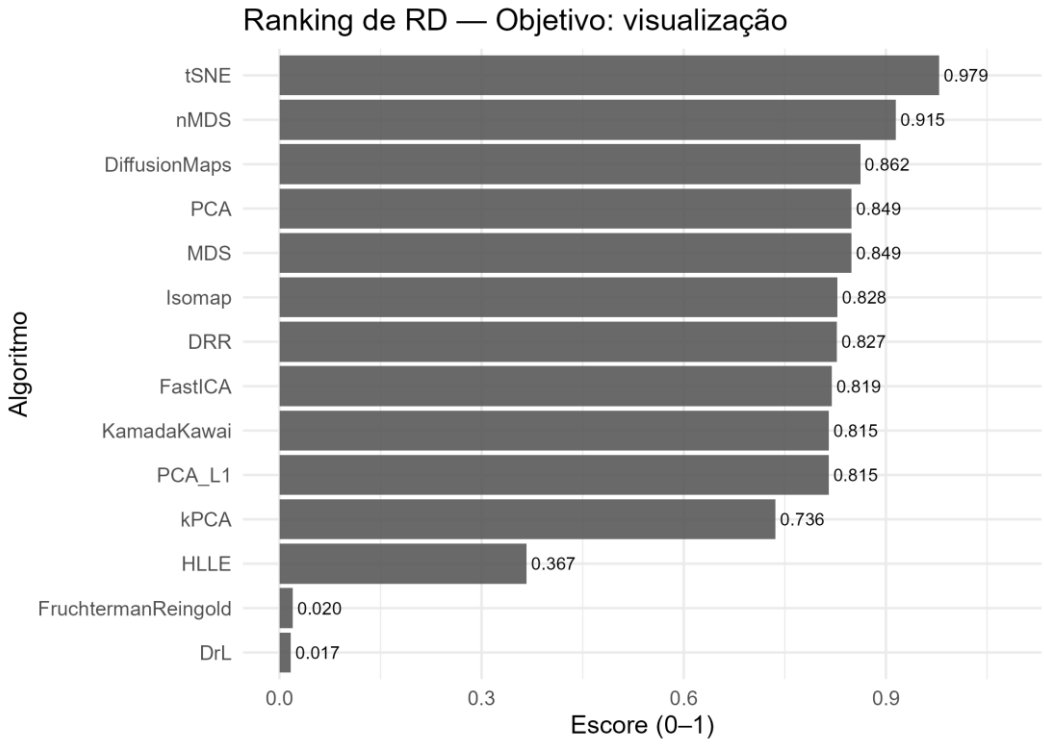
Algoritmo	Índice_Local	Índice_Global	Índice_Geom	Índice_Classe	Pontuação_Final	Objetivo
tSNE	1.000	0.895	0.970	1.000	**0.974**	**agrupamento**
nMDS	0.904	0.959	0.971	0.904	0.925	agrupamento
DiffusionMaps	0.862	0.842	0.945	0.872	0.872	agrupamento
PCA	0.824	0.880	0.973	0.859	0.863	agrupamento
MDS	0.824	0.880	0.964	0.859	0.862	agrupamento
tSNE	1.000	0.895	0.970	1.000	**0.979**	**visualização**
nMDS	0.904	0.959	0.971	0.904	0.915	visualização
DiffusionMaps	0.862	0.842	0.945	0.872	0.862	visualização
PCA	0.824	0.880	0.973	0.859	0.849	visualização
MDS	0.824	0.880	0.964	0.859	0.849	visualização
tSNE	1.000	0.895	0.970	1.000	**0.956**	**reconstrução**
nMDS	0.904	0.959	0.971	0.904	0.947	reconstrução
PCA	0.824	0.880	0.973	0.859	0.901	reconstrução
MDS	0.824	0.880	0.964	0.859	0.897	reconstrução
DiffusionMaps	0.862	0.842	0.945	0.872	0.889	reconstrução
tSNE	1.000	0.895	0.970	1.000	**0.979**	**pipeline de ML**
nMDS	0.904	0.959	0.971	0.904	0.915	pipeline de ML
DiffusionMaps	0.862	0.842	0.945	0.872	0.862	pipeline de ML
PCA	0.824	0.880	0.973	0.859	0.849	pipeline de ML
MDS	0.824	0.880	0.964	0.859	0.849	pipeline de ML

***** Os valores em negrito representam os melhores resultados para cada objetivo.

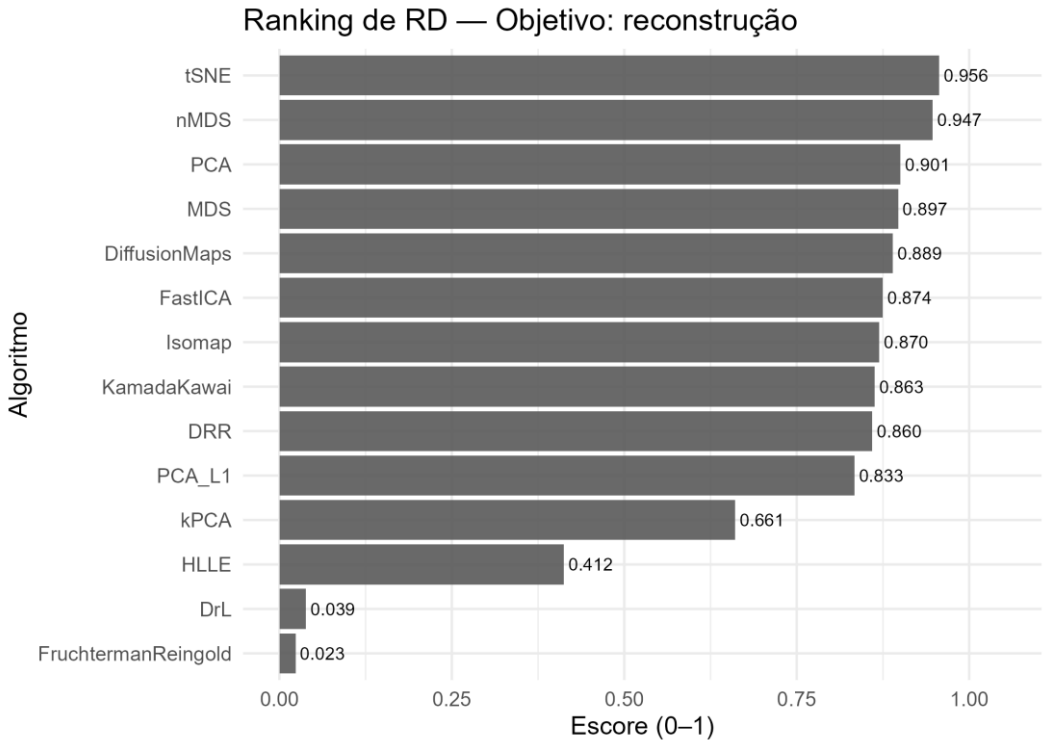
A Figura 22 resume o ranqueamento dos algoritmos de redução de dimensionalidade, com base nos objetivos, para o conjunto de dados df2 nos quatro cenários analíticos. O t-SNE lidera todos os objetivos, com pontuações finais de 0,974 para agrupamento, 0,979 para visualização e para integração em pipelines de aprendizado de máquina, e 0,956 para reconstrução, sustentado por índices local e de classe perfeitos (Índice_Local = Índice_Classe = 1,000). O nMDS forma um segundo grupo próximo, ficando menos de 0,01 atrás no objetivo de reconstrução (0,947) graças ao maior índice global do conjunto (Índice_Global = 0,959). Diffusion Maps, PCA e MDS clássico seguem como um grupo intermediário estável, enquanto kPCA, HLLE, DrL e Fruchterman–Reingold permanecem claramente atrás nos quatro cenários.



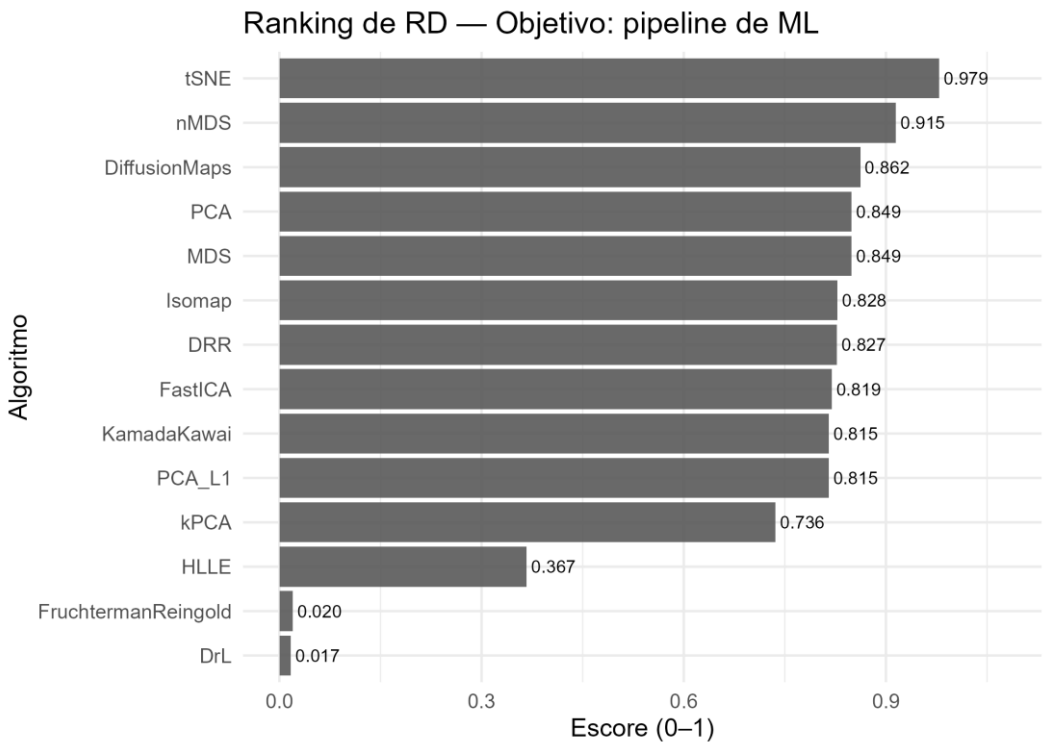
(a)


Ranking de RD — Objetivo: visualização
Algoritmo
tSNE
nMDS
DiffusionMaps
PCA
MDS
Isomap
DRR
FastICA
KamadaKawai
PCA_L1
kPCA
HLLE
FruchtermanReingold
DrL
0.979
0.915
0.862
0.849
0.849
0.828
0.827
0.819
0.815
0.815
0.736
0.367
0.020
0.017
0.0
0.3
0.6
0.9
Escore (0–1)

(b)


Ranking de RD — Objetivo: reconstrução
Algoritmo
tSNE
nMDS
PCA
MDS
DiffusionMaps
FastICA
Isomap
KamadaKawai
DRR
PCA_L1
kPCA
HLLE
DrL
FruchtermanReingold
0.956
0.947
0.901
0.897
0.889
0.874
0.870
0.863
0.860
0.833
0.661
0.412
0.039
0.023
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

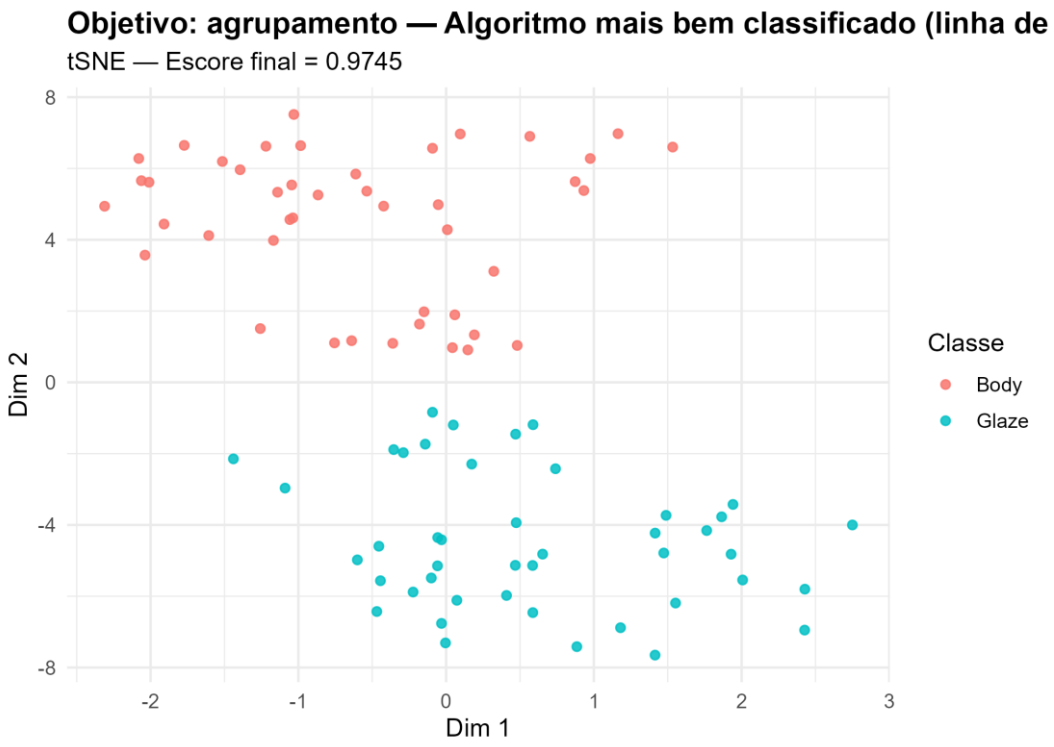
(c)



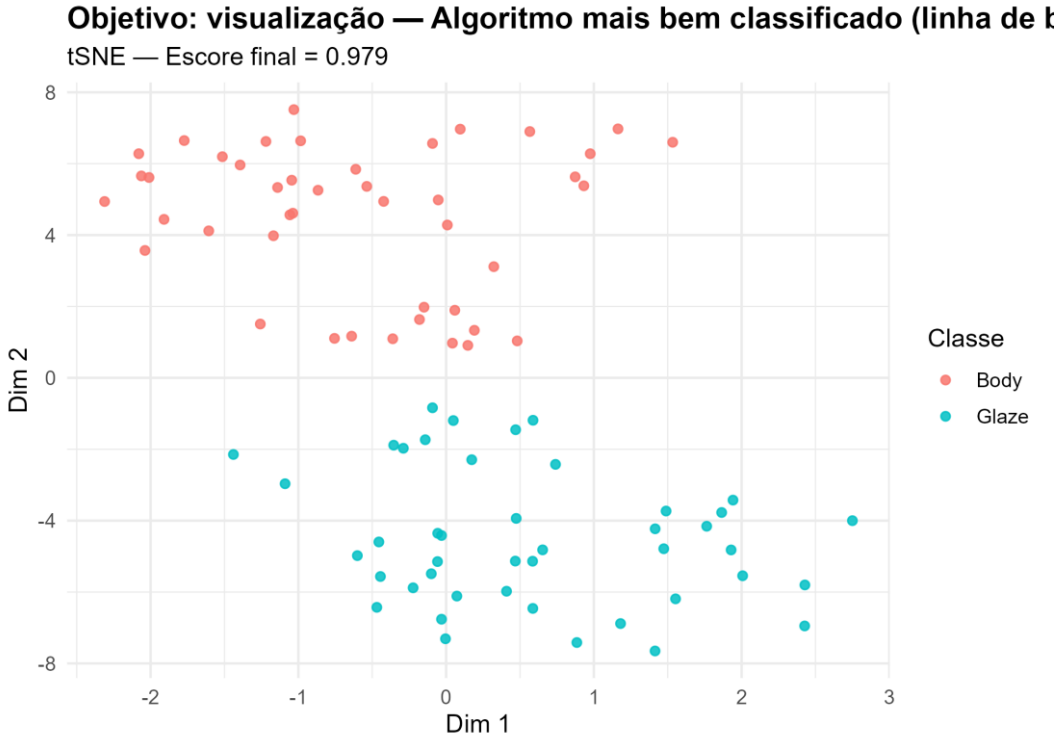
(d)

Figura 22 – Gráficos de barras horizontais mostrando as pontuações de desempenho normalizadas (0–1) para cada algoritmo de redução de dimensionalidade nos quatro objetivos analíticos: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

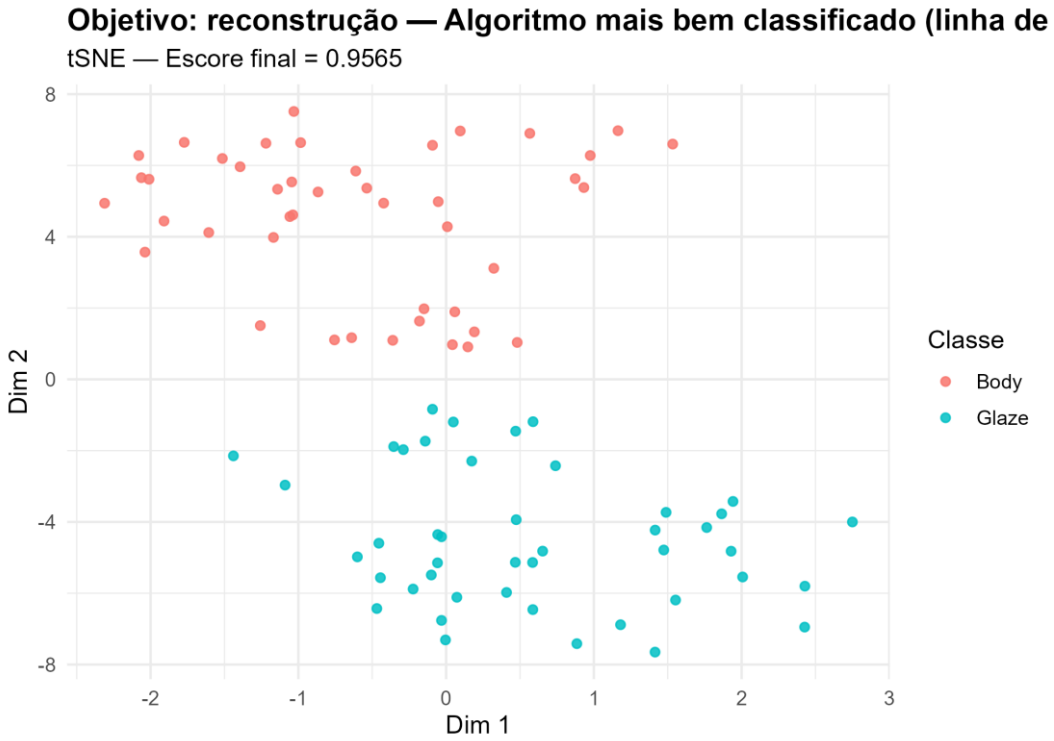
A Figura 23 apresenta as projeções bidimensionais produzidas pelo algoritmo mais bem classificado pela Pontuação Final em cada objetivo. Como o t-SNE lidera os quatro cenários para este conjunto de dados, os quatro painéis mostram o mesmo método e diferem apenas na pontuação indicada no subtítulo. Os corpos cerâmicos e os esmaltes (glazes) separam-se em dois grupos compactos e bem resolvidos, com uma fronteira nítida entre eles, o que é coerente com o índice de classe perfeito obtido para este conjunto de dados e confirma que a composição química medida por EDXRF discrimina quase completamente os dois grupos de fornos.


Objetivo: agrupamento — Algoritmo mais bem classificado (linha de
tSNE — Escore final = 0.9745
Dim 2
Dim 1
8
4
0
-4
-8
-2
-1
0
1
2
3
Classe
Body
Glaze

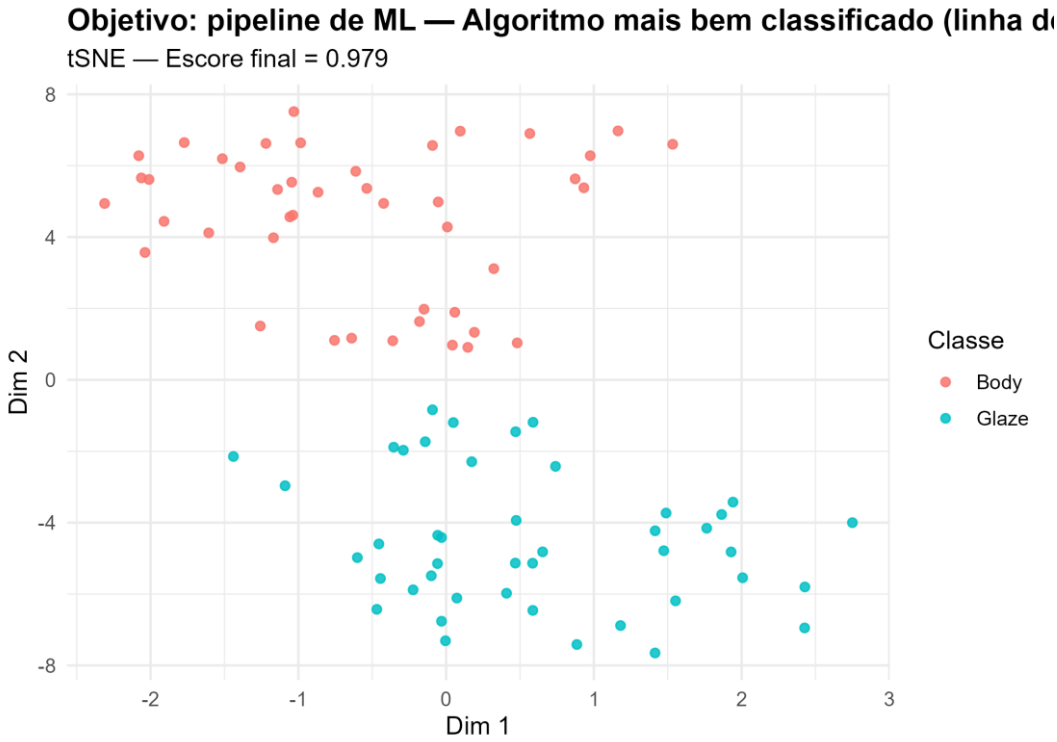
(a)


Objetivo: visualização — Algoritmo mais bem classificado (linha de b
tSNE — Escore final = 0.979
Dim 2
Dim 1
8
4
0
-4
-8
-2
-1
0
1
2
3
Classe
Body
Glaze

(b)



(c)

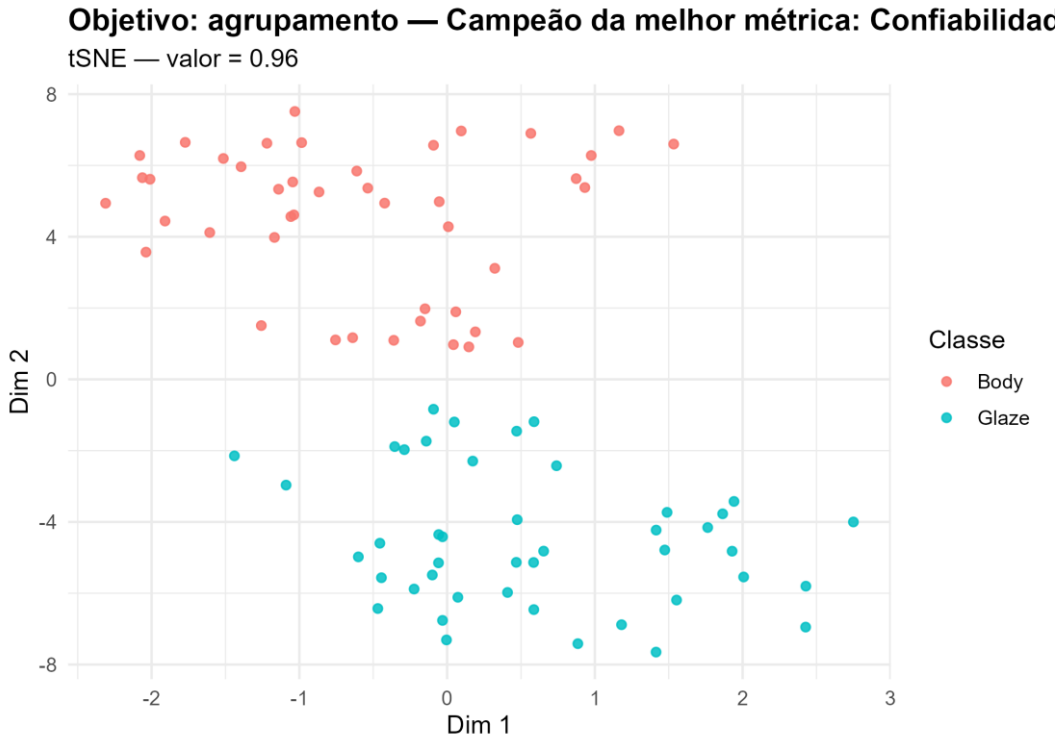


(d)

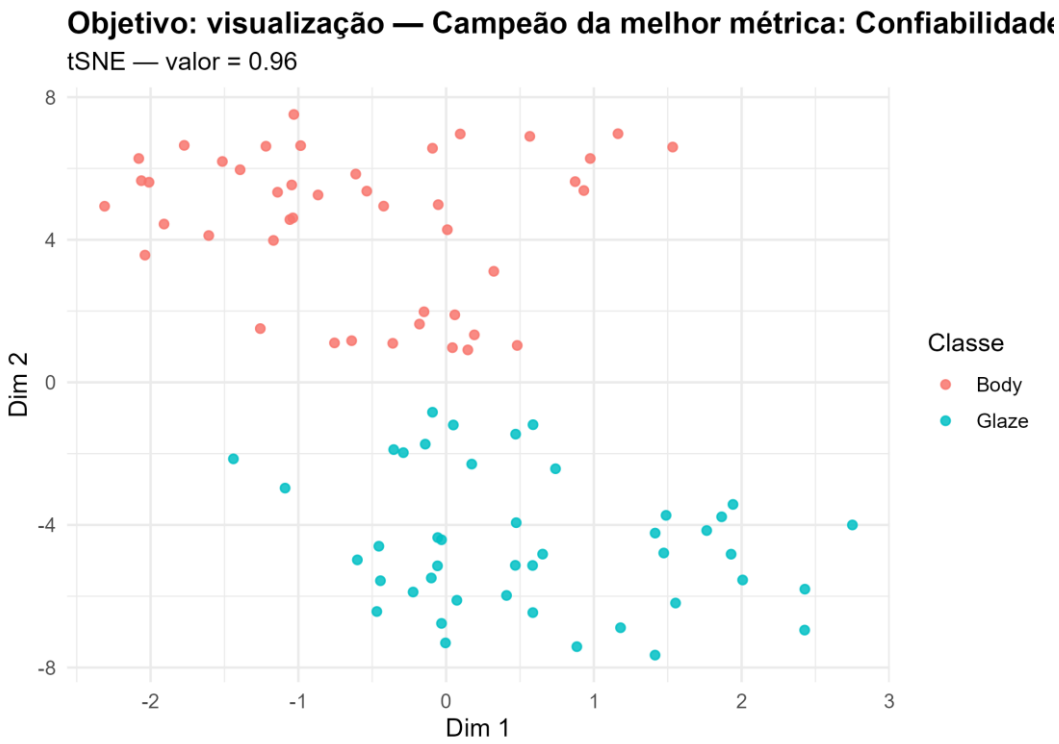
Figura 23 – Projeções bidimensionais produzidas pelo algoritmo melhor classificado para cada objetivo, com base na Pontuação Final (Final Score) do ranqueamento de referência (Baseline

Ranking): (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

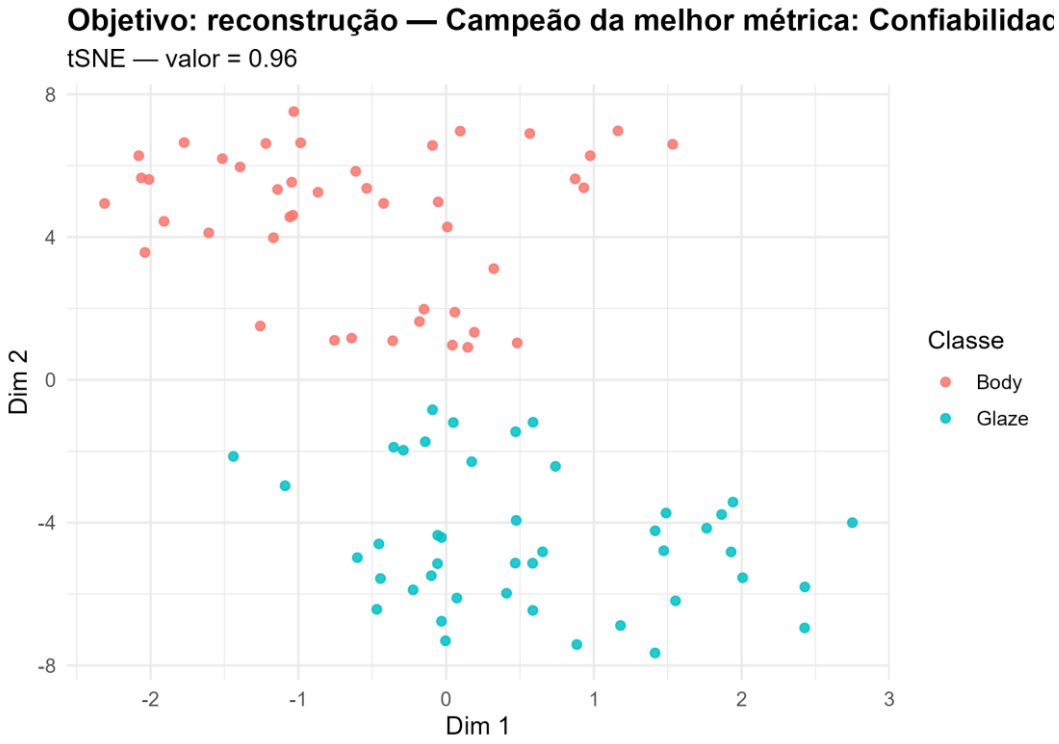
A Figura 24 mostra as projeções geradas pelo algoritmo campeão sob a métrica mais consistente. Para o conjunto de dados df2, essa métrica é a Confiabilidade (Trustworthiness), e o campeão é novamente o t-SNE, de modo que a disposição espelha de perto a figura anterior. A concordância entre o ranqueamento de referência e a seleção orientada pela métrica é, em si, informativa: quando um conjunto de dados se separa de forma tão nítida quanto este, a escolha do critério de avaliação tem pouca influência sobre qual técnica é preferida, e a decisão pode ser tomada com base em critérios secundários, como a interpretabilidade ou a disponibilidade de um mapeamento explícito.



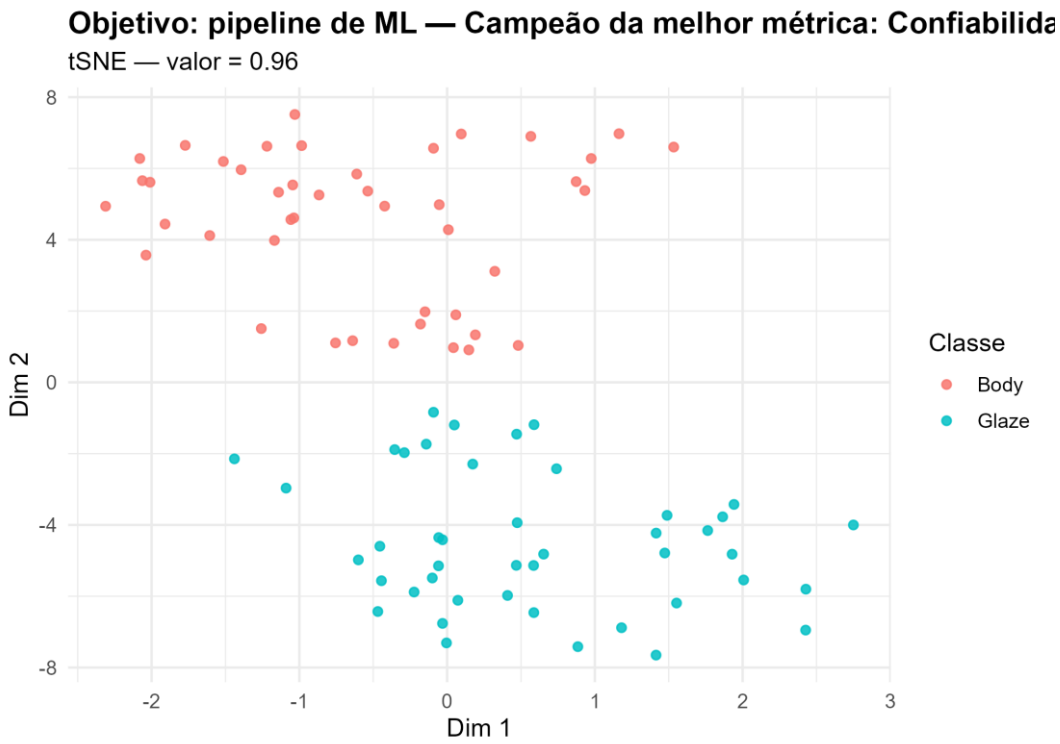
(a)


Objetivo: visualização — Campeão da melhor métrica: Confiabilidade
tSNE — valor = 0.96
Dim 2
Dim 1
8
4
0
-4
-8
-2
-1
0
1
2
3
Classe
Body
Glaze

(b)


Objetivo: reconstrução — Campeão da melhor métrica: Confiabilidad
tSNE — valor = 0.96
Dim 2
Dim 1
8
4
0
-4
-8
-2
-1
0
1
2
3
Classe
Body
Glaze

(c)



(d)

Figura 24 – Projeções bidimensionais geradas pelo algoritmo campeão, selecionado com base na métrica de melhor desempenho para cada objetivo analítico: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

6. ESTUDO DE CASO III

6.1 Descrição do Conjunto de Dados

O conjunto de dados Dry Bean foi denominado df3. Imagens de 13.611 grãos, pertencentes a sete variedades registradas de feijão seco, foram obtidas com uma câmera de alta resolução. A partir dessas imagens, foram extraídas 16 características, correspondentes a 12 medidas dimensionais e a 4 descritores de forma dos grãos. As sete variedades de feijão utilizadas neste estudo foram selecionadas com base em atributos como forma, formato, tipo, estrutura e importância comercial. Foi desenvolvido um sistema de visão computacional para distinguir entre essas sete variedades registradas de feijão seco, cujas características são bastante semelhantes, possibilitando a classificação automática e uniforme das sementes [89].

6.2 Resultados e Discussão

O mapa de calor de correlação revela fortes dependências entre métricas de avaliação conceitualmente relacionadas, utilizadas para avaliar o desempenho das técnicas de redução de dimensionalidade (ver Figura 25).

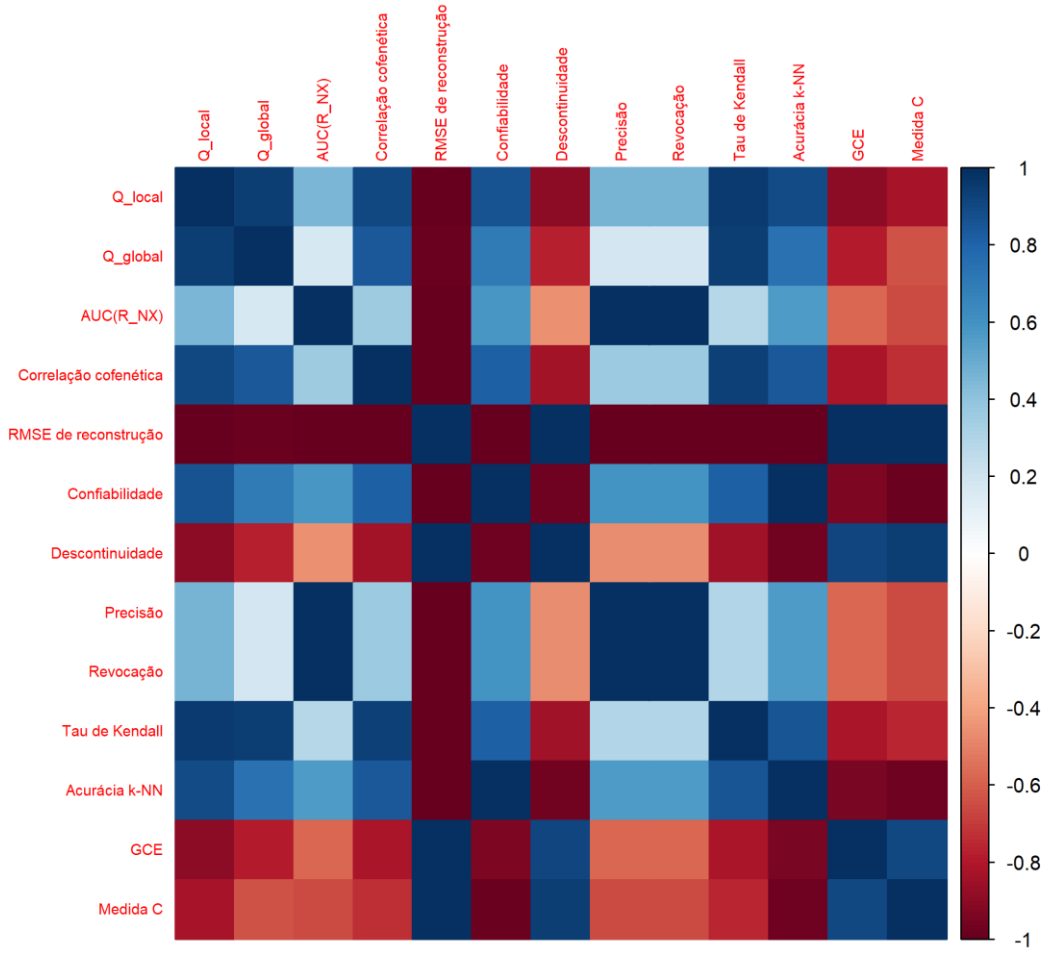


Figura 25 – Estrutura da matriz de correlação entre as métricas de avaliação utilizadas no framework de benchmarking.

As métricas de preservação das relações de vizinhança local (por exemplo, Q_{local}, *Trustworthiness, Continuity* e *Accuracy-kNN*) apresentam fortes correlações positivas, indicando elevada redundância e um foco comum na fidelidade da estrutura local dos dados. De maneira semelhante, as métricas de preservação da estrutura global (Q_{global}, *Cophenetic correlation* e *Kendall's Tau*) formam um grupo fortemente correlacionado, refletindo uma avaliação consistente da preservação da estrutura da variedade (manifold) em larga escala. As métricas Precision e Recall exibem correlação praticamente perfeita, como esperado em cenários de classificação balanceada.

Em contrapartida, a métrica *RMSE_Reconstruction* apresenta fortes correlações negativas com a maioria das métricas de vizinhança e de classificação, evidenciando o compromisso (trade-off) fundamental entre a precisão da reconstrução e a preservação da estrutura dos dados. As métricas de distorção geométrica (*GCE* e *C-Measure*) formam um agrupamento distinto e apresentam correlações negativas com as métricas de preservação local e global, reforçando seu papel analítico específico. De modo geral, os resultados demonstram que a avaliação de técnicas de redução de dimensionalidade é intrinsecamente multiobjetivo, sustentando a necessidade de ponderar as métricas de acordo com o cenário de aplicação, em vez de se basear em um único indicador de desempenho.

A Tabela 32A e a Tabela 32B apresentam um conjunto abrangente de métricas de desempenho relacionadas à preservação da estrutura local, global, geométrica e à classificação para o Conjunto de Dados 3, considerando diversas técnicas de redução de dimensionalidade. Métodos lineares e quase lineares, como PCA, MDS, DRR, Isomap e Kamada–Kawai, apresentam, de forma consistente, elevados valores de Qglobal, correlação cofenética, Kendall's Tau e Continuity, indicando excelente preservação da estrutura global da variedade (manifold) associada à manutenção estável das relações de vizinhança locais. As abordagens baseadas em DRR e PCA também apresentam baixos erros de reconstrução, confirmando sua adequação para aplicações em que a reconstrução dos dados constitui o principal objetivo.

Os métodos não lineares voltados à preservação das vizinhanças locais apresentam compromissos (trade-offs) distintos. O t-SNE alcança os maiores valores de Precision, Recall e Accuracy-kNN, além dos menores valores das métricas de distorção geométrica (GCE e C-Measure), evidenciando sua superioridade para tarefas de separação entre classes e visualização, embora apresente menor capacidade de preservar a estrutura global dos dados.

Por outro lado, Kernel PCA (kPCA), HLLE e nMDS apresentam desempenho inferior em quase todas as métricas, especialmente quanto à preservação da estrutura global e à exatidão de classificação. Em conjunto, os resultados reforçam a ideia de que

nenhum método é universalmente ótimo. Em vez disso, o desempenho depende fortemente do objetivo analítico, o que corrobora a adoção de um framework de avaliação multicritério, orientado ao cenário de aplicação, para a seleção da técnica de redução de dimensionalidade mais apropriada.

Tabela 32A – Figuras de mérito obtidas do conjunto de dados df3.

Algoritmo	Q_local	Q_global	AUC(R_NX)	Correlação cofenética	RMSE de reconstrução	Confiabilidade	Continuidade
DRR	0.616	**0.938**	0.117	0.964	**0.425**	0.934	**0.991**
Isomap	0.614	0.934	0.121	0.963		0.937	**0.991**
PCA	0.615	**0.938**	0.118	0.963	**0.425**	0.934	**0.991**
PCA_L1	0.602	0.925	0.109	0.941		0.925	0.989
kPCA	0.444	0.790	0.073	0.406	174.8	0.863	0.980
FastICA	0.600	0.913	0.117	0.946	**0.425**	0.934	0.990
MDS	0.615	**0.938**	0.118	0.963		0.934	**0.991**
nMDS	0.080	0.580	0.001	-0.002		0.501	0.499
DrL	0.385	0.735	0.150	0.542		0.982	0.960
FruchtermanReingold	0.468	0.842	0.047	0.783		0.887	0.973
KamadaKawai	**0.637**	**0.938**	0.132	**0.978**		0.947	0.990
HLLE	0.284	0.769	0.002	0.004		0.560	0.605
DiffusionMaps	0.420	0.834	0.013	0.142		0.818	0.858
tSNE	0.577	0.809	**0.484**	0.647		**0.997**	0.985

Tabela 32B – Figuras de mérito obtidas do conjunto de dados df3.

Algoritmo	Descontinuidade	Precisão	Revocação	Tau de Kendall	Acurácia k-NN	GCE	Medida C
DRR	**0.009**	0.122	0.122	0.850	0.854	2.581	13905.4
Isomap	**0.009**	0.125	0.125	0.842	0.864	2.195	13299.8
PCA	**0.009**	0.123	0.123	0.849	0.853	2.339	13879.3
PCA_L1	0.011	0.114	0.114	0.809	0.873	2.083	14816.6
kPCA	0.020	0.075	0.075	0.362	0.688	4.469	17585.6
FastICA	0.010	0.122	0.122	0.795	0.852	2.568	13986.4
MDS	**0.009**	0.123	0.123	0.849	0.853	2.335	13879.3
nMDS	0.501	0.001	0.001	0.000	0.186	10.321	42386.2
DrL	0.040	0.155	0.155	0.439	0.897	1.889	9648.4
FruchtermanReingold	0.027	0.048	0.048	0.579	0.761	3.581	16927.7
KamadaKawai	0.010	0.137	0.137	**0.874**	0.876	2.072	13062.3
HLLE	0.395	0.002	0.002	0.121	0.283	5.863	40166.6
DiffusionMaps	0.142	0.014	0.014	0.533	0.670	5.071	17791.5
tSNE	0.015	**0.491**	**0.491**	0.553	**0.917**	**1.545**	**4432.1**

A Tabela 33 resume os índices compostos orientados ao objetivo e as pontuações finais (Final Score) obtidas para o Conjunto de Dados 3, integrando, em um único framework de ranqueamento, o desempenho relacionado à preservação das estruturas local, global e geométrica, bem como à classificação. Em todos os cenários analíticos, o t-SNE alcança, de forma consistente, a maior Pontuação Final, impulsionado pelos seus valores praticamente ótimos dos Índices Local (Índice_Local) e de Classificação (Índice_Classe), confirmando sua superioridade para tarefas de agrupamento (clustering), visualização e integração em pipelines de aprendizado de máquina.

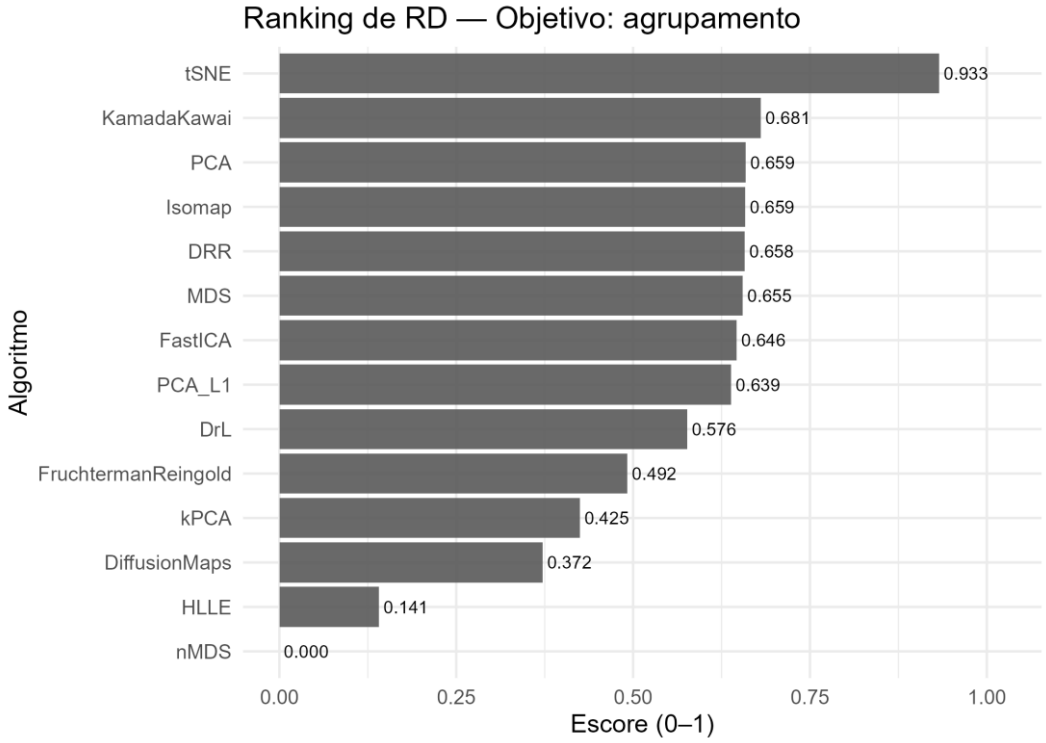
Nos cenários orientados à reconstrução, PCA e DRR apresentam desempenho competitivo, refletindo um compromisso (trade-off) mais equilibrado entre a preservação da estrutura global dos dados e a manutenção da estabilidade geométrica. Os métodos Kamada–Kawai e Isomap ocupam posições intermediárias no ranqueamento, demonstrando boa fidelidade à estrutura global e às propriedades geométricas, porém com capacidade de discriminação entre classes mais limitada.

De modo geral, a tabela demonstra que o ranqueamento dos algoritmos depende fortemente do objetivo analítico e que o emprego de índices compostos ponderados conforme o cenário de aplicação constitui uma estratégia robusta e de fácil interpretação para a seleção da técnica de redução de dimensionalidade mais adequada.

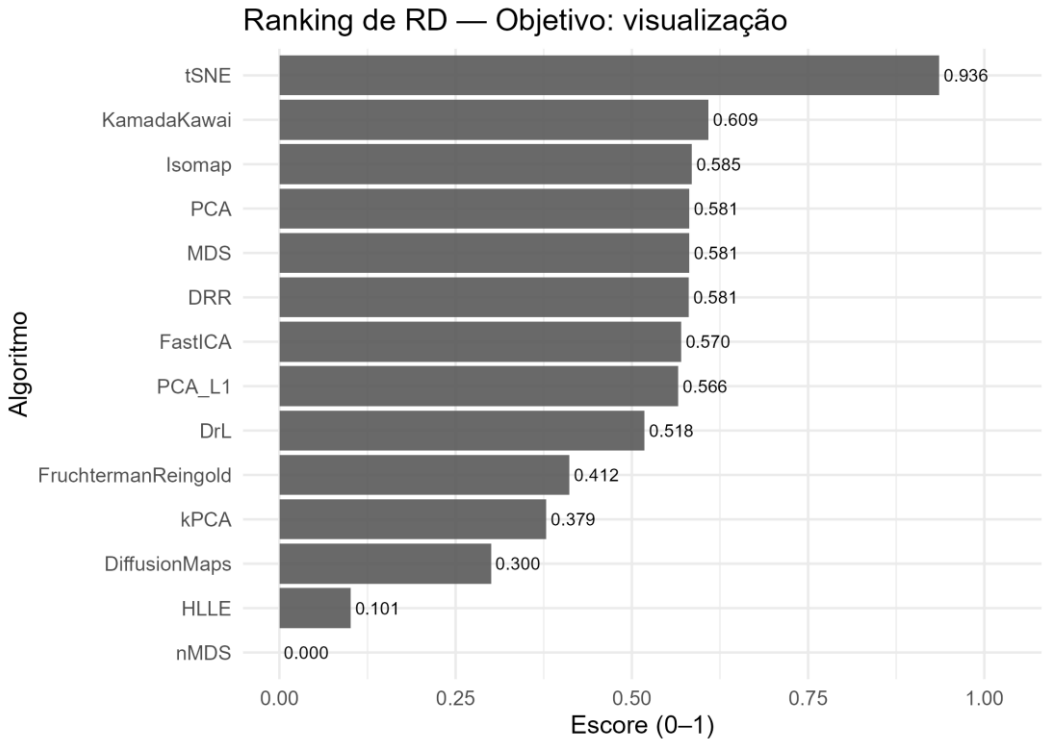
Tabela 33 – Figuras de mérito obtidas do conjunto de dados df3.

Algoritmo	Índice_Local	Índice_Global	Índice_Geom	Índice_Classe	Pontuação_Final	Objetivo
tSNE	0.973	0.734	0.996	1.000	**0.933**	**agrupamento**
KamadaKawai	0.614	0.818	0.904	0.500	0.681	agrupamento
PCA	0.583	0.800	0.915	0.470	0.659	agrupamento
Isomap	0.586	0.796	0.897	0.478	0.659	agrupamento
DRR	0.582	0.800	0.908	0.469	0.658	agrupamento
tSNE	0.973	0.734	0.996	1.000	**0.936**	**visualização**
KamadaKawai	0.614	0.818	0.904	0.500	0.609	visualização
Isomap	0.586	0.796	0.897	0.478	0.585	visualização
PCA	0.583	0.800	0.915	0.470	0.581	visualização
MDS	0.583	0.800	0.887	0.470	0.581	visualização
tSNE	0.973	0.734	0.996	1.000	**0.910**	**reconstrução**
KamadaKawai	0.614	0.818	0.904	0.500	0.791	reconstrução
PCA	0.583	0.800	0.915	0.470	0.781	reconstrução
DRR	0.582	0.800	0.908	0.469	0.778	reconstrução
Isomap	0.586	0.796	0.897	0.478	0.774	reconstrução
tSNE	0.973	0.734	0.996	1.000	**0.936**	**pipeline de ML**
KamadaKawai	0.614	0.818	0.904	0.500	0.609	pipeline de ML
Isomap	0.586	0.796	0.897	0.478	0.585	pipeline de ML
PCA	0.583	0.800	0.915	0.470	0.581	pipeline de ML
MDS	0.583	0.800	0.887	0.470	0.581	pipeline de ML

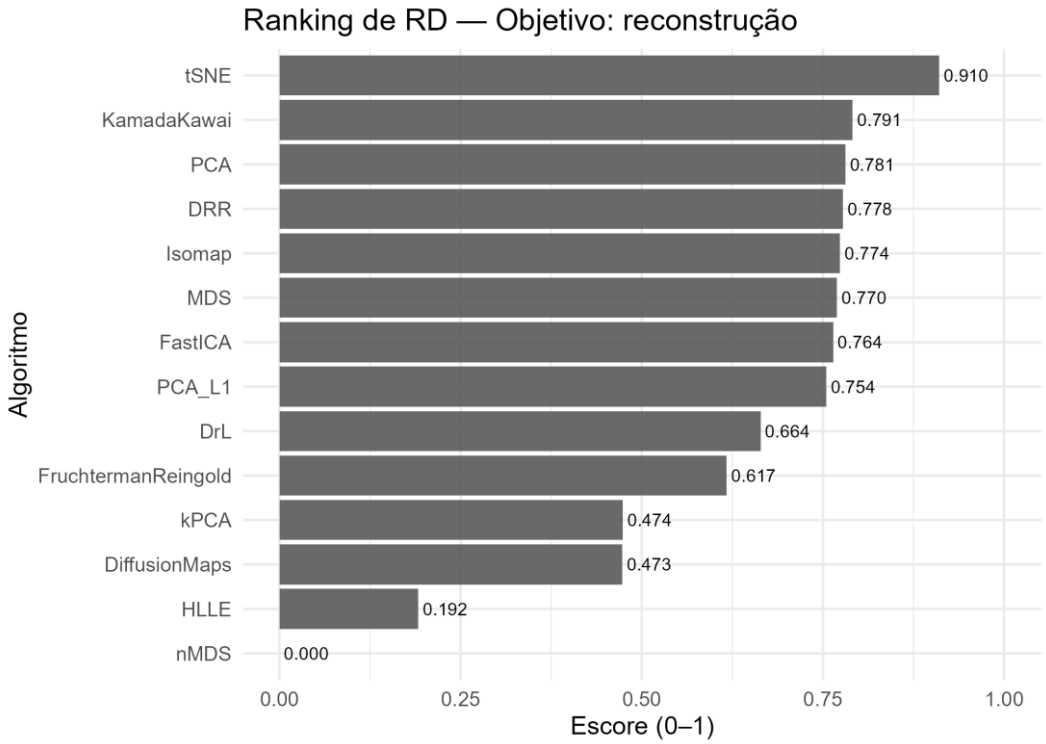
A Figura 26 apresenta os ranqueamentos dos algoritmos de redução de dimensionalidade (RD) orientados por objetivos para quatro cenários analíticos: agrupamento (clustering), visualização, reconstrução e integração em pipelines de aprendizado de máquina.



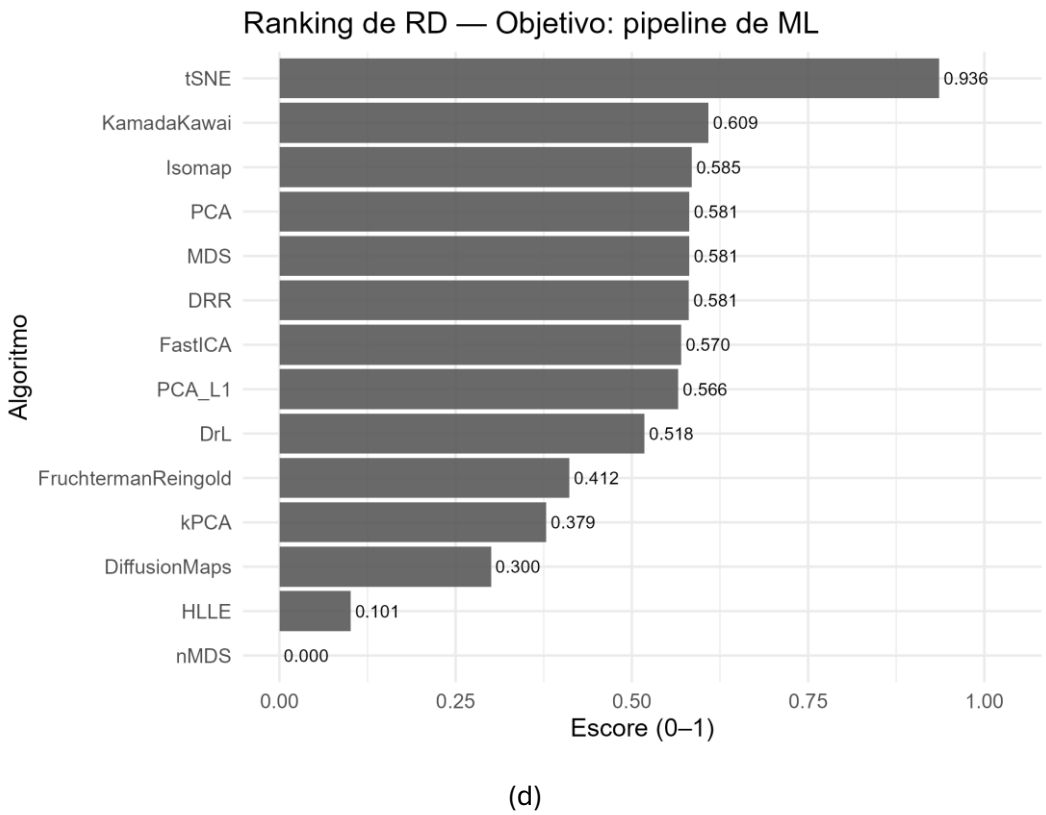
(a)


Ranking de RD — Objetivo: visualização
tSNE
KamadaKawai
Isomap
PCA
MDS
DRR
FastICA
PCA_L1
DrL
FruchtermanReingold
kPCA
DiffusionMaps
HLLE
nMDS
0.936
0.609
0.585
0.581
0.581
0.581
0.570
0.566
0.518
0.412
0.379
0.300
0.101
0.000
Algoritmo
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

(b)


Ranking de RD — Objetivo: reconstrução
tSNE
KamadaKawai
PCA
DRR
Isomap
MDS
FastICA
PCA_L1
DrL
FruchtermanReingold
kPCA
DiffusionMaps
HLLE
nMDS
0.910
0.791
0.781
0.778
0.774
0.770
0.764
0.754
0.664
0.617
0.474
0.473
0.192
0.000
Algoritmo
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

(c)



(d)

Figura 26 – Gráficos de barras horizontais mostrando as pontuações de desempenho normalizadas (0–1) para cada algoritmo de redução de dimensionalidade nos quatro objetivos analíticos: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

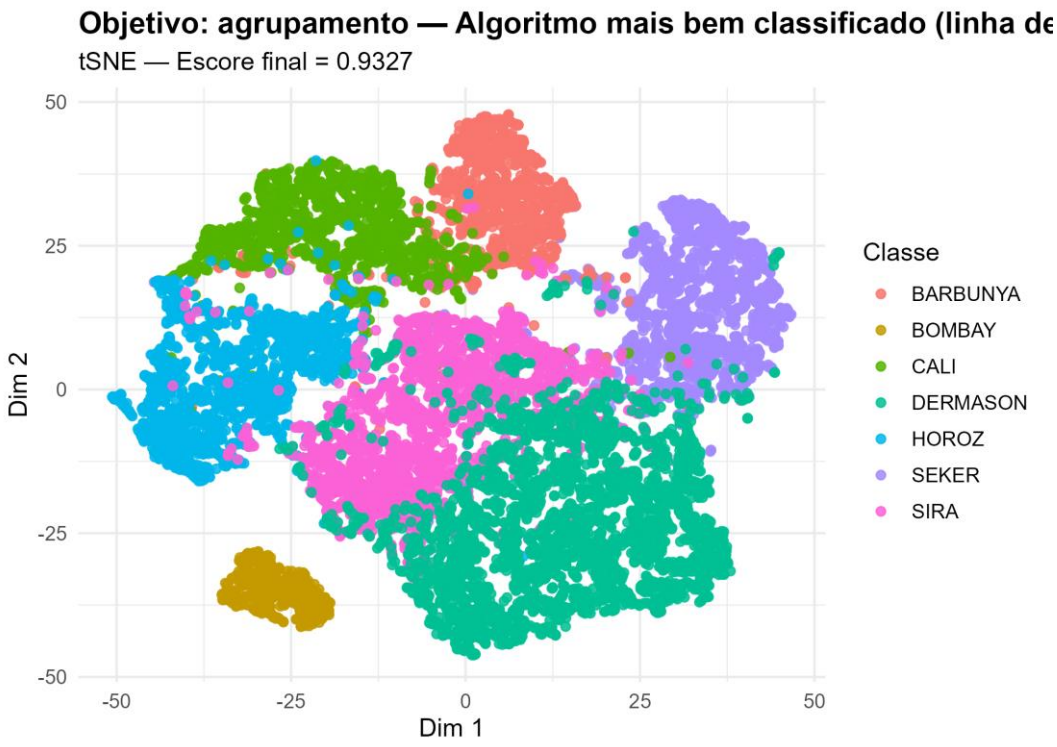
Em todos os objetivos analíticos, o t-SNE alcança, de forma consistente, as maiores pontuações, especialmente nas tarefas de agrupamento, visualização e integração em pipelines de aprendizado de máquina, refletindo sua elevada capacidade de preservar as relações de vizinhança local e a separabilidade entre as classes.

Para os objetivos orientados à reconstrução, PCA e DRR constituem alternativas competitivas, apresentando desempenho equilibrado ao preservar a estrutura global dos dados e, simultaneamente, ao minimizar o erro de reconstrução. Os métodos Kamada–Kawai e Isomap ocupam posições intermediárias, oferecendo boa fidelidade à estrutura global e às propriedades geométricas, embora apresentem desempenho inferior nos

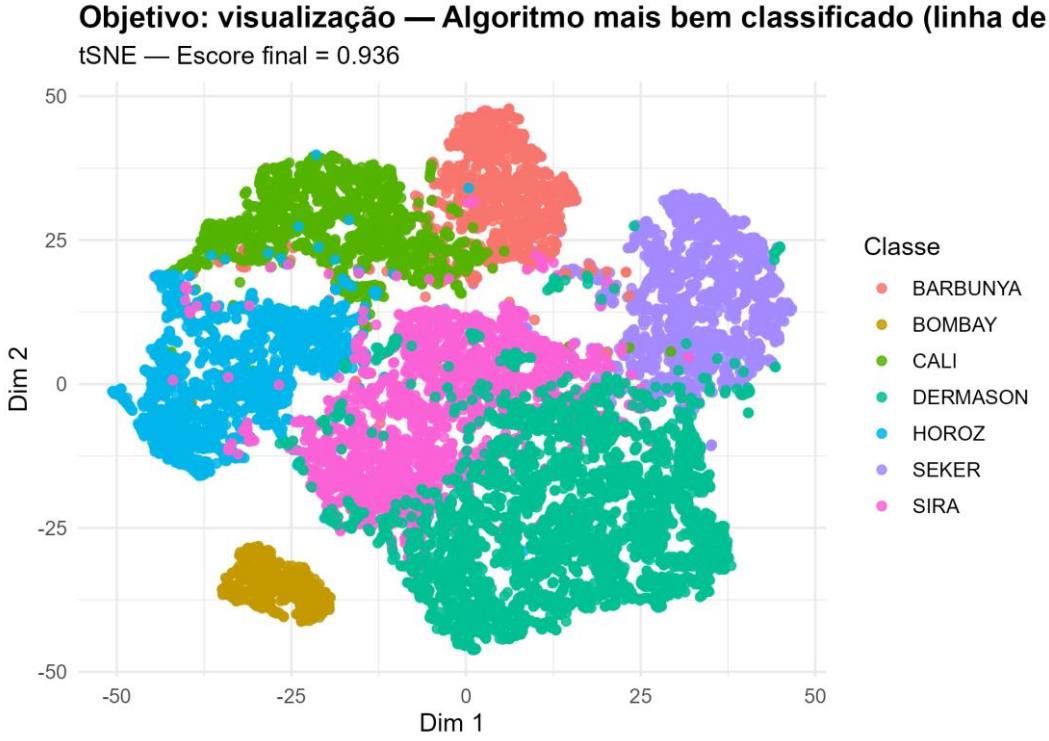
critérios de discriminação entre classes. Em contraste, Kernel PCA (kPCA), HLLE e nMDS ocupam consistentemente as últimas posições nos diferentes cenários, indicando adequação limitada aos objetivos analíticos avaliados.

De modo geral, a figura evidencia que o desempenho dos algoritmos depende fortemente do objetivo da análise, reforçando a necessidade de um processo de ranqueamento baseado no cenário de aplicação e em múltiplos critérios de avaliação, em vez da escolha de um método de redução de dimensionalidade considerado universalmente ótimo.

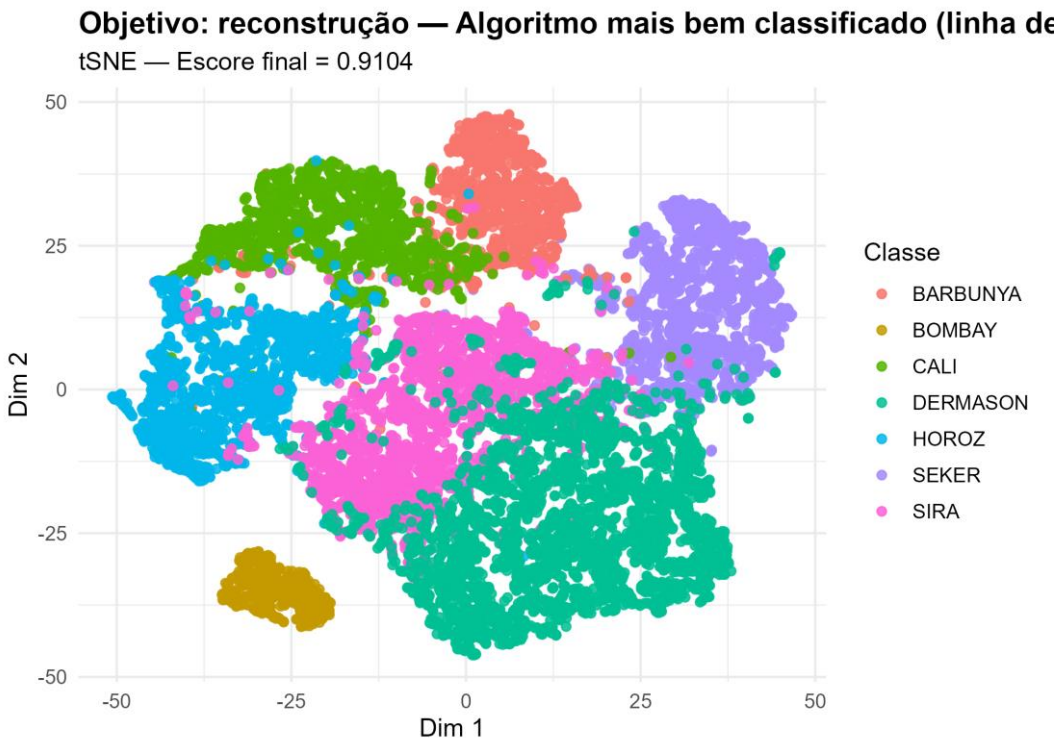
A Figura 27 apresenta as projeções bidimensionais geradas pelo algoritmo campeão, selecionado com base na Pontuação Final composta (Final Composite Score), para quatro objetivos analíticos: agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina. Em todos os cenários, o t-SNE ocupa consistentemente a primeira posição, produzindo projeções com separação bem definida entre os grupos e estruturas de vizinhança locais coerentes. As diferentes classes formam agrupamentos compactos e visualmente bem separados, evidenciando a elevada capacidade do método de preservar tanto as informações relacionadas às classes quanto a topologia local dos dados.


Objetivo: agrupamento — Algoritmo mais bem classificado (linha de
tSNE — Escore final = 0.9327
Dim 2
Dim 1
50
25
0
-25
-50
-50
-25
0
25
50
Classe
BARBUNYA
BOMBAY
CALI
DERMASON
HOROZ
SEKER
SIRA

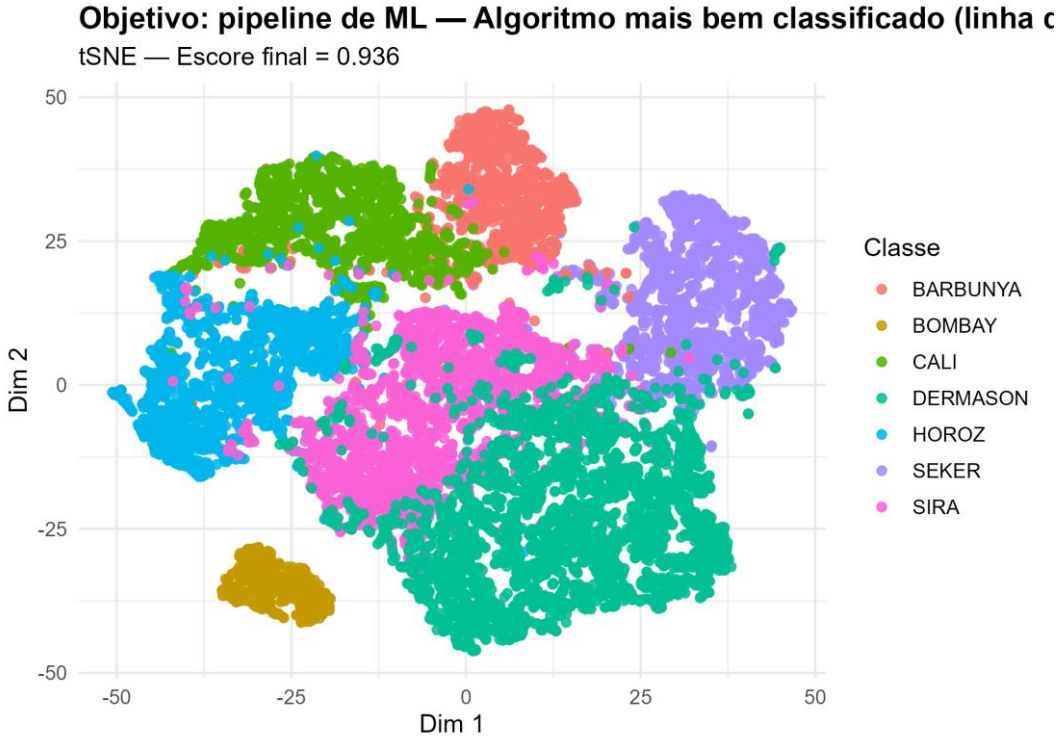
(a)


Objetivo: visualização — Algoritmo mais bem classificado (linha de
tSNE — Escore final = 0.936
Dim 2
Dim 1
50
25
0
-25
-50
-50
-25
0
25
50
Classe
BARBUNYA
BOMBAY
CALI
DERMASON
HOROZ
SEKER
SIRA

(b)



(c)



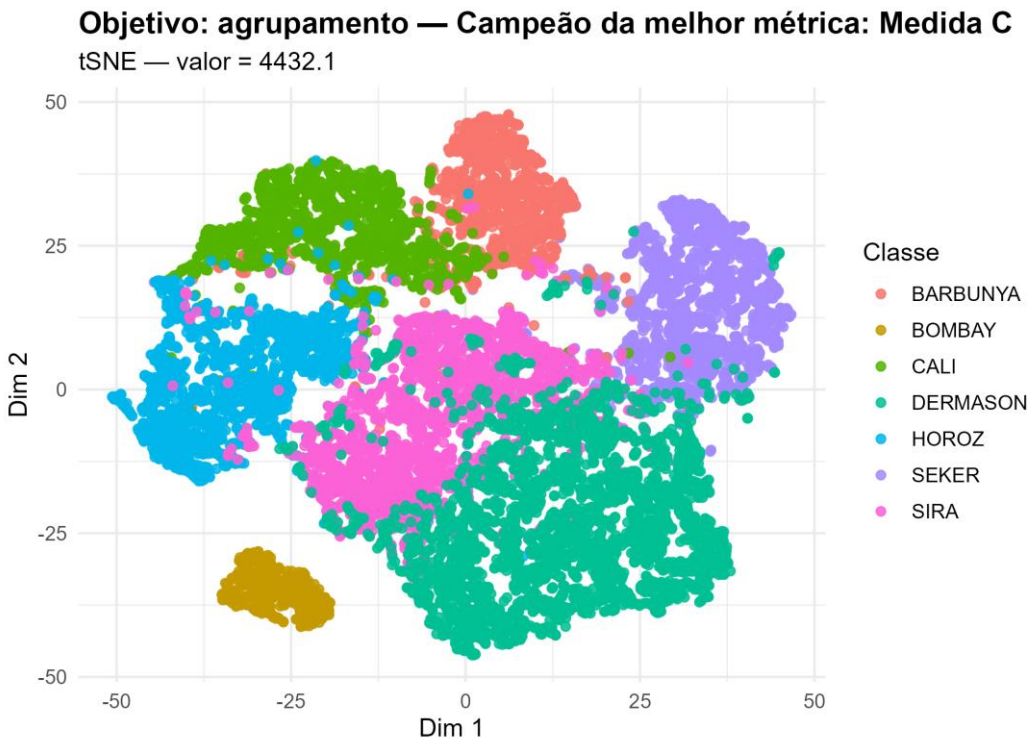
(d)

Figura 27 – Projeções bidimensionais produzidas pelo algoritmo melhor classificado para cada objetivo, com base na Pontuação Final (Final Score) do ranqueamento de referência (Baseline

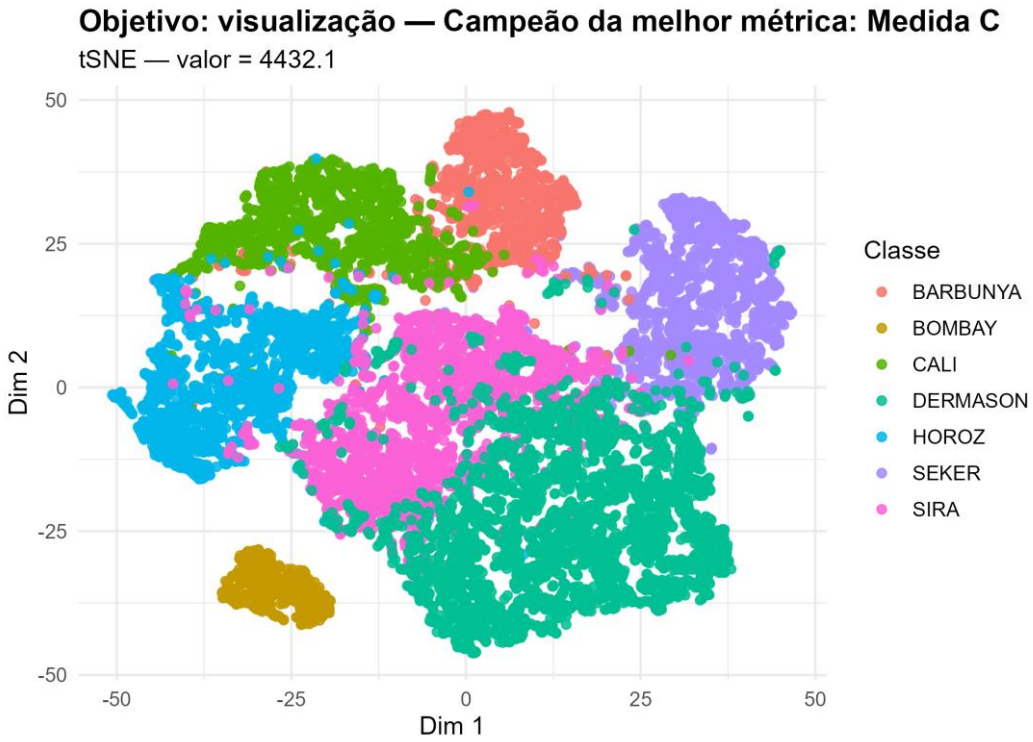
Ranking): (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

Embora a configuração geométrica geral permaneça semelhante entre os diferentes objetivos, diferenças sutis na dispersão dos pontos refletem a ponderação específica das métricas de avaliação em cada cenário analítico. Os resultados confirmam que o ranqueamento orientado por objetivos produz projeções estáveis e facilmente interpretáveis, ao mesmo tempo em que demonstram que a qualidade de visualização e a separabilidade entre classes não implicam, necessariamente, desempenho ótimo em termos de reconstrução ou de preservação da estrutura global dos dados. De modo geral, a figura evidencia a eficácia do framework multicritério proposto na seleção de métodos de redução de dimensionalidade alinhados a objetivos analíticos específicos.

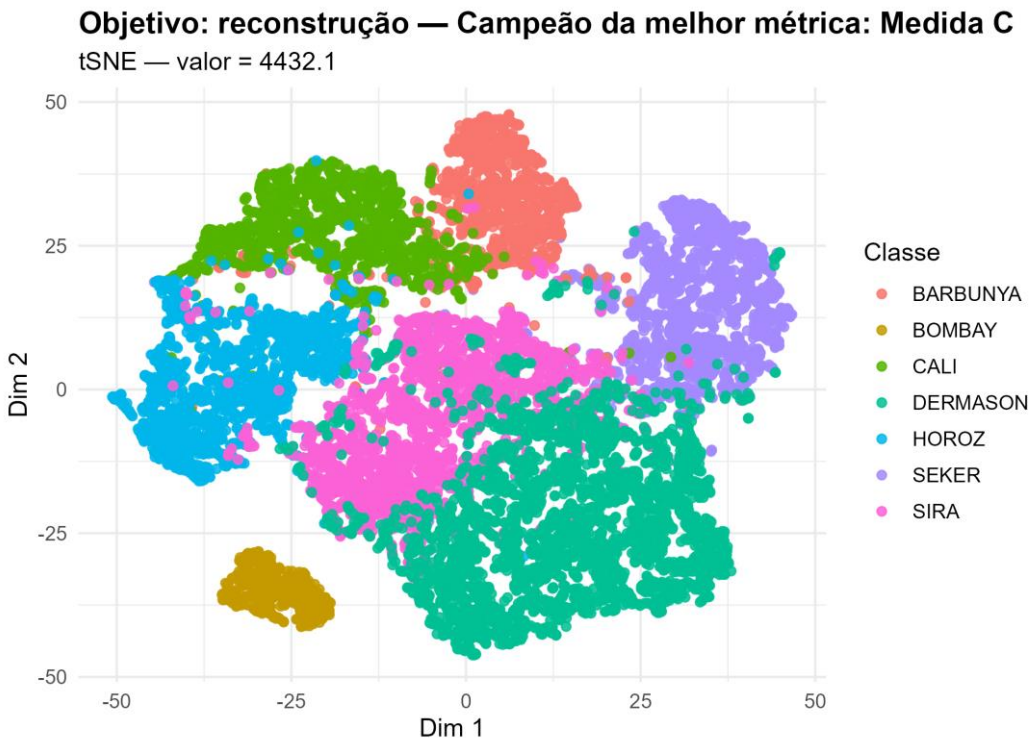
A Figura 28 apresenta as projeções bidimensionais geradas pelo algoritmo campeão da melhor métrica individual (Discontinuity) para os objetivos de agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina. Em todos os casos, o nMDS é selecionado por minimizar as descontinuidades na variedade (manifold) de baixa dimensionalidade. Entretanto, as projeções obtidas apresentam acentuada sobreposição entre as classes e baixa separação entre os agrupamentos, indicando fraca preservação das relações de vizinhança local e da estrutura das classes. Esses resultados evidenciam uma limitação crítica da otimização baseada em uma única métrica: minimizar apenas a descontinuidade geométrica não garante projeções interpretáveis nem analiticamente úteis.


Objetivo: agrupamento — Campeão da melhor métrica: Medida C
tSNE — valor = 4432.1
Dim 2
Dim 1
50
25
0
-25
-50
-50
-25
0
25
50
Classe
BARBUNYA
BOMBAY
CALI
DERMASON
HOROZ
SEKER
SIRA

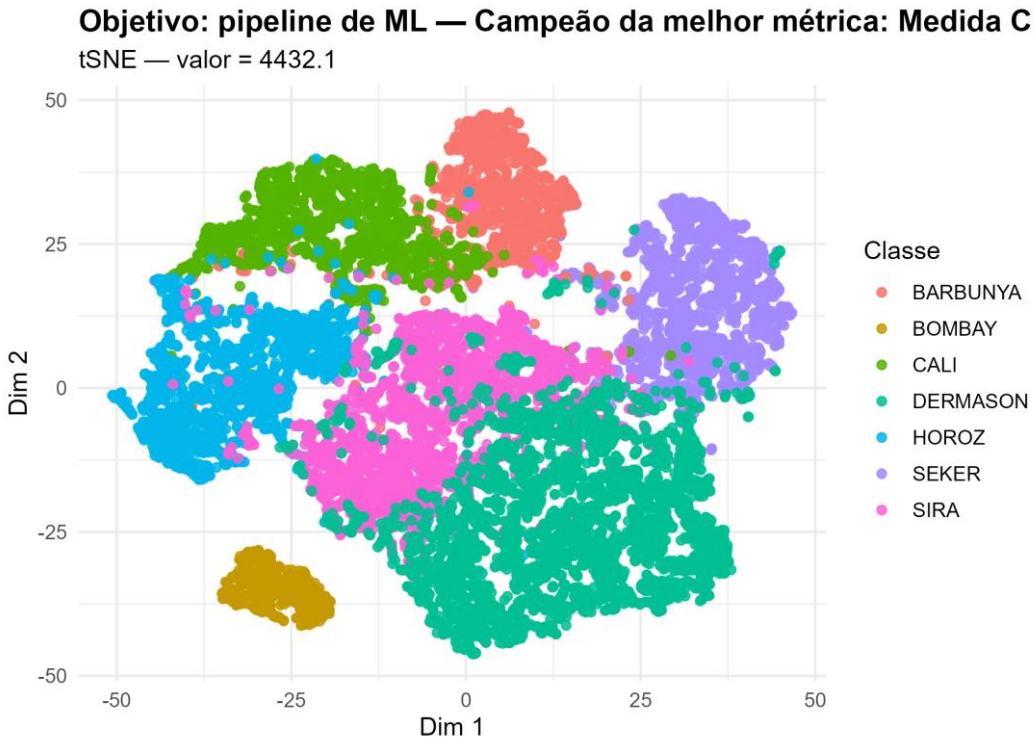
(a)


Objetivo: visualização — Campeão da melhor métrica: Medida C
tSNE — valor = 4432.1
Dim 2
Dim 1
50
25
0
-25
-50
-50
-25
0
25
50
Classe
BARBUNYA
BOMBAY
CALI
DERMASON
HOROZ
SEKER
SIRA

(b)



(c)



(d)

Figura 28 – Projeções bidimensionais geradas pelo algoritmo campeão, selecionado com base na métrica de melhor desempenho para cada objetivo analítico: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

A figura contrasta de forma marcante com as seleções obtidas pelo método multicritério orientado por objetivos, demonstrando que a otimização baseada em uma única métrica pode conduzir a soluções degeneradas. Consequentemente, a figura reforça a necessidade de frameworks de avaliação compostos e ponderados, de acordo com o cenário de aplicação, para a seleção robusta de métodos de redução de dimensionalidade.

7. ESTUDO DE CASO IV

7.1 Descrição do Conjunto de Dados

O conjunto de dados Glass Identification foi denominado df4. Ele contém 214 instâncias e 9 variáveis (atributos). O Serviço de Ciência Forense dos Estados Unidos (USA Forensic Science Service) identificou seis tipos de vidro com base na composição de seus óxidos [90].

7.2 Resultados e Discussão

O mapa de calor de correlação apresentado na Figura 29 ilustra as relações entre as diversas métricas de avaliação empregadas na análise do desempenho dos algoritmos de redução de dimensionalidade.

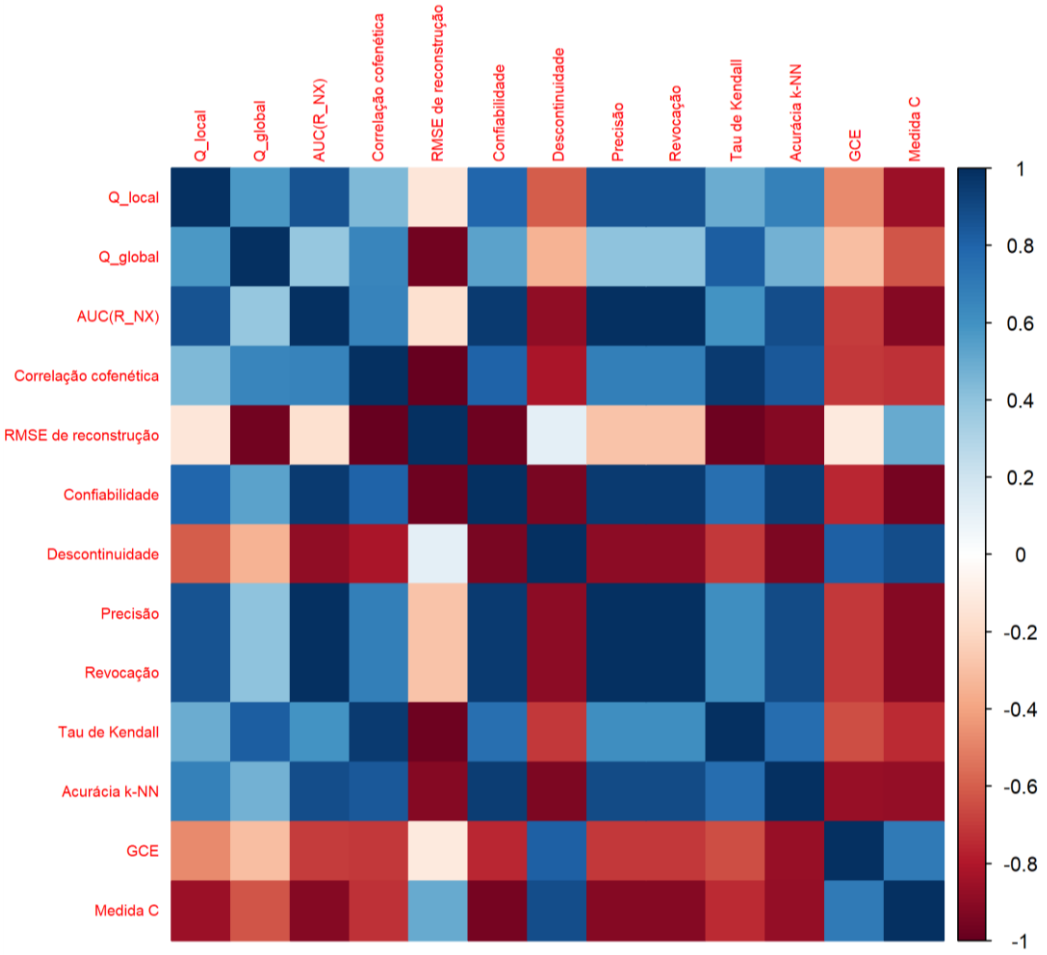


Figura 29 – Estrutura da matriz de correlação entre as métricas de avaliação utilizadas no framework de benchmarking.

A figura revela dois agrupamentos dominantes: (i) as medidas de preservação da estrutura local, incluindo Q_{local}, *Trustworthiness*, *Precision*, *Recall* e *Accuracy_kNN*, que apresentam fortes correlações positivas entre si; e (ii) as medidas de preservação da estrutura global, como Q_{global}, *AUC_R(NX)*, *Cophenetic* e *KendallTau*. Esses grupos representam famílias coerentes de métricas que capturam propriedades estruturais complementares da variedade dos dados. Em contraste, as métricas baseadas em reconstrução e distorção (*RMSE_Reconstruction*, *Discontinuity*, *GCE* e *C_measure*) apresentam fortes correlações negativas com os grupos associados à preservação local e global, indicando a existência de um compromisso (trade-off) inerente: algoritmos que otimizam a fidelidade das relações de vizinhança ou da variedade geralmente apresentam desempenho inferior em reconstrução, e vice-versa. De modo geral, a figura evidencia a natureza multidimensional da avaliação de métodos de redução de dimensionalidade e destaca a necessidade de selecionar métricas de acordo com o cenário analítico, em vez de depender de um único indicador de desempenho.

As métricas resumidas do Conjunto de Dados 4 revelam padrões claros de desempenho entre os algoritmos de redução de dimensionalidade avaliados, conforme apresentado na Tabela 34A e na Tabela 34B. O MDS não métrico (nMDS) destaca-se como um dos métodos de melhor desempenho, alcançando as maiores pontuações de preservação da estrutura global (Qglobal, AUC_R(NX) e Cophenetic) e valores elevados de precisão e revocação, além de produzir o melhor indicador de preservação da variedade (KendallTau) entre todos os métodos.

Os algoritmos Kamada–Kawai e Isomap também apresentam um comportamento equilibrado entre as métricas locais, globais e orientadas a classes, indicando preservação

robusta tanto da topologia das relações de vizinhança quanto da geometria da variedade. Em contraste, os métodos baseados em projeções espectrais não lineares (HLLE e DrL) e em leiautes dirigidos por forças (Fruchterman–Reingold) apresentam desempenho inferior, particularmente nas métricas globais, nos valores de precisão e revocação e na acurácia de classificação baseada em k-NN.

Notavelmente, o t-SNE alcança a maior pontuação de preservação local (Qlocal) e os maiores valores combinados de precisão e revocação, refletindo excelente desempenho em agrupamento e separabilidade entre classes. Entretanto, suas métricas relacionadas à preservação da estrutura global são, em comparação, inferiores, o que é uma característica amplamente reconhecida desse método.

De modo geral, os resultados confirmam que nenhum algoritmo apresenta desempenho ótimo em todos os critérios. A preservação global da variedade favorece nMDS, Kamada–Kawai e Isomap, enquanto o t-SNE representa melhor a fidelidade das relações de vizinhança local e a estrutura discriminante dos dados. Esses resultados reforçam a importância de selecionar os algoritmos de redução de dimensionalidade de acordo com o objetivo analítico pretendido, em vez de adotar um único método como solução universal.

Tabela 34A – Figuras de mérito obtidas do conjunto de dados df4.

Algoritmo	Q_local	Q_global	AUC(R_NX)	Correlação cofenética	RMSE de reconstrução	Confiabilidade	Continuidade
DRR	0.360	0.790	0.403	0.848	**0.701**	0.841	0.901
Isomap	0.466	0.833	0.495	0.911		0.888	0.940
PCA	0.405	0.811	0.433	0.859	**0.701**	0.853	0.922
PCA L1	0.291	0.772	0.337	0.781		0.802	0.881
kPCA	0.380	0.732	0.419	0.510	7.808	0.795	0.913
FastICA	0.390	0.806	0.436	0.854	**0.701**	0.854	0.923
MDS	0.405	0.811	0.434	0.859		0.853	0.922
nMDS	0.530	**0.874**	0.579	**0.952**		0.929	**0.953**
DrL	0.186	0.671	0.089	-0.013		0.550	0.570
Fruchterman-Reingold	0.308	0.707	0.340	0.246		0.769	0.868
Kamada-Kawai	0.486	0.818	0.550	0.907		0.863	0.926
HLLE	0.389	0.852	0.146	0.169		0.659	0.616
t-SNE	**0.637**	0.761	**0.684**	0.461		**0.936**	0.944

Tabela 34B – Figuras de mérito obtidas do conjunto de dados df4.

Algoritmo	Descontinuidade	Precisão	Revocação	Tau de Kendall	Acurácia k-NN	GCE	Medida C
DRR	0.099	0.425	0.425	0.662	0.636	4.209	209.2
Isomap	0.060	0.513	0.513	0.743	0.626	5.552	146.8
PCA	0.078	0.455	0.455	0.712	0.678	4.219	206.9
PCA L1	0.119	0.352	0.352	0.631	0.621	4.572	262.2
kPCA	0.087	0.437	0.437	0.495	0.579	4.350	210.7
FastICA	0.077	0.457	0.457	0.709	0.673	4.832	196.6
MDS	0.078	0.455	0.455	0.712	0.678	4.243	206.9
nMDS	**0.047**	0.615	0.615	**0.872**	0.659	4.977	**120.6**
DrL	0.430	0.089	0.089	0.012	0.388	6.864	493.0
Fruchterman-Reingold	0.132	0.359	0.359	0.226	0.570	5.424	244.2
Kamada-Kawai	0.074	0.576	0.576	0.756	**0.692**	**4.195**	161.1
HLLE	0.384	0.153	0.153	0.425	0.458	5.931	292.4
t-SNE	0.056	**0.697**	**0.697**	0.372	0.692	4.412	123.8

Os resultados do conjunto de dados df4, apresentados na Tabela 35, evidenciam uma clara hierarquia de desempenho entre os métodos de redução de dimensionalidade. Em todos os objetivos analíticos — agrupamento, reconstrução, visualização e integração em pipelines de aprendizado de máquina — t-SNE e nMDS superam consistentemente os demais algoritmos, embora de maneiras complementares.

O t-SNE alcança valores máximos para os índices de preservação da estrutura local e de discriminação entre classes (Índice_Local = 1,000 e Índice_Classe = 1,000), resultando nas maiores pontuações globais em tarefas que enfatizam a fidelidade das relações de vizinhança e a separabilidade discriminante entre as classes. Em contraste, o nMDS apresenta a melhor preservação da estrutura global da variedade, atingindo o maior Índice_Global (0,956) e obtendo Pontuações Finais (Final Scores) competitivas em todos os objetivos analíticos.

O método Kamada–Kawai apresenta um comportamento equilibrado, combinando preservação moderada da estrutura local com elevada continuidade geométrica (Índice_Geom = 0,940) e boa capacidade de separação entre classes, configurando-se como uma alternativa robusta de desempenho intermediário.

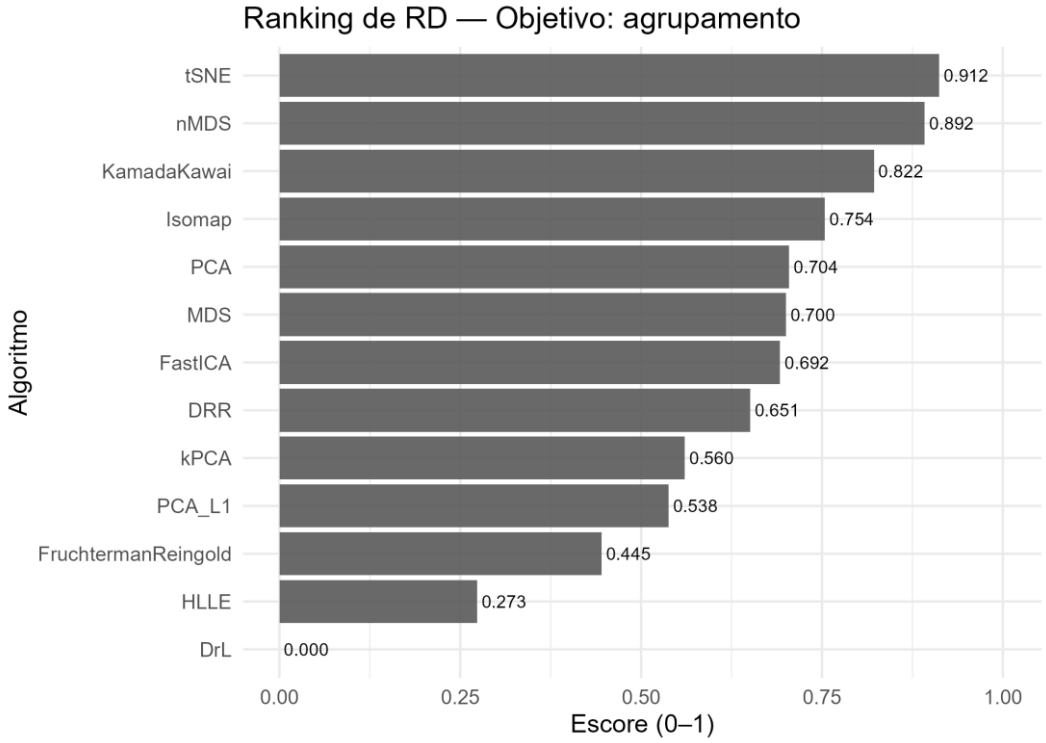
Os métodos lineares, como a PCA, apresentam desempenho consistente, porém em níveis inferiores, o que reflete suas limitações na representação de estruturas não lineares.

De modo geral, a tabela reforça que a superioridade de um algoritmo depende do objetivo analítico. O t-SNE destaca-se quando a preservação da estrutura local e a discriminação entre classes são prioritárias, enquanto o nMDS é a melhor escolha para aplicações que exigem uma representação fiel da geometria global da variedade dos dados.

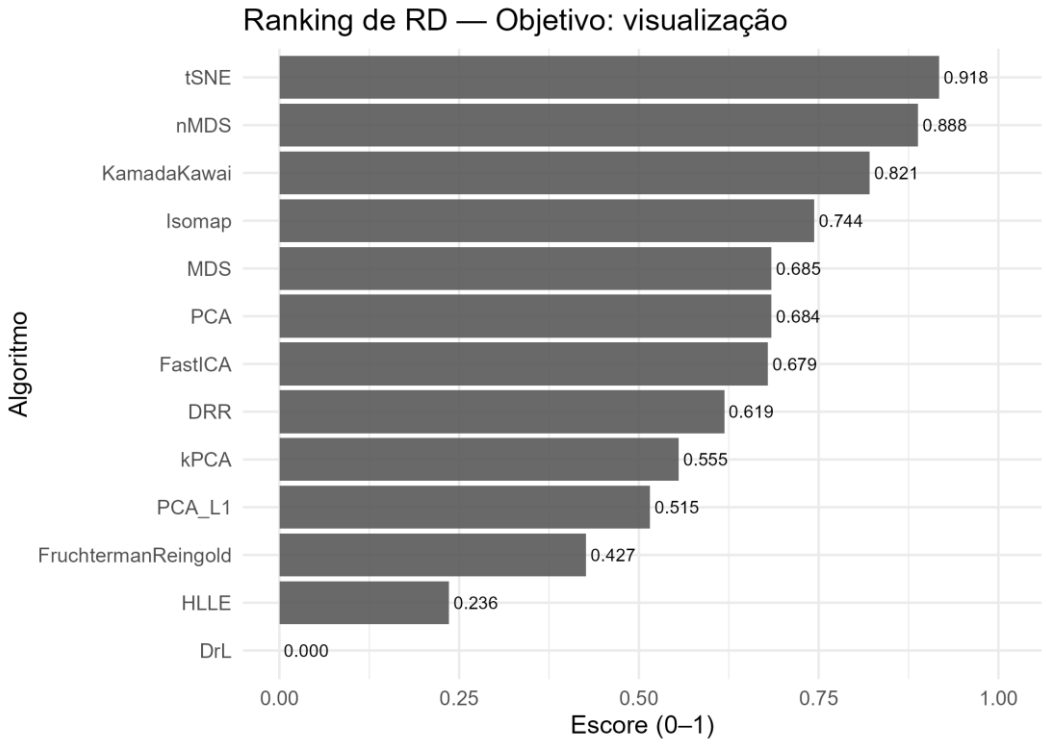
Tabela 35 – Figuras de mérito obtidas do conjunto de dados df4.

Algoritmo	Índice_Local	Índice_Global	Índice_Geom	Índice_Classe	Pontuação_Final	Objetivo
tSNE	1.000	0.588	0.962	1.000	**0.912**	**agrupamento**
nMDS	0.869	0.956	0.902	0.874	0.892	agrupamento
KamadaKawai	0.770	0.829	0.940	0.867	0.822	agrupamento
Isomap	0.723	0.822	0.796	0.726	0.754	agrupamento
PCA	0.619	0.746	0.920	0.719	0.704	agrupamento
tSNE	1.000	0.588	0.962	1.000	**0.918**	**visualização**
nMDS	0.869	0.956	0.902	0.874	0.888	visualização
KamadaKawai	0.770	0.829	0.940	0.867	0.821	visualização
Isomap	0.723	0.822	0.796	0.726	0.744	visualização
MDS	0.619	0.747	0.890	0.719	0.685	visualização
nMDS	0.869	0.956	0.902	0.874	**0.908**	**reconstrução**
tSNE	1.000	0.588	0.962	1.000	0.861	reconstrução
KamadaKawai	0.770	0.829	0.940	0.867	0.856	reconstrução
Isomap	0.723	0.822	0.796	0.726	0.782	reconstrução
PCA	0.619	0.746	0.920	0.719	0.777	reconstrução
tSNE	1.000	0.588	0.962	1.000	**0.918**	**pipeline de ML**
nMDS	0.869	0.956	0.902	0.874	0.888	pipeline de ML
KamadaKawai	0.770	0.829	0.940	0.867	0.821	pipeline de ML
Isomap	0.723	0.822	0.796	0.726	0.744	pipeline de ML
MDS	0.619	0.747	0.890	0.719	0.685	pipeline de ML

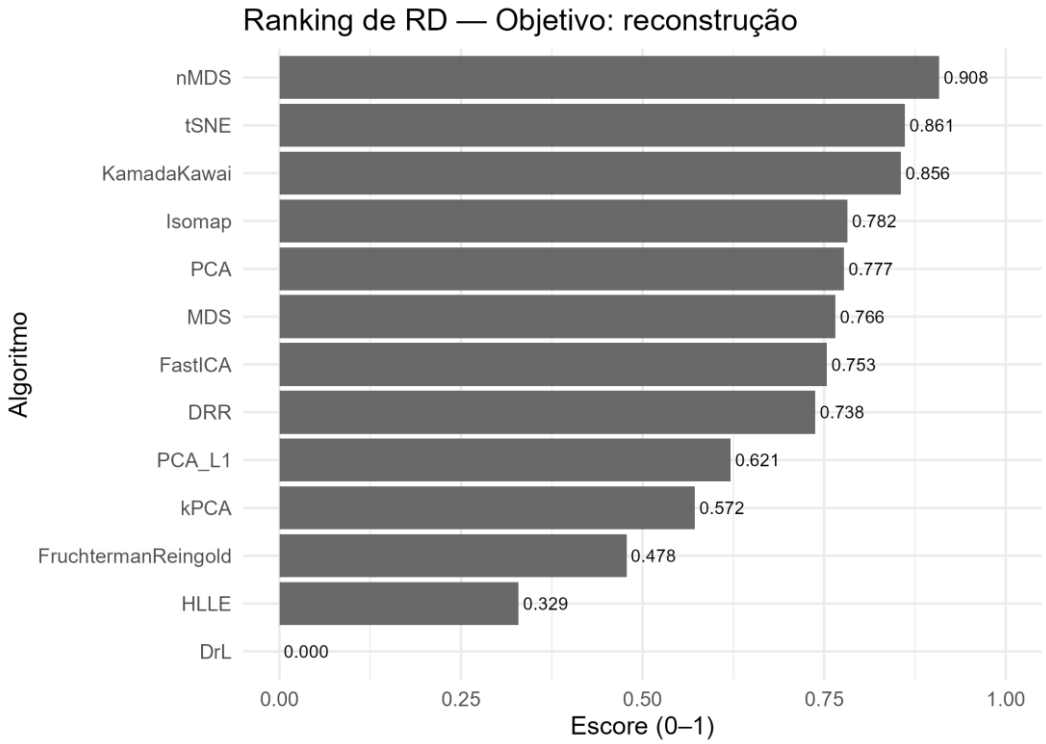
A Figura 30 apresenta o ranqueamento dos algoritmos de redução de dimensionalidade orientado por objetivos para o Conjunto de Dados 4, considerando quatro cenários analíticos: agrupamento (clustering), visualização, reconstrução e integração em pipelines de aprendizado de máquina.



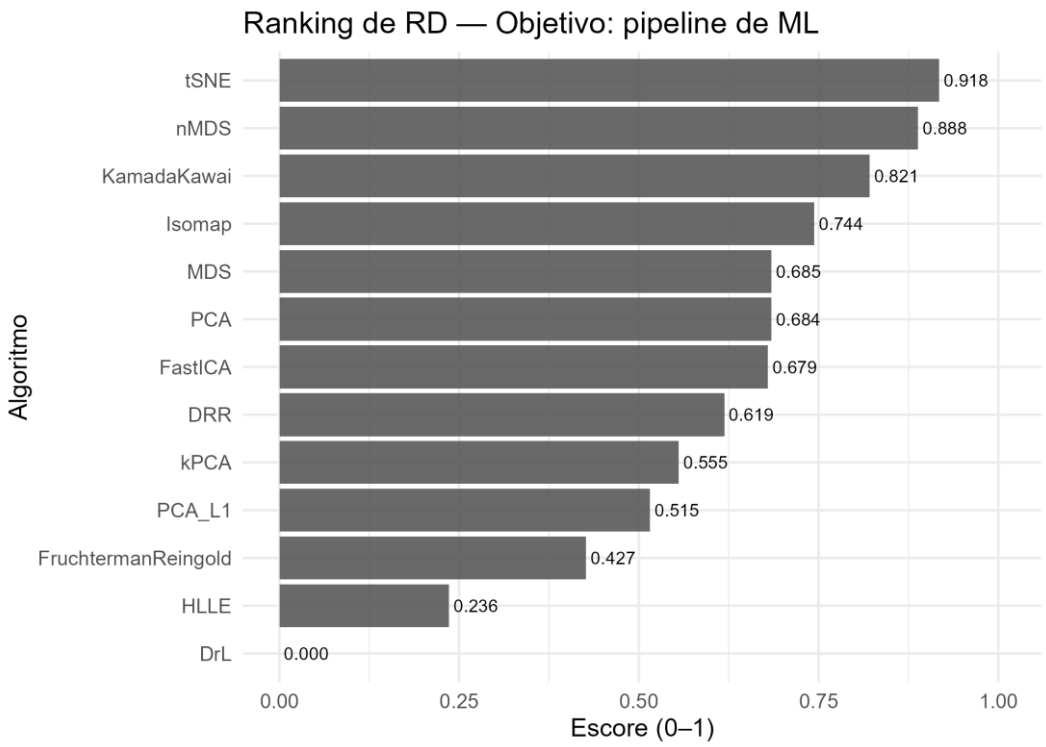
(a)


Ranking de RD — Objetivo: visualização
tSNE
nMDS
KamadaKawai
Isomap
MDS
PCA
FastICA
DRR
kPCA
PCA_L1
FruchtermanReingold
HLLE
DrL
0.918
0.888
0.821
0.744
0.685
0.684
0.679
0.619
0.555
0.515
0.427
0.236
0.000
Algoritmo
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

(b)


Ranking de RD — Objetivo: reconstrução
nMDS
tSNE
KamadaKawai
Isomap
PCA
MDS
FastICA
DRR
PCA_L1
kPCA
FruchtermanReingold
HLLE
DrL
0.908
0.861
0.856
0.782
0.777
0.766
0.753
0.738
0.621
0.572
0.478
0.329
0.000
Algoritmo
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

(c)



(d)

Figura 30 – Gráficos de barras horizontais mostrando as pontuações de desempenho normalizadas (0–1) para cada algoritmo de redução de dimensionalidade nos quatro objetivos analíticos: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

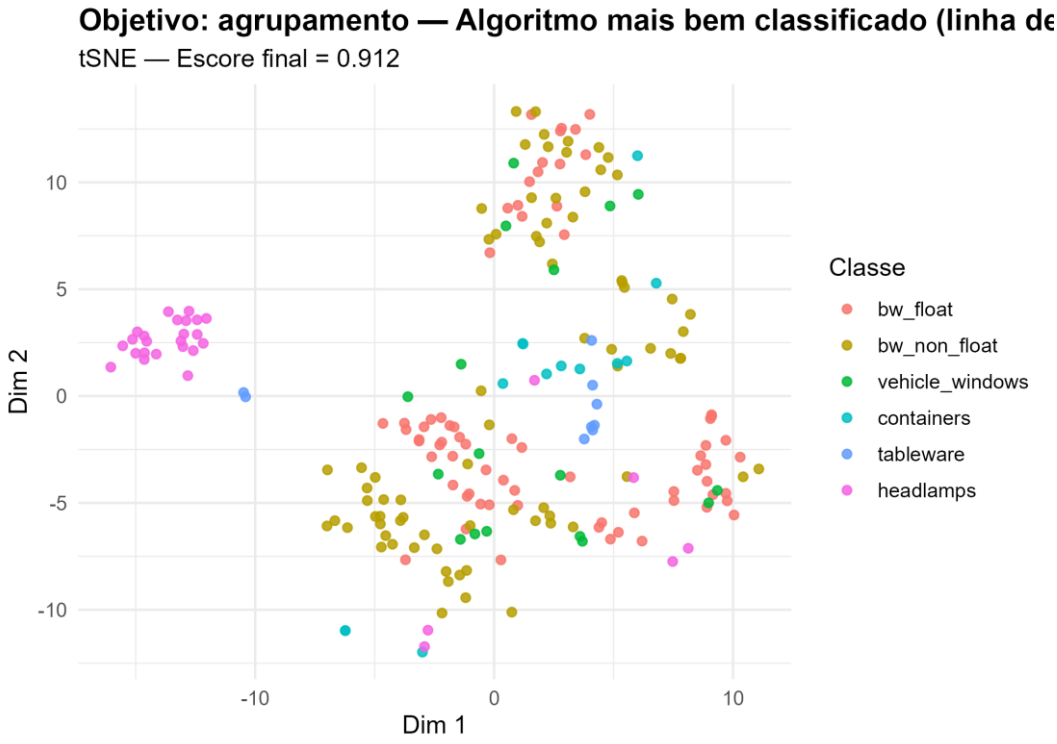
De modo geral, t-SNE e nMDS alcançam pontuações mais altas de forma consistente, embora apresentem pontos fortes distintos. O t-SNE destaca-se nos objetivos de agrupamento, visualização e integração em pipelines de aprendizado de máquina, graças à sua elevada capacidade de preservar a estrutura das relações de vizinhança local e à excelente separabilidade entre classes. O nMDS, embora apresente desempenho muito próximo ao do t-SNE em diversos objetivos, torna-se o método de melhor desempenho na tarefa de reconstrução, em concordância com sua reconhecida capacidade de preservar as relações globais da variedade dos dados.

Os métodos Kamada–Kawai e Isomap constituem um segundo grupo de destaque, apresentando desempenho equilibrado entre os diferentes objetivos e configurando-se

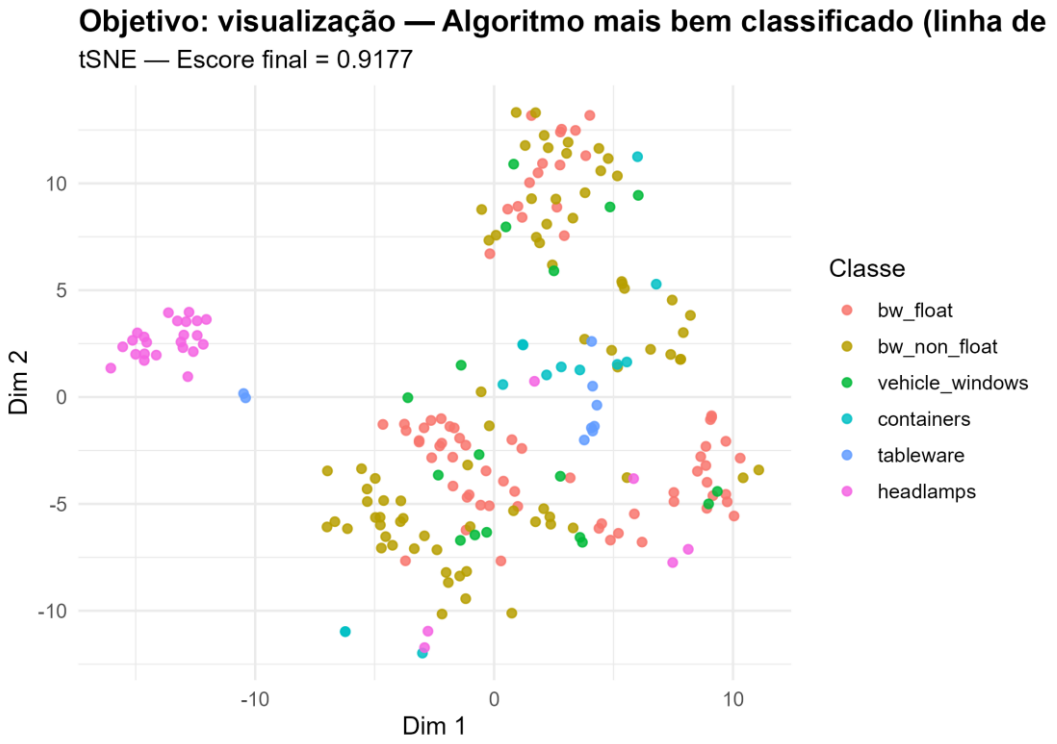
como alternativas competitivas quando tanto a continuidade geométrica quanto a preservação da estrutura das classes são aspectos relevantes. Os métodos lineares (PCA, MDS e FastICA) apresentam desempenho moderado, porém consistente. Em contraste, os métodos baseados em projeções espectrais e em desenhos de grafos, como HLLE, DrL e Fruchterman–Reingold, permanecem entre os algoritmos de menor desempenho, o que reflete limitações na preservação da geometria global ou da estrutura discriminante dos dados.

De modo geral, o ranqueamento evidencia que nenhuma técnica é universalmente ótima. Em vez disso, a adequação de cada algoritmo depende fortemente do objetivo analítico: o t-SNE é superior em tarefas que exigem elevada fidelidade à estrutura local e boa separação entre classes, enquanto o nMDS oferece melhor desempenho na preservação da estrutura global e na reconstrução da variedade dos dados.

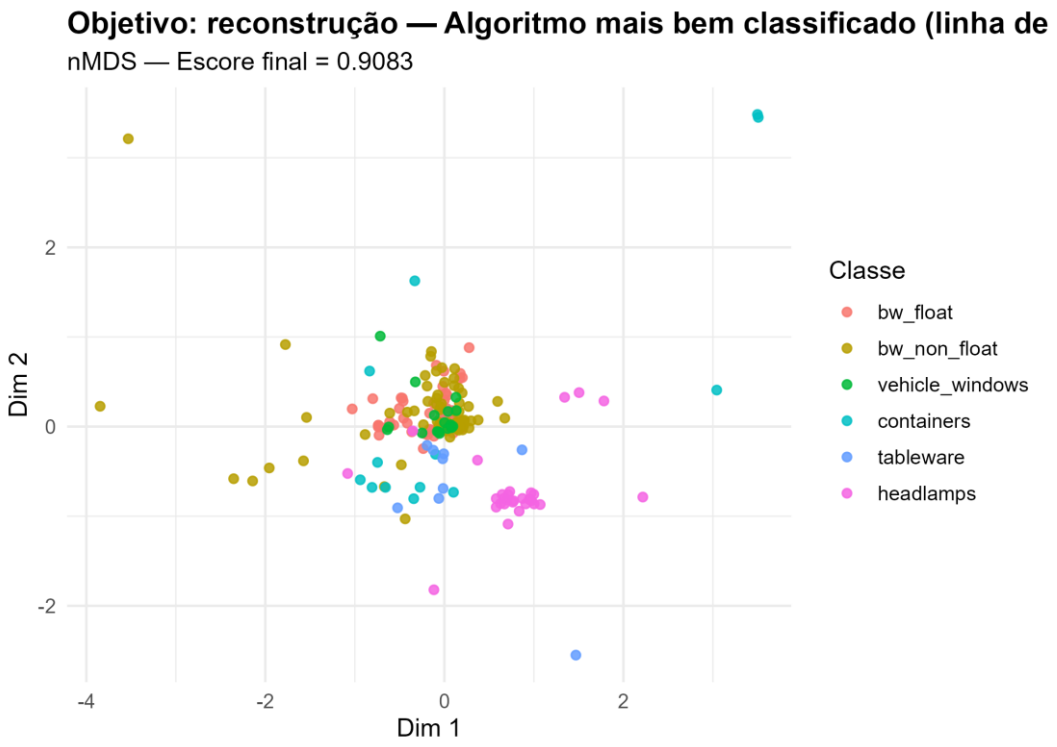
A Figura 31 compara as projeções bidimensionais produzidas pelos algoritmos de redução de dimensionalidade mais bem classificados para o Conjunto de Dados 4, considerando quatro objetivos analíticos distintos.


Objetivo: agrupamento — Algoritmo mais bem classificado (linha de
tSNE — Escore final = 0.912
Dim 2
Dim 1
10
5
0
-5
-10
-10
0
10
Classe
bw_float
bw_non_float
vehicle_windows
containers
tableware
headlamps

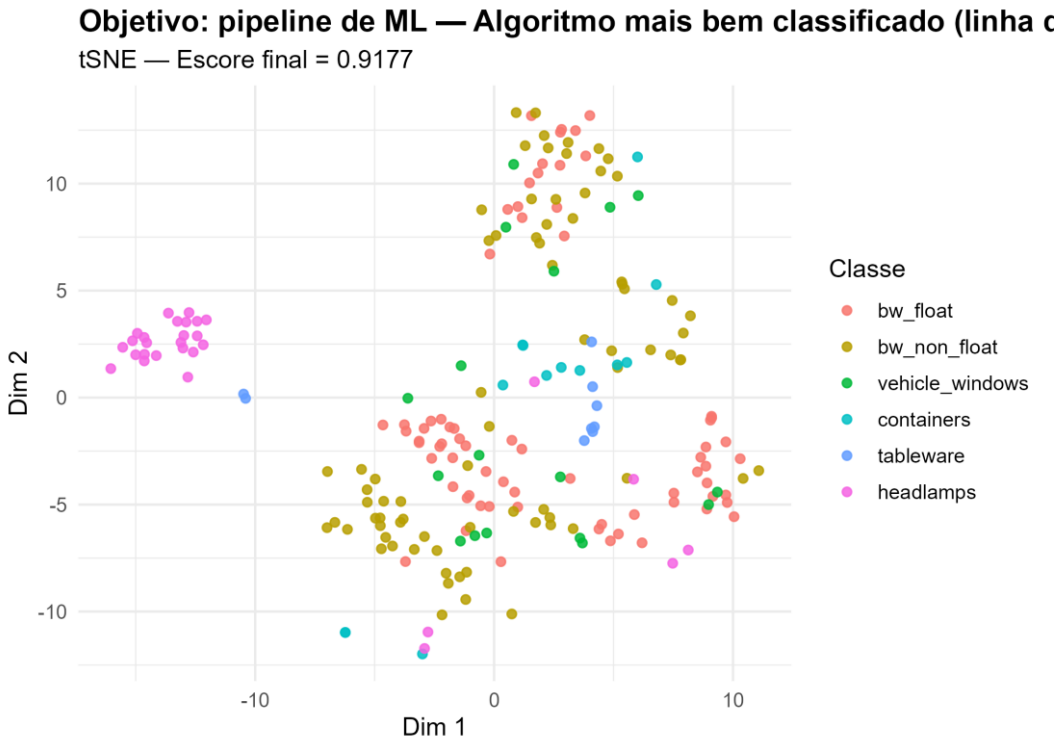
(a)


Objetivo: visualização — Algoritmo mais bem classificado (linha de
tSNE — Escore final = 0.9177
Dim 2
Dim 1
10
5
0
-5
-10
-10
0
10
Classe
bw_float
bw_non_float
vehicle_windows
containers
tableware
headlamps

(b)



(c)



(d)

Figura 31 – Projeções bidimensionais produzidas pelo algoritmo melhor classificado para cada objetivo, com base na Pontuação Final (Final Score) do ranqueamento de referência (Baseline

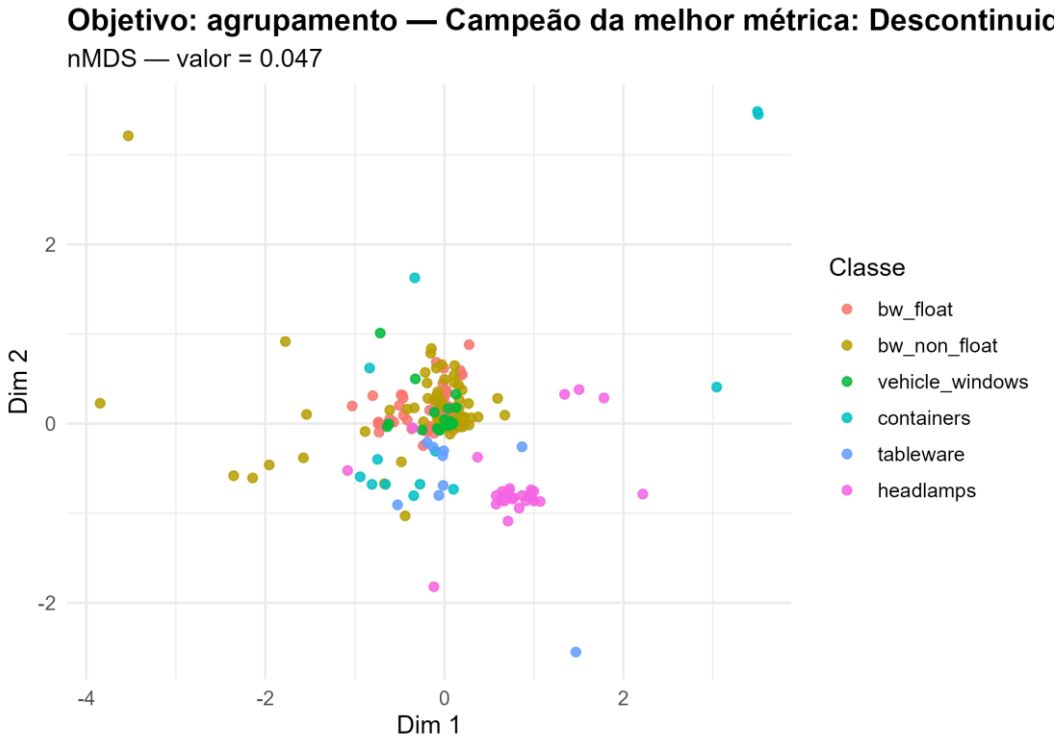
Ranking): (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

Para os objetivos de agrupamento, visualização e integração em pipelines de aprendizado de máquina, o t-SNE apresenta, de forma consistente, o melhor desempenho, produzindo agrupamentos de classes bem definidos, com clara separação entre os grupos e estruturas visualmente interpretáveis. Suas projeções evidenciam elevada preservação das relações de vizinhança local, permitindo uma organização espacial distinta das seis categorias de vidro.

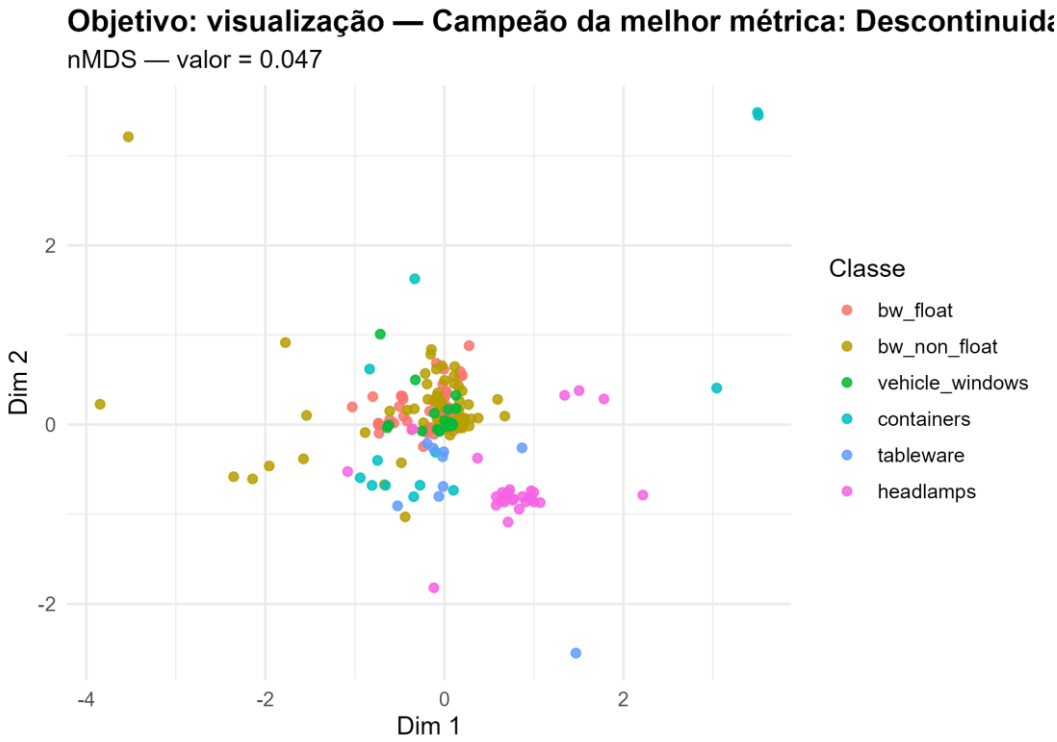
Em contraste, para o objetivo de reconstrução, o nMDS é selecionado como o método de melhor desempenho. A projeção obtida por esse algoritmo apresenta distribuições de classes compactas, porém com elevada sobreposição, refletindo sua ênfase na preservação das dissimilaridades globais entre pares de amostras, em vez de maximizar a separabilidade entre classes. Embora seja menos discriminativa do ponto de vista visual, essa representação está em conformidade com o objetivo do método de reproduzir fielmente a geometria global dos dados.

De modo geral, a figura demonstra que a projeção ótima depende fortemente do objetivo analítico. O t-SNE destaca-se quando a preservação das relações de vizinhança e a discriminação visual entre grupos são prioritárias, enquanto o nMDS constitui a alternativa mais adequada quando se busca maior fidelidade à geometria global da variedade dos dados.

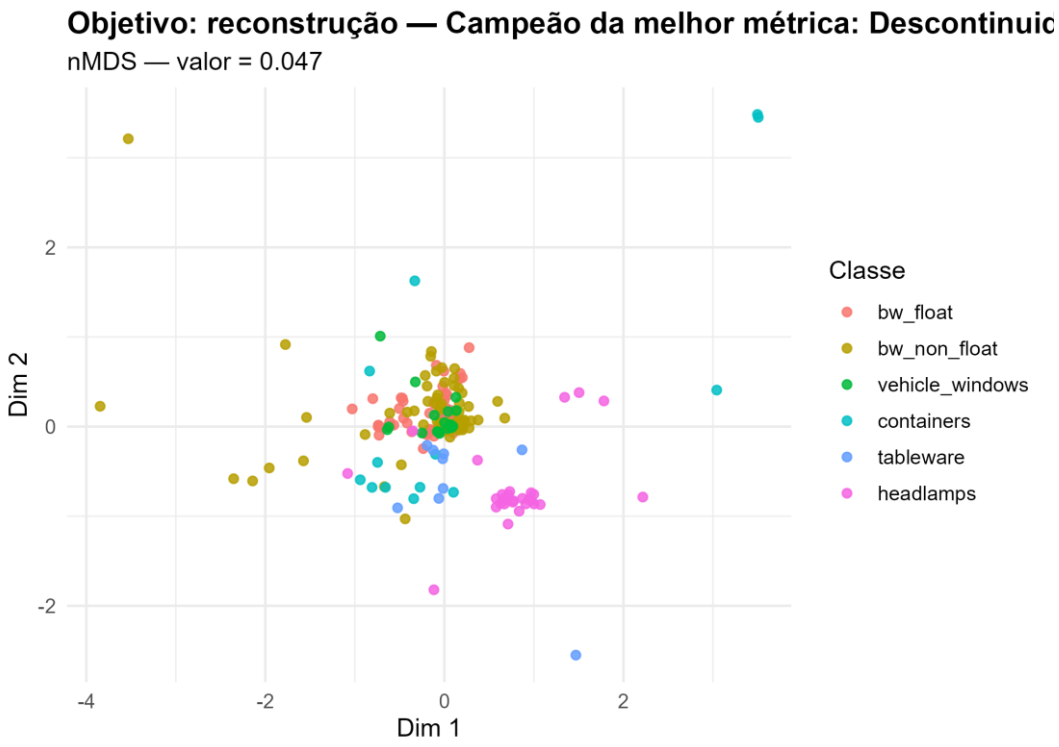
A Figura 32 apresenta as projeções bidimensionais geradas pelo algoritmo que alcança o melhor desempenho na métrica Discontinuity — o MDS não métrico (nMDS) — para quatro objetivos analíticos: agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina.


Objetivo: agrupamento — Campeão da melhor métrica: Descontinuic
nMDS — valor = 0.047
Dim 2
Dim 1
2
0
-2
-4
-2
0
2
Classe
bw_float
bw_non_float
vehicle_windows
containers
tableware
headlamps

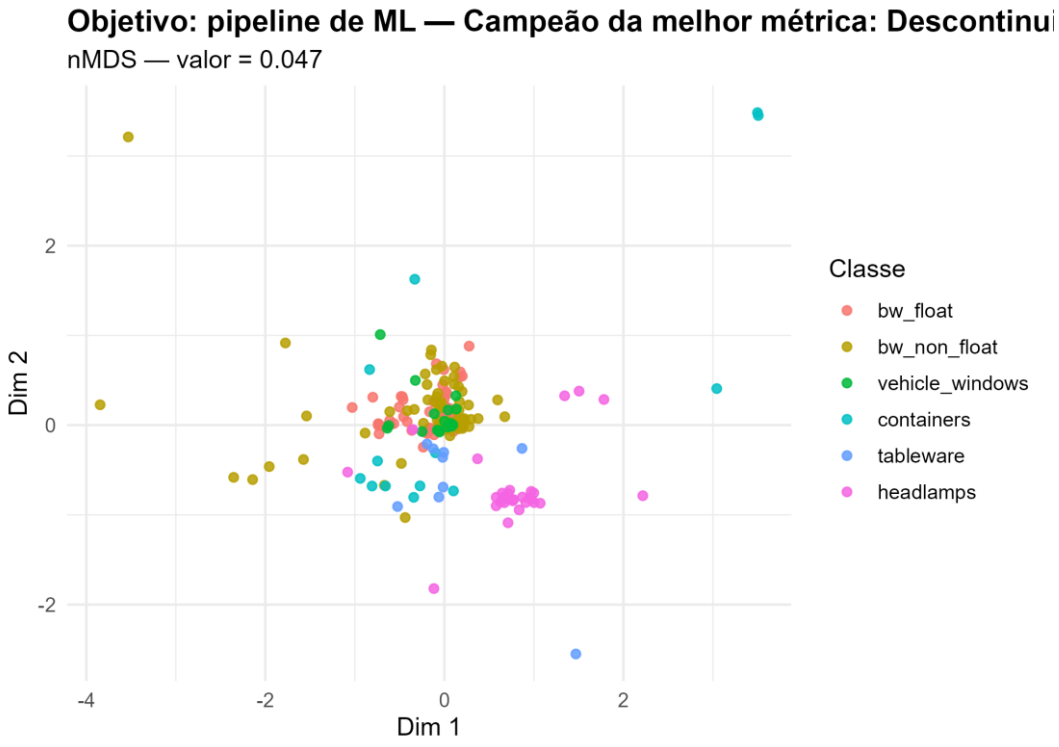
(a)


Objetivo: visualização — Campeão da melhor métrica: Descontinuida
nMDS — valor = 0.047
Dim 2
Dim 1
2
0
-2
-4
-2
0
2
Classe
bw_float
bw_non_float
vehicle_windows
containers
tableware
headlamps

(b)



(c)



(d)

Figura 32 – Projeções bidimensionais geradas pelo algoritmo campeão, selecionado com base na métrica de melhor desempenho para cada objetivo analítico: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

Em todos os cenários, o nMDS produz uma projeção compacta na qual as amostras das diferentes categorias de vidro ocupam uma região amplamente sobreposta no espaço bidimensional. Esse comportamento reflete a natureza da métrica *C-measure*, que privilegia a continuidade geométrica e a baixa distorção, em vez da separabilidade entre as classes.

Embora as projeções preservem satisfatoriamente as relações globais de similaridade entre as amostras, elas oferecem capacidade limitada de discriminação visual entre as classes, evidenciando o compromisso (trade-off) inerente à otimização da suavidade geométrica. A consistência das projeções nos quatro objetivos analíticos demonstra a estabilidade do nMDS sob o critério da *C-measure*, mas também indica que essa métrica prioriza a coerência geométrica em detrimento da interpretabilidade em nível de classes.

De modo geral, os resultados reforçam a importância de selecionar métricas de avaliação alinhadas ao objetivo analítico pretendido, uma vez que métricas que favorecem a continuidade geométrica podem produzir projeções com baixo poder discriminante entre as classes.

8. ESTUDO DE CASO V

8.1 Descrição do Conjunto de Dados

O conjunto de dados Hepatitis foi denominado df5. Ele contém 155 instâncias, 19 variáveis (atributos) e duas classes. O conjunto de dados UCI Hepatitis é um conjunto de dados multivariado utilizado para prever a sobrevivência do paciente — se ele viveu ou morreu — a partir de informações clínicas e demográficas [91].

8.2 Resultados e Discussão

O mapa de calor, apresentado na Figura 33, exibe a estrutura de correlação entre as principais métricas de avaliação empregadas na análise do desempenho dos métodos de redução de dimensionalidade.

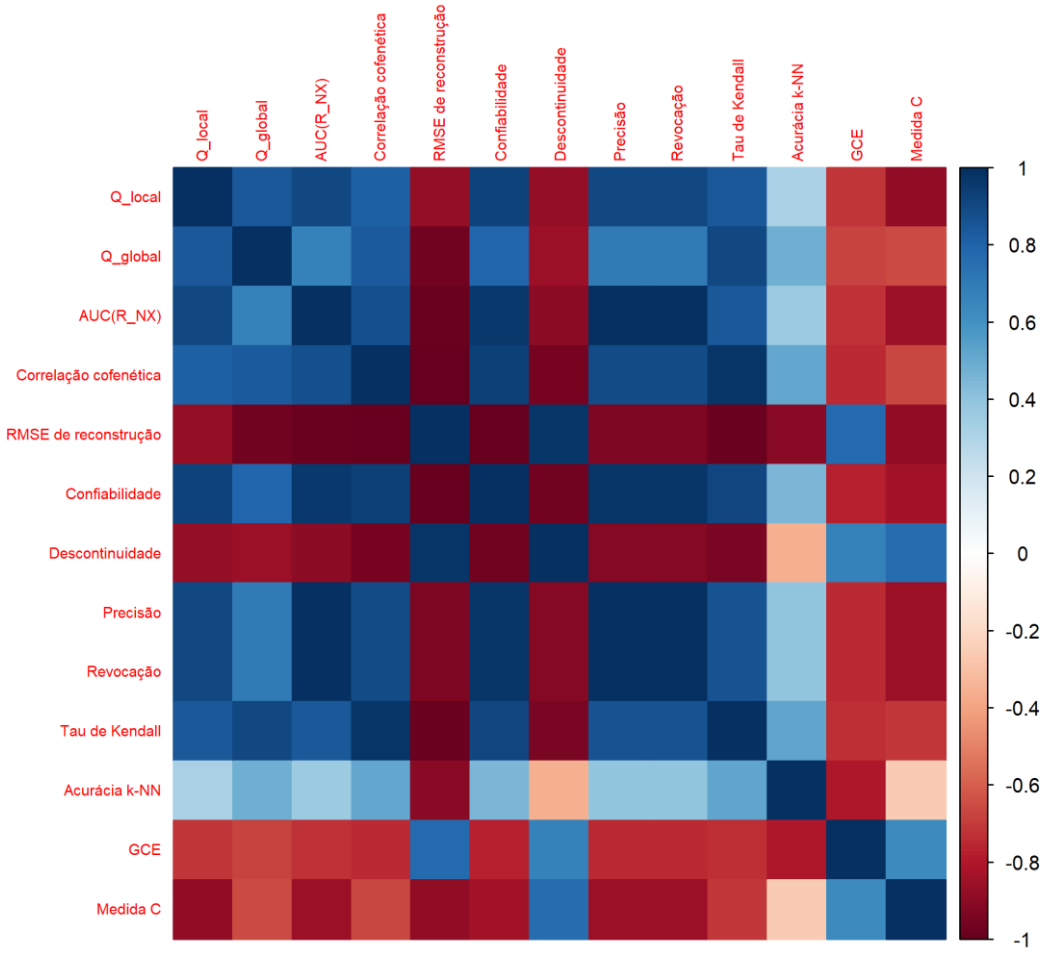


Figura 33 – Estrutura da matriz de correlação entre as métricas de avaliação utilizadas no framework de benchmarking.

As métricas de preservação da estrutura local (Q_{local}, *Trustworthiness*, *Precision*, *Recall* e *Accuracy_kNN*) formam um agrupamento coeso, com fortes correlações positivas entre si, indicando sensibilidade consistente à preservação das relações de vizinhança. Da mesma forma, as métricas de preservação da estrutura global (Q_{global}, *AUC_R(NX)*, *Cophenetic* e *KendallTau*) também apresentam fortes correlações positivas, refletindo sua ênfase comum na preservação da geometria da variedade dos dados.

As métricas associadas ao erro de reconstrução e à distorção geométrica (*RMSE_Reconstruction*, *GCE*, *C_measure* e *Discontinuity*) apresentam fortes correlações

negativas com os grupos de métricas locais e globais. Essa divergência evidencia um compromisso fundamental (trade-off): algoritmos que preservam adequadamente a estrutura topológica tendem a apresentar desempenho inferior em tarefas de reconstrução, enquanto métodos orientados à reconstrução frequentemente introduzem distorções na variedade dos dados. De modo geral, o mapa de calor reforça a natureza multifacetada da avaliação de métodos de redução de dimensionalidade e a necessidade de selecionar métricas de acordo com o objetivo analítico.

A avaliação do conjunto de dados df5, apresentada na Tabela 36A e na Tabela 36B, revela padrões consistentes de desempenho entre os algoritmos de redução de dimensionalidade, com os métodos não lineares de aprendizado de variedades superando claramente os métodos lineares e os baseados em grafos.

Entre as técnicas avaliadas, o MDS não métrico (nMDS) apresenta a melhor preservação da estrutura global da variedade, alcançando os maiores valores de Qglobal, AUC_R(NX), Cophenetic e KendallTau, ao mesmo tempo em que mantém métricas competitivas de preservação local e de acurácia de classificação. Esse equilíbrio indica uma recuperação eficiente tanto da estrutura geométrica em pequena escala quanto da geometria global dos dados.

O t-SNE destaca-se como o método de melhor desempenho na preservação da estrutura local, apresentando os maiores valores de Qlocal, Precision, Recall e Discontinuity. Suas elevadas métricas de preservação local e de separabilidade entre classes evidenciam sua adequação para aplicações que priorizam a identificação de agrupamentos e a discriminação visual, embora suas métricas de preservação da estrutura global permaneçam inferiores às obtidas por nMDS e Kamada–Kawai.

Os métodos Isomap, PCA/MDS e FastICA compõem um grupo de desempenho intermediário, apresentando preservação consistente, porém menos expressiva, das

relações estruturais dos dados. Em contraste, HLLE, DrL e Fruchterman–Reingold exibem os resultados mais modestos na maioria das métricas, refletindo limitações tanto na fidelidade geométrica quanto na capacidade de discriminação entre classes.

De modo geral, os resultados demonstram que a adequação de cada algoritmo depende diretamente do objetivo analítico. Métodos como o t-SNE destacam-se quando a preservação da estrutura local e a separabilidade entre classes são prioritárias, enquanto nMDS e Kamada–Kawai proporcionam melhor reconstrução da geometria global da variedade dos dados.

Tabela 36A – Figuras de mérito obtidas do conjunto de dados df5.

Algoritmo	Q_local	Q_global	AUC(R_NX)	Correlação cofenética	RMSE de reconstrução	Confiabilidade	Continuidade
DRR	0.518	**0.870**	0.435	0.836	**0.706**	0.841	0.925
Isomap	0.425	0.834	0.456	0.847		0.855	**0.931**
PCA	0.442	0.840	0.434	0.838	**0.706**	0.839	0.925
PCA_L1	0.428	0.813	0.353	0.613		0.766	0.865
kPCA	0.366	0.762	0.381	0.564	8.066	0.785	0.888
FastICA	0.479	0.851	0.424	0.810	**0.706**	0.836	0.917
MDS	0.442	0.840	0.434	0.838		0.839	0.925
nMDS	0.509	0.864	0.516	**0.927**		0.876	0.924
DrL	0.024	0.505	0.099	-0.092		0.509	0.500
FruchtermanReingold	0.184	0.656	0.222	0.238		0.682	0.703
KamadaKawai	0.488	0.849	0.505	0.880		0.852	0.925
HLLE	0.340	0.804	0.181	0.150		0.657	0.659
DiffusionMaps	0.409	0.817	0.302	0.401		0.721	0.819
tSNE	**0.619**	0.754	**0.605**	0.610		**0.900**	0.898

Tabela 36B – Figuras de mérito obtidas do conjunto de dados df5.

Algoritmo	Descontinuidade	Precisão	Revocação	Tau de Kendall	Acurácia k-NN	GCE	Medida C
DRR	0.075	0.452	0.452	0.657	0.819	**2.029**	184.3
Isomap	**0.069**	0.468	0.468	0.665	0.826	2.360	193.1
PCA	0.075	0.446	0.446	0.658	0.826	2.043	179.9
PCA_L1	0.135	0.357	0.357	0.474	0.729	3.102	221.9
kPCA	0.112	0.395	0.395	0.454	0.768	2.863	171.2
FastICA	0.083	0.431	0.431	0.628	0.800	2.588	188.5
MDS	0.075	0.446	0.446	0.658	0.826	2.043	179.9
nMDS	0.076	0.530	0.530	**0.774**	**0.852**	2.132	132.3
DrL	0.500	0.091	0.091	-0.058	0.755	3.321	298.8
FruchtermanReingold	0.297	0.232	0.232	0.175	0.787	2.893	248.4
KamadaKawai	0.075	0.516	0.516	0.720	0.813	2.395	189.0
HLLE	0.341	0.189	0.189	0.243	0.826	2.548	224.0
DiffusionMaps	0.181	0.314	0.314	0.481	0.742	2.969	160.7
tSNE	0.102	**0.595**	**0.595**	0.462	0.774	2.183	**103.4**

A Tabela 37 resume o desempenho multicritério dos algoritmos de redução de dimensionalidade para o conjunto de dados df5, utilizando índices compostos de preservação da estrutura local, preservação da estrutura global, continuidade geométrica e fidelidade às classes.

Tabela 37 – Figuras de mérito obtidas do conjunto de dados df5.

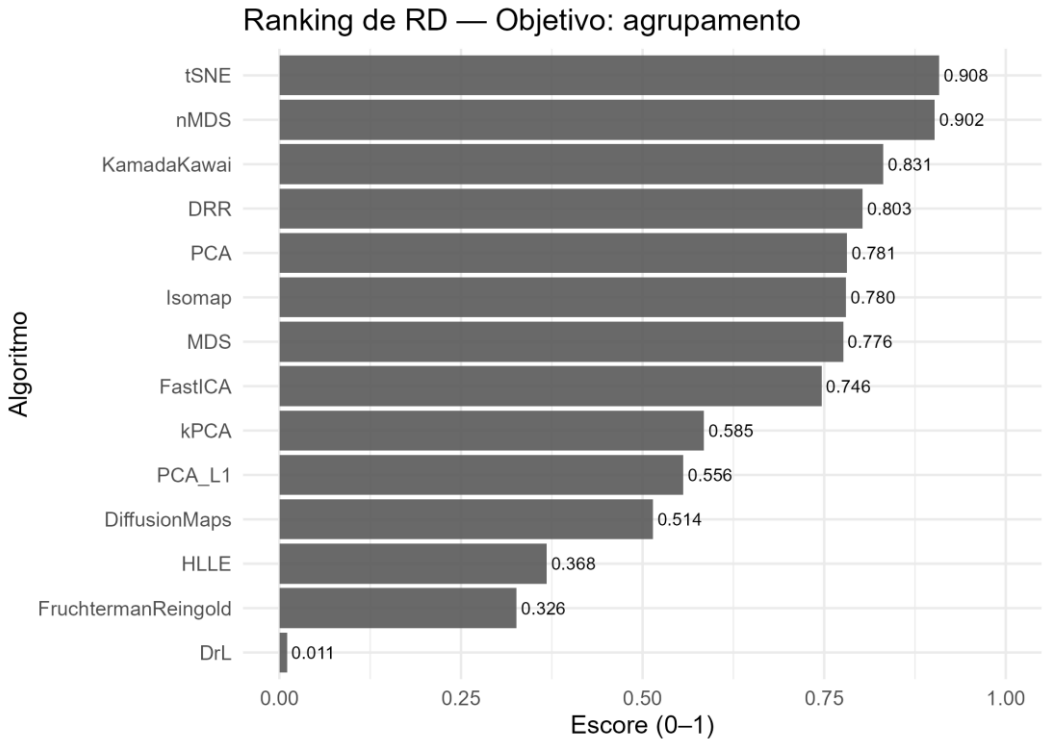
Algoritmo	Índice_Local	Índice_Global	Índice_Geom	Índice_Classe	Pontuação_Final	Objetivo
tSNE	1.000	0.749	0.935	0.789	**0.908**	**agrupamento**
nMDS	0.874	0.952	0.919	0.914	0.902	agrupamento
KamadaKawai	0.836	0.908	0.755	0.790	0.831	agrupamento
DRR	0.778	0.859	0.893	0.721	0.803	agrupamento
PCA	0.739	0.838	0.896	0.732	0.781	agrupamento
nMDS	0.874	0.952	0.919	0.914	**0.906**	**visualização**
tSNE	1.000	0.749	0.935	0.789	0.865	visualização
KamadaKawai	0.836	0.908	0.755	0.790	0.832	visualização
Isomap	0.764	0.849	0.762	0.762	0.780	visualização
DRR	0.778	0.859	0.893	0.721	0.771	visualização
nMDS	0.874	0.952	0.919	0.914	**0.915**	**reconstrução**
tSNE	1.000	0.749	0.935	0.789	0.899	reconstrução
DRR	0.778	0.859	0.893	0.721	0.848	reconstrução
PCA	0.739	0.838	0.896	0.732	0.831	reconstrução
KamadaKawai	0.836	0.908	0.755	0.790	0.825	reconstrução
nMDS	0.874	0.952	0.919	0.914	**0.906**	**pipeline de ML**
tSNE	1.000	0.749	0.935	0.789	0.865	pipeline de ML
KamadaKawai	0.836	0.908	0.755	0.790	0.832	pipeline de ML
Isomap	0.764	0.849	0.762	0.762	0.780	pipeline de ML
DRR	0.778	0.859	0.893	0.721	0.771	pipeline de ML

Dois algoritmos destacam-se de forma consistente: t-SNE e nMDS, embora apresentem pontos fortes complementares. O t-SNE alcança desempenho máximo na preservação da estrutura local (*Índice_Local* = 1,000) e elevada separação entre classes, obtendo as maiores pontuações para os objetivos de agrupamento e integração em pipelines de aprendizado de máquina. Em contraste, o nMDS apresenta a melhor preservação da estrutura global (*Índice_Global* = 0,952) e as maiores Pontuações Finais (Final Scores) para os objetivos de visualização e reconstrução, refletindo sua capacidade de recuperar a geometria da variedade dos dados com mínima distorção.

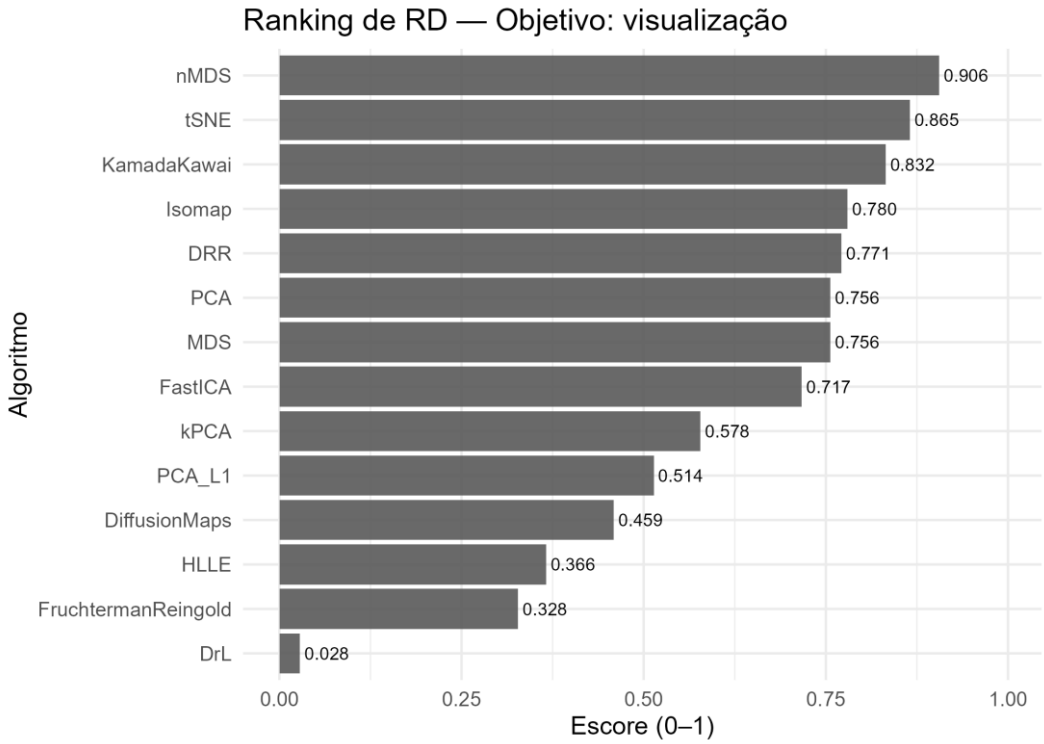
O Kamada–Kawai destaca-se como um método robusto de desempenho intermediário, apresentando um equilíbrio entre os índices de preservação local e global, embora permaneça abaixo dos métodos líderes nas métricas relacionadas à continuidade geométrica e à fidelidade às classes. Métodos lineares, como PCA e DRR, exibem desempenho estável e elevada continuidade geométrica, porém com menor capacidade de discriminação entre classes.

De modo geral, os resultados confirmam que a seleção do algoritmo permanece fortemente dependente do objetivo analítico. O t-SNE é a escolha mais adequada quando a separação entre agrupamentos e a preservação das relações de vizinhança são prioritárias, enquanto o nMDS se mostra superior em aplicações que exigem reconstrução fiel da geometria global da variedade dos dados.

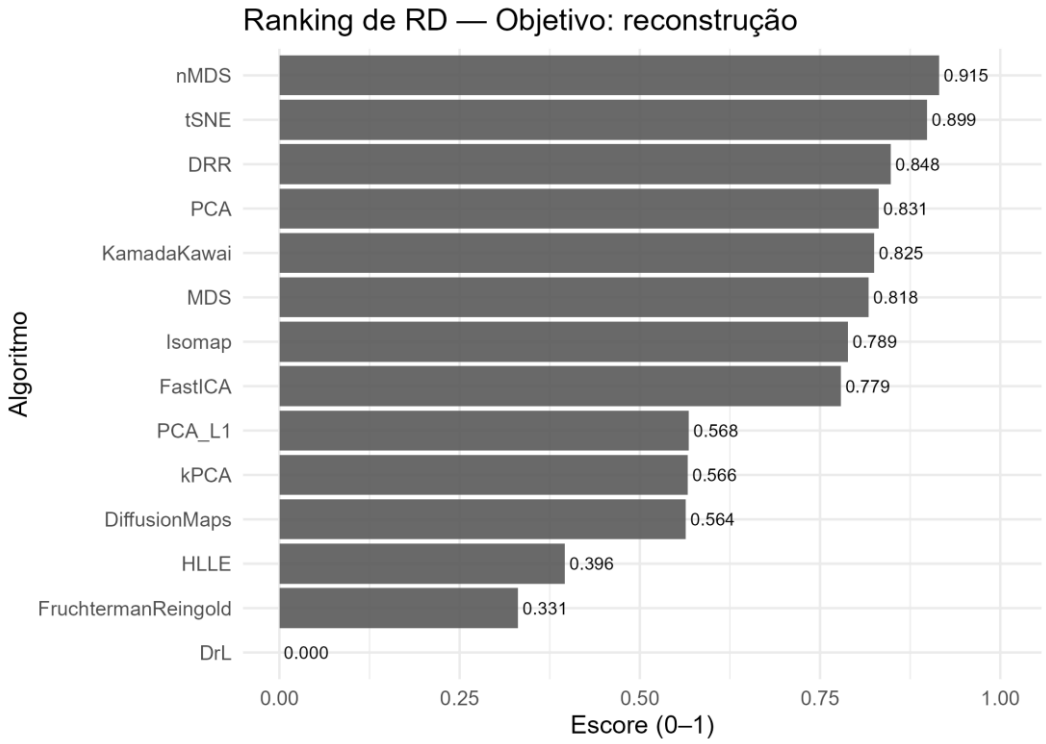
A Figura 34 apresenta os ranqueamentos dos algoritmos de redução de dimensionalidade orientados por objetivos para o conjunto de dados df5, evidenciando padrões de desempenho claros e consistentes para os objetivos de agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina. O t-SNE e o nMDS destacam-se como os dois métodos de melhor desempenho, embora apresentem competências complementares.


Ranking de RD — Objetivo: agrupamento
Algoritmo
tSNE
nMDS
KamadaKawai
DRR
PCA
Isomap
MDS
FastICA
kPCA
PCA_L1
DiffusionMaps
HLLE
FruchtermanReingold
DrL
0.908
0.902
0.831
0.803
0.781
0.780
0.776
0.746
0.585
0.556
0.514
0.368
0.326
0.011
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

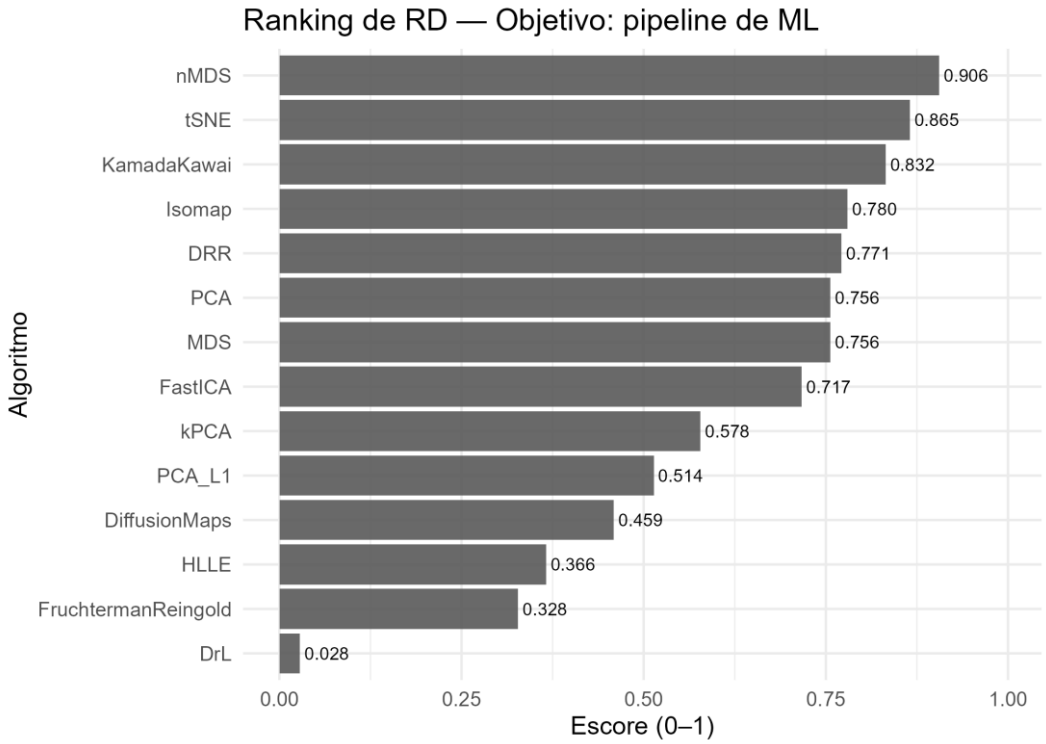
(a)


Ranking de RD — Objetivo: visualização
Algoritmo
nMDS
tSNE
KamadaKawai
Isomap
DRR
PCA
MDS
FastICA
kPCA
PCA_L1
DiffusionMaps
HLLE
FruchtermanReingold
DrL
0.906
0.865
0.832
0.780
0.771
0.756
0.756
0.717
0.578
0.514
0.459
0.366
0.328
0.028
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

(b)



(c)



(d)

Figura 34 – Gráficos de barras horizontais mostrando as pontuações de desempenho normalizadas (0–1) para cada algoritmo de redução de dimensionalidade nos quatro objetivos

analíticos: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

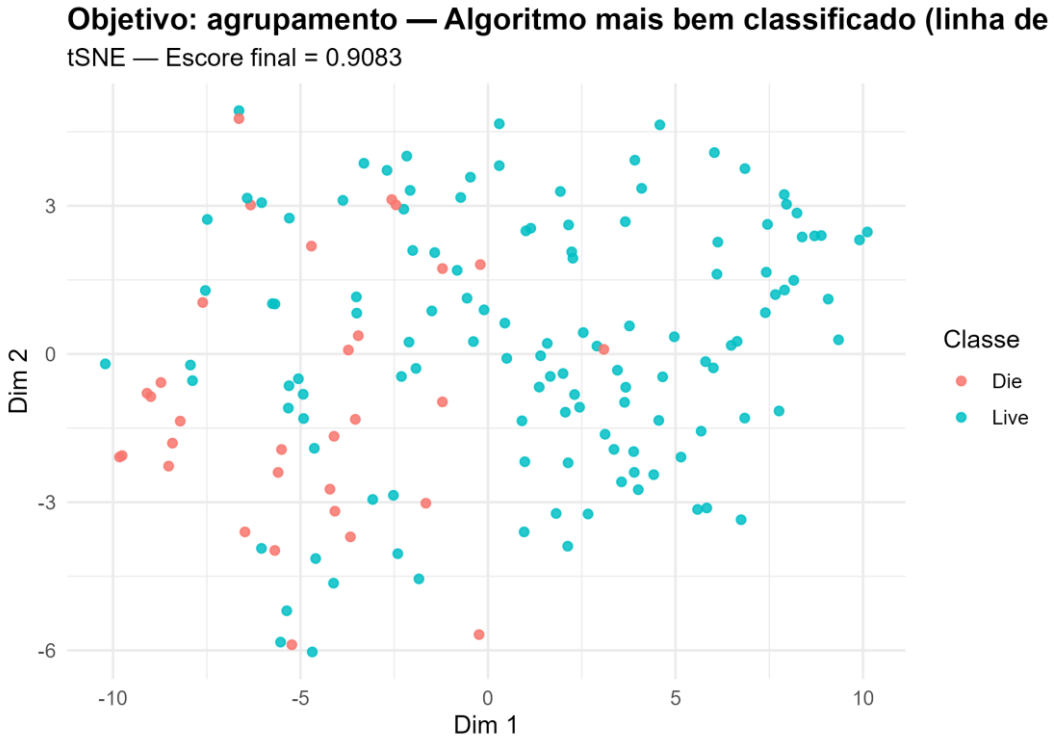
Para o objetivo de agrupamento, o t-SNE alcança a maior pontuação, refletindo sua elevada capacidade de preservar a estrutura local e de evidenciar agrupamentos bem separados. O nMDS apresenta desempenho praticamente equivalente, destacando sua robustez mesmo em tarefas nas quais a preservação discriminativa das relações de vizinhança é essencial.

Nos objetivos de visualização e integração em pipelines de aprendizado de máquina, o nMDS supera o t-SNE, obtendo as maiores pontuações globais e reforçando sua vantagem na preservação das relações geométricas globais da variedade dos dados. Os resultados para reconstrução também favorecem o nMDS, que alcança a maior pontuação e demonstra superior consistência geométrica.

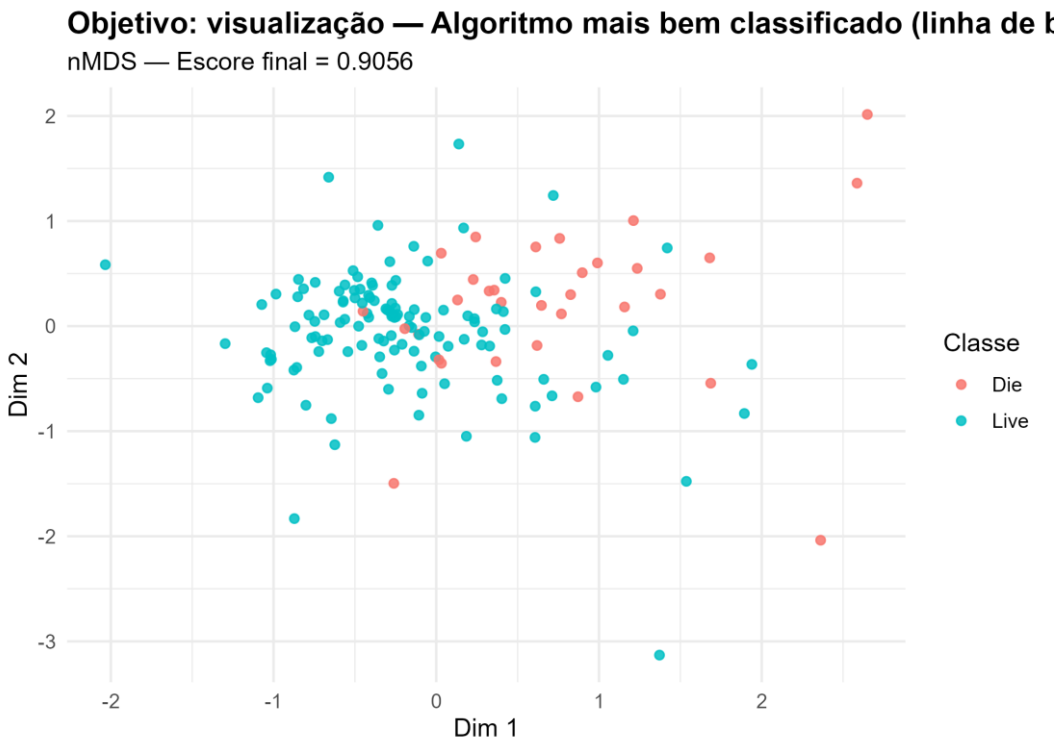
Os métodos Kamada–Kawai, Isomap, DRR, PCA e MDS compõem um grupo de desempenho intermediário, oferecendo resultados equilibrados, porém menos expressivos, em todos os objetivos avaliados. Em contrapartida, métodos como HLLE, Diffusion Maps, Fruchterman–Reingold e, sobretudo, DrL apresentam pontuações substancialmente inferiores, indicando adequação limitada para este conjunto de dados em todos os cenários analíticos considerados.

De modo geral, os resultados confirmam que o desempenho dos algoritmos depende fortemente do objetivo analítico. O t-SNE destaca-se em aplicações que priorizam a separabilidade local entre as amostras, enquanto o nMDS apresenta melhor desempenho quando a preservação da estrutura global e a fidelidade da reconstrução são requisitos fundamentais.

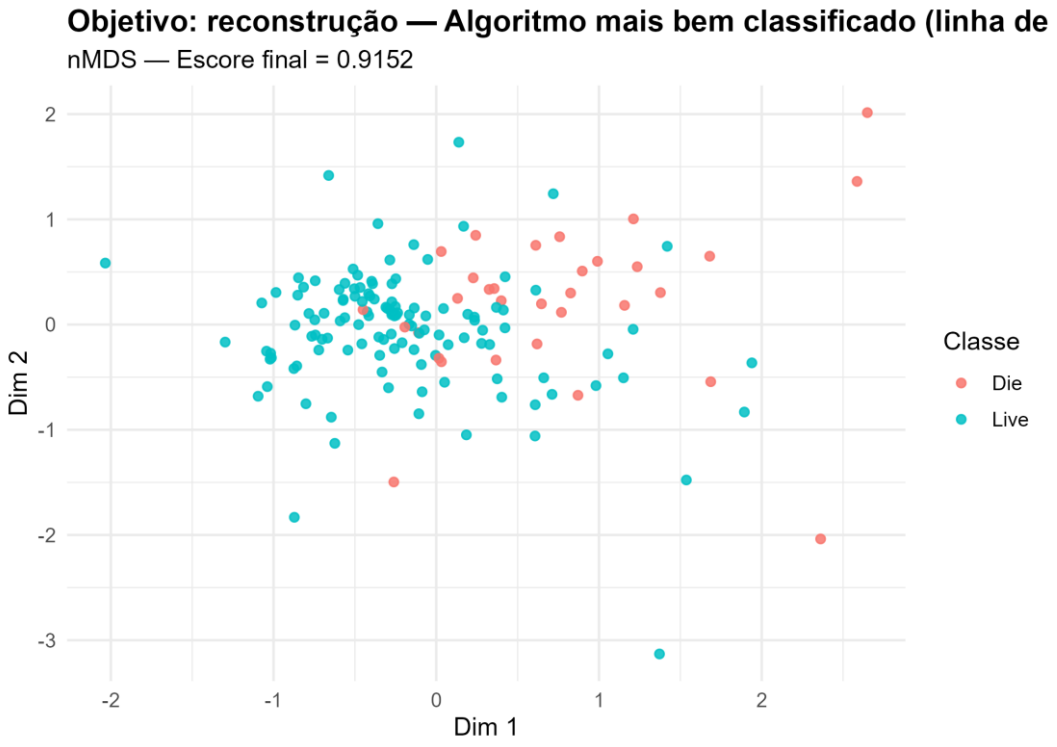
A Figura 35 ilustra as projeções bidimensionais geradas pelos algoritmos de redução de dimensionalidade mais bem classificados para o conjunto de dados df5, considerando os quatro objetivos analíticos.



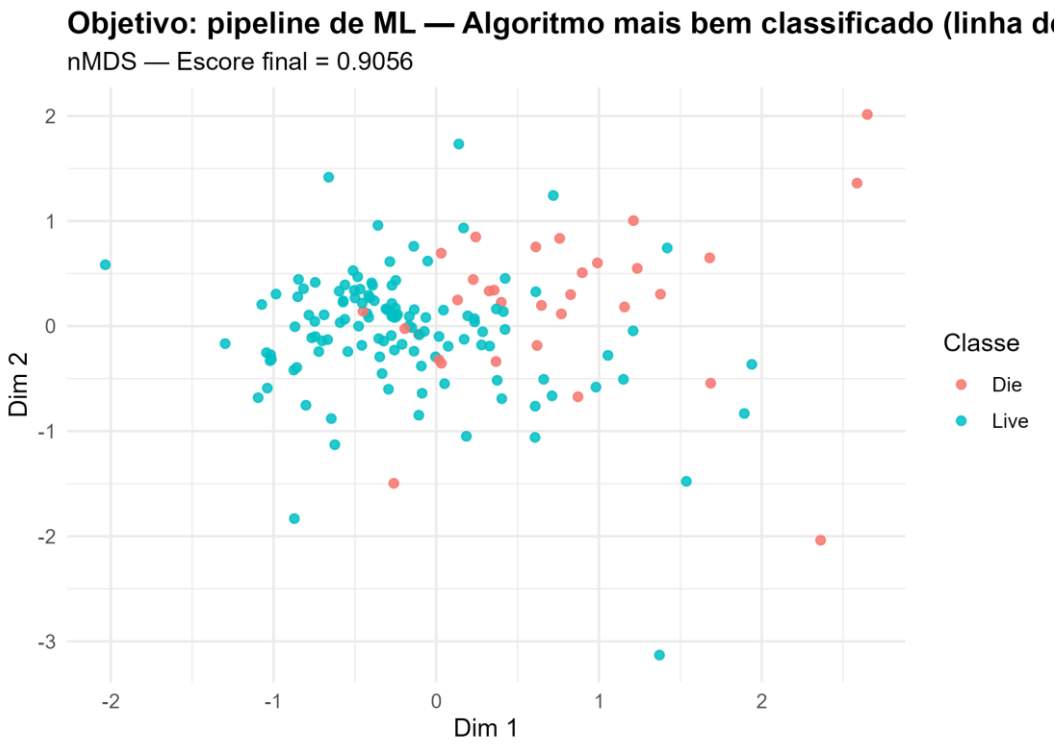
(a)


Objetivo: visualização — Algoritmo mais bem classificado (linha de b
nMDS — Escore final = 0.9056
Dim 2
Dim 1
Classe
Die
Live

(b)


Objetivo: reconstrução — Algoritmo mais bem classificado (linha de
nMDS — Escore final = 0.9152
Dim 2
Dim 1
Classe
Die
Live

(c)



(d)

Figura 35 – Projeções bidimensionais produzidas pelo algoritmo melhor classificado para cada objetivo, com base na Pontuação Final (Final Score) do ranqueamento de referência (Baseline Ranking): (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

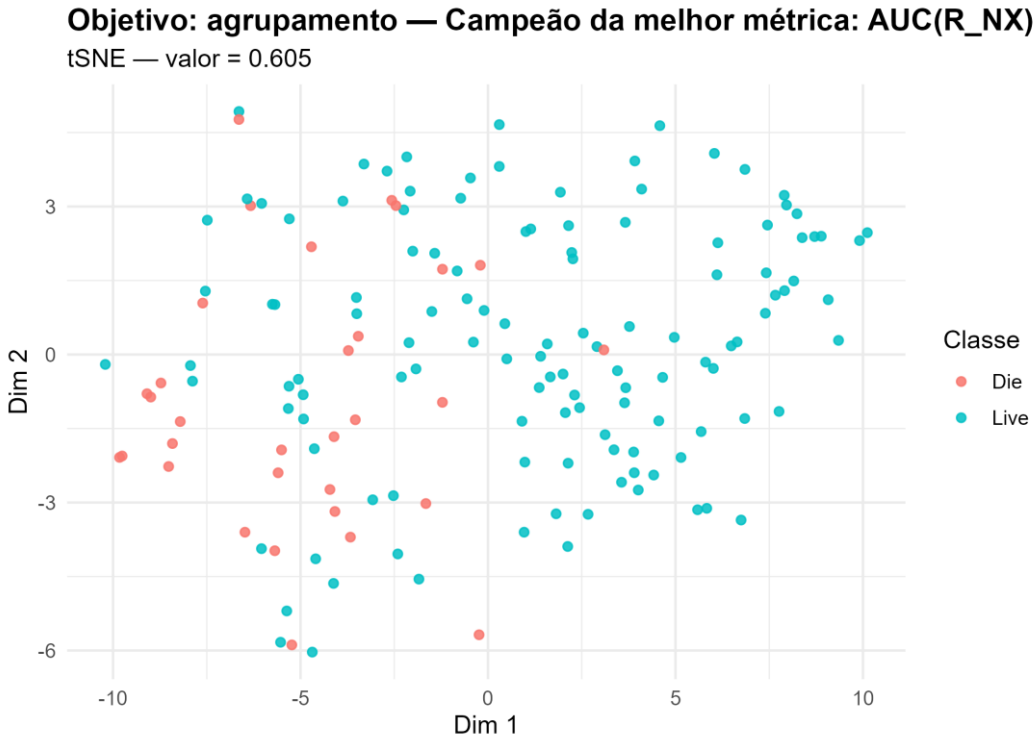
Para a tarefa de agrupamento, o t-SNE produz uma representação amplamente dispersa, com separação parcial entre as classes, refletindo sua elevada capacidade de preservar a estrutura local e de revelar estruturas heterogêneas presentes nos dados.

Em contraste, o nMDS — selecionado como o melhor método para os objetivos de visualização, reconstrução e integração em pipelines de aprendizado de máquina — gera projeções mais compactas e com maior coerência geométrica global. Nesses três objetivos, as projeções obtidas pelo nMDS apresentam uma organização geométrica consistente, preservando as relações globais de dissimilaridade ao mesmo tempo em que produzem sobreposição moderada entre as classes *Live* e *Die*.

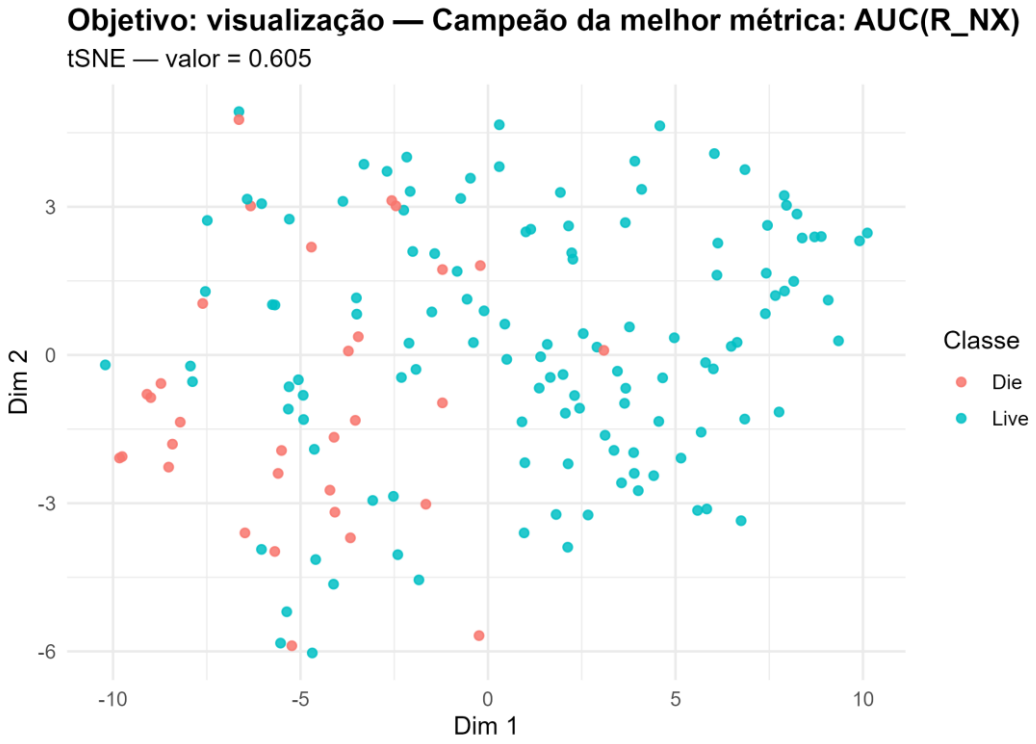
Esse comportamento está de acordo com a característica do nMDS de minimizar o stress em toda a matriz de distâncias, em vez de maximizar a discriminação entre classes. Embora apresente menor separabilidade visual que o t-SNE, o nMDS produz projeções mais estáveis e estruturalmente fiéis, o que contribui para seu desempenho superior nas métricas relacionadas à preservação da estrutura global e à reconstrução.

De modo geral, a figura demonstra que a projeção mais adequada depende do objetivo analítico. O t-SNE oferece melhor visualização dos agrupamentos e maior capacidade de discriminação da estrutura local, enquanto o nMDS fornece uma representação mais confiável da geometria global dos dados para aplicações de modelagem e reconstrução.

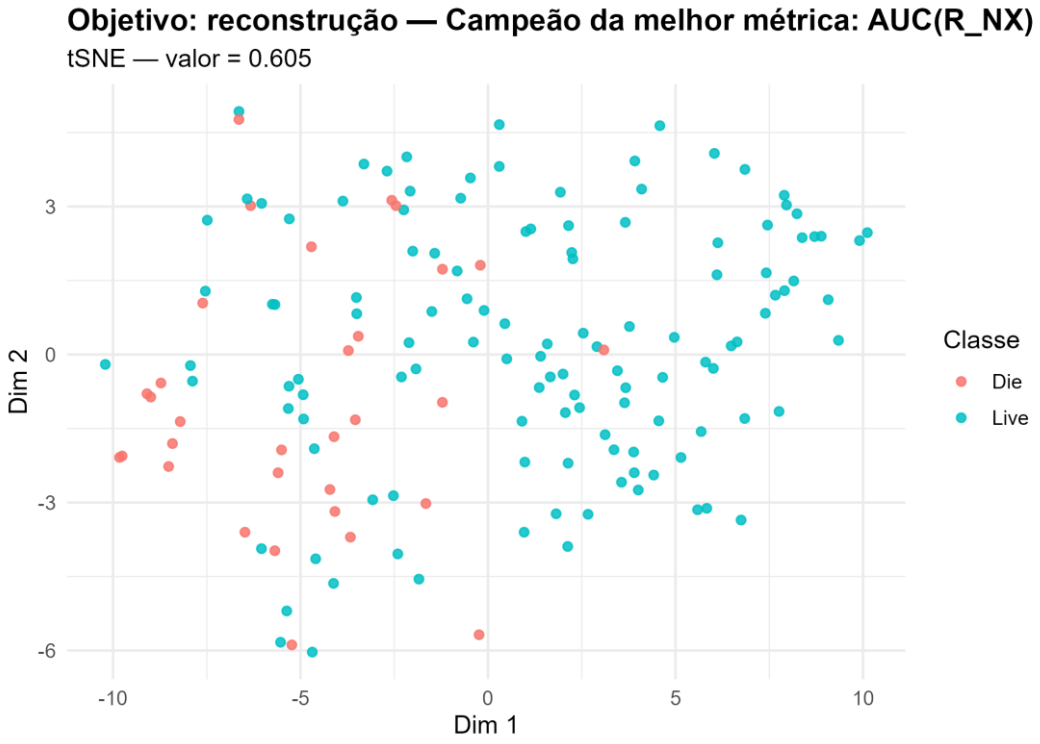
A Figura 36 apresenta as projeções bidimensionais geradas pelo t-SNE, selecionado como o algoritmo de melhor desempenho de acordo com a métrica AUC_R(NX), para os quatro objetivos analíticos: agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina.


Objetivo: agrupamento — Campeão da melhor métrica: AUC(R_NX)
tSNE — valor = 0.605
Dim 2
Dim 1
3
0
-3
-6
-10
-5
0
5
10
Classe
Die
Live

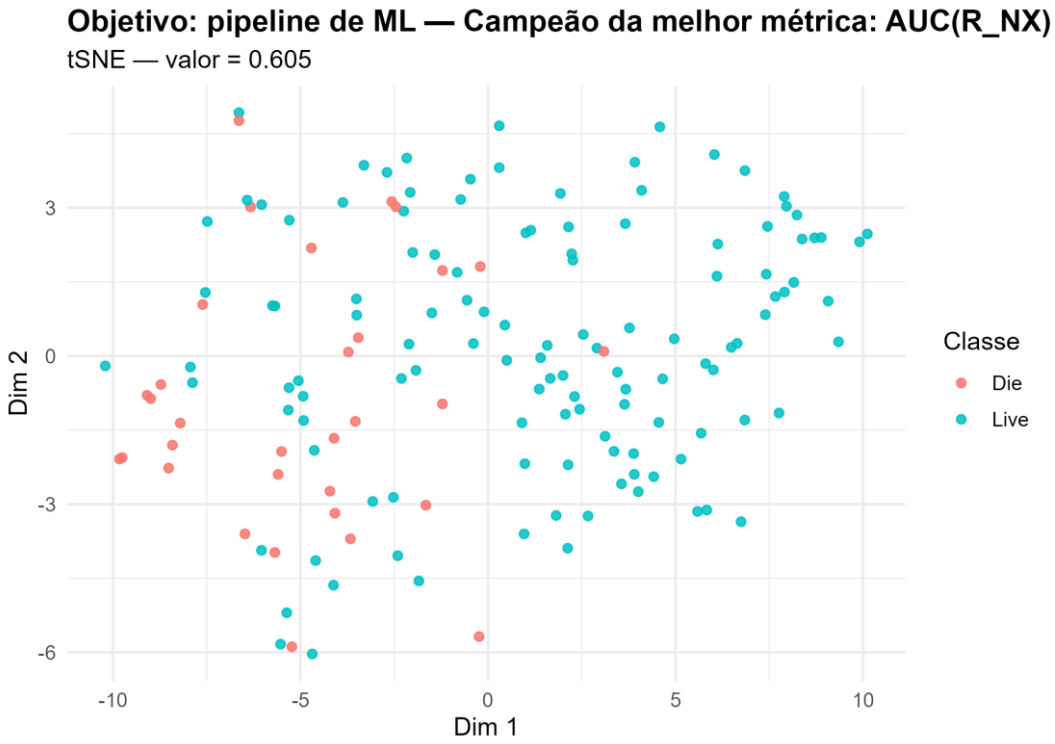
(a)


Objetivo: visualização — Campeão da melhor métrica: AUC(R_NX)
tSNE — valor = 0.605
Dim 2
Dim 1
3
0
-3
-6
-10
-5
0
5
10
Classe
Die
Live

(b)



(c)



(d)

Figura 36 – Projeções bidimensionais geradas pelo algoritmo campeão, selecionado com base na métrica de melhor desempenho para cada objetivo analítico: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

Em todos os cenários, as projeções obtidas pelo t-SNE apresentam padrões geométricos semelhantes, caracterizados por nuvens de pontos dispersas e por sobreposição parcial entre as classes *Live* e *Die*. Esse comportamento reflete a natureza da métrica *AUC(R_NX)*, que prioriza a preservação da ordenação das relações de vizinhança em múltiplas escalas, em vez de maximizar a separabilidade entre as classes.

Embora as projeções não apresentem uma estrutura fortemente discriminativa, elas preservam de forma consistente as relações de vizinhança locais e de média distância, conforme evidenciado pela disposição relativamente estável das amostras em todos os objetivos analíticos avaliados. A elevada similaridade entre as projeções demonstra a robustez do t-SNE quando avaliado pelo critério da métrica *AUC_R(NX)*.

Esses resultados sugerem que a AUC_R(NX) favorece projeções que conciliam a fidelidade às relações de vizinhança locais com a continuidade da estrutura dos dados, em vez de privilegiar a formação de agrupamentos visualmente bem separados.

9. ESTUDO DE CASO VI

9.1 Descrição do Conjunto de Dados

O conjunto de dados Iris foi denominado df6. Trata-se de um dos primeiros conjuntos de dados utilizados na literatura sobre métodos de classificação e é amplamente empregado em Estatística e em Aprendizado de Máquina. O conjunto contém três classes, cada uma composta por 50 instâncias, correspondentes às diferentes espécies de plantas do gênero Iris [92].

9.2 Resultados e Discussão

O mapa de calor apresentado na Figura 37 mostra a estrutura de correlação entre as principais métricas utilizadas para avaliar o desempenho dos algoritmos de redução de dimensionalidade.

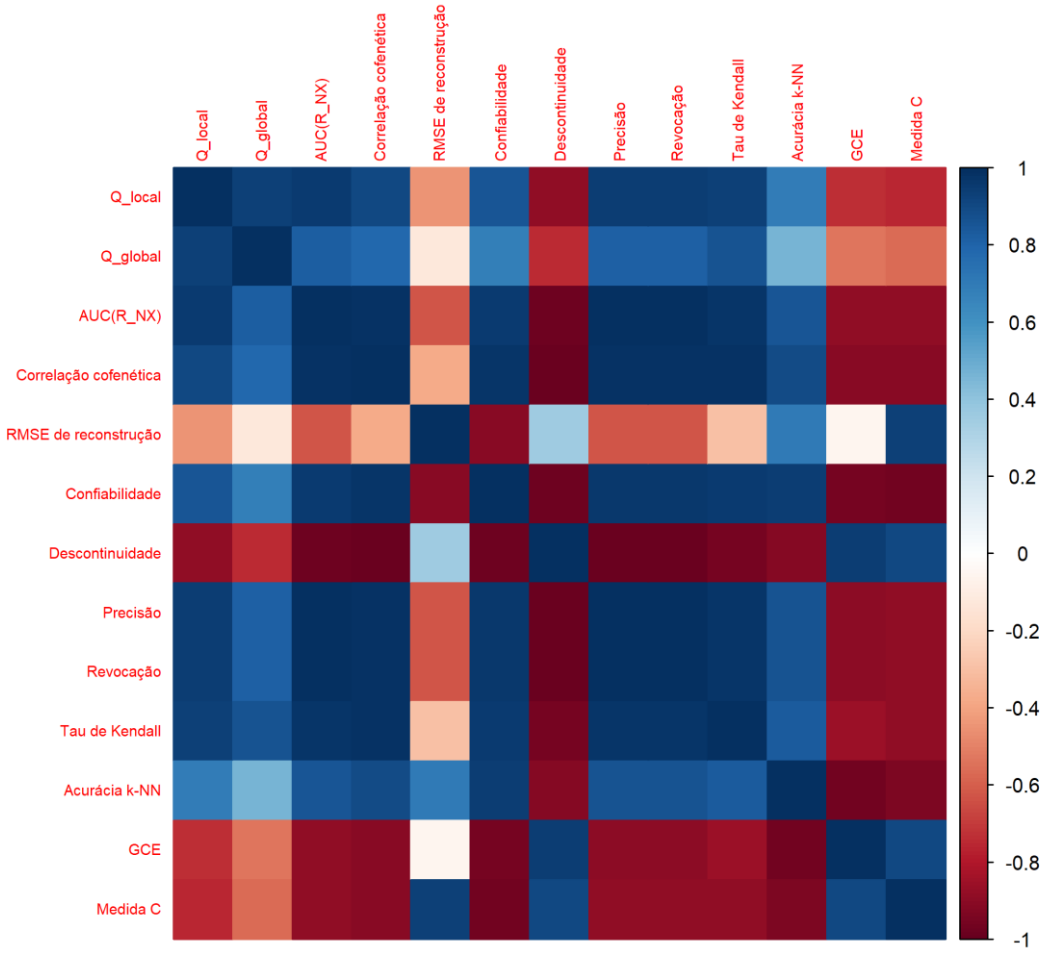


Figura 37 – Estrutura da matriz de correlação entre as métricas de avaliação utilizadas no framework de benchmarking.

As métricas de preservação da estrutura local (Q_{local}, *Trustworthiness*, *Precision*, *Recall* e *Accuracy_kNN*) formam um agrupamento fortemente correlacionado, o que reflete sua ênfase comum na preservação das relações de vizinhança. As métricas de preservação da estrutura global (Q_{global}, *AUC_R(NX)*, *Cophenetic* e *KendallTau*) também se agrupam de maneira consistente, indicando sensibilidade semelhante quanto à preservação da geometria da variedade dos dados.

Em contraste, as métricas relacionadas ao erro de reconstrução e à distorção geométrica (*RMSE_Reconstruction*, *GCE*, *C_measure* e *Discontinuity*) apresentam fortes

correlações negativas tanto com as métricas de preservação local quanto com as de preservação global. Esse comportamento evidencia um compromisso fundamental (trade-off): métodos que se destacam na preservação das relações de vizinhança e da estrutura da variedade tendem a apresentar desempenho inferior na reconstrução dos dados, e vice-versa.

De modo geral, a figura ressalta que a avaliação de métodos de redução de dimensionalidade é intrinsecamente multidimensional e que a escolha das métricas deve estar alinhada ao objetivo analítico.

A avaliação do conjunto de dados df6, apresentada Tabela 38A e na Tabela 38B, revela uma hierarquia bem definida entre os algoritmos de redução de dimensionalidade, com diversos métodos apresentando desempenho elevado e consistente.

Em praticamente todas as métricas de preservação da estrutura global e local, os métodos clássicos de aprendizado de variedades — PCA, MDS, nMDS, Isomap e Kamada–Kawai — superam de forma consistente as abordagens não lineares baseadas em métodos espectrais e em grafos. Esses algoritmos apresentam valores próximos ao máximo para Qglobal, AUC_R(NX), Cophenetic, Trustworthiness e Continuity, indicando elevada capacidade de recuperar fielmente tanto as relações de vizinhança locais quanto a geometria global da variedade dos dados.

Em particular, nMDS e Kamada–Kawai destacam-se como os métodos mais equilibrados, alcançando os maiores valores de Kendall Tau, Accuracy_kNN e das métricas de Precisão e Revocação (Recall), confirmando sua superior capacidade de preservar as relações de ordenação e a estrutura em nível de classes.

Os métodos PCA e MDS apresentam desempenhos praticamente idênticos, o que demonstra que projeções lineares podem ser altamente eficazes para conjuntos de dados com forte regularidade geométrica global.

O t-SNE também apresenta excelente desempenho, especialmente nas métricas Qlocal e nas relacionadas à discriminação entre classes; entretanto, suas métricas de preservação da estrutura global permanecem ligeiramente inferiores às dos principais métodos clássicos.

Por outro lado, DrL, HLLE e Fruchterman–Reingold apresentam os resultados mais modestos, caracterizados por baixa fidelidade geométrica e desempenho reduzido nas métricas de classificação, evidenciando sua limitada adequação a este conjunto de dados. O método Diffusion Maps apresenta desempenho intermediário, sendo capaz de capturar parte da estrutura não linear dos dados, porém com menor capacidade discriminativa em comparação aos algoritmos de melhor desempenho.

De modo geral, os resultados evidenciam que o conjunto de dados df6 favorece algoritmos capazes de preservar de forma eficiente a estrutura global da variedade dos dados, enquanto métodos voltados predominantemente à preservação da estrutura local oferecem apenas benefícios marginais.

Tabela 38A – Figuras de mérito obtidas do conjunto de dados df6.

Algoritmo	Q_local	Q_global	AUC(R_NX)	Correlação cofenética	RMSE de reconstrução	Confiabilidade	Continuidade
DRR	0.645	0.909	0.688	0.958	**0.204**	0.973	0.973
Isomap	0.681	0.944	0.750	0.990		0.979	0.988
PCA	0.724	**0.962**	0.770	0.995	**0.204**	0.981	0.990
PCA_L1	0.638	0.934	0.708	0.986		0.974	0.984
kPCA	0.631	0.915	0.675	0.932	3.780	0.963	0.977
FastICA	0.639	0.896	0.727	0.919	**0.204**	0.978	0.984
MDS	0.724	**0.962**	0.769	0.995		0.981	0.990
nMDS	0.721	0.961	0.785	**0.996**		0.983	**0.991**
DrL	0.343	0.826	0.098	0.004		0.500	0.506
FruchtermanReingold	0.266	0.688	0.317	0.466		0.793	0.760
KamadaKawai	**0.747**	0.954	**0.804**	0.993		**0.984**	**0.991**
HLLE	0.302	0.773	0.159	0.146		0.687	0.550
DiffusionMaps	0.569	0.879	0.629	0.781		0.949	0.958
tSNE	0.723	0.890	0.796	0.884		0.982	0.984

Tabela 38B – Figuras de mérito obtidas do conjunto de dados df6.

Algoritmo	Descontinuidade	Precisão	Revocação	Tau de Kendall	Acurácia k-NN	GCE	Medida C
DRR	0.027	0.712	0.712	0.826	0.913	1.182	40.3
Isomap	0.012	0.777	0.777	0.913	0.853	1.691	37.1
PCA	0.010	0.801	0.801	0.949	0.913	1.283	36.8
PCA_L1	0.016	0.757	0.757	0.898	0.940	1.104	46.8
kPCA	0.023	0.702	0.702	0.805	0.933	1.353	47.8
FastICA	0.016	0.767	0.767	0.776	0.880	1.657	35.7
MDS	0.010	0.800	0.800	0.949	0.913	1.343	36.8
nMDS	**0.009**	0.811	0.811	**0.953**	0.907	1.353	38.0
DrL	0.494	0.089	0.089	0.004	0.393	5.555	263.8
FruchtermanReingold	0.240	0.335	0.335	0.284	0.880	2.054	103.8
KamadaKawai	**0.009**	**0.823**	**0.823**	0.932	0.913	1.162	38.3
HLLE	0.450	0.157	0.157	0.224	0.613	4.218	113.9
DiffusionMaps	0.042	0.671	0.671	0.708	0.880	**0.493**	56.4
tSNE	0.016	0.814	0.814	0.758	**0.960**	0.983	**25.7**

A Tabela 39 resume o ranqueamento multicritério dos algoritmos de redução de dimensionalidade para o Conjunto de Dados 6 e revela um perfil de desempenho notavelmente consistente em todos os objetivos avaliados.

O Kamada–Kawai alcança as maiores Pontuações Finais (Final Scores) em todos os objetivos — agrupamento, reconstrução, visualização e integração em pipelines de aprendizado de máquina — refletindo seu excelente equilíbrio entre a preservação das estruturas local e global dos dados. Seu valor máximo para o Índice_Local (1,000) e o valor praticamente máximo para o Índice_Global (0,986), combinados ao elevado desempenho nas métricas relacionadas às classes, evidenciam sua robusta capacidade de preservar as relações de vizinhança ao mesmo tempo em que reconstrói fielmente a geometria da variedade dos dados.

Os métodos nMDS, PCA e MDS clássico formam um grupo de elevado desempenho imediatamente abaixo do Kamada–Kawai. Esses algoritmos apresentam níveis praticamente idênticos de preservação da estrutura global (Índice_Global ≥ 0,986) e excelente coerência entre as classes, enquanto o PCA se destaca por sua elevada continuidade geométrica (Índice_Geom = 0,949).

O t-SNE, embora alcance o maior valor para o Índice_Classe (0,992), apresenta desempenho inferior aos métodos lineares e aos baseados em grafos na preservação da estrutura global, sugerindo que sua elevada capacidade de produzir projeções discriminativas ocorre à custa de menor fidelidade à geometria da variedade dos dados.

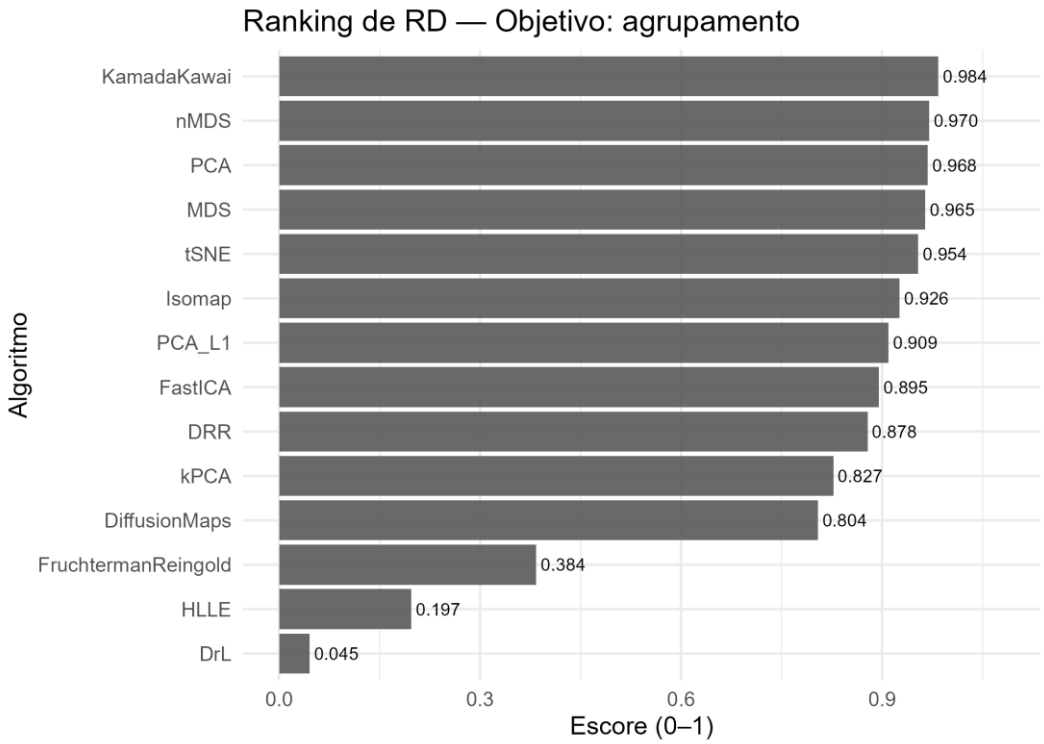
De modo geral, a tabela demonstra que o conjunto de dados df6 favorece fortemente algoritmos capazes de preservar a geometria global dos dados. Os métodos clássicos de aprendizado de variedades — especialmente Kamada–Kawai, nMDS, PCA e MDS — superam de forma consistente as abordagens não lineares e estocásticas,

reforçando a importância de selecionar algoritmos cujas características sejam compatíveis com a geometria intrínseca do conjunto de dados.

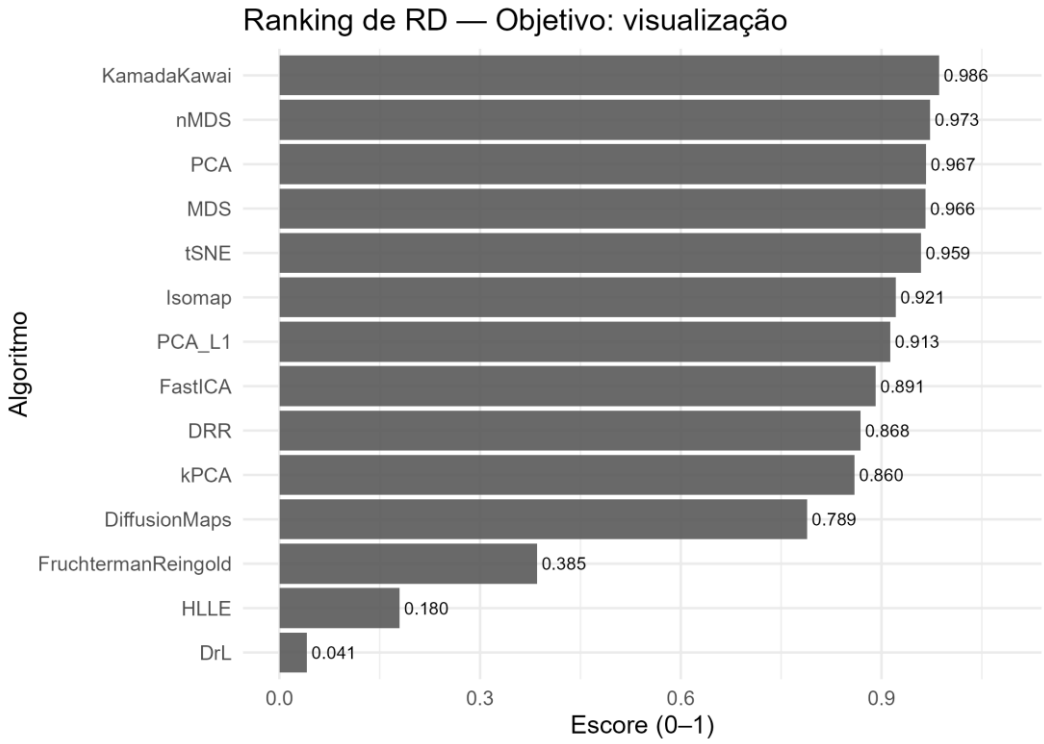
Tabela 39 – Figuras de mérito obtidas do conjunto de dados df6.

Algoritmo	Índice_Local	Índice_Global	Índice_Geom	Índice_Classe	Pontuação_Final	Objetivo
KamadaKawai	1.000	0.986	0.938	0.972	**0.984**	**agrupamento**
nMDS	0.978	0.992	0.926	0.958	0.970	agrupamento
PCA	0.972	0.987	0.949	0.952	0.968	agrupamento
MDS	0.971	0.986	0.928	0.951	0.965	agrupamento
tSNE	0.980	0.852	0.963	0.992	0.954	agrupamento
KamadaKawai	1.000	0.986	0.938	0.972	**0.986**	**visualização**
nMDS	0.978	0.992	0.926	0.958	0.973	visualização
PCA	0.972	0.987	0.949	0.952	0.967	visualização
MDS	0.971	0.986	0.928	0.951	0.966	visualização
tSNE	0.980	0.852	0.963	0.992	0.959	visualização
KamadaKawai	1.000	0.986	0.938	0.972	**0.971**	**reconstrução**
PCA	0.972	0.987	0.949	0.952	0.967	reconstrução
nMDS	0.978	0.992	0.926	0.958	0.962	reconstrução
MDS	0.971	0.986	0.928	0.951	0.958	reconstrução
tSNE	0.980	0.852	0.963	0.992	0.935	reconstrução
KamadaKawai	1.000	0.986	0.938	0.972	**0.986**	**pipeline de ML**
nMDS	0.978	0.992	0.926	0.958	0.973	pipeline de ML
PCA	0.972	0.987	0.949	0.952	0.967	pipeline de ML
MDS	0.971	0.986	0.928	0.951	0.966	pipeline de ML
tSNE	0.980	0.852	0.963	0.992	0.959	pipeline de ML

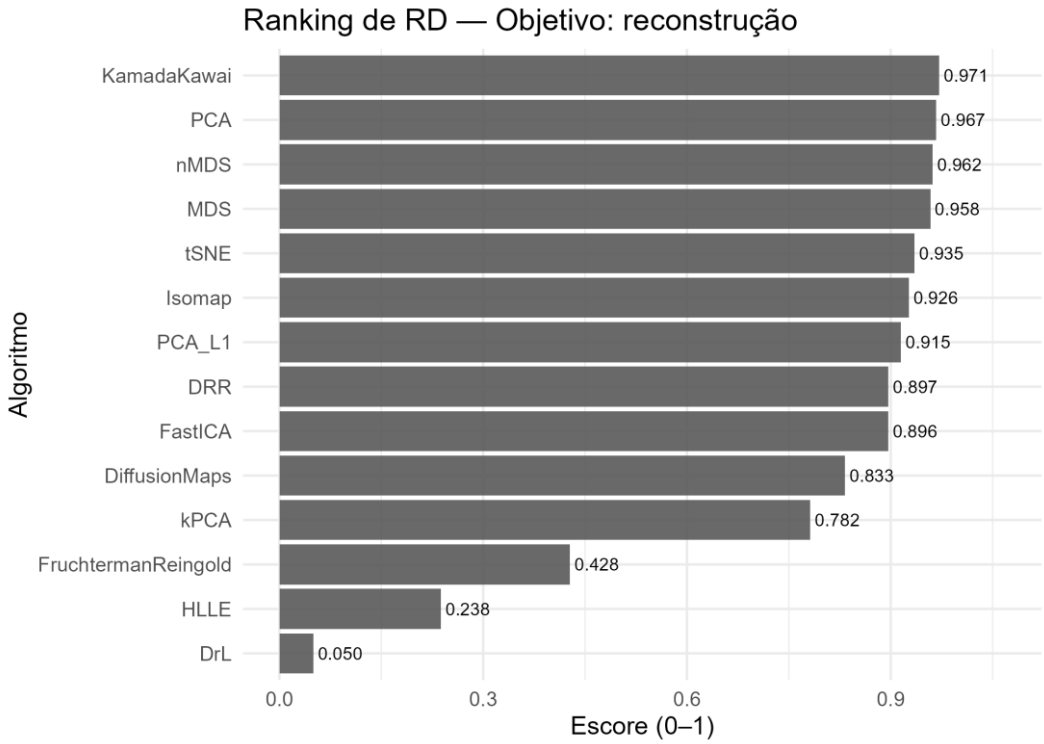
A Figura 38 apresenta o ranqueamento dos algoritmos de redução de dimensionalidade orientado por objetivos para o conjunto de dados df6, revelando uma hierarquia de desempenho notavelmente consistente entre os quatro objetivos analíticos avaliados: agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina.



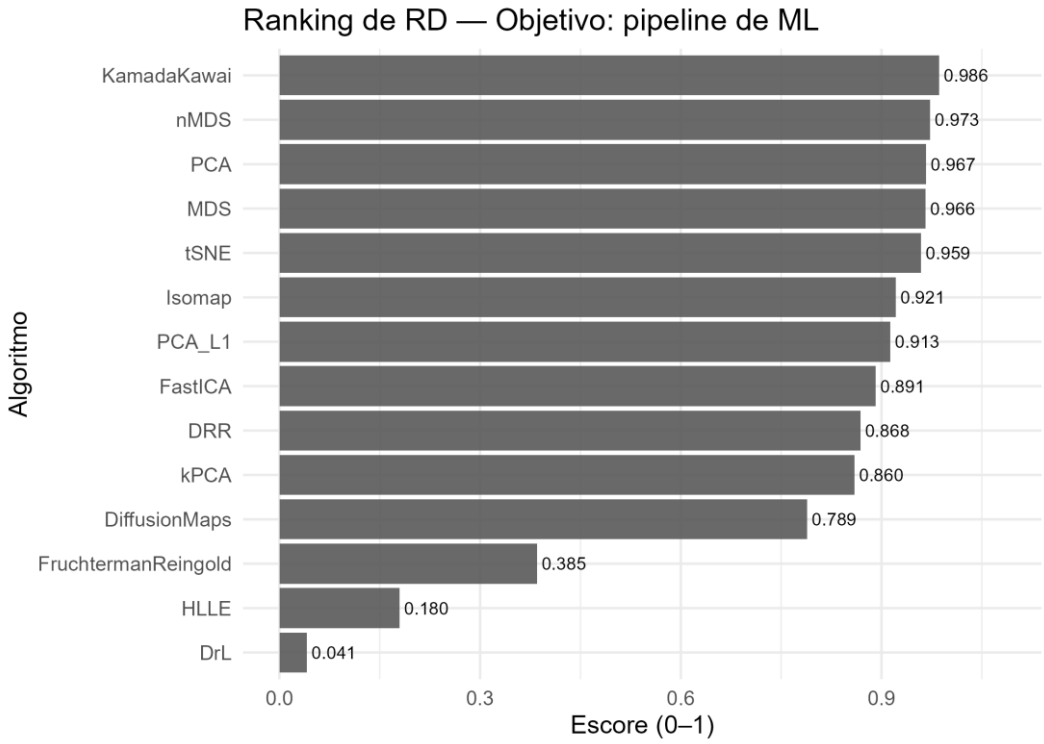
(a)


Ranking de RD — Objetivo: visualização
KamadaKawai
nMDS
PCA
MDS
tSNE
Isomap
PCA_L1
FastICA
DRR
kPCA
DiffusionMaps
FruchtermanReingold
HLLE
DrL
0.986
0.973
0.967
0.966
0.959
0.921
0.913
0.891
0.868
0.860
0.789
0.385
0.180
0.041
Algoritmo
0.0
0.3
0.6
0.9
Escore (0–1)

(b)


Ranking de RD — Objetivo: reconstrução
KamadaKawai
PCA
nMDS
MDS
tSNE
Isomap
PCA_L1
DRR
FastICA
DiffusionMaps
kPCA
FruchtermanReingold
HLLE
DrL
0.971
0.967
0.962
0.958
0.935
0.926
0.915
0.897
0.896
0.833
0.782
0.428
0.238
0.050
Algoritmo
0.0
0.3
0.6
0.9
Escore (0–1)

(c)



(d)

Figura 38 – Gráficos de barras horizontais mostrando as pontuações de desempenho normalizadas (0–1) para cada algoritmo de redução de dimensionalidade nos quatro objetivos analíticos: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

Os métodos Kamada–Kawai, PCA, nMDS e MDS clássico formam um grupo dominante, alcançando as maiores pontuações em todos os objetivos avaliados. Seu elevado desempenho reflete uma preservação excepcional tanto das relações de vizinhança locais quanto da estrutura global da variedade dos dados, resultado corroborado pelos elevados índices geométricos e de fidelidade às classes apresentados nas tabelas correspondentes.

Para os objetivos de agrupamento e visualização, o Kamada–Kawai ocupa a primeira posição, seguido de muito perto pelo nMDS e pelo PCA. Esses resultados indicam que o conjunto de dados df6 apresenta uma geometria altamente compatível com os métodos clássicos de aprendizado de variedades, permitindo que esses algoritmos

recuperem uma representação de baixa dimensionalidade significativa com mínima distorção.

No objetivo de reconstrução, o Kamada–Kawai apresenta o melhor desempenho, com o PCA e o nMDS a menos de 0,01 da pontuação máxima, confirmando a vantagem dos métodos lineares e daqueles que preservam as distâncias em aplicações que priorizam a reversibilidade e a fidelidade geométrica.

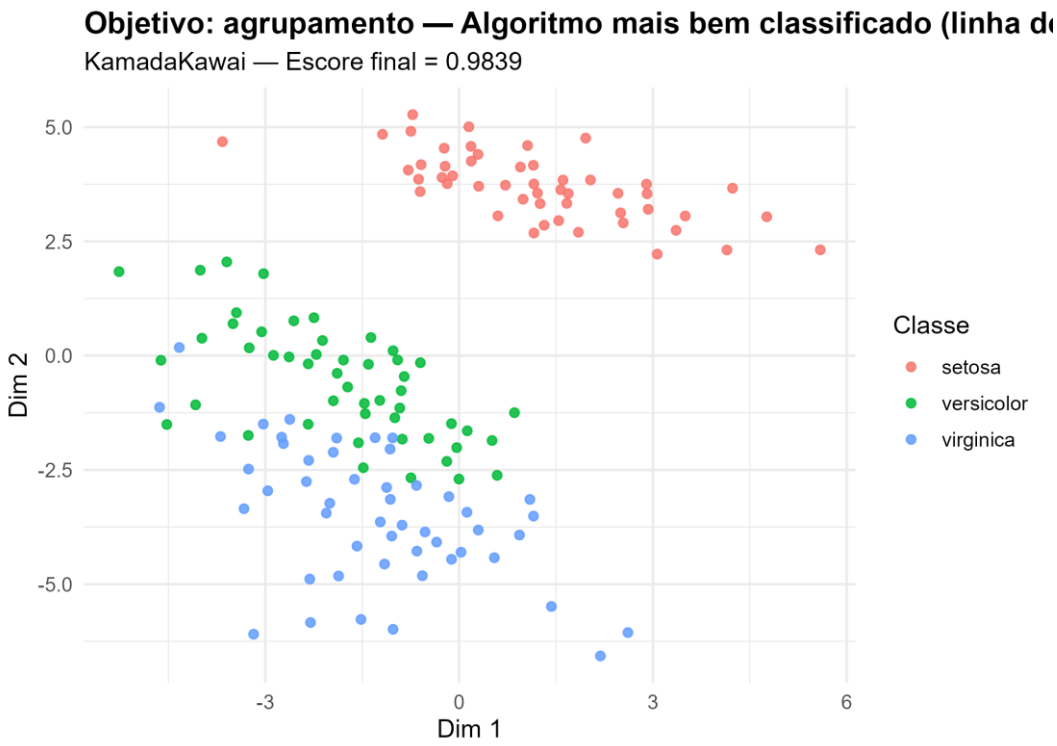
O t-SNE também apresenta desempenho elevado, posicionando-se de forma consistente entre os cinco melhores algoritmos. Entretanto, suas pontuações permanecem ligeiramente inferiores às dos principais métodos clássicos, refletindo sua ênfase na preservação da estrutura local em detrimento da estrutura global.

Em contraste, algoritmos como HLLE, DrL, Diffusion Maps e Fruchterman–Reingold ocupam sistematicamente as últimas posições do ranqueamento, indicando adequação limitada para este conjunto de dados.

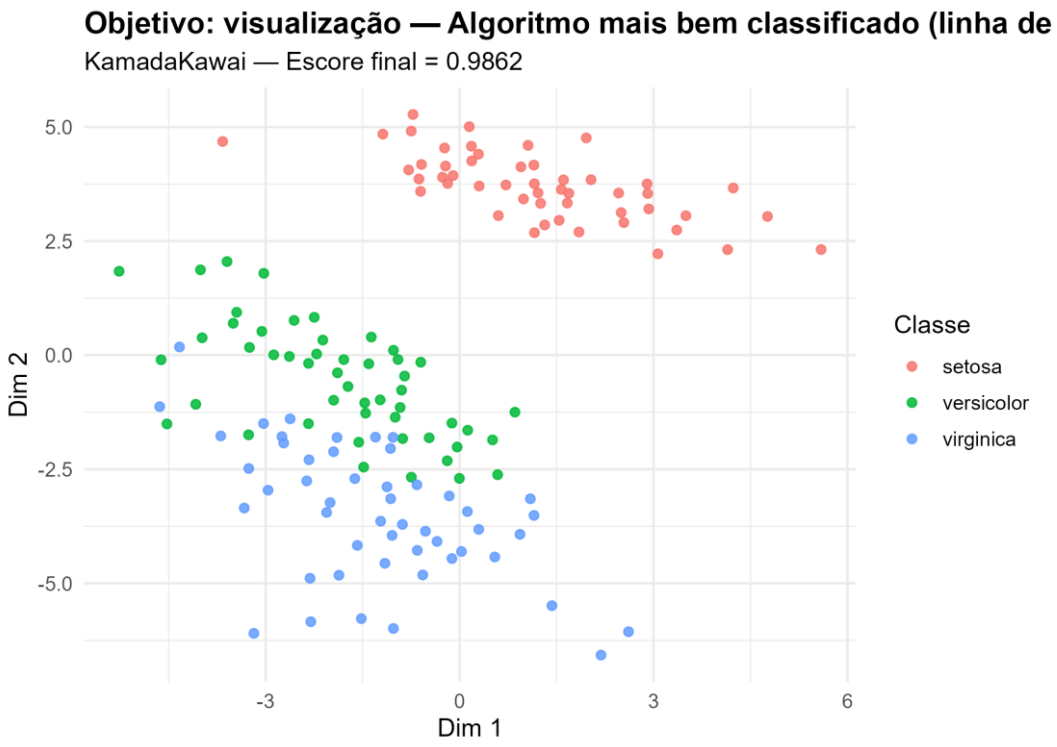
De modo geral, a figura demonstra que algoritmos capazes de preservar eficientemente a estrutura global da variedade dos dados apresentam desempenho superior em todos os objetivos analíticos considerados para o conjunto de dados df6. Em contrapartida, abordagens não lineares e baseadas em grafos oferecem apenas benefícios marginais.

A Figura 39 ilustra as projeções bidimensionais geradas pelos algoritmos de redução de dimensionalidade de melhor desempenho para o conjunto de dados df6, considerando quatro objetivos analíticos distintos. O Kamada–Kawai destaca-se como o método de melhor desempenho para os objetivos de agrupamento, visualização e integração em pipelines de aprendizado de máquina, produzindo projeções altamente estruturadas e com clara separação entre as classes do conjunto *Iris*. Nos painéis (a), (b) e (d), a projeção revela três agrupamentos bem definidos, organizados de forma

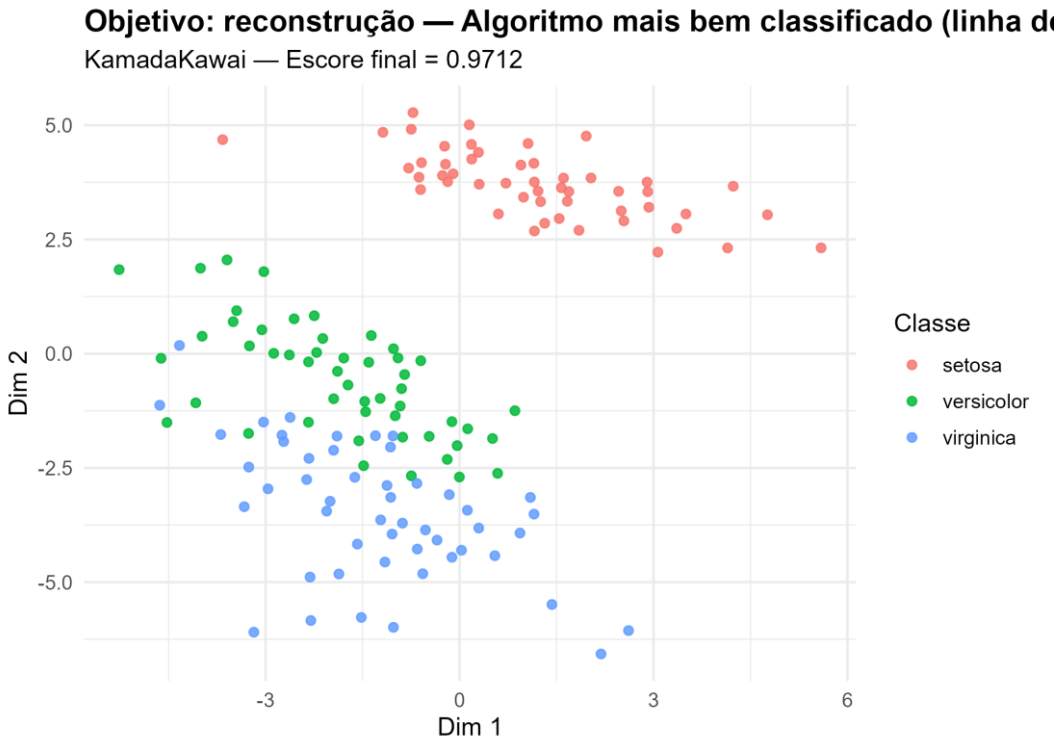
aproximadamente linear e correspondentes às espécies *setosa*, *versicolor* e *virginica*. O método preserva simultaneamente as relações de vizinhança locais e a geometria global dos dados, resultando em transições suaves e mínima distorção entre as fronteiras das classes.



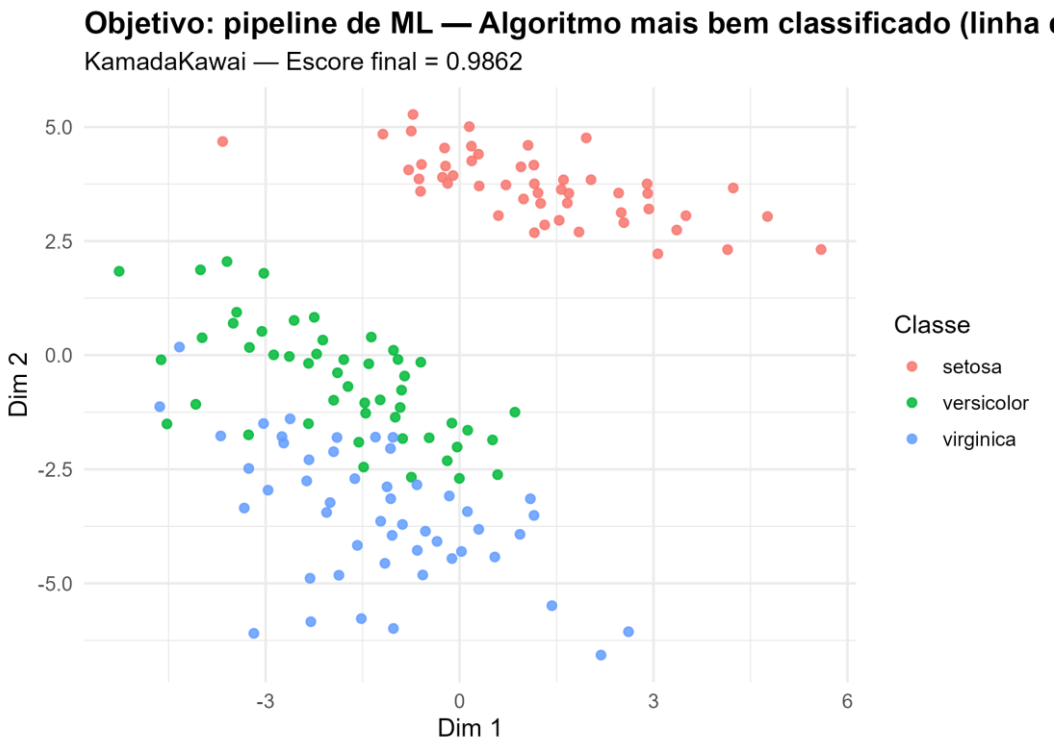
(a)


Objetivo: visualização — Algoritmo mais bem classificado (linha de
KamadaKawai — Escore final = 0.9862
Dim 2
Dim 1
5.0
2.5
0.0
-2.5
-5.0
-3
0
3
6
Classe
setosa
versicolor
virginica

(b)


Objetivo: reconstrução — Algoritmo mais bem classificado (linha d
KamadaKawai — Escore final = 0.9712
Dim 2
Dim 1
5.0
2.5
0.0
-2.5
-5.0
-3
0
3
6
Classe
setosa
versicolor
virginica

(c)



(d)

Figura 39 – Projeções bidimensionais produzidas pelo algoritmo melhor classificado para cada objetivo, com base na Pontuação Final (Final Score) do ranqueamento de referência (Baseline Ranking): (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

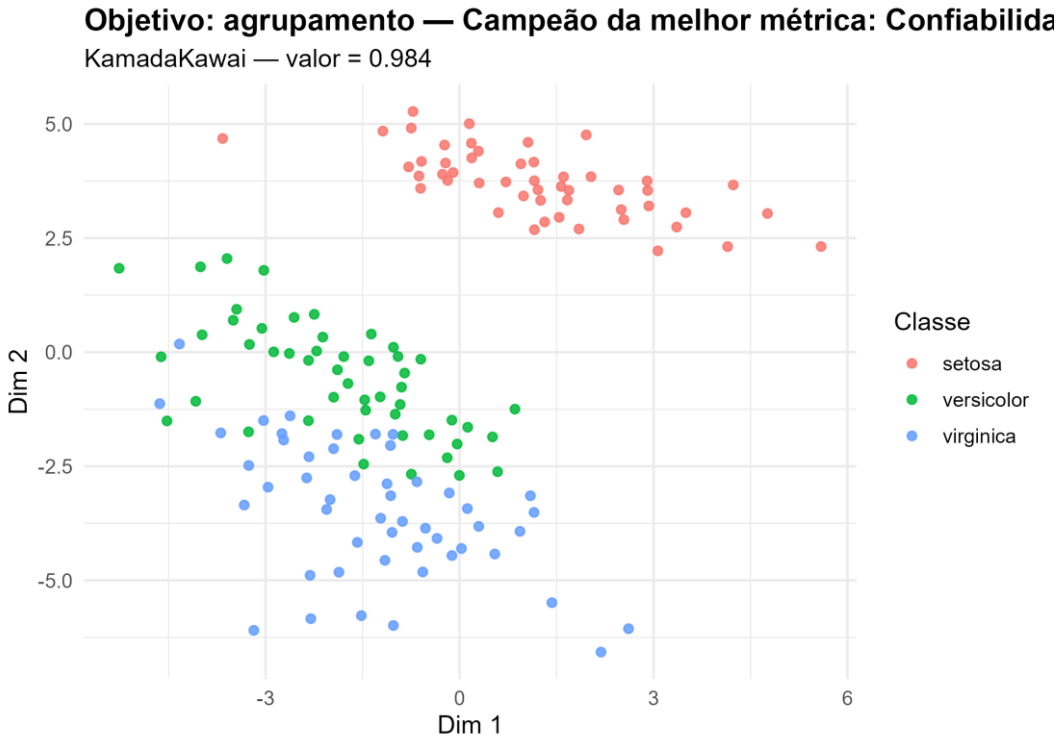
Para o objetivo de reconstrução, o Kamada–Kawai apresenta o melhor desempenho, conforme mostrado no painel (c), à frente do PCA por uma margem estreita. Sua projeção reproduz o padrão clássico de separabilidade do conjunto de dados *Iris*, com a classe *setosa* claramente isolada e uma sobreposição parcial entre as classes *versicolor* e *virginica*. O PCA vem a menos de 0,01 de distância, em concordância com sua principal característica, que consiste em preservar a variância global dos dados e fornecer transformações estáveis e invertíveis, propriedades essenciais para aplicações voltadas à reconstrução.

De modo geral, a figura demonstra que o conjunto de dados df6 favorece fortemente algoritmos capazes de preservar a estrutura global da variedade dos dados. O

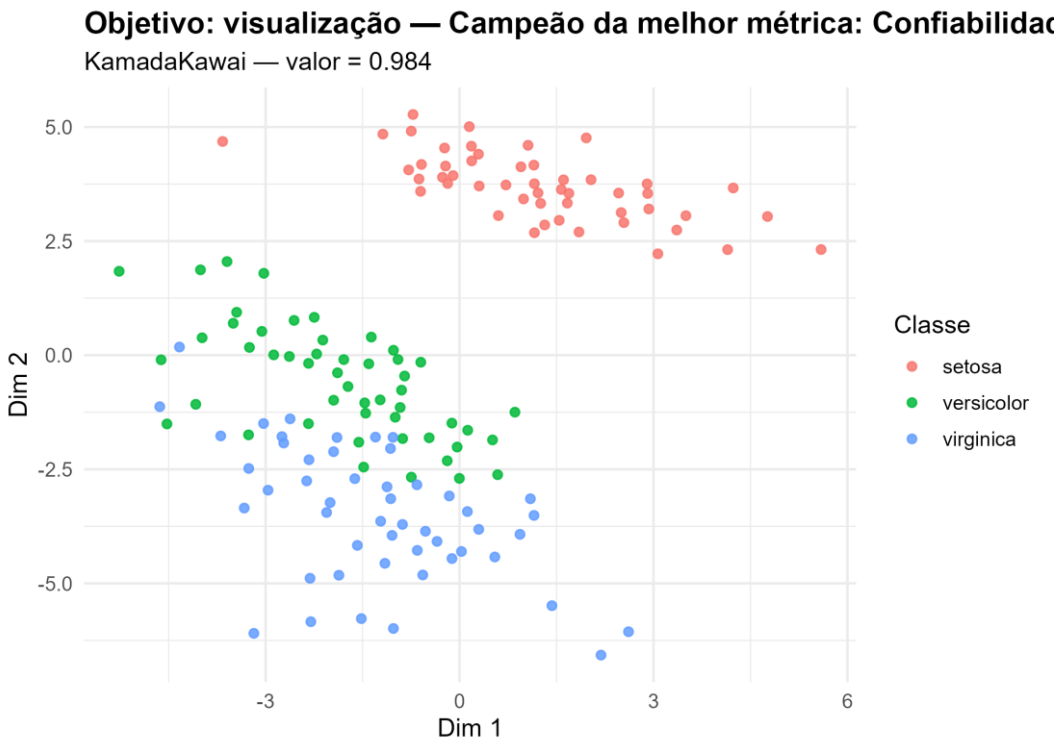
Kamada–Kawai produz, de forma consistente, projeções com excelente separabilidade entre classes e elevada coerência geométrica, enquanto o PCA permanece como uma alternativa igualmente forte sempre que a fidelidade da reconstrução e um mapeamento invertível constituem os requisitos principais.

Os resultados reforçam a importância de selecionar o método de redução de dimensionalidade de acordo com as prioridades específicas de cada aplicação analítica.

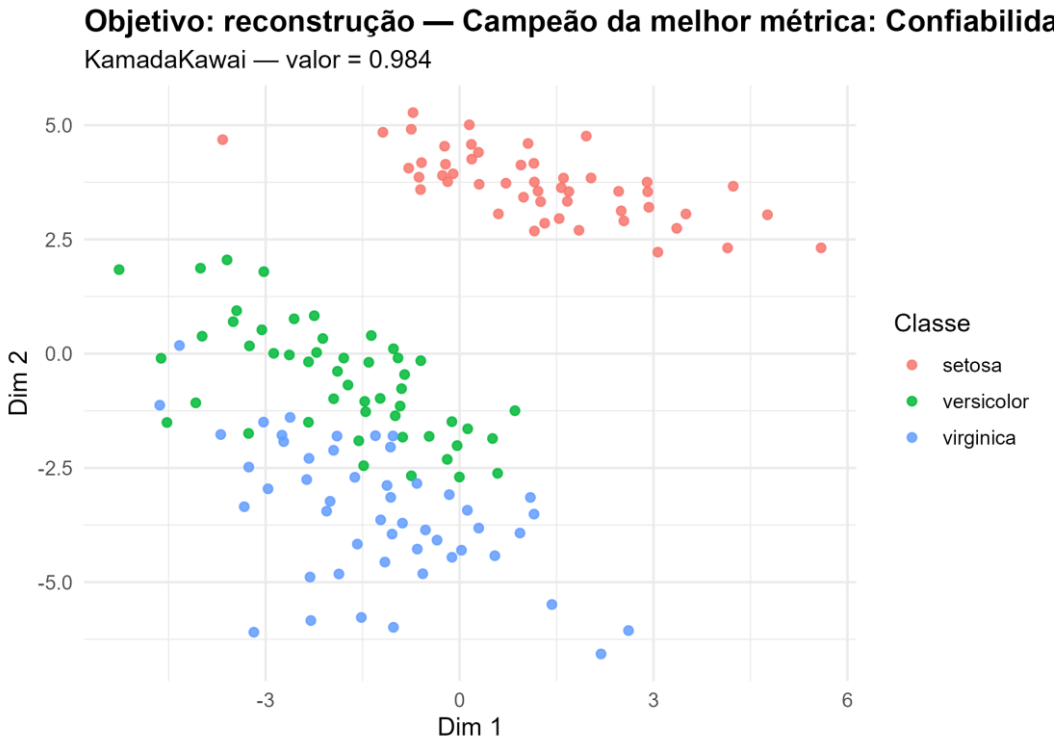
A Figura 40 apresenta as projeções bidimensionais obtidas pelo algoritmo Kamada–Kawai, identificado como o de melhor desempenho de acordo com a métrica Confiabilidade (Trustworthiness), para os quatro objetivos analíticos considerados no conjunto de dados df6.



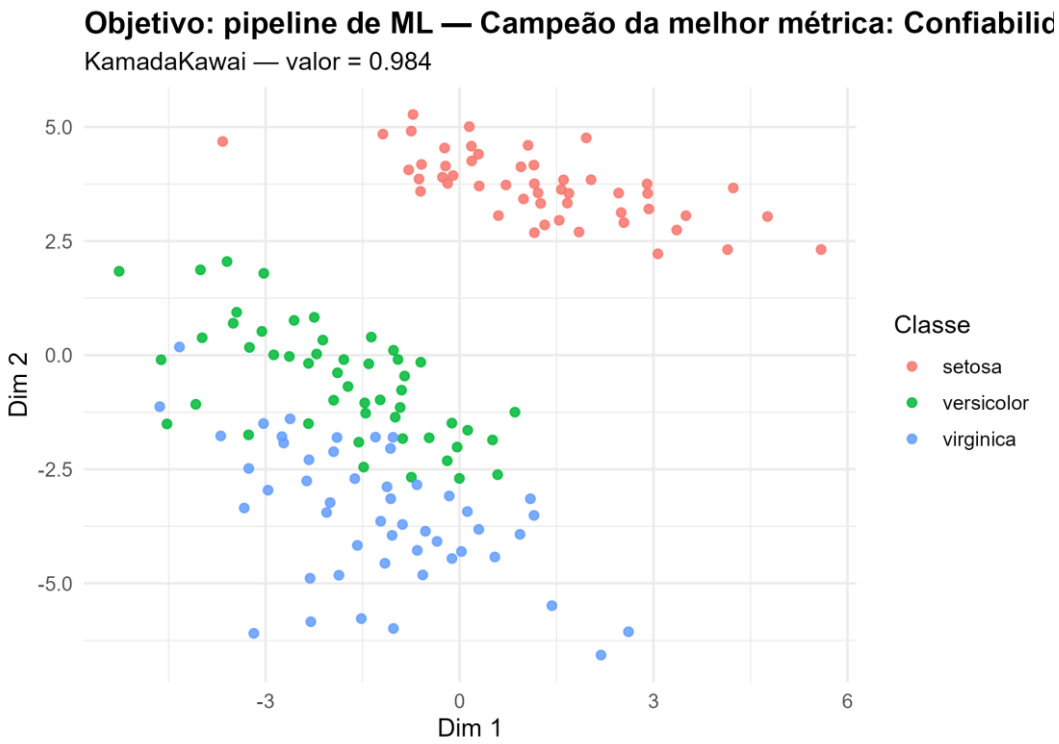
(a)


Objetivo: visualização — Campeão da melhor métrica: Confiabilidad
KamadaKawai — valor = 0.984
Dim 2
Dim 1
5.0
2.5
0.0
-2.5
-5.0
-3
0
3
6
Classe
setosa
versicolor
virginica

(b)


Objetivo: reconstrução — Campeão da melhor métrica: Confiabilida
KamadaKawai — valor = 0.984
Dim 2
Dim 1
5.0
2.5
0.0
-2.5
-5.0
-3
0
3
6
Classe
setosa
versicolor
virginica

(c)



(d)

Figura 40 – Projeções bidimensionais geradas pelo algoritmo campeão, selecionado com base na métrica de melhor desempenho para cada objetivo analítico: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

A seleção consistente do Kamada–Kawai evidencia sua elevada capacidade de manter genuinamente próximos, no espaço original, os pontos que aparecem próximos na projeção — exatamente o aspecto privilegiado pela Confiabilidade (Trustworthiness). Nos quatro objetivos analíticos — agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina — as projeções apresentam organização geométrica praticamente idêntica, refletindo a estabilidade e a robustez do algoritmo quando avaliado por essa métrica.

Em todos os painéis, as classes do conjunto *Iris* — *setosa*, *versicolor* e *virginica* — formam regiões claramente distinguíveis, com transições suaves e mínima distorção. A classe *setosa* permanece completamente separada das demais espécies, enquanto

versicolor e *virginica* apresentam a sobreposição parcial esperada, em concordância com a estrutura intrínseca já conhecida desse conjunto de dados.

A preservação da ordenação das relações de vizinhança locais e de média distância permite que o método mantenha, na projeção bidimensional, relações biologicamente significativas entre as amostras. De modo geral, a figura demonstra que a Confiabilidade (Trustworthiness) privilegia projeções livres de falsos vizinhos, e que o Kamada–Kawai oferece um equilíbrio excelente entre a fidelidade às relações de vizinhança e a organização geométrica global. Sua superioridade consistente em todos os objetivos analíticos reforça sua adequação para conjuntos de dados caracterizados por relações geométricas suaves e estruturas semelhantes a grafos.

10. ESTUDO DE CASO VII

10.1 Descrição do Conjunto de Dados

O conjunto de dados Wine foi denominado df7. Ele contém 178 instâncias e 13 variáveis (atributos). Esses dados correspondem aos resultados de análises químicas de vinhos produzidos na mesma região da Itália, porém provenientes de três diferentes cultivares. O estudo original determinou as concentrações de 13 constituintes químicos em cada um dos três tipos de vinho [93].

10.2 Resultados e Discussão

O mapa de calor apresentado na Figura 41 fornece uma visão geral da estrutura de correlação entre as métricas utilizadas para avaliar o desempenho dos algoritmos de redução de dimensionalidade.

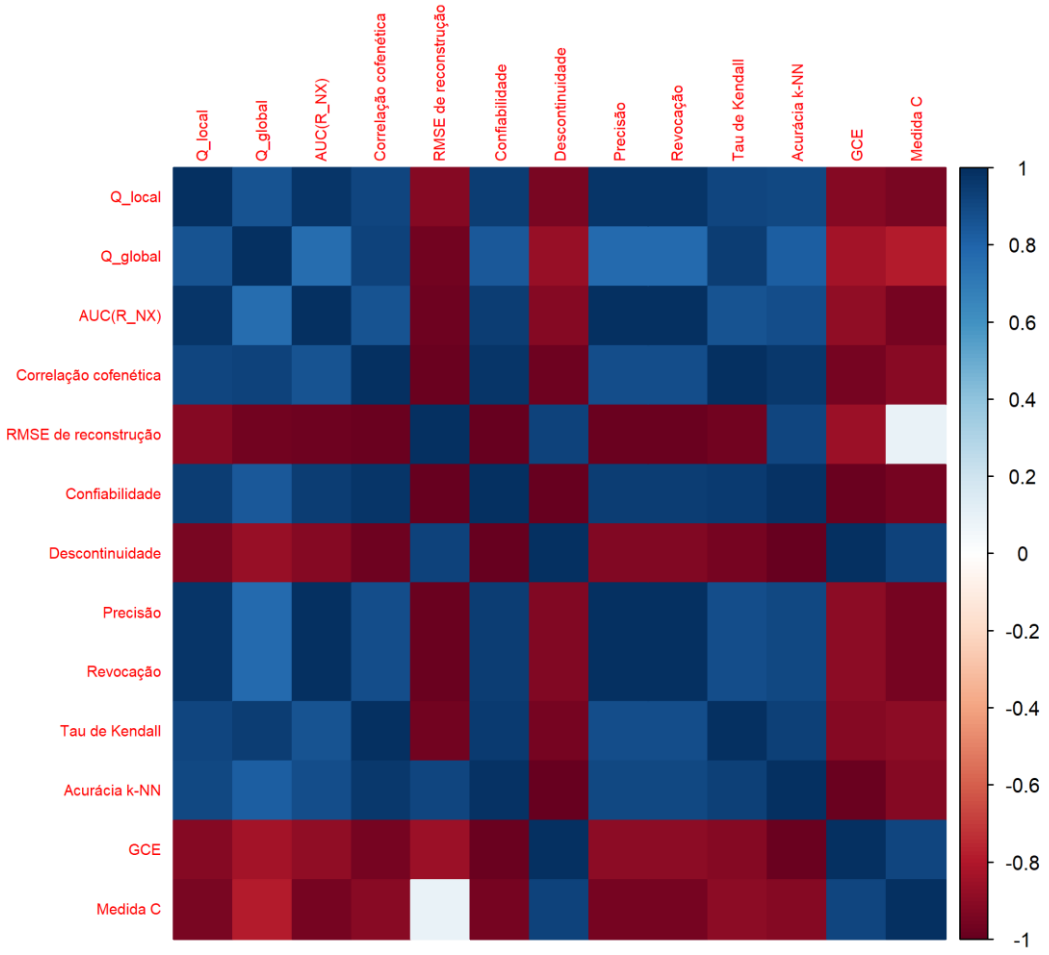


Figura 41 – Estrutura da matriz de correlação entre as métricas de avaliação utilizadas no framework de benchmarking.

As métricas orientadas à preservação da estrutura local — Q_{local}, *Trustworthiness*, *Precision*, *Recall* e *Accuracy_kNN* — formam um grupo fortemente correlacionado, indicando uma resposta consistente à preservação das relações de vizinhança. Da mesma forma, as métricas de preservação da estrutura global (Q_{global}, *AUC_R(NX)*, *Cophenetic* e *KendallTau*) também constituem um agrupamento coeso, refletindo sua sensibilidade comum à preservação da geometria da variedade dos dados.

As métricas relacionadas à reconstrução e à distorção geométrica (*RMSE_Reconstruction*, *GCE*, *C_measure* e *Discontinuity*) apresentam fortes correlações

negativas tanto com as métricas locais quanto com as globais, evidenciando um compromisso (trade-off) amplamente conhecido: algoritmos que preservam com elevada fidelidade a estrutura dos dados tendem a apresentar menor desempenho na reconstrução, enquanto métodos otimizados para reconstrução frequentemente introduzem distorções nas relações geométricas.

De modo geral, a figura reforça o caráter multidimensional da avaliação de métodos de redução de dimensionalidade e a necessidade de selecionar métricas de acordo com o objetivo analítico.

As métricas obtidas para o conjunto de dados df7, apresentadas na Tabela 40A e na Tabela 40B, evidenciam uma clara distinção entre os métodos clássicos de aprendizado de variedades, que apresentam elevado desempenho, e os métodos baseados em grafos ou altamente não lineares, que obtêm resultados inferiores.

Entre todos os algoritmos avaliados, nMDS, PCA/MDS, Isomap, Kamada–Kawai, FastICA e DRR constituem o grupo de melhor desempenho, alcançando, de forma consistente, elevados valores tanto nas métricas de fidelidade geométrica quanto nas métricas relacionadas às classes.

O nMDS destaca-se por apresentar o maior valor de Qglobal (0,909), a mais elevada correlação cofenética (Cophenetic = 0,917) e excelente desempenho nas métricas de preservação das relações de vizinhança, como Trustworthiness (0,916) e Continuity (0,934). Esses resultados indicam uma capacidade superior de preservar simultaneamente a estrutura local e a geometria global da variedade de dados. Além disso, o nMDS alcança o maior valor de Kendall τ (0,781) e uma elevada Accuracy_kNN (0,978), confirmando sua excelente capacidade de preservar a ordenação relativa das amostras e a estrutura em nível de classes.

O PCA e o MDS clássico também apresentam desempenho robusto, exibindo valores praticamente idênticos em todas as métricas geométricas, o que reforça a adequação das projeções lineares quando o conjunto de dados apresenta uma estrutura global de variância bem definida.

Os métodos Isomap e Kamada–Kawai também demonstram excelente capacidade de preservação da variedade dos dados, apresentando elevados valores nas métricas globais e forte continuidade das relações de vizinhança.

Em contrapartida, o t-SNE, embora obtenha o maior valor de Qlocal (0,628) e excelentes métricas relacionadas às classes (Precision/Recall = 0,652 e Accuracy_kNN = 0,983), apresenta menor capacidade de preservar a estrutura global e maior erro de reconstrução, ilustrando o compromisso (trade-off) característico entre a separação discriminativa da estrutura local e a preservação fiel da geometria global.

Na extremidade inferior do desempenho, DrL e HLLE apresentam severa distorção geométrica e baixo desempenho nas métricas relacionadas às classes, refletidos por valores extremamente reduzidos de Qlocal, AUC_R(NX) e Kendall τ, além de elevados valores de erro, como C_Measure superior a 500, confirmando sua inadequação para o conjunto de dados df7.

De modo geral, os resultados demonstram que o conjunto de dados df7 favorece fortemente métodos capazes de equilibrar a preservação das estruturas locais e globais dos dados, destacando nMDS, PCA/MDS, Isomap e Kamada–Kawai como os algoritmos mais confiáveis em termos de fidelidade à variedade dos dados, preservação das relações de vizinhança e desempenho nas métricas orientadas à classificação.

Tabela 40A – Figuras de mérito obtidas do conjunto de dados df7.

Algoritmo	Q_local	Q_global	AUC(R_NX)	Correlação cofenética	RMSE de reconstrução	Confiabilidade	Continuidade
DRR	0.518	0.870	0.439	0.807	**0.651**	0.898	0.926
Isomap	0.551	0.884	0.455	0.827		0.901	0.941
PCA	0.543	0.887	0.449	0.842	**0.651**	0.899	0.941
PCA_L1	0.487	0.870	0.372	0.803		0.877	0.910
kPCA	0.485	0.801	0.397	0.632	20.376	0.867	0.905
FastICA	0.532	0.863	0.439	0.803	**0.651**	0.897	0.936
MDS	0.543	0.887	0.449	0.842		0.899	0.941
nMDS	0.562	**0.909**	0.473	**0.917**		0.916	0.934
DrL	0.301	0.783	0.107	0.098		0.557	0.535
FruchtermanReingold	0.365	0.814	0.271	0.627		0.803	0.804
KamadaKawai	0.528	0.888	0.444	0.872		0.901	0.929
HLLE	0.232	0.719	0.108	0.044		0.565	0.489
DiffusionMaps	0.529	0.873	0.428	0.800		0.900	0.932
tSNE	**0.628**	0.848	**0.655**	0.777		**0.957**	**0.954**

Tabela 40B – Figuras de mérito obtidas do conjunto de dados df7.

Algoritmo	Descontinuidade	Precisão	Revocação	Tau de Kendall	Acurácia k-NN	GCE	Medida C
DRR	0.074	0.457	0.457	0.634	0.966	0.794	348.4
Isomap	0.059	0.472	0.472	0.660	0.978	0.667	296.6
PCA	0.059	0.463	0.463	0.679	0.972	0.745	322.3
PCA_L1	0.090	0.373	0.373	0.626	0.966	0.503	319.9
kPCA	0.095	0.407	0.407	0.435	0.983	0.382	333.5
FastICA	0.064	0.452	0.452	0.616	0.972	0.567	322.6
MDS	0.059	0.463	0.463	0.679	0.972	0.745	322.3
nMDS	0.066	0.491	0.491	**0.781**	0.978	0.632	248.3
DrL	0.465	0.108	0.108	0.067	0.433	4.896	535.0
FruchtermanReingold	0.196	0.283	0.283	0.450	0.831	1.859	374.1
KamadaKawai	0.071	0.464	0.464	0.713	**0.989**	0.625	330.7
HLLE	0.511	0.110	0.110	0.066	0.478	5.705	524.1
DiffusionMaps	0.068	0.436	0.436	0.624	0.983	**0.303**	290.9
tSNE	**0.046**	**0.652**	**0.652**	0.622	0.983	0.323	**204.5**

A Tabela 41 apresenta uma visão consolidada do desempenho multicritério dos algoritmos de redução de dimensionalidade para o conjunto de dados df7, evidenciando diferenças claras entre os métodos otimizados para a preservação da estrutura local e aqueles que preservam com maior eficiência a geometria global da variedade dos dados.

O t-SNE alcança, de forma consistente, os maiores valores para Índice_Local (1,000) e Índice_Classe (0,997), obtendo também as maiores Pontuações Finais (Final Scores) para os objetivos de agrupamento (0,964), visualização (0,963) e integração em pipelines de aprendizado de máquina (0,963). Esses resultados confirmam sua elevada capacidade de capturar relações de vizinhança em pequena escala e de produzir projeções altamente discriminativas, com excelente separação visual entre as classes.

Em contrapartida, o nMDS demonstra a melhor preservação da geometria global, apresentando o maior valor de Índice_Global (0,917) e elevada fidelidade às classes em todos os objetivos avaliados. Embora suas Pontuações Finais (Final Scores) sejam ligeiramente inferiores às do t-SNE nos objetivos de visualização e integração em pipelines de aprendizado de máquina, o nMDS permanece como o segundo algoritmo de melhor desempenho, refletindo um equilíbrio robusto entre a preservação das estruturas local e global dos dados.

Métodos lineares, como PCA e Isomap, constituem um grupo de desempenho intermediário e estável. Seus valores de Índice_Geom figuram entre os mais elevados (PCA = 0,883 e FastICA = 0,889), o que explica sua confiabilidade em tarefas voltadas à reconstrução, nas quais o nMDS ocupa a primeira posição entre os métodos que não o t-SNE, seguido pelo PCA.

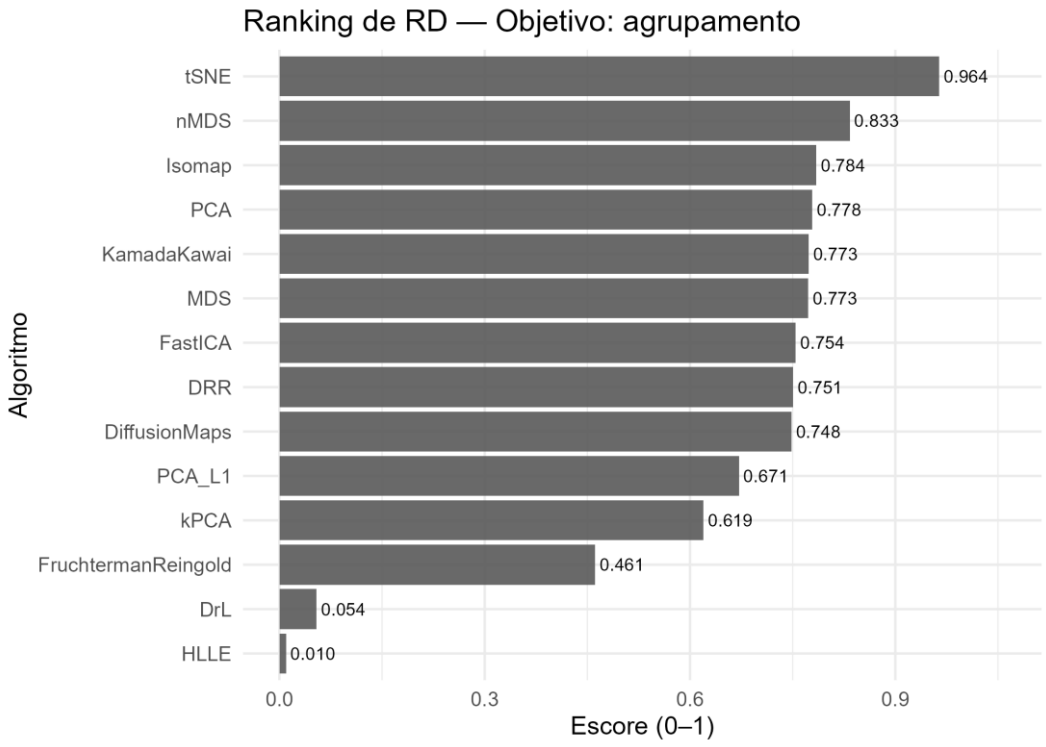
O Kamada–Kawai também apresenta desempenho consistentemente elevado, especialmente na preservação da continuidade da estrutura global, embora apresente capacidade de discriminação entre classes ligeiramente inferior à do t-SNE.

Em conjunto, os resultados demonstram que o conjunto de dados df7 favorece algoritmos capazes de (i) maximizar a preservação das relações de vizinhança locais, como o t-SNE, ou (ii) preservar com elevada fidelidade as distâncias globais entre pares de amostras, como o nMDS. Os padrões de desempenho claros e consistentes reforçam a importância de alinhar a escolha do algoritmo às propriedades estruturais predominantes dos dados e ao objetivo analítico específico.

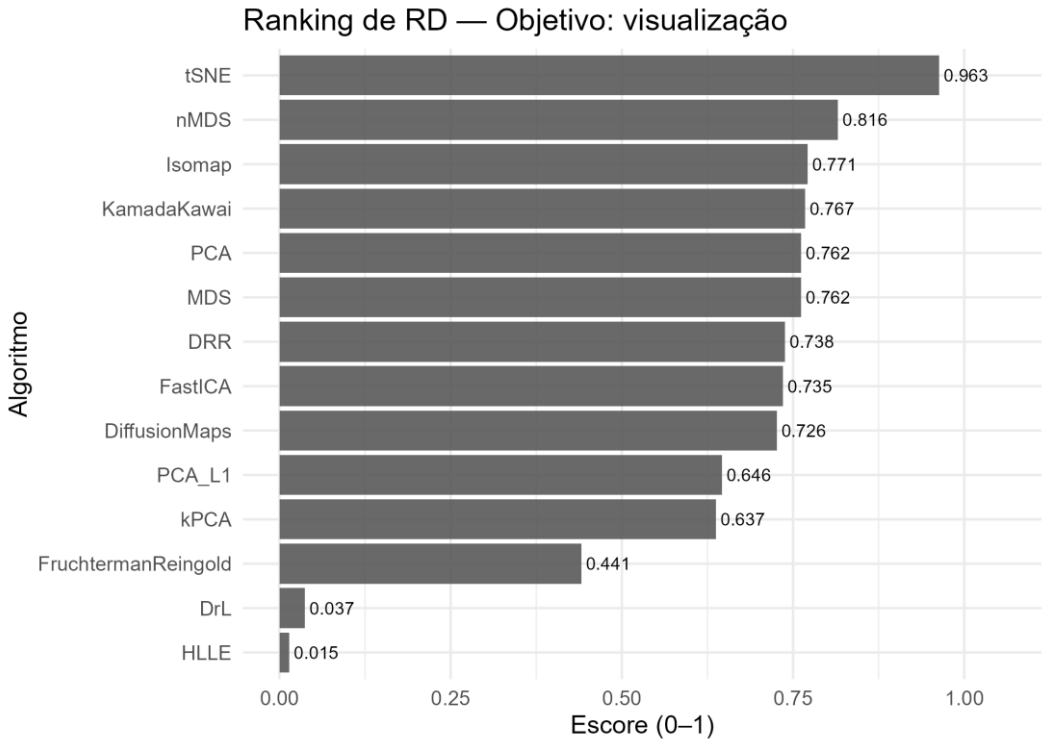
Tabela 41 – Figuras de mérito obtidas do conjunto de dados df7.

Algoritmo	Índice_Local	Índice_Global	Índice_Geom	Índice_Classe	Pontuação_Final	Objetivo
tSNE	1.000	0.824	0.999	0.996	**0.964**	**agrupamento**
nMDS	0.785	0.917	0.921	0.796	0.833	agrupamento
Isomap	0.751	0.808	0.875	0.773	0.784	agrupamento
PCA	0.736	0.820	0.883	0.758	0.778	agrupamento
KamadaKawai	0.729	0.839	0.835	0.770	0.773	agrupamento
tSNE	1.000	0.824	0.999	0.996	**0.963**	**visualização**
nMDS	0.785	0.917	0.921	0.796	0.816	visualização
Isomap	0.751	0.808	0.875	0.773	0.771	visualização
KamadaKawai	0.729	0.839	0.835	0.770	0.767	visualização
PCA	0.736	0.820	0.883	0.758	0.762	visualização
tSNE	1.000	0.824	0.999	0.996	**0.947**	**reconstrução**
nMDS	0.785	0.917	0.921	0.796	0.879	reconstrução
PCA	0.736	0.820	0.883	0.758	0.820	reconstrução
Isomap	0.751	0.808	0.875	0.773	0.818	reconstrução
MDS	0.736	0.820	0.845	0.758	0.805	reconstrução
tSNE	1.000	0.824	0.999	0.996	**0.963**	**pipeline de ML**
nMDS	0.785	0.917	0.921	0.796	0.816	pipeline de ML
Isomap	0.751	0.808	0.875	0.773	0.771	pipeline de ML
KamadaKawai	0.729	0.839	0.835	0.770	0.767	pipeline de ML
PCA	0.736	0.820	0.883	0.758	0.762	pipeline de ML

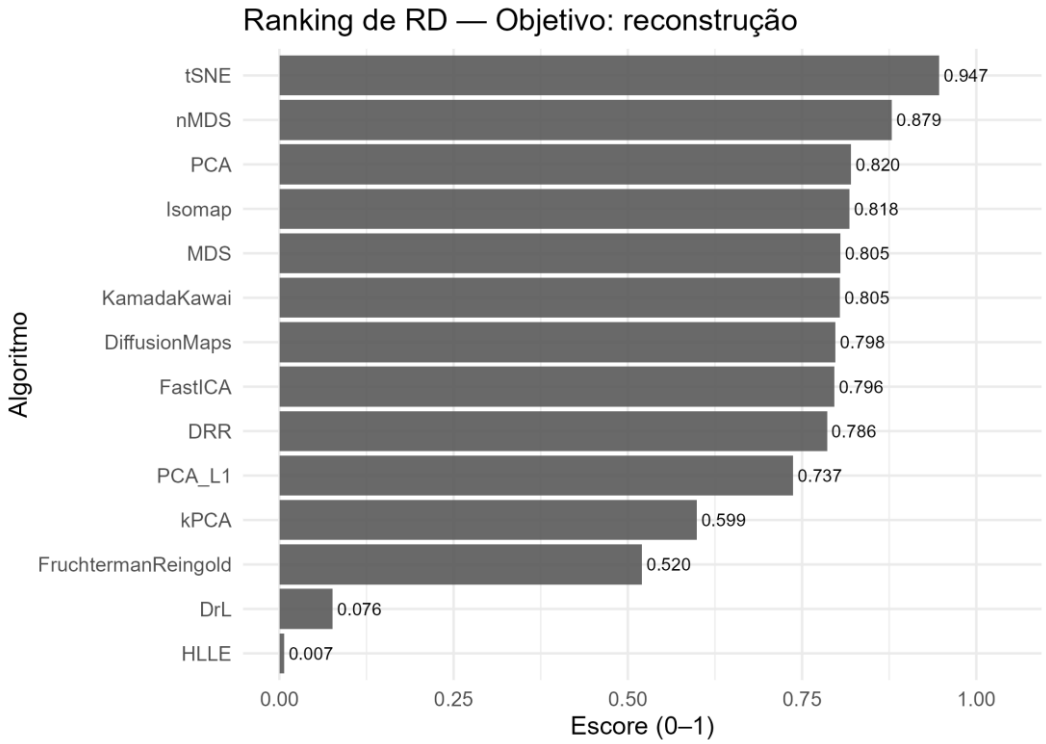
A Figura 42 apresenta o ranqueamento dos algoritmos de redução de dimensionalidade orientado por objetivos para o conjunto de dados df7, revelando uma hierarquia de desempenho consistente para os quatro objetivos analíticos avaliados: agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina.



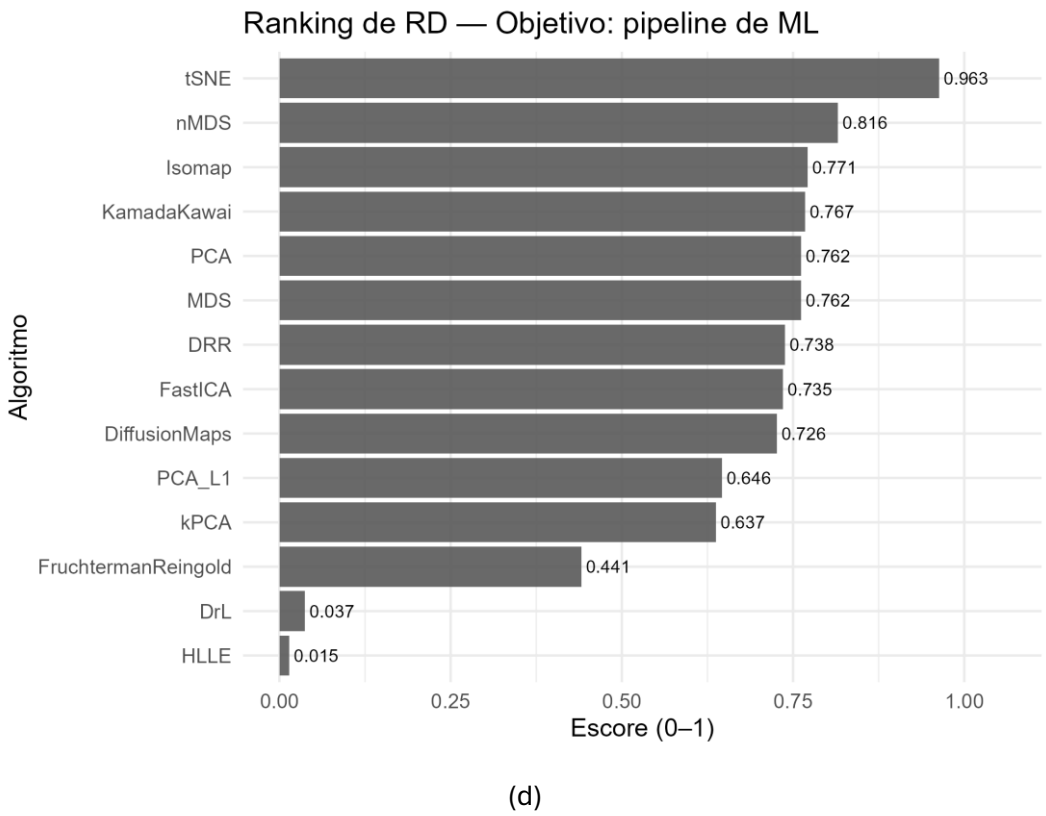
(a)


Ranking de RD — Objetivo: visualização
Algoritmo
tSNE
nMDS
Isomap
KamadaKawai
PCA
MDS
DRR
FastICA
DiffusionMaps
PCA_L1
kPCA
FruchtermanReingold
DrL
HLLE
0.963
0.816
0.771
0.767
0.762
0.762
0.738
0.735
0.726
0.646
0.637
0.441
0.037
0.015
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

(b)


Ranking de RD — Objetivo: reconstrução
Algoritmo
tSNE
nMDS
PCA
Isomap
MDS
KamadaKawai
DiffusionMaps
FastICA
DRR
PCA_L1
kPCA
FruchtermanReingold
DrL
HLLE
0.947
0.879
0.820
0.818
0.805
0.805
0.798
0.796
0.786
0.737
0.599
0.520
0.076
0.007
0.00
0.25
0.50
0.75
1.00
Escore (0–1)

(c)



(d)

Figura 42 – Gráficos de barras horizontais mostrando as pontuações de desempenho normalizadas (0–1) para cada algoritmo de redução de dimensionalidade nos quatro objetivos analíticos: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

Em todos os quatro objetivos, o t-SNE obtém a maior pontuação global, refletindo sua excepcional capacidade de preservar as relações de vizinhança locais e de produzir projeções de baixa dimensionalidade altamente discriminativas. Essa superioridade é particularmente evidente nos objetivos de visualização e integração em pipelines de aprendizado de máquina, nos quais o t-SNE alcança pontuações próximas do valor máximo (≈ 0,96), evidenciando sua elevada capacidade de separação entre classes e de preservação da estrutura local dos dados.

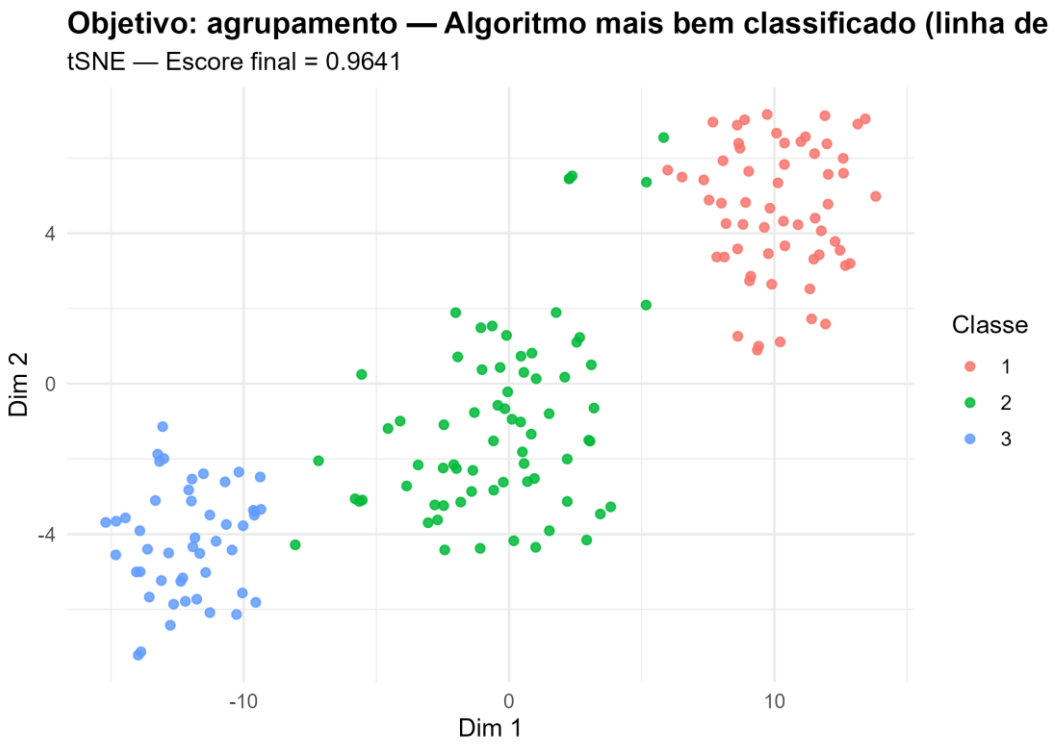
O nMDS destaca-se como o segundo algoritmo de melhor desempenho em todos os objetivos avaliados, apresentando excelentes propriedades de preservação das estruturas global e local. Suas pontuações permanecem consistentemente elevadas (≈

0,77–0,82), demonstrando robustez e equilíbrio entre a preservação da geometria global da variedade dos dados e das relações de vizinhança.

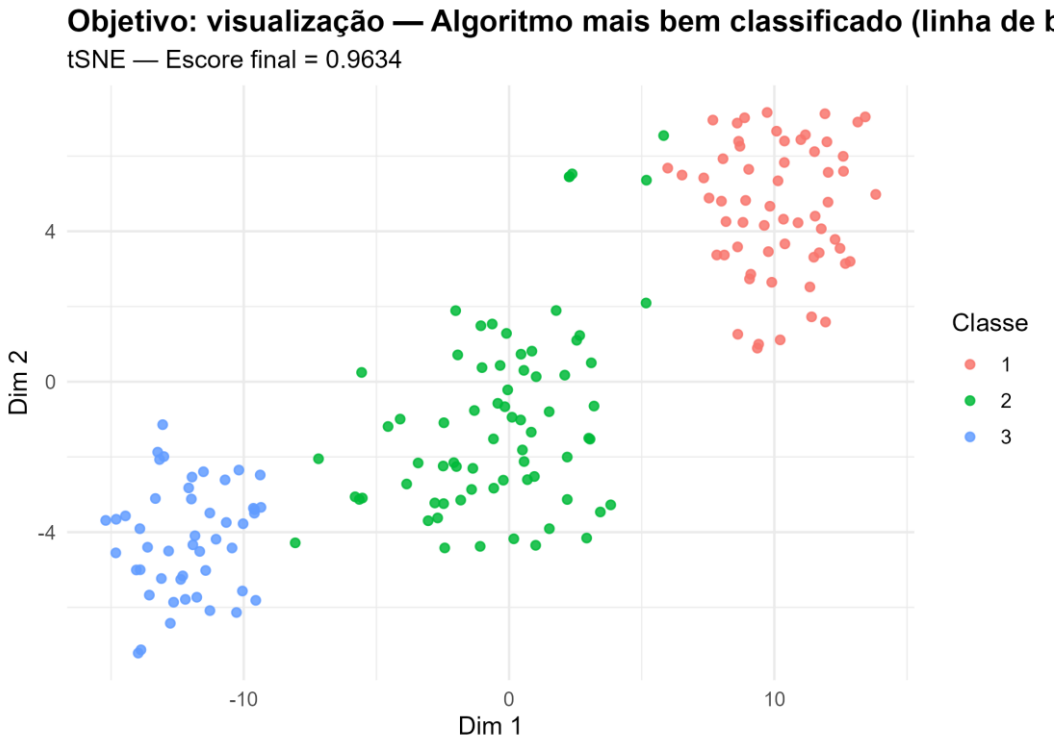
Os métodos Isomap, Kamada–Kawai, PCA e MDS formam um grupo intermediário, com desempenho estável, produzindo projeções confiáveis, embora menos discriminativas do que as obtidas pelo t-SNE e pelo nMDS. Em contraste, HLLE, DrL e Fruchterman–Reingold ocupam sistematicamente as últimas posições em todos os objetivos, apresentando pontuações extremamente baixas que indicam fraca preservação da estrutura da variedade dos dados e reduzida capacidade de recuperar a estrutura das classes. Esses resultados evidenciam a sua limitada aplicabilidade a este conjunto de dados.

De modo geral, a figura demonstra que o conjunto de dados df7 favorece fortemente algoritmos otimizados para preservar as relações de vizinhança locais, com o t-SNE superando de forma consistente todos os demais métodos. Ao mesmo tempo, o nMDS permanece como a alternativa mais robusta para aplicações que exigem um equilíbrio entre a preservação das estruturas local e global dos dados.

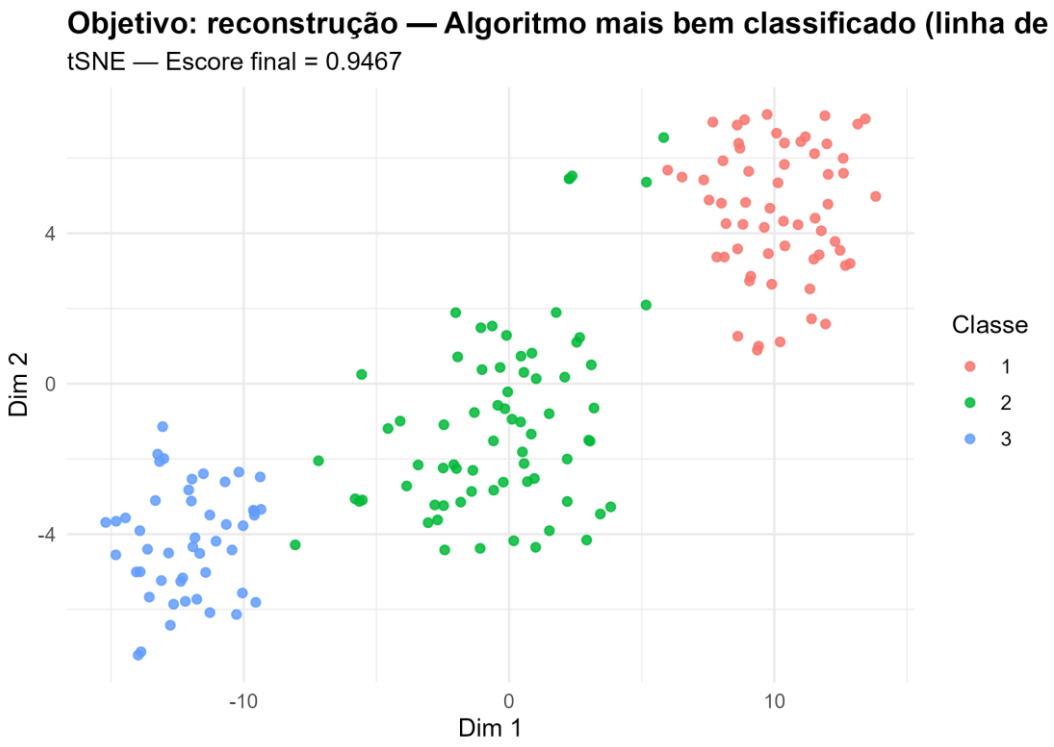
A Figura 43 apresenta as projeções de baixa dimensionalidade geradas pelo algoritmo de melhor desempenho — t-SNE — para os quatro objetivos analíticos considerados no conjunto de dados df7: agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina.


Objetivo: agrupamento — Algoritmo mais bem classificado (linha de
tSNE — Escore final = 0.9641
Dim 2
4
0
-4
-10
0
10
Dim 1
Classe
1
2
3

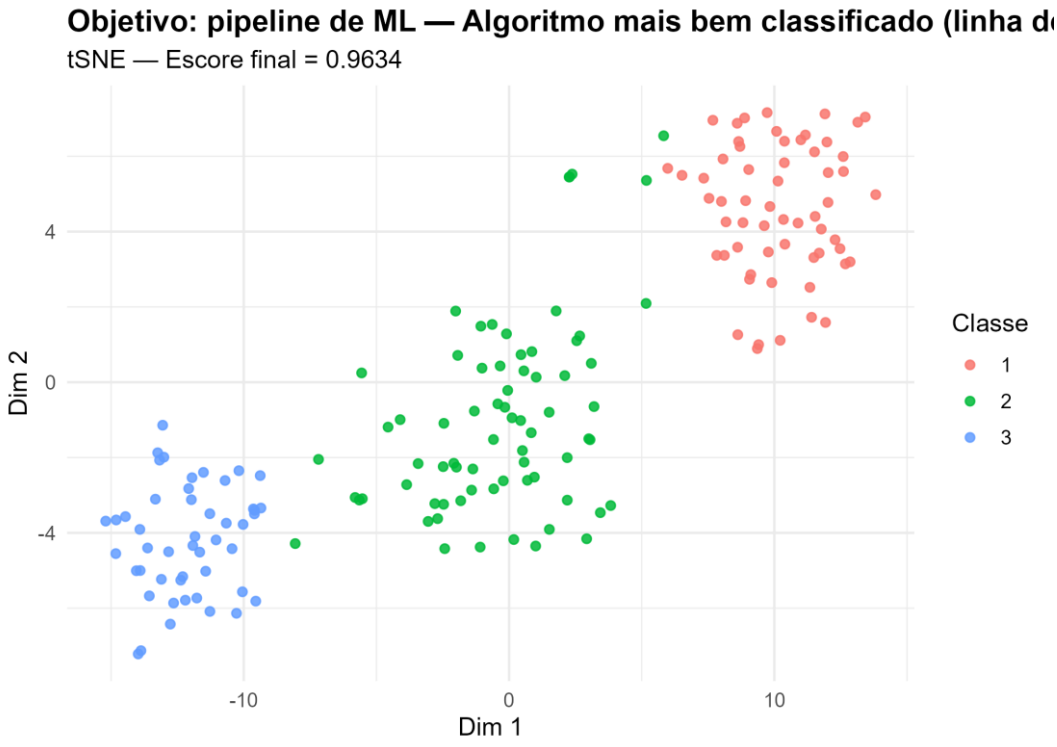
(a)


Objetivo: visualização — Algoritmo mais bem classificado (linha de b
tSNE — Escore final = 0.9634
Dim 2
4
0
-4
-10
0
10
Dim 1
Classe
1
2
3

(b)



(c)



(d)

Figura 43 – Projeções bidimensionais produzidas pelo algoritmo melhor classificado para cada objetivo, com base na Pontuação Final (Final Score) do ranqueamento de referência (Baseline

Ranking): (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

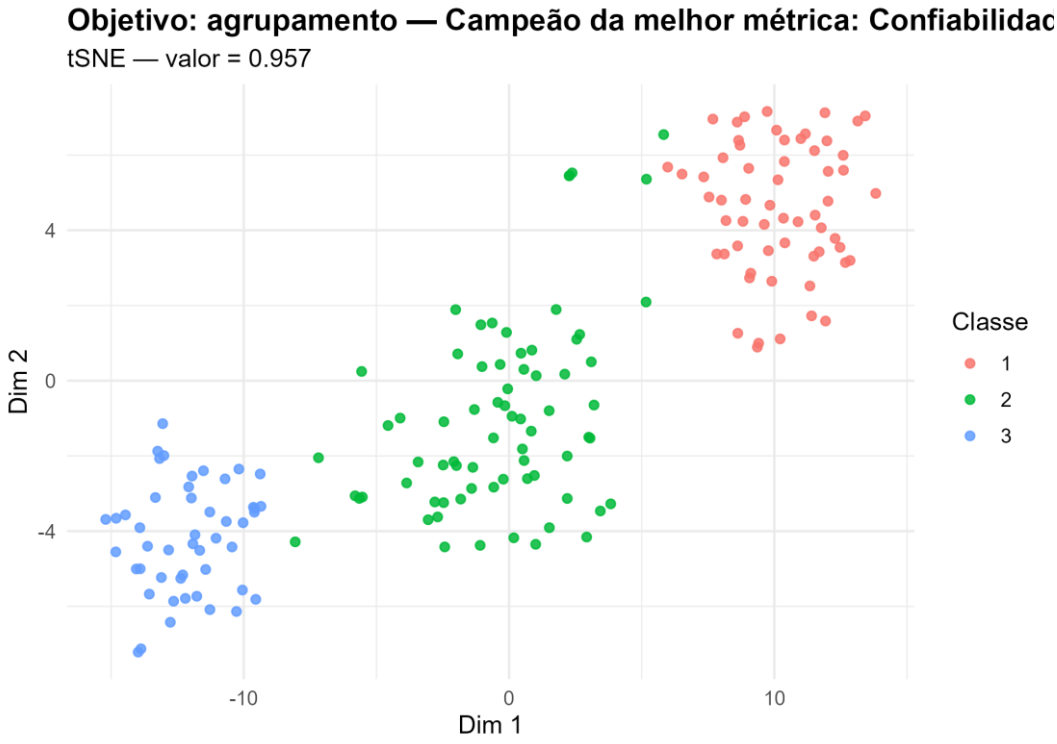
Em todos os casos, o t-SNE produz projeções com organização geométrica praticamente idêntica, o que reflete sua elevada estabilidade e seu desempenho superior em diferentes métricas de avaliação neste conjunto de dados. As projeções separam claramente as três classes em agrupamentos compactos e bem definidos, com mínima sobreposição, demonstrando a reconhecida capacidade do t-SNE de preservar a estrutura local das relações de vizinhança e aumentar a discriminação entre as classes.

Esse elevado grau de separação é particularmente notável, considerando que o mesmo algoritmo é selecionado como o de melhor desempenho também para os objetivos de reconstrução e integração em pipelines de aprendizado de máquina, aplicações tradicionalmente mais sensíveis às distorções na geometria global dos dados.

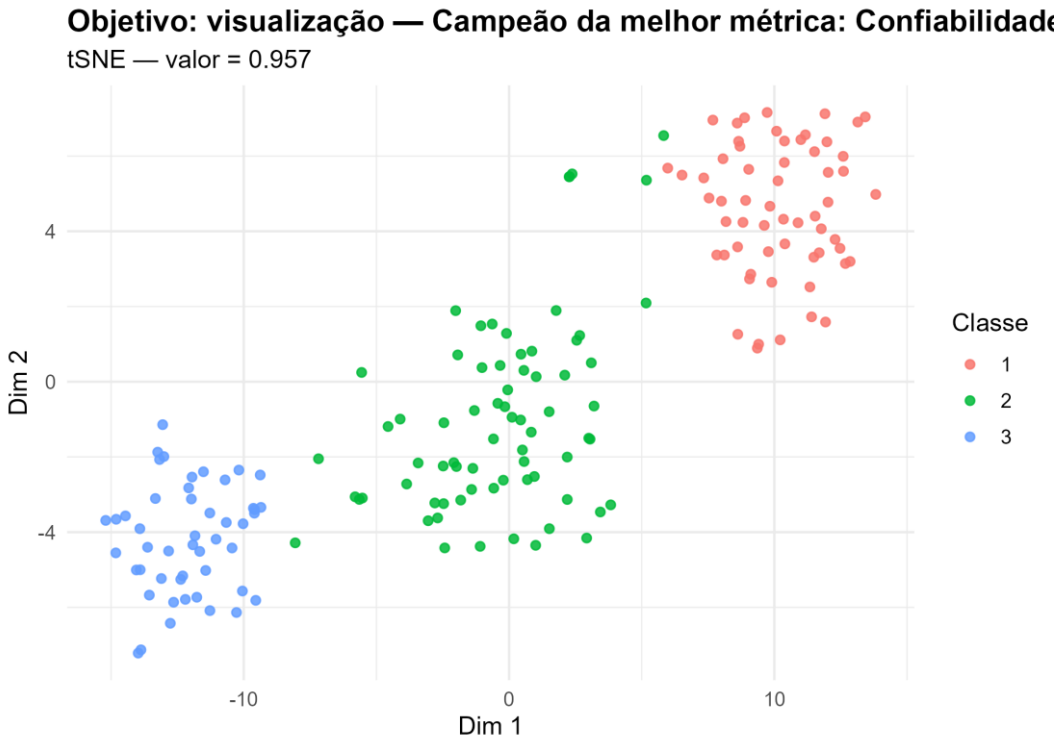
A consistência da disposição dos agrupamentos em todos os objetivos evidencia a robustez do t-SNE na projeção da estrutura intrínseca da variedade dos dados para um espaço bidimensional.

De modo geral, a figura destaca o t-SNE como a técnica de redução de dimensionalidade mais eficaz para o conjunto de dados df7, proporcionando excelente separação visual entre as classes, elevada preservação das relações de vizinhança e desempenho confiável em diferentes objetivos analíticos.

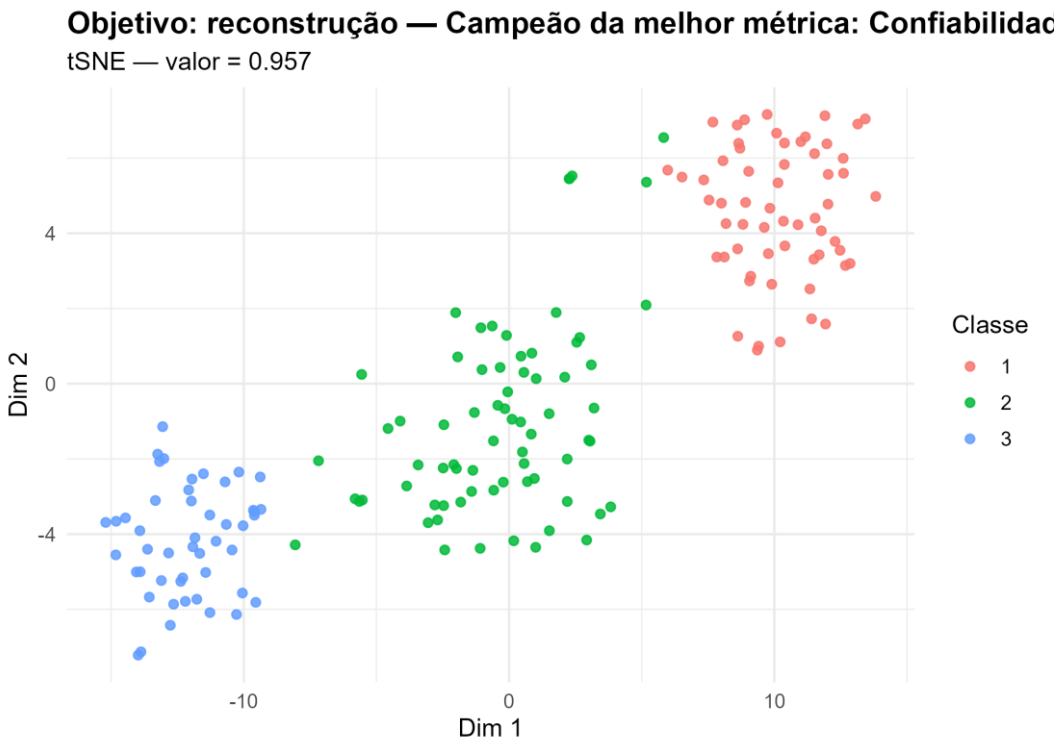
A Figura 44 apresenta as projeções bidimensionais obtidas pelo t-SNE, identificado como o algoritmo de melhor desempenho de acordo com a métrica Confiabilidade (Trustworthiness), para os quatro objetivos analíticos: agrupamento, visualização, reconstrução e integração em pipelines de aprendizado de máquina.


Objetivo: agrupamento — Campeão da melhor métrica: Confiabilidac
tSNE — valor = 0.957
Dim 2
4
0
-4
-10
0
10
Dim 1
Classe
1
2
3

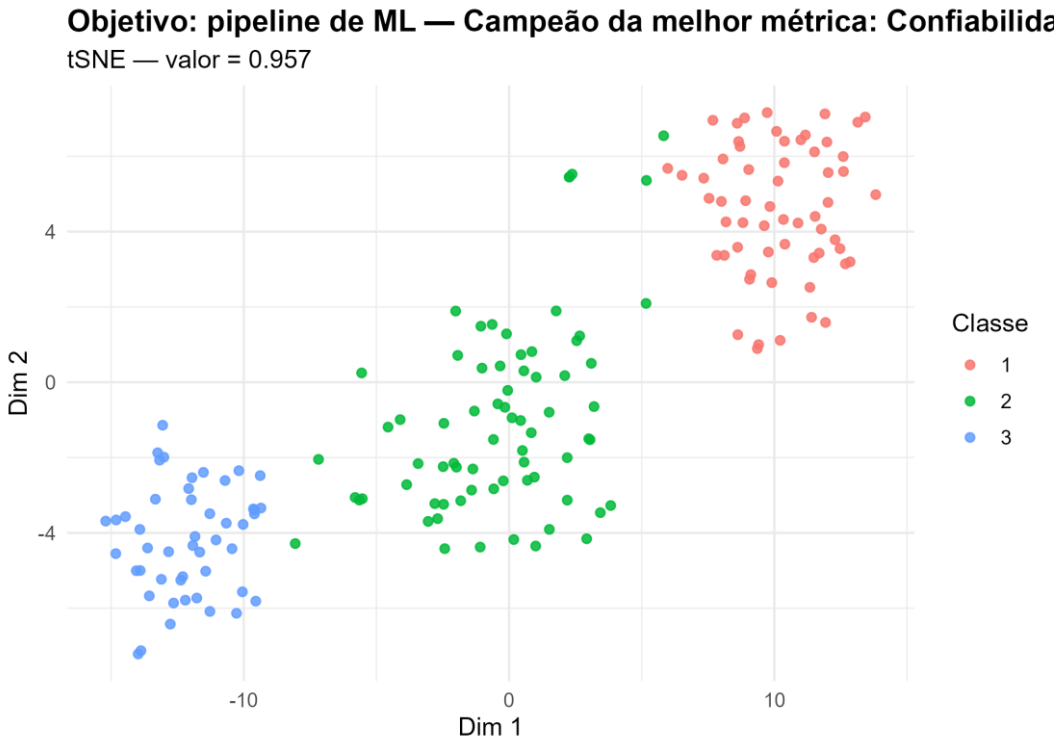
(a)


Objetivo: visualização — Campeão da melhor métrica: Confiabilidade
tSNE — valor = 0.957
Dim 2
4
0
-4
-10
0
10
Dim 1
Classe
1
2
3

(b)



(c)



(d)

Figura 44 – Projeções bidimensionais geradas pelo algoritmo campeão, selecionado com base na métrica de melhor desempenho para cada objetivo analítico: (a) agrupamento (clustering), (b) visualização, (c) reconstrução e (d) integração em pipelines de aprendizado de máquina.

A métrica Confiabilidade (Trustworthiness) avalia a fidelidade das relações de vizinhança locais no espaço de baixa dimensionalidade, e o elevado valor observado, de forma consistente (0,95684), em todos os painéis reflete a capacidade excepcional do t-SNE de preservar a estrutura local dos dados.

Em cada um dos subgráficos, as três classes formam agrupamentos altamente compactos e bem separados, com sobreposição mínima e fronteiras claramente definidas entre si. Essa organização fortemente discriminativa evidencia a estreita correspondência entre a métrica Confiabilidade (Trustworthiness) e a concepção do t-SNE, que prioriza a preservação precisa das relações entre vizinhos mais próximos.

O padrão geométrico recorrente em todos os objetivos analíticos demonstra, ainda, a robustez e a estabilidade do t-SNE quando avaliado por métricas que enfatizam a preservação da estrutura local. Embora possam ocorrer distorções na geometria global — uma característica frequentemente associada ao t-SNE —, as projeções permanecem altamente eficazes para aplicações voltadas à identificação de agrupamentos, ao reconhecimento de padrões e às tarefas posteriores de classificação.

De modo geral, a figura demonstra que, quando a fidelidade das relações de vizinhança locais é o principal critério de avaliação, o t-SNE fornece projeções consistentemente superiores, visualmente interpretáveis e altamente adequadas ao conjunto de dados df7.

11. CONSIDERAÇÕES FINAIS

O benchmarking de algoritmos de redução de dimensionalidade apresenta um desafio metodológico inerente, pois diferentes técnicas priorizam propriedades estruturais distintas dos dados. Alguns métodos enfatizam a preservação das relações de vizinhança local, enquanto outros se concentram em manter a geometria global da variedade ou em minimizar o erro de reconstrução. Como consequência, comparações baseadas em um único critério de avaliação frequentemente oferecem apenas uma visão parcial do desempenho dos algoritmos e podem levar a conclusões enganosas quanto à adequação de um determinado método a uma tarefa analítica específica. Para superar essa limitação, o presente estudo adota uma estratégia de benchmarking multimétrica e orientada por cenários, que avalia simultaneamente as técnicas de redução de dimensionalidade sob perspectivas estruturais complementares, incluindo a fidelidade das relações de vizinhança, a preservação da estrutura global, a distorção geométrica e a consistência da classificação. Ao integrar esses critérios em um framework unificado de avaliação, a abordagem proposta permite uma avaliação mais abrangente e objetiva do comportamento dos algoritmos, fornecendo assim uma base robusta para a seleção de métodos de redução de dimensionalidade em conjuntos de dados complexos de alta dimensionalidade.

12. DISPONIBILIDADE DOS DADOS

Os dados podem ser acessados, assim como código em R utilizado neste trabalho podem ser acessados no GitHub: https://github.com/Laboratorio-de-Tecnologia-Computacional/Dimensionality-Reduction-Techniques-An-Innovative-Approach. Para quase todos os conjuntos de dados, o download pode ser feito diretamente a partir da URL citada no texto. Dois conjuntos, porém, não puderam ser baixados diretamente e foram disponibilizados no GitHub, de modo que os interessados possam executar o código proposto.

13. REFERÊNCIAS

[1] K. Fukunaga, Introduction to Statistical Pattern Recognition, Academic Press Professional, Inc., San Diego, CA, USA, 1990.

[2] P. Sharma, R.P. Saxena, A review on nonlinear dimensionality reduction techniques for face recognition, Int. J. Recent Innov. Trends Comput. Commun. 5 (7) (2017) 195–200. https://doi.org/10.17762/ijritcc.v5i7.1026.

[3] L.O. Jimenez, D.A. Landgrebe, Supervised classification in high-dimensional space: geometrical, statistical, and asymptotical properties of multivariate data, IEEE Trans. Syst. Man Cybern. 28 (1) (1997) 39–54. https://doi.org/10.1109/5326.661089.

[4] G. Kraemer, M. Reichstein, M. Mahecha, dimRed and coRanking – unifying dimensionality reduction in R, R J. 10 (1) (2018) 342–358. https://doi.org/10.32614/RJ-2018-039.

[5] L. van der Maaten, E. Postma, J. van den Herik, Dimensionality reduction: a comparative review, Tech. Rep. TiCC TR 2009-005, Tilburg University, Tilburg, The Netherlands, 2009.

[6] I.T. Jolliffe, J. Cadima, Principal component analysis: a review and recent developments, Philos. Trans. R. Soc. A 374 (2065) (2016) 20150202. https://doi.org/10.1098/rsta.2015.0202.

[7] B. Schölkopf, A. Smola, K.-R. Müller, Nonlinear component analysis as a kernel eigenvalue problem, Neural Comput. 10 (5) (1998) 1299–1319. https://doi.org/10.1162/089976698300017467.

[8] J.P. Brooks, J.H. Dulá, E.L. Boone, A pure L1-norm principal component analysis, Comput. Stat. Data Anal. 61 (2013) 83–98. https://doi.org/10.1016/j.csda.2012.11.007.

[9] N.D. Sidiropoulos, P.P. Markopoulos, G. Karypis, Optimal L1-norm principal-component analysis, IEEE Trans. Signal Process. 62 (2) (2014) 504–517. https://doi.org/10.1109/TSP.2013.2291275.

[10] K.-L. Chan, N.D. Sidiropoulos, Robust principal component analysis using L1-norm maximization, IEEE Trans. Signal Process. (2009).

[11] T.F. Cox, M.A.A. Cox, Multidimensional Scaling, 2nd ed., Chapman & Hall/CRC, Boca Raton, FL, 2001.

[12] J. Wang, Classical multidimensional scaling, in: Geometric Structure of High-Dimensional Data and Dimensionality Reduction, Springer, Berlin, Heidelberg, 2012, pp. 115–129. https://doi.org/10.1007/978-3-642-27497-8_6.

[13] J.B. Tenenbaum, V. de Silva, J.C. Langford, A global geometric framework for nonlinear dimensionality reduction, Science 290 (5500) (2000) 2319–2323. https://doi.org/10.1126/science.290.5500.2319.

[14] J. Wang, Isomaps, in: Geometric Structure of High-Dimensional Data and Dimensionality Reduction, Springer, Berlin, Heidelberg, 2012, pp. 151–180. https://doi.org/10.1007/978-3-642-27497-8_8.

[15] R.R. Coifman, S. Lafon, Diffusion maps, Appl. Comput. Harmon. Anal. 21 (1) (2006) 5–30. https://doi.org/10.1016/j.acha.2006.04.006.

[16] J.A. Lee, M. Verleysen, Nonlinear Dimensionality Reduction, Springer, New York, 2007.

[17] V. Laparra, J. Malo, G. Camps-Valls, Dimensionality reduction via regression in hyperspectral imagery, IEEE J. Sel. Top. Signal Process. 9 (6) (2015) 1026–1036. https://doi.org/10.1109/JSTSP.2015.2417833.

[18] A. Hyvärinen, J. Karhunen, E. Oja, Independent Component Analysis, Wiley, New York, 2001.

[19] A. Hyvärinen, Fast and robust fixed-point algorithms for independent component analysis, IEEE Trans. Neural Netw. 10 (3) (1999) 626–634. https://doi.org/10.1109/72.761722.

[20] S. Wu, J. Dong, Research of fast-ICA algorithm and its improvement, in: IGARSS 2022 – IEEE International Geoscience and Remote Sensing Symposium, Kuala Lumpur, Malaysia, 2022, pp. 3251–3254. https://doi.org/10.1109/IGARSS46834.2022.9884681.

[21] D.L. Donoho, C. Grimes, Hessian eigenmaps: locally linear embedding techniques for high-dimensional data, Proc. Natl. Acad. Sci. U. S. A. 100 (10) (2003) 5591–5596. https://doi.org/10.1073/pnas.1031596100.

[22] S.T. Roweis, L.K. Saul, Nonlinear dimensionality reduction by locally linear embedding, Science 290 (5500) (2000) 2323–2326. https://doi.org/10.1126/science.290.5500.2323.

[23] J. Wang, Locally linear embedding, in: Geometric Structure of High-Dimensional Data and Dimensionality Reduction, Springer, Berlin, Heidelberg, 2012, pp. 203–220. https://doi.org/10.1007/978-3-642-27497-8_13.

[24] D. Harel, Y. Koren, A fast multi-scale method for drawing large graphs, J. Graph Algorithms Appl. 6 (3) (2002) 179–202. https://doi.org/10.7155/jgaa.00051.

[25] M. Shawn, W.M. Brown, B.N. Wylie, Dr.L: Distributed Recursive (Graph) Layout [software], OSTI.GOV, November 18, 2007. https://doi.org/10.11578/dc.20210416.20.

[26] T. Kamada, S. Kawai, An algorithm for drawing general undirected graphs, Inf. Process. Lett. 31 (1989) 7–15. https://doi.org/10.1016/0020-0190(89)90102-6.

[27] T.M.J. Fruchterman, E.M. Reingold, Graph drawing by force-directed placement, Softw. Pract. Exp. 21 (11) (1991) 1129–1164. https://doi.org/10.1002/spe.4380211102.

[28] A. Noack, Energy models for graph clustering, J. Graph Algorithms Appl. 11 (2) (2007) 453–480. https://doi.org/10.7155/jgaa.00154.

[29] S.G. Kobourov, Spring embedders and force-directed graph drawing algorithms, arXiv:1201.3011 (2012). https://doi.org/10.48550/arXiv.1201.3011.

[30] J.B. Kruskal, Nonmetric multidimensional scaling: a numerical method, Psychometrika 29 (1964) 115–129. https://doi.org/10.1007/BF02289694.

[31] J.B. Kruskal, M. Wish, Multidimensional Scaling, Sage Publications, Beverly Hills, CA, 1978.

[32] L. van der Maaten, G. Hinton, Visualizing data using t-SNE, J. Mach. Learn. Res. 9 (2008) 2579–2605.

[33] L. van der Maaten, Accelerating t-SNE using tree-based algorithms, J. Mach. Learn. Res. 15 (2014) 3221–3245.

[34] J.A. Lee, M. Verleysen, Quality assessment of dimensionality reduction: rank-based criteria, Neurocomputing 72 (7–9) (2009) 1431–1443. https://doi.org/10.1016/j.neucom.2008.12.017.

[35] L. Chen, A. Buja, Local multidimensional scaling for nonlinear dimension reduction, graph drawing, and proximity analysis, J. Am. Stat. Assoc. 104 (485) (2009) 209–219. https://doi.org/10.1198/jasa.2009.0111.

[36] J.A. Lee, E. Renard, G. Bernard, P. Dupont, M. Verleysen, Type 1 and 2 mixtures of Kullback–Leibler divergences as cost functions in dimensionality reduction based on similarity preservation, Neurocomputing 112 (2013) 92–108. https://doi.org/10.1016/j.neucom.2012.12.036.

[37] R.R. Sokal, F.J. Rohlf, The comparison of dendrograms by objective methods, Taxon 11 (2) (1962) 33–40. https://doi.org/10.2307/1217208.

[38] M.C. Thrun, J. Märte, Q. Stier, Analyzing quality measurements for dimensionality reduction, Mach. Learn. Knowl. Extr. 5 (3) (2023) 1076–1118. https://doi.org/10.3390/make5030056.

[39] J. Venna, S. Kaski, Neighborhood preservation in nonlinear projection methods: an experimental study, in: Lecture Notes in Computer Science, vol. 2130, Springer, Berlin, Heidelberg, 2001, pp. 485–491. https://doi.org/10.1007/3-540-44668-0_68.

[40] D.M.W. Powers, Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation, J. Mach. Learn. Technol. 2 (1) (2011) 37–63.

[41] M. Sokolova, G. Lapalme, A systematic analysis of performance measures for classification tasks, Inf. Process. Manag. 45 (4) (2009) 427–437. https://doi.org/10.1016/j.ipm.2009.03.002.

[42] M.G. Kendall, A new measure of rank correlation, Biometrika 30 (1–2) (1938) 81–93. https://doi.org/10.1093/biomet/30.1-2.81.

[43] R.R. Sokal, F.J. Rohlf, Biometry: The Principles and Practice of Statistics in Biological Research, 3rd ed., W.H. Freeman, New York, 1995.

[44] B. Everitt, S. Landau, M. Leese, D. Stahl, Cluster Analysis, 5th ed., Wiley, Chichester, 2011.

[45] I.T. Jolliffe, Principal Component Analysis, 2nd ed., Springer, New York, 2002.

[46] I. Goodfellow, Y. Bengio, A. Courville, Deep Learning, MIT Press, Cambridge, MA, 2016.

[47] T. Cover, P. Hart, Nearest neighbor pattern classification, IEEE Trans. Inf. Theory 13 (1) (1967) 21–27. https://doi.org/10.1109/TIT.1967.1053964.

[48] T. Hastie, R. Tibshirani, J. Friedman, The Elements of Statistical Learning, 2nd ed., Springer, New York, 2009.

[49] R Core Team, R: A Language and Environment for Statistical Computing, R Foundation for Statistical Computing [software], Vienna, Austria, 2025. https://www.R-project.org/.

[50] Posit Team, RStudio: Integrated Development Environment for R, Posit Software, PBC [software], Boston, MA, 2025. http://www.posit.co/.

[51] H. Wickham, ggplot2: Elegant Graphics for Data Analysis, Springer-Verlag, New York, 2016. ISBN 978-3-319-24277-4.

[52] H. Wickham, J. Hester, J. Bryan, readr: Read Rectangular Text Data, R package version 2.1.6 [software], Tidyverse, 2025. https://readr.tidyverse.org.

[53] H. Wickham, R. François, L. Henry, K. Müller, D. Vaughan, dplyr: A Grammar of Data Manipulation, R package version 1.1.4 [software], Tidyverse, 2025. https://dplyr.tidyverse.org.

[54] T. Wei, V. Simko, corrplot: Visualization of a Correlation Matrix, R package version 0.95 [software], GitHub, 2024. https://github.com/taiyun/corrplot.

[55] W. Revelle, psych: Procedures for Psychological, Psychometric, and Personality Research, Northwestern University, Evanston, IL. R package version 2.5.6 [software], CRAN, June 23, 2025. https://CRAN.R-project.org/package=psych.

[56] B. Schloerke, D. Cook, J. Larmarange, F. Briatte, M. Marbach, E. Thoen, A. Elberg, J. Crowley, GGally: Extension to 'ggplot2', R package version 2.4.0 [software], CRAN, August 23, 2025. https://doi.org/10.32614/CRAN.package.GGally, https://CRAN.R-project.org/package=GGally.

[57] H. Wickham, L. Henry, purrr: Functional Programming Tools, R package version 1.2.0 [software], CRAN, November 4, 2025. https://doi.org/10.32614/CRAN.package.purrr, https://CRAN.R-project.org/package=purrr.

[58] H. Wickham, D. Vaughan, M. Girlich, tidyr: Tidy Messy Data, R package version 1.3.1 [software], CRAN, January 24, 2024. https://doi.org/10.32614/CRAN.package.tidyr, https://CRAN.R-project.org/package=tidyr.

[59] J. Ooms, writexl: Export Data Frames to Excel 'xlsx' Format, R package version 1.5.4 [software], CRAN, April 15, 2025. https://doi.org/10.32614/CRAN.package.writexl, https://CRAN.R-project.org/package=writexl.

[60] H. Wickham, stringr: Simple, Consistent Wrappers for Common String Operations, R package version 1.6.0 [software], CRAN, November 4, 2025. https://doi.org/10.32614/CRAN.package.stringr, https://CRAN.R-project.org/package=stringr.

[61] L. Henry, H. Wickham, rlang: Functions for Base Types and Core R and 'Tidyverse' Features, R package version 1.1.6 [software], CRAN, April 11, 2025. https://doi.org/10.32614/CRAN.package.rlang, https://CRAN.R-project.org/package=rlang.

[62] M. Becker, B. Bischl, J. Bossek, farff: A Faster 'ARFF' File Reader and Writer, R package version 1.1.1 [software], CRAN, May 10, 2021. https://doi.org/10.32614/CRAN.package.farff, https://CRAN.R-project.org/package=farff.

[63] H. Wickham, J. Bryan, readxl: Read Excel Files, R package version 1.4.5 [software], CRAN, March 7, 2025. https://doi.org/10.32614/CRAN.package.readxl, https://CRAN.R-project.org/package=readxl.

[64] S. Bache, H. Wickham, magrittr: A Forward-Pipe Operator for R, R package version 2.0.4 [software], CRAN, September 12, 2025. https://doi.org/10.32614/CRAN.package.magrittr, https://CRAN.R-project.org/package=magrittr.

[65] Q. Stier, J. Märte, M.C. Thrun, DRquality: Quality Measurements for Dimensionality Reduction, R package version 0.2.1 [software], CRAN, October 12, 2023. https://doi.org/10.32614/CRAN.package.DRquality, https://CRAN.R-project.org/package=DRquality.

[66] M.C. Thrun, A. Ultsch, Using projection-based clustering to find distance- and density-based clusters in high-dimensional data, J. Classif. 38 (2021) 280–312. https://doi.org/10.1007/s00357-020-09373-2.

[67] G. Besanson, FastKNN: Fast k-Nearest Neighbors, R package version 0.0.1 [software], CRAN, February 12, 2015. https://doi.org/10.32614/CRAN.package.FastKNN, https://CRAN.R-project.org/package=FastKNN.

[68] M.C. Thrun, Q. Stier, Fundamental clustering algorithms suite, SoftwareX 13 (2021) 100642. https://doi.org/10.1016/j.softx.2020.100642.

[69] P. Filzmoser, H. Fritz, K. Kalcher, pcaPP: Robust PCA by Projection Pursuit, R package version 2.0-5 [software], CRAN, August 19, 2024. https://doi.org/10.32614/CRAN.package.pcaPP, https://CRAN.R-project.org/package=pcaPP.

[70] D.J. Marchette, cccd: Class Cover Catch Digraphs, R package version 1.6 [software], CRAN, April 8, 2022. https://doi.org/10.32614/CRAN.package.cccd, https://CRAN.R-project.org/package=cccd.

[71] R. Bivand, R packages for analyzing spatial data: a comparative case study with areal data, Geogr. Anal. 54 (3) (2022) 488–518. https://doi.org/10.1111/gean.12319.

[72] J.L. Marchini, C. Heaton, B.D. Ripley, fastICA: FastICA Algorithms to Perform ICA and Projection Pursuit, R package version 1.2-7 [software], CRAN, December 11, 2024. https://doi.org/10.32614/CRAN.package.fastICA, https://CRAN.R-project.org/package=fastICA.

[73] J.H. Krijthe, Rtsne: T-Distributed Stochastic Neighbor Embedding Using a Barnes-Hut Implementation [software], GitHub, 2015. https://github.com/jkrijthe/Rtsne.

[74] J. Oksanen, G. Simpson, F. Blanchet, R. Kindt, P. Legendre, P. Minchin, R. O'Hara, P. Solymos, M. Stevens, E. Szoecs, H. Wagner, M. Barbour, M. Bedward, B. Bolker, D. Borcard, T. Borman, G. Carvalho, M. Chirico, M. De Caceres, S. Durand, H. Evangelista, R. FitzJohn, M. Friendly, B. Furneaux, G. Hannigan, M. Hill, L. Lahti, C. Martino, D. McGlinn, M. Ouellette, E. Ribeiro Cunha, T. Smith, A. Stier, C. Ter Braak, J. Weedon, vegan: Community

Ecology Package, R package version 2.7-2 [software], CRAN, October 8, 2025. https://doi.org/10.32614/CRAN.package.vegan, https://CRAN.R-project.org/package=vegan.

[75] J. Richards, R. Cannoodt, diffusionMap: Diffusion Map, R package version 1.2.0 [software], CRAN, September 10, 2019. https://doi.org/10.32614/CRAN.package.diffusionMap, https://CRAN.R-project.org/package=diffusionMap.

[76] S. Jot, J.P. Brooks, A. Visentin, Y.W. Park, Y. Zhou, pcaL1: L1-Norm PCA Methods, R package version 1.5.9 [software], CRAN, May 3, 2025. https://CRAN.R-project.org/package=pcaL1.

[77] G. Kraemer, DRR: Dimensionality Reduction via Regression, R package version 0.0.4 [software], CRAN, February 12, 2020. https://doi.org/10.32614/CRAN.package.DRR, https://CRAN.R-project.org/package=DRR.

[78] G. Csárdi, T. Nepusz, The igraph software package for complex network research, InterJournal Complex Syst. 1695 (2006) 1–9. https://igraph.org.

[79] M. Antonov, G. Csárdi, S. Horvát, K. Müller, T. Nepusz, D. Noom, M. Salmon, V. Traag, B.F. Welles, F. Zanini, igraph enables fast and robust network analysis across programming languages, arXiv:2311.10260 (2023). https://doi.org/10.48550/arXiv.2311.10260.

[80] G. Csárdi, T. Nepusz, V. Traag, S. Horvát, F. Zanini, D. Noom, K. Müller, D. Schoch, M. Salmon, igraph: Network Analysis and Visualization in R, R package version 2.2.1 [software], Zenodo, October 29, 2025. https://doi.org/10.5281/zenodo.7682609.

[81] A. Karatzoglou, A. Smola, K. Hornik, kernlab: Kernel-Based Machine Learning Lab, R package version 0.9-33 [software], CRAN, August 13, 2024. https://doi.org/10.32614/CRAN.package.kernlab, https://CRAN.R-project.org/package=kernlab.

[82] A. Karatzoglou, A. Smola, K. Hornik, A. Zeileis, kernlab – an S4 package for kernel methods in R, J. Stat. Softw. 11 (9) (2004) 1–20. https://doi.org/10.18637/jss.v011.i09.

[83] G. Jefferis, S.E. Kemp, S. Arya, D. Mount, RANN: Fast Nearest Neighbour Search (Wraps ANN Library) Using L2 Metric, R package version 2.6.2 [software], CRAN, August 25, 2024. https://doi.org/10.32614/CRAN.package.RANN, https://CRAN.R-project.org/package=RANN.

[84] D. Bates, M. Maechler, M. Jagan, Matrix: Sparse and Dense Matrix Classes and Methods, R package version 1.7-4 [software], CRAN, August 28, 2025. https://doi.org/10.32614/CRAN.package.Matrix, https://CRAN.R-project.org/package=Matrix.

[85] Y. Qiu, J. Mei, RSpectra: Solvers for Large-Scale Eigenvalue and SVD Problems, R package version 0.16-2 [software], CRAN, July 18, 2024. https://doi.org/10.32614/CRAN.package.RSpectra, https://CRAN.R-project.org/package=RSpectra.

[86] W.N. Venables, B.D. Ripley, Modern Applied Statistics with S, 4th ed., Springer, New York, 2002. ISBN 0-387-95457-0.

[87] Breast Cancer Wisconsin (Diagnostic), UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic (accessed 1 October 2025).

[88] Chemical Composition of Ceramic Samples, UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/583/chemical+composition+of+ceramic+samples (accessed 1 October 2025).

[89] Dry Bean Dataset, UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/602/dry+bean+dataset (accessed 1 October 2025).

[90] Glass Identification, UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/42/glass+identification (accessed 1 October 2025).

[91] Hepatitis, UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/46/hepatitis (accessed 1 October 2025).

[92] Iris, UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/53/iris (accessed 1 October 2025).

[93] Wine, UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/109/wine (accessed 1 October 2025).

Índice Remissivo

A

Análise de componentes independentes, 56
Análise de componentes principais, 5
  kernel, 11
  norma L1, 18
Aprendizado de variedades, 2
D

Diffusion maps, 38
E

Escalonamento multidimensional, 24
  não métrico, 91
I

Isomap, 32
L

Leiaute de grafos
  Fruchterman–Reingold, 84
  Kamada–Kawai, 77
Locally linear embedding, 63
  Hessiano, 63
M

Maldição da dimensionalidade, 1
Medidas de qualidade
  confiabilidade, 111
  continuidade, 3
  correlação cofenética, 111
  descontinuidade, 111
  tau de Kendall, 121
Q

Quimiometria, 9
R

Reprodutibilidade, 31
T

t-SNE, 30

TÉCNICAS DE REDUÇÃO DE DIMENSIONALIDADE

Projeto, Teoria e Aplicações

Dados de alta dimensionalidade tornaram-se rotina nas ciências físicas, biológicas e da engenharia, e a redução de dimensionalidade é hoje etapa padrão para deles extrair estrutura interpretável. A dificuldade é que nenhuma técnica é universalmente preferível: uma projeção excelente para visualizar agrupamentos pode ser ruim para preservar a geometria global ou para sustentar a reconstrução.

Este livro substitui convenção por evidência. Quatorze métodos são apresentados com sua formulação matemática, suas premissas e seu custo computacional, e então avaliados por treze medidas de qualidade normalizadas, combinadas em quatro índices compostos — ponderados de modo que a escolha do método decorra do propósito da análise.

NESTE LIVRO

- Quatorze métodos convexos e não convexos, do PCA ao t-SNE
- Treze medidas de qualidade cobrindo fidelidade local, geometria global, erro de reconstrução e separabilidade de classes
- Quatro objetivos analíticos: agrupamento, visualização, reconstrução e pipelines de aprendizado de máquina
- Sete conjuntos de dados de referência do UCI, de 88 a 13.611 observações
- Totalmente reprodutível: código em R, dados e sementes publicados abertamente

Aderval S. Luna
Professor Titular da Universidade do Estado do Rio de Janeiro (UERJ) e docente permanente do Programa de Pós-Graduação em Engenharia Química.

Nathalia Alvim de Souza
Doutoranda do Programa de Pós-Graduação em Engenharia Química da Universidade do Estado do Rio de Janeiro (UERJ).

EDIÇÃO DIGITAL GRATUITA · NÃO DESTINADA À VENDA

Técnicas de Redução de Dimensionalidade © 2026 Aderval S. Luna e Nathalia Alvim de Souza
Licenciado sob Creative Commons BY-NC-SA 4.0
DOI: 10.5281/zenodo.23225955
Primeira edição · Rio de Janeiro, Brasil · 2026